Università degli Studi di Trento

Dipartimento di Psicologia e Scienze Cognitive

Corso di Laurea in Scienze e Tecniche di Psicologia Cognitiva

Corso di

Analisi dei dati con applicazioni informatiche

Statistica inferenziale

Ottavia M. Epifania

ottavia.epifania@unitn.it

Licenza

Quest'opera è distribuita con licenza Creative Commons Attribuzione 4.0 Internazionale (CC BY 4.0). Puoi copiare, ridistribuire e modificare il materiale con qualsiasi mezzo e per qualsiasi fine, a condizione di citare l'autrice e di indicare se sono state apportate modifiche.

Per citare questa dispensa:
Epifania, O. M. *Statistica inferenziale. Dispensa del corso Analisi dei dati con applicazioni informatiche, Modulo 4.* Università degli Studi di Trento.

Indice

1 Cenni di calcolo delle probabilità **4**
- 1.1 Eventi . . . 4
- 1.2 Funzione di probabilità . . . 6
- 1.3 Indipendenza tra gli eventi . . . 9
- 1.4 Variabile casuale . . . 9
- 1.5 Distribuzioni di probabilità in R . . . 10
- 1.6 Funzioni di probabilità discrete . . . 10

2 Distribuzione binomiale **12**

3 Distribuzioni di probabilità continue **20**
- 3.1 Definizioni generali . . . 20
- 3.2 Distribuzione normale . . . 21
- 3.3 Normale standardizzata . . . 26
- 3.4 Distribuzione t di Student . . . 29
- 3.5 Distribuzione χ^2 . . . 30
- 3.6 Altre distribuzioni continue . . . 32

4 Principi base di inferenza statistica **33**
- 4.1 Inferenza statistica . . . 33
- 4.2 Stimatore . . . 35
- 4.3 Distribuzioni campionarie . . . 36
- 4.4 Test di ipotesi . . . 38
- 4.5 Null Hypothesis Significance Testing (NHST) . . . 39
- 4.6 Valore critico . . . 41
- 4.7 Cos'è il p-value? . . . 44

5 Test statistici **48**
- 5.1 Il workflow dell'inferenza . . . 48
- 5.2 Test su indici di tendenza centrale . . . 48

6 Funzioni riassuntive dei moduli **66**
- 6.1 Calcolo combinatorio . . . 66
- 6.2 Distribuzioni di probabilità . . . 66
- 6.3 Test sulle medie . . . 66

1 Cenni di calcolo delle probabilità

Nei moduli di statistica descrittiva abbiamo lavorato con **variabili statistiche**: insiemi di categorie osservate su un campione, ciascuna accompagnata dalla propria *frequenza* n_k. La statistica descrittiva si limita a descrivere quello che è stato osservato *sul campione specifico*. Quello che interessa è dire se il campione è composto maggiormente da bambini o da adulti, da maschi o da femmine, con che età media e se ci sono delle associazioni tra le variabili.

La teoria della probabilità sposta lo sguardo dal campione alla popolazione. Invece di frequenze osservate, si lavora con **variabili casuali**, caratterizzate da *probabilità*: modelli teorici che descrivono come ci si aspetta che i valori si distribuiscano nella popolazione (Tabella 1.1). Quello che interessa è *stimare* la probabilità con cui determinate categorie si presentano nella popolazione.

La struttura delle due tabelle è identica: cambia il significato della seconda colonna. Nel primo caso indica *quante volte* una modalità è stata osservata, nel secondo *quanto è probabile* che quel valore si presenti.

1.1 Eventi

Un **esperimento aleatorio** è un esperimento che ammette almeno due risultati possibili e per il quale c'è incertezza su quale risultato si realizzerà (ad esempio, il lancio di un dado). Le manifestazioni di un esperimento aleatorio (i.e., i possibili risultati) sono descritte da **eventi**, e la **probabilità** è una misura del presentarsi di un evento.

Si distinguono diversi tipi di eventi:

1. **Eventi elementari** $\omega_1, \omega_2, ...$: sono i singoli risultati possibili dell'esperimento. Nel caso del dado a 6 facce: $\omega_1 = \{1\}, \omega_2 = \{2\}, \dots, \omega_6 = \{6\}$.

Table 1.1: Dalla variabile statistica (frequenze osservate) alla variabile casuale (probabilità).

Statistica descrittiva		**Teoria della probabilità**	
x	n_k	x	$\Pr[X = x_k]$
x_1	n_1	x_1	$\Pr[X = x_1]$
x_2	n_2	x_2	$\Pr[X = x_2]$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_h	n_h	x_h	$\Pr[X = x_h]$

2. **Eventi composti** $A_1, A_2, ...$: sono insiemi di eventi elementari. Ad esempio, per il dado a 6 facce, l'evento "esce un numero pari" è $A = \{2, 4, 6\}$.
3. **Eventi particolari**:
    - l'**evento impossibile** $\emptyset$ (l'insieme vuoto, che non contiene alcun risultato). Questo evento non può verificarsi per la natura stessa dell'epserimento. Ad esempio, nel lancio di un dado a 6 facce, non può presentarsi la faccia 7, per cui $\omega_7 = \emptyset$

- l'**evento certo** Ω (lo spazio di tutti i possibili risultati, che si verifica sempre).

L'obiettivo è costruire modelli teorici che permettano di calcolare la probabilità di *tutti* gli eventi. Per farlo, abbiamo bisogno di alcune operazioni che permettano di combinare gli eventi tra loro.

1.1.1 Operazioni tra eventi

Dato che gli eventi sono insiemi, si possono combinare con le operazioni della teoria degli insiemi. È utile rappresentarle graficamente con i *diagrammi di Venn*: il rettangolo rappresenta lo spazio degli eventi Ω, i cerchi rappresentano gli eventi A e B e l'area colorata è il risultato dell'operazione.

Unione (A **o** B). L'unione di A e B contiene tutti i risultati che appartengono ad A, a B o a entrambi (Figura 1.1):

$$A \cup B = \{\omega \in \Omega : \omega \in A \text{ o } \omega \in B\}$$

Intersezione (A **e** B). L'intersezione di A e B contiene solo i risultati che appartengono contemporaneamente sia ad A sia a B (Figura 1.2):

$$A \cap B = \{\omega \in \Omega : \omega \in A \text{ e } \omega \in B\}$$

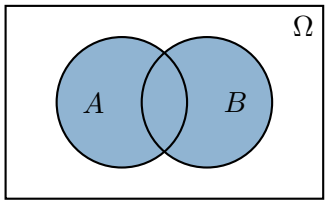


Figure 1.1: Unione $A \cup B$

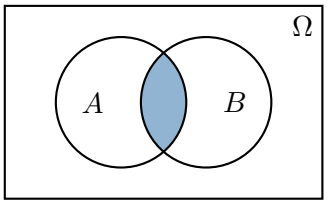


Figure 1.2: Intersezione $A \cap B$

Complementare (tutto quello che non è A). Il complementare di A contiene tutti i risultati di Ω che *non* appartengono ad A (Figura 1.3):

$$A^C = \{\omega \in \Omega : \omega \notin A\}$$

Differenza simmetrica (A **o** B, ma non entrambi). La differenza simmetrica contiene i risultati che appartengono ad A ma non a B, oppure a B ma non ad A (Figura 1.4). In altre parole, è l'unione tolta l'intersezione:

$$A \Delta B = \{\omega \in \Omega : (\omega \in A \text{ e } \omega \notin B) \text{ o } (\omega \in B \text{ e } \omega \notin A)\}$$

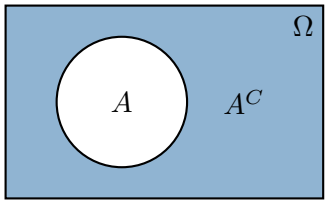


Figure 1.3: Complementare A^C

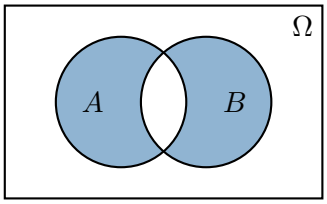


Figure 1.4: Differenza simmetrica $A \Delta B$

Due eventi si dicono **disgiunti** (o incompatibili) se non hanno elementi in comune, ossia se la loro intersezione è vuota: $A \cap B = \emptyset$.

Esempio: il lancio di un dado

Consideriamo il lancio di un dado a 6 facce, per cui $\Omega = \{1, 2, 3, 4, 5, 6\}$, e definiamo tre eventi:

- A = "esce una faccia pari" = $\{2, 4, 6\}$
- B = "esce una faccia maggiore di 3" = $\{4, 5, 6\}$
- C = "esce la faccia 1" = $\{1\}$

Applicando le operazioni appena viste:

- $A^C = \{1, 3, 5\}$ (le facce dispari)
- $A \cup B = \{2, 4, 5, 6\}$ (pari *oppure* maggiori di 3)
- $A \cap B = \{4, 6\}$ (pari *e* maggiori di 3)
- $A \Delta B = \{2, 5\}$ (pari oppure maggiori di 3, ma non entrambe le cose)
- $B \cap C = \emptyset$: B e C non hanno elementi in comune, quindi sono *disgiunti*

1.2 Funzione di probabilità

Una volta definiti gli eventi, bisogna definire la **funzione di probabilità**: una legge Pr che permetta di calcolare $\Pr[A]$ per ogni evento $A \subseteq \Omega$. Per costruirla servono tre "ingredienti":

1. gli **assiomi**, ovvero le proprietà che ogni funzione di probabilità deve rispettare;
2. una **regola per assegnare la probabilità agli eventi elementari**;
3. delle **regole per calcolare la probabilità degli altri eventi** a partire da quella degli eventi elementari.

1.2.1 Assiomi del calcolo delle probabilità

Sia Ω lo spazio (finito) degli eventi elementari. La funzione Pr soddisfa i seguenti assiomi:

1. $\Pr[A] \geq 0$ per ogni evento $A \subseteq \Omega$: la probabilità non è mai negativa;
2. $\Pr[\Omega] = 1$: l'evento certo ha probabilità 1;
3. $\Pr\left[\bigcup_i A_i\right] = \sum_i \Pr[A_i]$ se gli eventi A_i sono disgiunti: la probabilità dell'unione di eventi disgiunti è la somma delle loro probabilità.

1.2.2 Regole di calcolo

Dagli assiomi discendono alcune regole che permettono di calcolare la probabilità di eventi ottenuti combinando altri eventi:

1. **Probabilità dell'evento certo**: $\Pr[\Omega] = 1$.
2. **Probabilità del complementare**: $\Pr[A^C] = 1 - \Pr[A]$. Dato che A e A^C sono disgiunti e la loro unione è Ω, le loro probabilità devono sommare a 1.
3. **Probabilità dell'evento impossibile**: $\Pr[\emptyset] = 0$ (l'evento impossibile è il complementare dell'evento certo).
4. **Probabilità dell'unione**:

   $$\Pr[A \cup B] = \Pr[A] + \Pr[B] - \Pr[A \cap B]$$

   Sommando $\Pr[A]$ e $\Pr[B]$ l'intersezione viene contata due volte, quindi va sottratta una volta. Se A e B sono disgiunti, $\Pr[A \cap B] = 0$ e si ritrova il terzo assioma.
5. **Probabilità della differenza** (ciò che sta in A ma non in B):

   $$\Pr[A - B] = \Pr[A] - \Pr[A \cap B]$$

   Se $B \subset A$, allora $A \cap B = B$ e quindi $\Pr[A - B] = \Pr[A] - \Pr[B]$. Questa regola ci servirà per calcolare probabilità del tipo $\Pr[a < X \leq b]$.

Di conseguenza, la probabilità di qualsiasi evento è sempre compresa tra 0 e 1: $0 \leq \Pr[A] \leq 1$.

1.2.3 Assegnare la probabilità: il dado equilibrato

Gli eventi elementari sono disgiunti tra loro e ogni evento composto è l'unione di eventi elementari. Per il terzo assioma, quindi, **basta assegnare la probabilità agli eventi elementari** per poter calcolare la probabilità di qualsiasi evento.

Nel caso di un dado equilibrato, ogni faccia ha la stessa probabilità di uscire (Table 1.2).

Table 1.2: Probabilità degli eventi elementari nel lancio di un dado equilibrato

x	1	2	3	4	5	6
$\Pr[X = x]$	1/6	1/6	1/6	1/6	1/6	1/6

La probabilità dell'evento $A =$ "esce una faccia pari" $= \{2, 4, 6\}$ si ottiene sommando le probabilità degli eventi elementari che lo compongono:

$$\Pr[A] = \Pr[\{2\}] + \Pr[\{4\}] + \Pr[\{6\}] = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{3}{6} = \frac{1}{2}$$

Lo stesso risultato si ottiene con la **formula classica** (o di Laplace):

$$\Pr[A] = \frac{\text{casi favorevoli ad } A}{\text{casi possibili}}$$

Attenzione

La formula classica vale solo se Ω è finito e gli eventi elementari sono **equiprobabili** (come nel caso del dado equilibrato o della moneta non truccata).

Esempio: lancio di due monete

Lanciando due monete, lo spazio degli eventi elementari è $\Omega = \{TT, TC, CT, CC\}$ (dove $T =$ testa e $C =$ croce). Se le monete non sono truccate, i quattro risultati hanno tutti probabilità 1/4. Definiamo:

- $A =$ "esce almeno una testa" $= \{TT, TC, CT\}$, per cui $\Pr[A] = 3/4 = 0.75$
- $B =$ "escono una testa e una croce" $= \{TC, CT\}$, per cui $\Pr[B] = 2/4 = 0.50$

Allora:

- $A^C = \{CC\}$, e $\Pr[A^C] = 1 - 3/4 = 0.25$ (regola del complementare)
- $A \cap B = \{TC, CT\} = B$ (dato che $B \subset A$), e $\Pr[A \cap B] = 2/4 = 0.50$

Se definiamo $X =$ "numero di teste ottenute", otteniamo:

$$\Pr[X = 0] = \frac{1}{4}, \qquad \Pr[X = 1] = \frac{2}{4}, \qquad \Pr[X = 2] = \frac{1}{4}$$

Questa distribuzione è un caso particolare della distribuzione binomiale (Section 2).

1.3 Indipendenza tra gli eventi

Due eventi A e B sono **indipendenti** se sapere che uno dei due si è verificato non cambia la probabilità che si verifichi l'altro. In questo caso, la probabilità dell'intersezione è il prodotto delle singole probabilità (*fattorizzazione della probabilità*):

$$\Pr[A \cap B] = \Pr[A] \Pr[B]$$

Un esempio tipico sono le **estrazioni con reimmissione**: dopo ogni estrazione l'elemento estratto viene reinserito, per cui a ogni estrazione si riparte dalla stessa identica situazione e le estrazioni sono indipendenti. Ad esempio, la probabilità di ottenere due teste lanciando due volte una moneta è $\Pr[T \cap T] = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$, in accordo con l'esempio precedente.

Attenzione: disgiunti $\neq$ indipendenti

Due eventi **disgiunti** non possono verificarsi insieme: $\Pr[A \cap B] = 0$.
Due eventi **indipendenti** non si influenzano: $\Pr[A \cap B] = \Pr[A] \Pr[B]$.
Si tratta di due concetti diversi. Se A e B sono disgiunti (e hanno entrambi probabilità maggiore di 0) non possono essere indipendenti: sapere che si è verificato A ci dice con certezza che B *non* si è verificato.
Si prenda ad esempio la moneta con Testa e Croce. I due eventi Testa e Croce sono per loro natura disgiunti, ovvero $Pr[\text{Testa} \cap \text{Croce}] = \emptyset$. Di conseguenza però, si sa anche che se esce Testa non può essere uscita croce, ovvero il manifestarsi dell'evento Testa implica che non si sia manifestato croce (all'interno dello stesso lancio).

1.4 Variabile casuale

Lavorare direttamente con gli eventi è scomodo. Per questo si introduce la **variabile casuale** X, che "traduce" gli eventi in numeri:

- gli eventi elementari $\omega \in \Omega$ diventano valori numerici $x \in S$, dove S è il **supporto** della variabile casuale X, ovvero l'insieme dei valori che X può assumere;
- gli eventi composti A diventano insiemi di valori assumibili da X, del tipo

  $$\{X = x\}, \qquad \{X \leq x\}, \qquad \{a < X \leq b\}$$

  a ciascuno dei quali è associata la probabilità che X assuma quel valore o quei valori.

Variabile casuale

Una variabile casuale è un insieme di valori e di probabilità associate. Costruire una variabile casuale significa:

1. determinare i valori x che X può assumere (il supporto S);
2. associare a ogni valore una misura di probabilità (la funzione di probabilità

$f_X(x|\theta)$ nel caso discreto, la funzione di densità nel caso continuo).

Le variabili casuali possono essere **discrete**, se il supporto S è un insieme numerabile di valori (es., il numero di teste in n lanci di una moneta), oppure **continue**, se possono assumere qualsiasi valore in un intervallo di numeri reali (es., il tempo di reazione). Le prime sono l'argomento di questo modulo, le seconde del Modulo 4b (Section 3).

1.5 Distribuzioni di probabilità in `R`

In `R`, per ogni distribuzione di probabilità sono disponibili quattro funzioni, che si distinguono per la lettera iniziale:

- `d*`: calcola la **massa di probabilità** (distribuzioni discrete) o la **densità** (distribuzioni continue);
- `p*`: calcola la **probabilità cumulata** $\Pr[X \leq q]$ dato un quantile q;
- `q*`: calcola il **quantile** dato un livello di probabilità cumulata;
- `r*`: genera un **campione casuale** dalla distribuzione.

L'asterisco `*` va sostituito con il nome della distribuzione in `R` (Table 1.3). Ad esempio, `dbinom()` calcola la massa di probabilità della distribuzione binomiale, `pnorm()` la probabilità cumulata della distribuzione normale.

Table 1.3: Nomi di alcune distribuzioni di probabilità in `R`

Distribuzione	Tipo	Nome in `R`
Binomiale	discreta	`binom`
Poisson	discreta	`pois`
Uniforme	continua	`unif`
Normale	continua	`norm`
t di Student	continua	`t`
χ^2	continua	`chisq`

1.6 Funzioni di probabilità discrete

Sia X una variabile casuale discreta che assume valori in un insieme numerabile $S \subset \mathbb{R}$. La **funzione di probabilità** (o *funzione di massa*) di X è indicata con $f_X(x|\theta)$ ed è definita come:

$$f_X(x|\theta) = \Pr[X = x], \qquad \forall x \in S,$$

mentre $f_X(x|\theta) = 0$ per tutti gli $x \notin S$ (la probabilità di osservare un valore che non appartiene al supporto è nulla).

In generale considereremo funzioni f_X *parametriche*, ovvero che dipendono da uno o più parametri θ che appartengono a un insieme di valori ammissibili Θ:

$$f_X : \mathbb{R} \times \Theta \to [0, 1].$$

La notazione indica che la funzione prende un valore x e un valore dei parametri θ e restituisce una probabilità, ovvero un numero compreso tra 0 e 1. Cambiando i parametri, cambia la distribuzione.

2 Distribuzione binomiale

2.0.1 Esperimento bernoulliano

Un **esperimento bernoulliano** è un esperimento dicotomico, con solo due possibili esiti, di cui si conosce la probabilità:

- **successo**, con probabilità $\Pr[\text{successo}] = \pi$;
- **insuccesso**, con probabilità $\Pr[\text{insuccesso}] = 1 - \pi$.

"Successo" e "insuccesso" sono etichette convenzionali: il successo è semplicemente l'esito che ci interessa contare (es., testa nel lancio di una moneta, risposta corretta a un item, …).

Se l'esperimento bernoulliano viene ripetuto n volte, sotto le seguenti ipotesi:

1. le n prove sono ripetute e **indipendenti** (es., estrazioni con reimmissione);
2. a ogni prova la probabilità di successo π **rimane invariata**;
3. le condizioni sperimentali sono sempre le medesime;

allora la variabile casuale X che conta il **numero di successi** nelle n prove è detta **binomiale**, e si scrive $X \sim \text{Bin}(n, \pi)$.

2.0.2 Probabilità di massa

La funzione di probabilità della binomiale è:

$$f_X(x|\pi) = \Pr[X = x] = \binom{n}{x} \pi^x (1-\pi)^{n-x}, \qquad x = 0, 1, \dots, n,$$

dove $\pi \in [0, 1]$ e il supporto è $S = \{0, 1, \dots, n\}$ (in n prove si possono ottenere da 0 a n successi). I vari elementi della formula hanno il seguente significato:

- $\Pr[X = x]$: probabilità di ottenere esattamente x successi in n prove;
- π^x: probabilità di ottenere x successi indipendenti (per l'indipendenza, le probabilità si moltiplicano);
- $(1-\pi)^{n-x}$: probabilità di ottenere i restanti $n - x$ insuccessi indipendenti;
- $\binom{n}{x}$: **coefficiente binomiale**, che conta in quanti modi diversi si possono disporre gli x successi nelle n prove.

Il coefficiente binomiale si calcola come:

$$\binom{n}{x} = \frac{n!}{x!(n-x)!}, \qquad \text{dove} \qquad n! = \begin{cases} 1 & \text{se } n = 0, \\ n \cdot (n-1) \cdot (n-2) \cdots 2 \cdot 1 & \text{se } n > 0. \end{cases}$$

Ad esempio, $5! = 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 120$. In `R` il fattoriale si calcola con `factorial()` e il coefficiente binomiale con `choose()`:

```
factorial(5)
```

```
[1] 120
```

```
choose(5, 2) # modi di disporre 2 successi in 5 prove
```

```
[1] 10
```

Riprendendo l'esempio del lancio di due monete, il numero di teste X è una binomiale con $n = 2$ e $\pi = 0.50$. La probabilità di ottenere una testa è

$$\Pr[X = 1] = \binom{2}{1} 0.50^1 (1 - 0.50)^1 = 2 \cdot 0.50 \cdot 0.50 = 0.50,$$

esattamente come avevamo trovato contando i casi favorevoli (TC e CT, da cui il coefficiente binomiale pari a 2).

2.0.3 Media e varianza della binomiale

La distribuzione binomiale è definita da due parametri: il numero di prove indipendenti n e la probabilità di successo in una singola prova π. Media, varianza e deviazione standard dipendono solo da questi due parametri:

$$\mu_X = n\pi, \qquad \sigma^2_X = n\pi(1-\pi), \qquad \sigma_X = \sqrt{n\pi(1-\pi)}$$

Ad esempio, lanciando 10 volte una moneta equilibrata ($n = 10$, $\pi = 0.50$) ci si aspetta in media $\mu_X = 10 \cdot 0.50 = 5$ teste.

La forma di $f_X(x|\pi)$ varia al variare di (n, π) (Figure 2.1):

- se $\pi \to 0.50$ la distribuzione è **simmetrica**;
- se $\pi \to 0$ o $\pi \to 1$ la distribuzione è **asimmetrica** (positiva se $\pi < 0.50$, negativa se $\pi > 0.50$);
- la distribuzione ha una sola moda, oppure due mode contigue.

All'aumentare di n la distribuzione tende ad assumere una forma "a campana", anche quando π è lontano da 0.50.

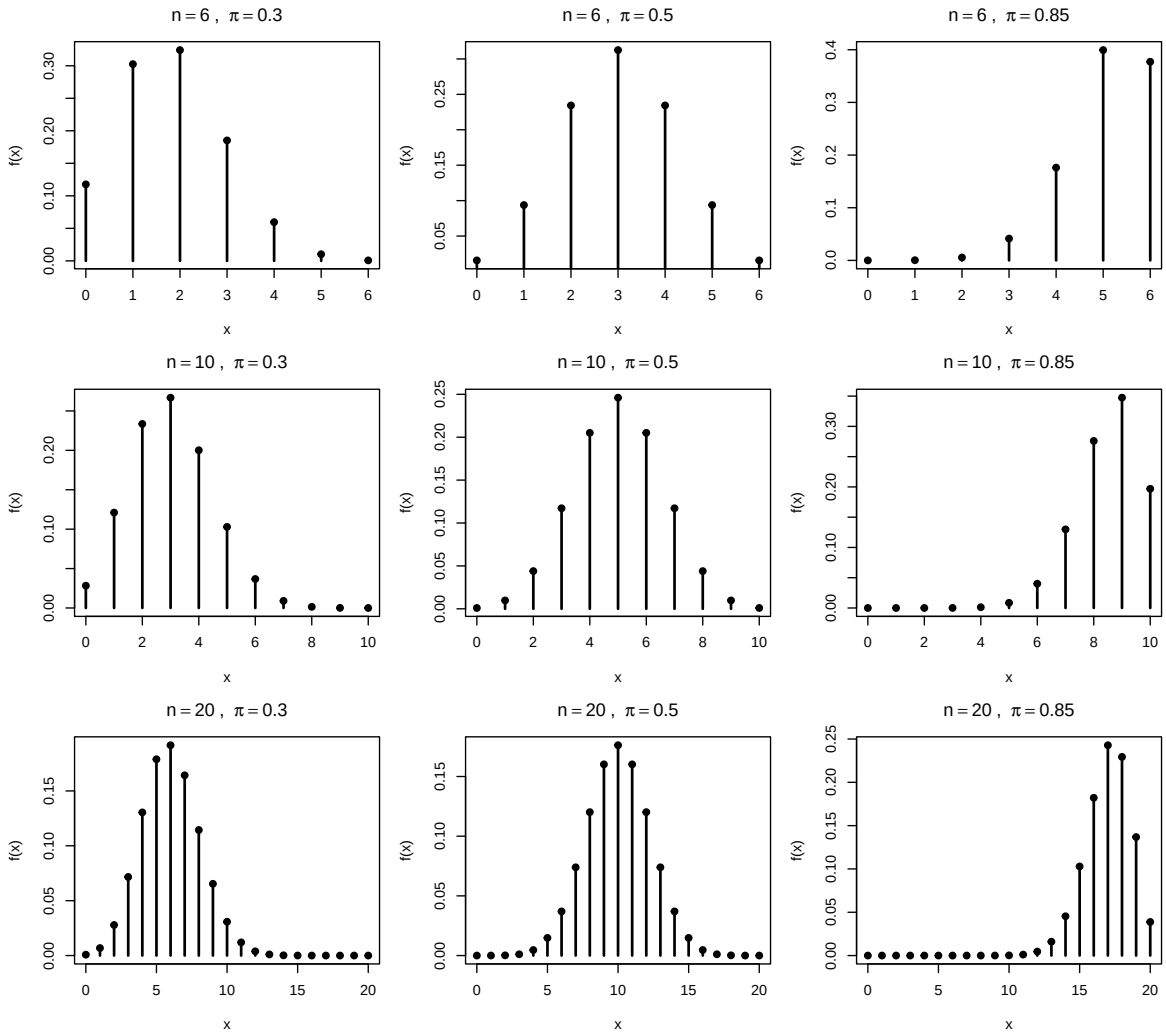


Figure 2.1: Funzione di massa della distribuzione binomiale per diversi valori di n (righe) e di π (colonne)

2.0.4 Probabilità cumulata

La **funzione di probabilità cumulata** di una variabile casuale discreta X si indica con $F_X(x|\theta)$ ed è definita come:

$$F_X(x|\theta) = \Pr[X \leq x] = \sum_{s \in S:\, s \leq x} f_X(s|\theta).$$

$F_X(x|\theta)$ rappresenta la probabilità che X assuma un valore *minore o uguale* a x, e si ottiene sommando le probabilità di massa di tutti i valori del supporto fino a x compreso. Anche la cumulata restituisce una probabilità:

$$F_X : \mathbb{R} \times \Theta \longrightarrow [0, 1].$$

Se $X \sim \text{Bin}(n, \pi)$, la funzione di probabilità cumulata è:

$$F_X(x|\pi) = \sum_{z=0}^{x} \binom{n}{z} \pi^z (1-\pi)^{n-z}, \qquad x = 0, 1, \ldots, n,$$

dove $\pi \in [0, 1]$. La cumulata è una funzione non decrescente: parte da $F_X(0|\pi) = \Pr[X = 0]$ e arriva a $F_X(n|\pi) = 1$ (Figure 2.2).

2.0.5 La binomiale in `R`

Seguendo la logica vista in Section 1.5, le funzioni `R` per la distribuzione binomiale sono riportate in Table 2.1.

Table 2.1: Funzioni `R` per la distribuzione binomiale

Funzione	Descrizione
`dbinom(x, size, prob)`	Restituisce i *valori di massa* $f_X(x\|\pi)$ associati al vettore discreto `x` di una distribuzione binomiale con `size` $= n$ prove e probabilità di successo `prob` $= \pi$.
`pbinom(q, size, prob)`	Restituisce i *valori di probabilità cumulata* $F_X(q\|\pi)$ associati al vettore discreto `q`. Con `lower.tail = FALSE` calcola $\Pr[X > q]$.
`qbinom(p, size, prob)`	Restituisce i *valori dei quantili* $q_X(p\|\pi)$ associati al vettore di probabilità `p`.
`rbinom(n, size, prob)`	Restituisce un vettore casuale di `n` osservazioni indipendenti campionate da una distribuzione binomiale.

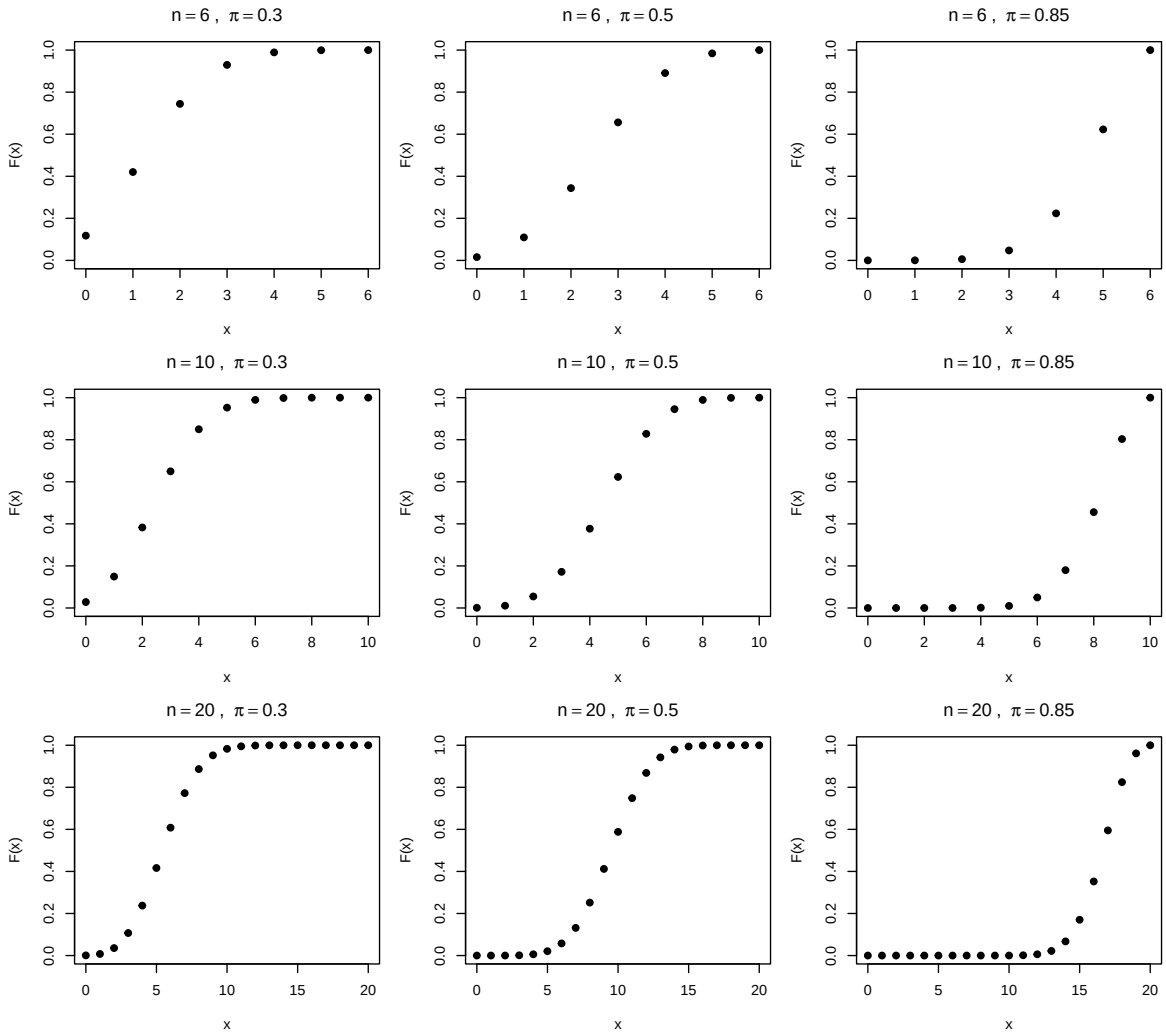


Figure 2.2: Probabilità cumulata della distribuzione binomiale per diversi valori di n (righe) e di π (colonne)

Attenzione a `n`

In `rbinom()` l'argomento `n` indica il numero di *osservazioni casuali* da generare, **non** il numero di prove della binomiale, che invece è sempre l'argomento `size`.

2.0.5.1 $f_X(x|\pi)$: `dbinom()`

```
dbinom(x, size, prob)
```

- `x`: supporto S della variabile casuale X (es., numero di volte in cui esce testa);
- `size`: numero di prove n (es., numero di lanci);
- `prob`: π, probabilità di successo nella singola prova.

Ad esempio, supponiamo di somministrare 10 item a scelta multipla con 4 alternative di risposta a una persona che risponde completamente a caso. La probabilità di rispondere correttamente a ciascun item è $\pi = 1/4 = 0.25$ e il numero di risposte corrette è $X \sim \text{Bin}(10, 0.25)$. Le probabilità di ottenere $0, 1, \dots, 10$ risposte corrette sono (Figure 2.3):

```
n <- 10
x <- 0:n
p_succ <- .25
round(dbinom(x, size = n, prob = p_succ), 4)
```

```
 [1] 0.0563 0.1877 0.2816 0.2503 0.1460 0.0584 0.0162 0.0031 0.0004 0.0000
[11] 0.0000
```

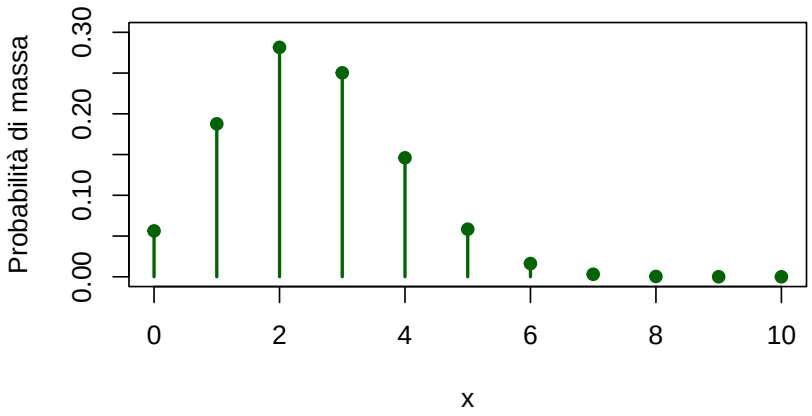


Figure 2.3: Funzione di massa di $X \sim \text{Bin}(10, 0.25)$

La somma di tutte le probabilità di massa è uguale a 1 (secondo assioma):

```r
sum(dbinom(x, size = n, prob = p_succ))
```

```
[1] 1
```

2.0.5.2 $F_X(x|\pi)$: `pbinom()`

```r
pbinom(q, size, prob)
```

- `q`: valore fino a cui è calcolata la probabilità cumulata;
- `size`: numero di prove n;
- `prob`: π, probabilità di successo nella singola prova.

La cumulata è la somma delle masse fino al valore indicato (Figure 2.4). Ad esempio, la probabilità di ottenere *al massimo* 3 risposte corrette, $\Pr[X \leq 3] = F_X(3|\pi)$, si può calcolare in due modi equivalenti:

```r
# probabilità di osservare un numero di successi <= 3
round(pbinom(3, size = n, prob = p_succ), 4)
```

```
[1] 0.7759
```

```r
# equivalente: somma delle masse da 0 a 3
round(sum(dbinom(0:3, size = n, prob = p_succ)), 4)
```

```
[1] 0.7759
```

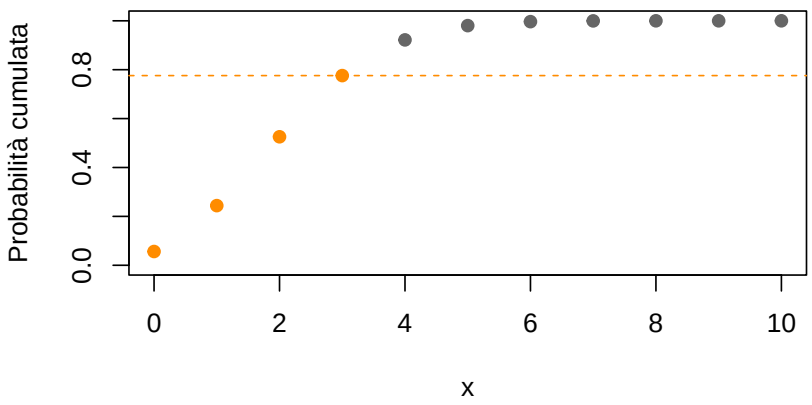


Figure 2.4: Probabilità cumulata di $X \sim \text{Bin}(10, 0.25)$. In arancione i valori che entrano nel calcolo di $F_X(3|\pi)$

2.0.5.3 Calcolare probabilità con `pbinom()`

Combinando `pbinom()` con le regole di calcolo viste in precedenza si possono ottenere le probabilità di diversi tipi di eventi.

Probabilità di ottenere al massimo 3 successi, $\Pr[X \leq 3] = F_X(3|\pi)$:

```
pbinom(3, n, prob = p_succ)
```

```
[1] 0.7758751
```

Probabilità di ottenere più di 3 successi, $\Pr[X > 3]$. L'evento $\{X > 3\}$ è il complementare di $\{X \leq 3\}$, quindi $\Pr[X > 3] = 1 - F_X(3|\pi)$. In `R` si può calcolare sottraendo la cumulata da 1 oppure con l'argomento `lower.tail = FALSE`:

```
1 - pbinom(3, n, prob = p_succ)
```

```
[1] 0.2241249
```

```
pbinom(3, n, prob = p_succ, lower.tail = FALSE)
```

```
[1] 0.2241249
```

Probabilità di ottenere tra 2 (escluso) e 5 (incluso) successi, $\Pr[2 < X \leq 5]$. Per la regola della differenza, $\Pr[2 < X \leq 5] = F_X(5|\pi) - F_X(2|\pi)$:

```
pbinom(5, n, prob = p_succ) - pbinom(2, n, prob = p_succ)
```

```
[1] 0.4546795
```

> Attenzione a $<$ e $\leq$ con le variabili discrete
>
> Per le variabili discrete la differenza tra $<$ e $\leq$ è importante: $\Pr[X \leq 3]$ include il valore 3, $\Pr[X < 3] = \Pr[X \leq 2]$ no. Ad esempio, $\Pr[X \geq 3] = 1 - \Pr[X \leq 2]$, quindi in `R` si scrive `1 - pbinom(2, n, prob = p_succ)`, e **non** `1 - pbinom(3, n, prob = p_succ)`.

3 Distribuzioni di probabilità continue

3.1 Definizioni generali

Sia X una variabile casuale continua distribuita secondo la **funzione di densità** $f_X(x|\theta)$:

$$f_X : \mathbb{R} \times \Theta \to \mathbb{R}_0^+$$

f_X è una funzione di densità parametrica con parametri $\theta \in \Theta$. A differenza della funzione di massa delle variabili discrete, la densità restituisce un numero non negativo ($\mathbb{R}_0^+$) che **non** è una probabilità: con una variabile continua la probabilità di osservare esattamente un singolo valore è nulla, $\Pr[X = x] = 0$. Le probabilità si calcolano invece sugli *intervalli*, come **aree sotto la curva** di densità.

La **funzione di ripartizione** (o *funzione di distribuzione cumulata*) $F_X(x|\theta)$ è definita come

$$F_X(x|\theta) = \Pr[X \leq x] = \int_{-\infty}^{x} f_X(z|\theta)\, dz, \qquad \text{con} \qquad F_X : \mathbb{R} \times \Theta \to [0, 1].$$

L'integrale gioca lo stesso ruolo della sommatoria nel caso discreto: $F_X(x|\theta)$ è l'area sotto la curva di densità da $-\infty$ fino a x.

Infine, la **funzione quantile** $q_X(p|\theta)$ è definita come la funzione inversa di F_X:

$$q_X(p|\theta) = F_X^{-1}(p|\theta) = x \in \mathbb{R} \text{ tale che } p = F_X(x|\theta), \qquad \text{con} \qquad q_X : [0, 1] \times \Theta \to \mathbb{R}.$$

In altre parole, la cumulata risponde alla domanda "qual è la probabilità di osservare un valore minore o uguale a x?", mentre la funzione quantile risponde alla domanda inversa "qual è il valore x al di sotto del quale cade una proporzione p dei casi?". Le due funzioni sono una l'inversa dell'altra:

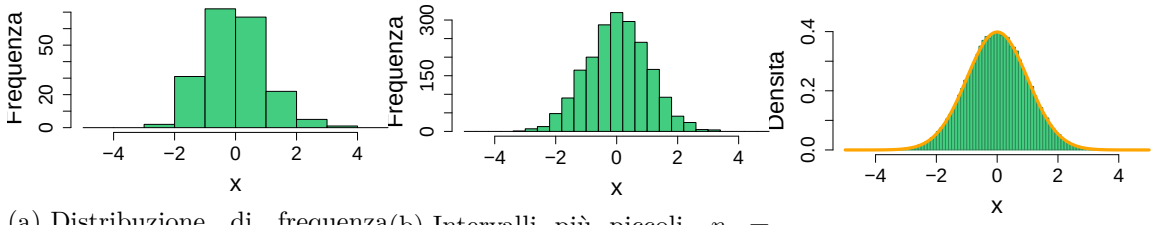
$$q_X(p|\theta) = F_X^{-1}(p|\theta) \quad \text{se e solo se} \quad F_X(x|\theta) = q_X^{-1}(x|\theta).$$

3.2 Distribuzione normale

La distribuzione **normale** (o *gaussiana*) è la distribuzione di probabilità più importante in statistica:

- è una distribuzione teorica di punteggi in una popolazione;
- riguarda solo variabili continue (misurate almeno su scale a intervalli equivalenti);
- molti fenomeni osservati si distribuiscono normalmente o con forme che approssimano la curva normale;
- gran parte della statistica inferenziale si basa sulle sue proprietà.

Per capire da dove viene la curva normale, partiamo da un istogramma delle frequenze di una variabile continua (Figure 3.1). Aumentando il numero di osservazioni e restringendo progressivamente l'ampiezza degli intervalli, i rettangoli dell'istogramma diventano sempre più sottili e il loro profilo si avvicina a una curva continua: la curva di densità.



(a) Distribuzione di frequenza ($n = 200$)

(b) Intervalli più piccoli, $n = 2000$

(c) Si ottiene una curva

Figure 3.1: Dalla distribuzione di frequenza alla curva di densità

3.2.1 Funzione di densità

Una variabile casuale X con distribuzione normale di media μ e varianza σ^2, $X \sim \mathcal{N}(\mu, \sigma^2)$, ha funzione di densità

$$f_X(x \mid \theta) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \qquad x \in \mathbb{R},$$

con parametri $\theta = (\mu, \sigma^2)$ e $\Theta = \mathbb{R} \times \mathbb{R}^+$, dove:

- μ è la media della popolazione;
- σ è la deviazione standard della popolazione (σ^2 la varianza);
- $\pi \approx 3.14$ ed $e \approx 2.718$ sono costanti.

π della normale e π della binomiale

Nella formula della densità normale π indica la costante 3.14 ..., **non** la probabilità di successo della binomiale. Il contesto chiarisce sempre a quale dei due ci si riferisce.

Un caso particolare è la **normale standard**, $Z \sim \mathcal{N}(0, 1)$, con media 0 e varianza 1 (Section 3.3):

$$f_Z(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2}, \qquad z \in \mathbb{R},$$

in cui i parametri sono fissati: $\theta = (\mu, \sigma^2) = (0, 1)$ e $\Theta = \{(0, 1)\}$.

3.2.2 Proprietà della curva normale

La curva normale (Figure 3.2) ha le seguenti proprietà:

- **Valori**: i valori di x vanno da $-\infty$ a $+\infty$. In ascissa si trovano tutti i valori di x, in ordinata la densità $f_X(x|\theta)$ di ciascun valore.
- **Simmetrica**: la curva è simmetrica rispetto al suo punto più alto, che si trova in corrispondenza di $x = \mu$. Solo il valore centrale ha densità massima, mentre allontanandosi dal centro (verso valori più bassi o più alti) la densità diminuisce allo stesso modo da entrambe le parti. La curva è **crescente** per $-\infty < x < \mu$ e **decrescente** per $\mu < x < +\infty$.
- **Unimodale**: ha una sola moda e, essendo simmetrica, media, moda e mediana coincidono: $\mu = Mo = Me$.
- **Asintotica**: le code della curva si avvicinano all'asse delle x senza mai toccarlo.
- **Punti di flesso**: la curva ha due punti di flesso in corrispondenza di $\mu - \sigma$ e $\mu + \sigma$. Nella metà sinistra la curva da convessa diventa concava, nella metà destra da concava diventa convessa.

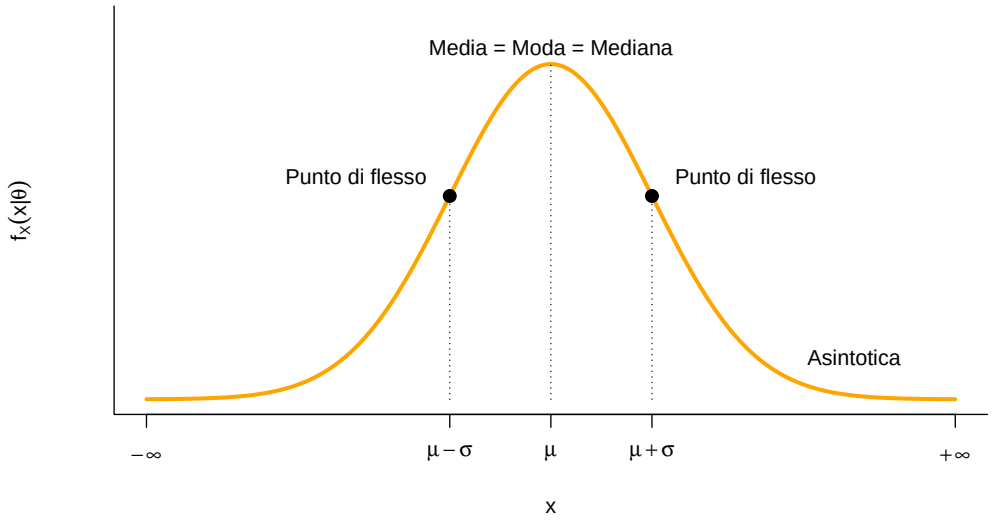


Figure 3.2: Proprietà della curva normale

3.2.3 Area e probabilità

Come per tutte le funzioni di densità, l'area totale sottesa alla curva normale è uguale a 1, ovvero al 100% dei casi:

$$\int_{-\infty}^{+\infty} f_X(x|\theta)\, dx = 1$$

L'area sotto la curva compresa tra due valori rappresenta la **probabilità** di osservare un valore in quell'intervallo. Una proprietà fondamentale della normale è che la porzione di area compresa tra la media e un valore espresso in deviazioni standard è sempre la stessa, qualunque siano μ e σ (Table 3.1 e Figure 3.3).

Table 3.1: Aree sotto la curva normale in funzione della distanza dalla media espressa in deviazioni standard

Tra μ e...	Area	Intervallo	Area
$\mu + \sigma$	34.13%	$\mu \pm \sigma$	68.26%
$\mu + 2\sigma$	47.73%	$\mu \pm 2\sigma$	95.45%
$\mu + 3\sigma$	49.87%	$\mu \pm 3\sigma$	99.73%

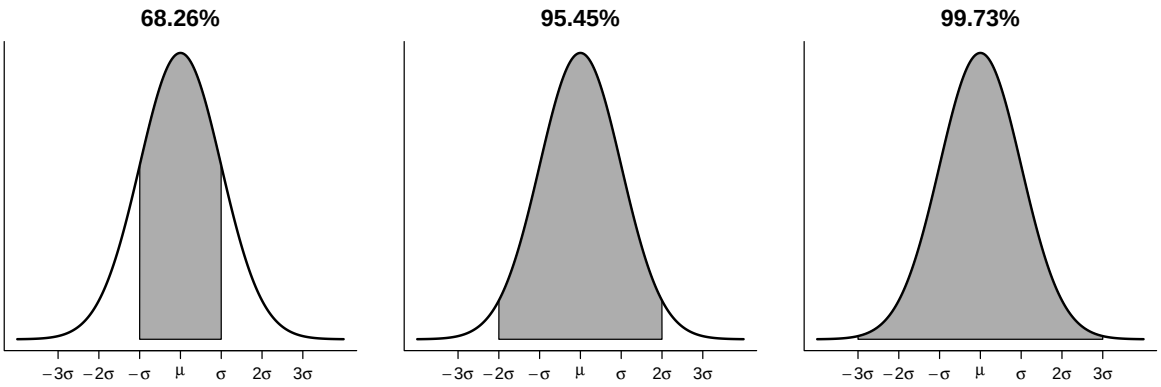


Figure 3.3: Area sotto la curva normale compresa entro 1, 2 e 3 deviazioni standard dalla media

Di conseguenza, conoscendo μ e σ è possibile calcolare:

- la densità $f_X(x|\theta)$ di ogni valore x;
- l'area (e quindi la **probabilità**) compresa tra due qualsiasi valori di x.

Poiché la curva è simmetrica, l'area tra $-\infty$ e μ è uguale a 0.50, come quella tra μ e $+\infty$: $F_X(\mu|\theta) = 0.50$.

Per calcolare la probabilità di osservare un valore *maggiore* di un certo x_1 si usa la regola del complementare (Figure 3.4):

$$\Pr[X > x_1] = \int_{x_1}^{+\infty} f_X(x|\theta)\, dx = 1 - F_X(x_1|\theta)$$

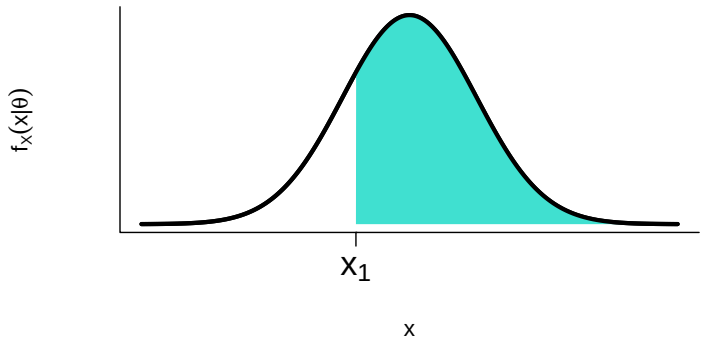


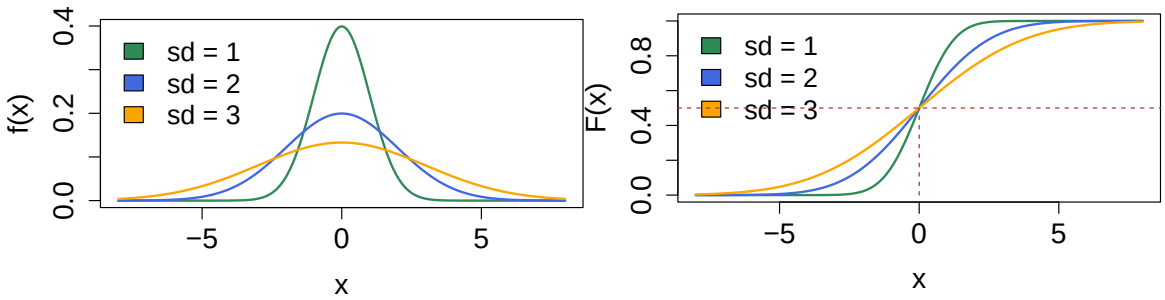
Figure 3.4: L'area bianca è $F_X(x_1|\theta) = \Pr[X \leq x_1]$, l'area azzurra è il suo complementare $\Pr[X > x_1] = 1 - F_X(x_1|\theta)$

3.2.4 Una famiglia di distribuzioni

Non esiste un'unica distribuzione normale, ma una *famiglia* di distribuzioni: ogni coppia di valori (μ, σ^2) individua una diversa curva normale.

- Cambiando σ e lasciando invariata μ, la curva resta centrata nello stesso punto ma diventa più "schiacciata" e larga all'aumentare di σ, più "appuntita" e stretta al diminuire di σ (Figure 3.5).
- Cambiando μ e lasciando invariata σ, la curva mantiene la stessa forma ma si sposta lungo l'asse delle x (Figure 3.6).

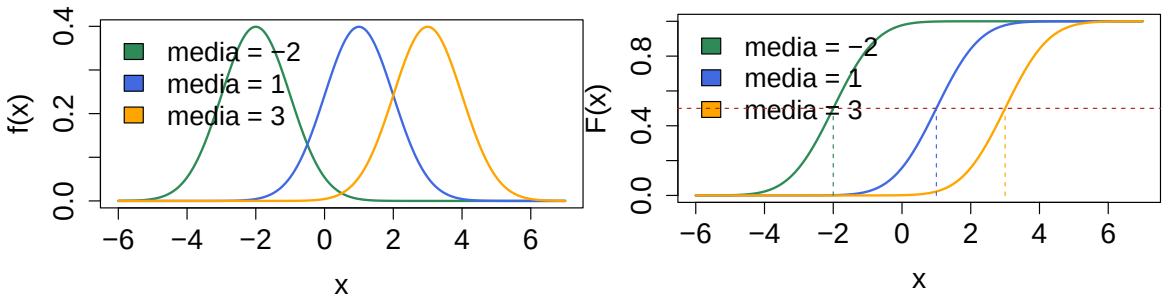
Si noti che, in tutti i casi, la cumulata vale 0.50 in corrispondenza della media.



(a) Densità

(b) Cumulata

Figure 3.5: Distribuzioni normali con la stessa media ($\mu = 0$) e diversa deviazione standard



(a) Densità

(b) Cumulata

Figure 3.6: Distribuzioni normali con la stessa deviazione standard ($\sigma = 1$) e diversa media

3.2.5 La normale in R

Le funzioni R per la distribuzione normale sono riportate in Table 3.2. Gli argomenti `mean` e `sd` corrispondono a μ e σ (attenzione: la **deviazione standard**, non la varianza).

Table 3.2: Funzioni R per la distribuzione normale

Funzione	Descrizione
`dnorm(x, mean, sd)`	Restituisce i *valori di densità* associati al vettore quantitativo `x` di una distribuzione normale con media `mean` e deviazione standard `sd`.
`pnorm(q, mean, sd)`	Restituisce i *valori di probabilità cumulata* associati al vettore `q`. Con `lower.tail = FALSE` calcola $\Pr[X > q]$.
`qnorm(p, mean, sd)`	Restituisce i *valori dei quantili* associati al vettore di probabilità `p` ($0 \leq p \leq 1$).
`rnorm(n, mean, sd)`	Genera un vettore casuale di `n` osservazioni indipendenti campionate da una normale con media `mean` e deviazione standard `sd`.

Ad esempio, se i punteggi di QI si distribuiscono come $X \sim \mathcal{N}(100, 15^2)$, la probabilità che una persona estratta a caso abbia un QI minore o uguale a 115 ($\mu + \sigma$) è

```
pnorm(115, mean = 100, sd = 15)
```

```
[1] 0.8413447
```

ovvero il 50% (area a sinistra della media) più il 34.13% (area tra μ e $\mu+\sigma$). La probabilità di avere un QI compreso tra 85 e 115 ($\mu \pm \sigma$) si ottiene per differenza:

```
pnorm(115, mean = 100, sd = 15) - pnorm(85, mean = 100, sd = 15)
```

```
[1] 0.6826895
```

3.3 Normale standardizzata

Per gli usi pratici della distribuzione normale si ricorre alla **normale standardizzata** $Z \sim \mathcal{N}(0, 1)$:

$$f_Z(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2}$$

Qualsiasi variabile normale si può trasformare in una normale standardizzata attraverso la **standardizzazione**: se $X \sim \mathcal{N}(\mu, \sigma^2)$, allora

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1) \qquad \Rightarrow \qquad z = \frac{x - \mu}{\sigma}$$

Per ogni valore x della variabile originaria esiste un corrispondente valore z, che indica di quante deviazioni standard x si trova sopra o sotto la media. L'area al di là di z sulla normale standardizzata corrisponde all'area al di là di x nella distribuzione originaria (Figure 3.7):

$$F_X(x|\theta) = F_Z\left(\frac{x - \mu}{\sigma}\right)$$

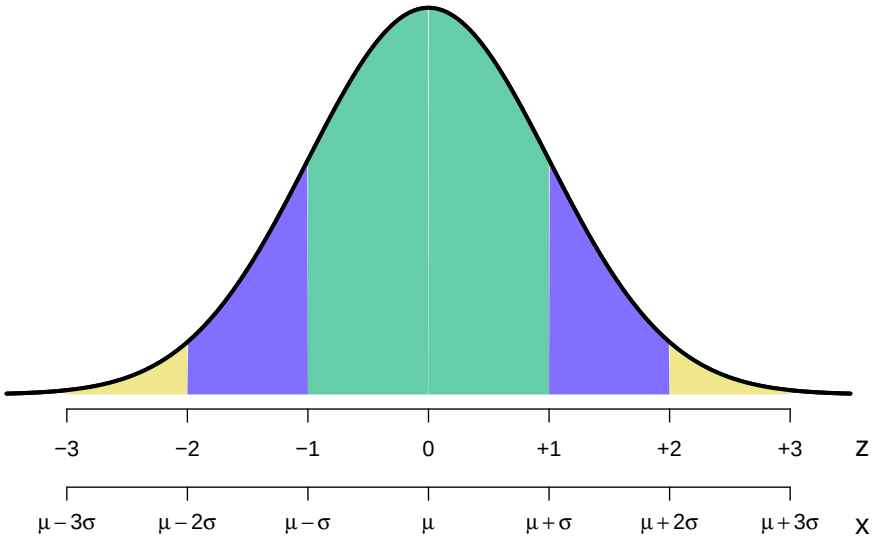


Figure 3.7: Corrispondenza tra i valori x della distribuzione originaria e i valori z della normale standardizzata

> Default delle funzioni `R`
>
> A meno che non venga specificato altrimenti con gli argomenti `mean` e `sd`, le funzioni di `R` relative alla distribuzione normale (`dnorm()`, `pnorm()`, `qnorm()`, `rnorm()`) usano di default la normale standardizzata, ovvero una distribuzione con $\mu = 0$ e $\sigma = 1$.

3.3.1 Tavole della normale standardizzata

Prima dei software statistici, le probabilità della normale standardizzata si ricavavano da apposite **tavole** (Table 3.3). Le tavole riportano l'area compresa tra 0 e z, cioè $F_Z(z) - 0.50$, solo per valori $z > 0$. Le righe indicano la parte intera e il primo decimale di z, le colonne il secondo decimale. Per i valori negativi si sfrutta la simmetria della curva: $F_Z(-z) = 1 - F_Z(z)$.

Table 3.3: Tavola della normale standardizzata: area compresa tra 0 e z

z	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
0.0	0.0000	0.0040	0.0080	0.0120	0.0160	0.0199	0.0239	0.0279	0.0319	0.0359
0.1	0.0398	0.0438	0.0478	0.0517	0.0557	0.0596	0.0636	0.0675	0.0714	0.0753
0.2	0.0793	0.0832	0.0871	0.0910	0.0948	0.0987	0.1026	0.1064	0.1103	0.1141
0.3	0.1179	0.1217	0.1255	0.1293	0.1331	0.1368	0.1406	0.1443	0.1480	0.1517
0.4	0.1554	0.1591	0.1628	0.1664	0.1700	0.1736	0.1772	0.1808	0.1844	0.1879
0.5	0.1915	0.1950	0.1985	0.2019	0.2054	0.2088	0.2123	0.2157	0.2190	0.2224
0.6	0.2257	0.2291	0.2324	0.2357	0.2389	0.2422	0.2454	0.2486	0.2517	0.2549
0.7	0.2580	0.2611	0.2642	0.2673	0.2704	0.2734	0.2764	0.2794	0.2823	0.2852
0.8	0.2881	0.2910	0.2939	0.2967	0.2995	0.3023	0.3051	0.3078	0.3106	0.3133
0.9	0.3159	0.3186	0.3212	0.3238	0.3264	0.3289	0.3315	0.3340	0.3365	0.3389
1.0	0.3413	0.3438	0.3461	0.3485	0.3508	0.3531	0.3554	0.3577	0.3599	0.3621
1.1	0.3643	0.3665	0.3686	0.3708	0.3729	0.3749	0.3770	0.3790	0.3810	0.3830
1.2	0.3849	0.3869	0.3888	0.3907	0.3925	0.3944	0.3962	0.3980	0.3997	0.4015
1.3	0.4032	0.4049	0.4066	0.4082	0.4099	0.4115	0.4131	0.4147	0.4162	0.4177
1.4	0.4192	0.4207	0.4222	0.4236	0.4251	0.4265	0.4279	0.4292	0.4306	0.4319
1.5	0.4332	0.4345	0.4357	0.4370	0.4382	0.4394	0.4406	0.4418	0.4429	0.4441
1.6	0.4452	0.4463	0.4474	0.4484	0.4495	0.4505	0.4515	0.4525	0.4535	0.4545
1.7	0.4554	0.4564	0.4573	0.4582	0.4591	0.4599	0.4608	0.4616	0.4625	0.4633
1.8	0.4641	0.4649	0.4656	0.4664	0.4671	0.4678	0.4686	0.4693	0.4699	0.4706
1.9	0.4713	0.4719	0.4726	0.4732	0.4738	0.4744	0.4750	0.4756	0.4761	0.4767
2.0	0.4772	0.4778	0.4783	0.4788	0.4793	0.4798	0.4803	0.4808	0.4812	0.4817
2.1	0.4821	0.4826	0.4830	0.4834	0.4838	0.4842	0.4846	0.4850	0.4854	0.4857
2.2	0.4861	0.4864	0.4868	0.4871	0.4875	0.4878	0.4881	0.4884	0.4887	0.4890
2.3	0.4893	0.4896	0.4898	0.4901	0.4904	0.4906	0.4909	0.4911	0.4913	0.4916
2.4	0.4918	0.4920	0.4922	0.4925	0.4927	0.4929	0.4931	0.4932	0.4934	0.4936
2.5	0.4938	0.4940	0.4941	0.4943	0.4945	0.4946	0.4948	0.4949	0.4951	0.4952
2.6	0.4953	0.4955	0.4956	0.4957	0.4959	0.4960	0.4961	0.4962	0.4963	0.4964
2.7	0.4965	0.4966	0.4967	0.4968	0.4969	0.4970	0.4971	0.4972	0.4973	0.4974
2.8	0.4974	0.4975	0.4976	0.4977	0.4977	0.4978	0.4979	0.4979	0.4980	0.4981
2.9	0.4981	0.4982	0.4982	0.4983	0.4984	0.4984	0.4985	0.4985	0.4986	0.4986
3.0	0.4987	0.4987	0.4987	0.4988	0.4988	0.4989	0.4989	0.4989	0.4990	0.4990

3.3.2 Dalla z alla probabilità e viceversa: a mano e in R

Esempio 1. Trovare la probabilità cumulata per $z = 1.85$, ovvero $\Pr[Z \leq 1.85]$ (Figure 3.8).

- *A mano*: si cerca nella tavola la riga corrispondente a 1.8 e la colonna .05. Il valore nella cella è l'area tra 0 e 1.85; siccome la tavola è "troncata a metà", per ottenere la cumulata bisogna sommare 0.50 al valore trovato.

- *In R*:

```
pnorm(1.85)
```

```
[1] 0.9678432
```

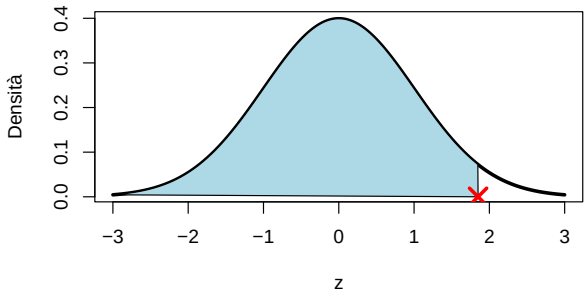


Figure 3.8: $\Pr[Z \leq 1.85]$

Esempio 2. Trovare il quantile z tale che $F_Z(z) = 0.275$, ovvero il valore al di sotto del quale cade il 27.5% dell'area (Figure 3.9).

- *A mano*: dato che $0.275 < 0.50$, il valore z cercato è negativo. Per simmetria, cerchiamo il valore positivo z tale che l'area tra 0 e z sia $0.50 - 0.275 = 0.225$: si individua nella tavola la cella con il valore più vicino possibile a 0.225, si risale al valore z corrispondente (riga + colonna) e lo si cambia di segno.
- *In R*:

```
qnorm(.275)
```

```
[1] -0.5977601
```

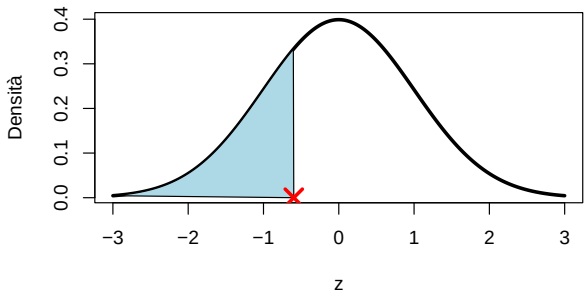


Figure 3.9: Quantile z tale che $F_Z(z) = 0.275$

3.4 Distribuzione t di Student

La distribuzione t **di Student** è una distribuzione continua, simmetrica e centrata sullo 0, con una forma a campana simile a quella della normale standardizzata. È definita da un unico parametro, i **gradi di libertà**: $\theta = df$, con $\Theta = \mathbb{R}^+$. Come vedremo nei prossimi moduli, nelle applicazioni i gradi di libertà dipendono dalla numerosità del campione (ad esempio, $df = n - 1$).

Rispetto alla normale standardizzata, la t di Student ha le **code più "pesanti"**: assegna più probabilità ai valori lontani dallo 0 e meno probabilità ai valori centrali (Figure 3.10). Come per tutte le funzioni di densità, l'area totale sotto la curva è uguale a 1:

$$\int_{-\infty}^{+\infty} f_X(x|\theta)\, dx = 1$$

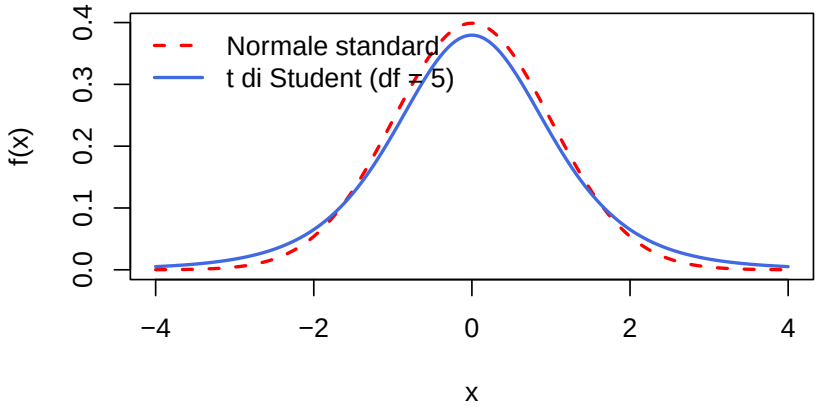


Figure 3.10: Confronto tra la normale standardizzata e la t di Student con 5 gradi di libertà

3.4.1 Una famiglia di distribuzioni

Come la normale, anche la t di Student è una famiglia di distribuzioni: per ogni valore dei gradi di libertà si ottiene una curva diversa (Figure 3.11). Al crescere dei gradi di libertà le code diventano più leggere e la t di Student si avvicina sempre di più alla normale standardizzata, fino a diventare praticamente indistinguibile da essa.

3.4.2 La t di Student in `R`

Table 3.4: Funzioni `R` per la distribuzione t di Student

Funzione	Descrizione
`dt(x, df)`	Restituisce i *valori di densità* associati al vettore quantitativo `x` di una distribuzione t con `df` gradi di libertà.

Funzione	Descrizione
`pt(q, df)`	Restituisce i *valori di probabilità cumulata* associati al vettore quantitativo `q`.
`qt(p, df)`	Restituisce i *valori dei quantili* associati al vettore di probabilità `p`.
`rt(n, df)`	Restituisce un vettore casuale di `n` osservazioni indipendenti campionate da una distribuzione t di Student con `df` gradi di libertà.

Le code più pesanti della t si vedono bene confrontando i quantili. Ad esempio, il valore che lascia alla sua destra il 2.5% dell'area è più grande per la t con pochi gradi di libertà che per la normale standardizzata, e si avvicina a quello della normale all'aumentare dei gradi di libertà:

```
qnorm(.975)
```

```
[1] 1.959964
```

```
qt(.975, df = c(5, 30, 100))
```

```
[1] 2.570582 2.042272 1.983972
```

3.5 Distribuzione χ^2

La distribuzione χ^2 (chi-quadrato) è una distribuzione continua definita solo per valori **non negativi** ($x \geq 0$) e, a differenza della normale e della t, **asimmetrica positiva**. Anche la χ^2 è definita da un unico parametro, i gradi di libertà: $\theta = df$, $\Theta = \mathbb{R}^+$.

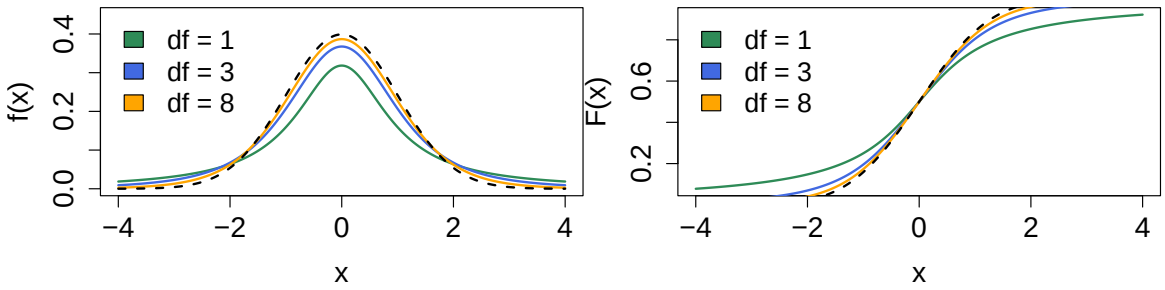
Nelle applicazioni che vedremo (variabili qualitative), i gradi di libertà dipendono dal numero di categorie considerate:

- con una variabile X con $k = 1, \dots, m$ categorie: $df = m - 1$;
- con due variabili X e Y, con $k = 1, \dots, m$ e $j = 1, \dots, h$ categorie rispettivamente: $df = (m-1)(h-1)$.

Ad esempio, per una tabella di contingenza 3×2, $df = (3-1)(2-1) = 2$.

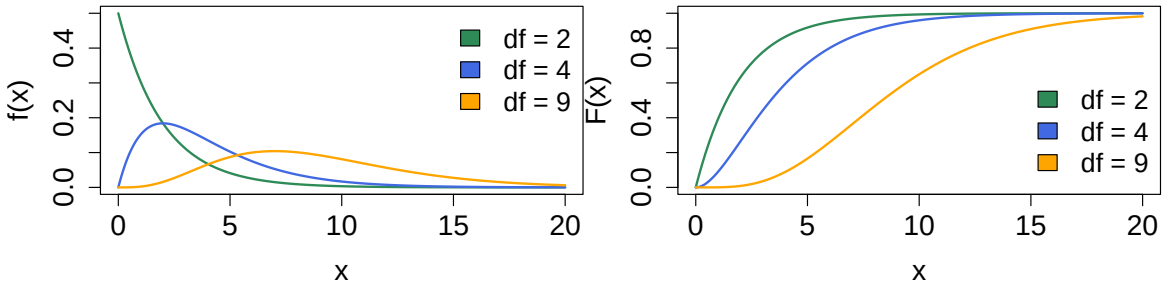
All'aumentare dei gradi di libertà la distribuzione si sposta verso destra e diventa progressivamente meno asimmetrica (Figure 3.12).

3.5.1 La χ^2 in R



(a) Densità (b) Cumulata

Figure 3.11: Distribuzioni t di Student con diversi gradi di libertà. La linea tratteggiata è la normale standardizzata



(a) Densità (b) Cumulata

Figure 3.12: Distribuzioni χ^2 con diversi gradi di libertà

Table 3.5: Funzioni `R` per la distribuzione χ^2

Funzione	Descrizione
`dchisq(x, df)`	Restituisce i *valori di densità* associati al vettore quantitativo `x` di una distribuzione χ^2 con `df` gradi di libertà.
`pchisq(q, df)`	Restituisce i *valori di probabilità cumulata* associati al vettore quantitativo `q`.
`qchisq(p, df)`	Restituisce i *valori dei quantili* associati al vettore di probabilità `p`.
`rchisq(n, df)`	Restituisce un vettore casuale di `n` osservazioni indipendenti campionate da una distribuzione χ^2 con `df` gradi di libertà.

3.6 Altre distribuzioni continue

La logica `d*`, `p*`, `q*`, `r*` vale per tutte le distribuzioni disponibili in `R`. Di seguito alcune altre distribuzioni continue di uso comune.

Esponenziale `exp`

`dexp(x, rate)`, `pexp(q, rate)`, `qexp(p, rate)`, `rexp(n, rate)`
`rate` (λ) è il tasso della distribuzione esponenziale.

Uniforme `unif`

`dunif(x, min, max)`, `punif(q, min, max)`, `qunif(p, min, max)`, `runif(n, min, max)`
`min` e `max` sono il valore minimo e massimo della distribuzione: tutti i valori compresi tra `min` e `max` hanno la stessa densità.

Gamma `gamma`

`dgamma(x, shape, scale)`, `pgamma(q, shape, scale)`, `qgamma(p, shape, scale)`, `rgamma(n, shape, scale)`
`shape` regola la forma della distribuzione, `scale` regola la sua variabilità.

4 Principi base di inferenza statistica

Partiamo da dove vogliamo arrivare. Alla fine di questo modulo e del successivo sapremo leggere un output come questo, in cui R confronta il consumo medio delle automobili con cambio automatico e manuale:

```
> t.test(mpg ~ am, data = mtcars)
Welch Two Sample t-test

data:  mpg by am
t = -3.7671, df = 18.332, p-value = 0.001374
alternative hypothesis: true difference in means between group 0 and
  group 1 is not equal to 0
95 percent confidence interval:
 -11.280194  -3.209684
sample estimates:
mean in group 0 mean in group 1
       17.14737        24.39231
```

1. Tipo di test (Welch: varianze non assunte uguali)
2. Statistica test t
3. Gradi di libertà
4. p-value
5. H_1: bidirezionale
6. Intervallo di confidenza al 95%
7. Medie dei due gruppi

4.1 Inferenza statistica

L'**inferenza statistica** è definita come un insieme di metodi, basati sulla teoria della probabilità, tali per cui si possano trarre conclusioni plausibili sulla variabile casuale associata a una particolare caratteristica di una *popolazione* a partire dall'osservazione di un **campione** di elementi della popolazione stessa.

Secondo l'impostazione classica, la teoria dell'inferenza statistica si sviluppa lungo due direttrici:

- la teoria della **stima di parametri**;
- la teoria della **verifica di ipotesi**.

4.1.1 Popolazione e campione

La maggior parte degli studi viene condotta su "gruppi" più o meno ampi di elementi che appartengono a un insieme più ampio, definito popolazione.

Popolazione

Rappresenta tutto l'universo di individui a cui si rivolge l'attenzione del ricercatore (ad esempio, la popolazione degli studenti della scuola elementare).

Campione

Sottoinsieme della popolazione, possibilmente composto da unità estratte **casualmente** dalla popolazione.

La popolazione può essere:

- **finita** (N): è possibile avere informazioni rispetto al numero di unità di analisi che la compongono. Può essere molto piccola (es., persone con una sindrome rara) o molto grande (es., tutti gli studenti di psicologia);
- **infinita**: non è possibile conoscere con precisione il numero di unità di analisi che la compongono (anche se hanno un numero finito), oppure non è possibile determinarlo (es., i lanci di un dado).

Dalla popolazione, attraverso il **campionamento** (*con o senza reinserimento*), si ottiene un **campione**, che è sempre *finito* (n).

Lo studio *dell'intera popolazione* porta alla **certezza delle conclusioni**.

Esempio

Si vuole verificare se il reddito familiare medio degli studenti di psicologia in Italia (popolazione A) sia superiore a quello dei loro colleghi in Francia (popolazione B). Se si calcolasse il reddito medio di tutte le famiglie italiane e francesi il risultato (indipendentemente da quale) sarebbe certo.

Studiare l'intera popolazione è però irrealistico (a livello di risorse umane, economiche, temporali, ecc.): è necessario ricorrere ai campioni e alla statistica inferenziale.

Un'*indagine campionaria* **non offre la certezza delle conclusioni**: quello che si osserva su due campioni A e B potrebbe non riflettere la realtà delle popolazioni. Il modo in cui viene selezionato il campione è di fondamentale importanza.

Gli strumenti statistici consentono di valutare **probabilisticamente** gli errori che si possono commettere traendo conclusioni sulle popolazioni a partire dalle caratteristiche di uno o più campioni. Gli errori di un'indagine campionaria possono essere ridotti se il campione è **rappresentativo** della popolazione, se cioè *possiede le caratteristiche della popolazione dalla quale proviene.*

Campionamento casuale

Se il campione è estratto *casualmente* dalla popolazione si può affermare che eventuali differenze sono dovute "al caso", cioè *a variazioni accidentali e non sistematiche*.

Conta non solo *come* si seleziona il campione, ma anche *quanto* è ampio: l'ampiezza campionaria è importante per poter fare inferenze valide.

4.2 Stimatore

Un **indicatore** o **statistica** o, più comunemente, **stimatore** è una funzione dei valori osservati sul campione $(X_1, X_2, \dots, X_n)$, utilizzata per la stima di un **parametro** (generalmente incognito) di una **popolazione** e che (possibilmente) rispetta una serie di caratteristiche.

La stima può essere:

- **puntuale**: il metodo di stima conduce a un unico valore per il parametro in oggetto;
- **intervallare**: il metodo di stima conduce a un intervallo di valori, all'interno dei quali si suppone che si trovi con una certa probabilità il valore vero del parametro.

4.2.1 Proprietà di uno stimatore

Uno stimatore è tanto migliore quanto più rispetta queste proprietà:

- **Correttezza** (o non distorsione): in media, su tutti i campioni possibili, lo stimatore restituisce il valore del parametro (ad esempio, $\mu_{\bar{x}} = \mu$);
- **Efficienza**: tra due stimatori corretti, è più efficiente quello con varianza minore, le cui stime cambiano meno da un campione all'altro;
- **Consistenza**: all'aumentare dell'ampiezza campionaria n, le stime si avvicinano sempre di più al valore del parametro.

La media campionaria $\bar{x}$ è uno stimatore corretto e consistente della media della popolazione μ, come si vedrà nell'esempio sulle distribuzioni campionarie (Section 4.3.2).

La **statistica inferenziale** ha pertanto l'obiettivo di stimare parametri incogniti attraverso certe funzioni dei dati campionari (*indicatori* o *stimatori*). Si calcolano, quindi, le **statistiche** del campione (ad esempio, $\bar{x}$) per conoscere i **parametri** della popolazione (ad esempio, μ). Questo passaggio dalle statistiche ai parametri si basa sulla conoscenza delle proprietà delle **distribuzioni campionarie** delle statistiche.

4.3 Distribuzioni campionarie

La **distribuzione campionaria** è la *distribuzione di probabilità* relativa a una specifica statistica calcolata su tutti i k campioni estraibili da una popolazione.

Per determinare una distribuzione campionaria bisogna:

1. estrarre tutti i possibili k campioni dalla popolazione di interesse con campionamento *casuale e indipendente*: ogni unità di analisi deve avere la stessa probabilità di essere estratta e l'estrazione di una unità non deve modificare la probabilità delle altre unità;
2. calcolare su ognuno dei k campioni la statistica (o stimatore) di interesse, ad esempio la media $\bar{x}$;
3. determinare (cioè contare) la frequenza di ognuno dei valori della statistica, ovvero quanti *campioni* presentano quel valore.

4.3.1 Distribuzione campionaria della media

La Figura 4.1 illustra il procedimento nel caso della media: da ciascun campione estratto dalla popolazione si calcola $\bar{x}$, e la media di tutte le $\bar{x}$ è la media della distribuzione campionaria.

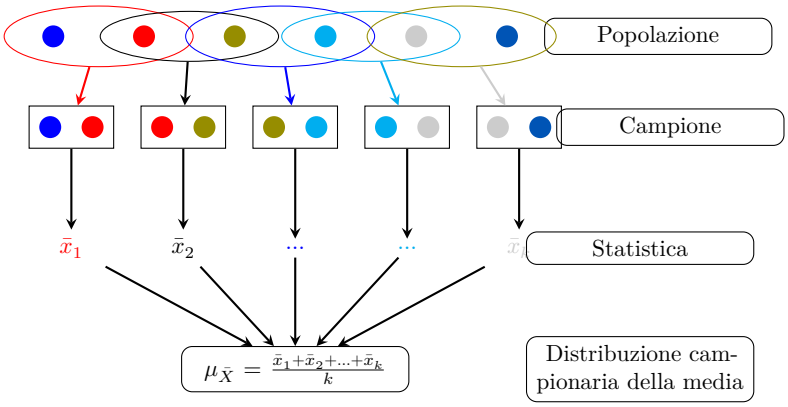


Figure 4.1: Costruzione della distribuzione campionaria della media. Sono illustrati solo alcuni dei possibili k campioni

4.3.2 Determinare la distribuzione campionaria

Consideriamo una popolazione di $N = 5$ persone a cui è stato somministrato un test con punteggio da 0 a 10 (Table 4.1), da cui si estraggono campioni di ampiezza $n = 2$. La media della popolazione è

$$\mu = \frac{6 + 8 + 10 + 3 + 8}{5} = 7$$

Table 4.2: Tutti i possibili campioni di ampiezza $n = 2$ estratti dalla popolazione con reinserimento (G = Giorgio, A = Alessandra, F = Francesco, L = Luca, J = Jessica)

Campione	Elem. 1	Elem. 2	Valore 1	Valore 2	**Media**	Campione	Elem. 1	Elem. 2	Valore 1	Valore 2	**Media**
1	G	G	6	6	6	16	L	G	3	6	4.5
2	G	A	6	8	7	17	L	A	3	8	5.5
3	G	F	6	10	8	18	L	F	3	10	6.5
4	G	L	6	3	4.5	19	L	L	3	3	3
5	G	J	6	8	7	20	L	J	3	8	5.5
6	A	G	8	6	7	21	J	G	8	6	7
7	A	A	8	8	8	22	J	A	8	8	8
8	A	F	8	10	9	23	J	F	8	10	9
9	A	L	8	3	5.5	24	J	L	8	3	5.5
10	A	J	8	8	8	25	J	J	8	8	8
11	F	G	10	6	8						
12	F	A	10	8	9						
13	F	F	10	10	10						
14	F	L	10	3	6.5						
15	F	J	10	8	9						

Table 4.1: Punteggi della popolazione ($N = 5$)

Soggetto	Punteggio
Giorgio	6
Alessandra	8
Francesco	10
Luca	3
Jessica	8

Se il campione estratto è composto da Giorgio e Alessandra, la media campionaria è $\bar{x} = (6+8)/2 = 7$. Se invece il campione è composto da Alessandra e Francesco, $\bar{x} = (8+10)/2 = 9$. La media cambia da campione a campione. La Tabella 4.2 riporta tutti i 25 campioni possibili, ottenuti con campionamento con reinserimento, e la Figura **??** la distribuzione delle loro medie.

La media della distribuzione campionaria si ottiene moltiplicando ogni valore di $\bar{x}$ per la sua frequenza e dividendo per il numero di campioni:

$$\mu_{\bar{x}} = \frac{6 \cdot 1 + 7 \cdot 4 + 8 \cdot 6 + 4.5 \cdot 2 + 9 \cdot 4 + 5.5 \cdot 4 + 10 \cdot 1 + 6.5 \cdot 2 + 3 \cdot 1}{25} = 7$$

e coincide con la media della popolazione: $\mu = \mu_{\bar{x}} = 7$. Le medie campionarie si distribuiscono **attorno a** $\mu = 7$: alcuni campioni sovrastimano μ, altri lo sottostimano, ma **in media** lo stimatore restituisce il valore del parametro (correttezza).

4.3.3 Errore standard

Oltre al centro della distribuzione campionaria serve sapere **quanto variano** le medie da un campione all'altro.

Errore standard della media

È la deviazione standard della distribuzione campionaria della media:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

dove σ è la deviazione standard della popolazione e n l'ampiezza dei campioni.

Nell'esempio, la varianza della popolazione è $\sigma^2 = 5.6$, mentre la varianza delle 25 medie è $2.8 = \frac{5.6}{2}$, quindi $\sigma_{\bar{x}} = \frac{\sqrt{5.6}}{\sqrt{2}} = 1.67$.

All'aumentare di n l'errore standard diminuisce: con campioni più grandi la media campionaria è una stima più precisa di μ (consistenza).

4.3.4 Forma della distribuzione campionaria

Teorema del limite centrale

Se l'ampiezza campionaria n è sufficientemente grande (regola pratica: $n \geq 30$), la distribuzione campionaria della media è **approssimativamente normale**, con media μ e deviazione standard $\frac{\sigma}{\sqrt{n}}$, *qualunque sia la forma della distribuzione nella popolazione.*

Se la popolazione ha distribuzione normale, la distribuzione campionaria della media è normale per qualsiasi n.

Standardizzando la media campionaria si ottiene una variabile normale standard:

$$z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

È questa la **curva** su cui si costruiscono le regioni di rifiuto e di non rifiuto del test di ipotesi.

4.4 Test di ipotesi

Il test di ipotesi è una procedura che si svolge per passi logici successivi:

- porsi una domanda di ricerca (dotata di senso e basata sulla letteratura);
- formulare le ipotesi riguardanti i parametri della popolazione;
- definire i criteri e i vincoli di accettazione dell'ipotesi;
- raccogliere i dati campionari;
- valutare le ipotesi formulate.

Le ipotesi di ricerca sono ipotesi statistiche:

- consistono in affermazioni di tipo logico-matematico che definiscono i rapporti fra i parametri di una o più popolazioni;
- il test delle ipotesi consiste in un **processo di decisione che termina con il rifiuto o il non rifiuto delle affermazioni contenute nell'ipotesi nulla**;
- un'ipotesi statistica è un'asserzione o supposizione sulla distribuzione di una o più variabili casuali, o su uno o più parametri della stessa, e si indica con la lettera H.

Esempio

Sia $X_1, X_2, \dots, X_n$ un campione casuale estratto da una popolazione normale con media incognita. Si può formulare l'ipotesi che la media di tale popolazione sia 12. Formalmente si esprime con:

$$H : \mu = 12$$

4.5 Null Hypothesis Significance Testing (NHST)

Il modo in cui si conduce oggi il test di ipotesi deriva da due approcci distinti:

- **Fisher (1925)**: considera solo H_0, senza un'ipotesi alternativa formale. Il p-value indica quanto i dati sono poco compatibili con H_0.
- **Neyman e Pearson (1933)**: confrontano H_0 con H_1, fissando α e β prima di raccogliere i dati. Il risultato è una decisione: si rifiuta o non si rifiuta H_0.

NHST

È una *forzatura* dei due approcci: prende H_0 e il p-value da Fisher, H_1, α e β da Neyman e Pearson, e li mette insieme (anche se i due approcci hanno logiche diverse).

4.5.1 Ipotesi nulla e ipotesi alternativa

Ipotesi nulla e ipotesi alternativa

Le distribuzioni di probabilità a livello delle popolazioni che identificano lo schema logico del confronto sono classificate in due gruppi distinti:

- H_0: definita come **ipotesi nulla**;
- H_1: definita come **ipotesi alternativa**.

L'ipotesi alternativa viene indicata anche con altri simboli equivalenti, come H_A oppure K.

Nota

H_0 e H_1 devono essere **mutuamente esclusive**: $\Theta_0 \cap \Theta_A = \emptyset$. Non devono per forza essere complementari:

- $H_0 : \mu = \mu_0$ e $H_1 : \mu \neq \mu_0$ sono complementari;
- $H_0 : \mu = \mu_0$ e $H_1 : \mu > \mu_0$ non lo sono, perché non considerano i valori $\mu < \mu_0$.

Ipotesi H_0. È l'ipotesi che costituisce l'oggetto del test: specifica i valori dei parametri della popolazione da cui si suppone provenga il campione (o i campioni) in esame. Stabilisce che le differenze osservate nel campione sono puramente **casuali**. Formalmente si esprime con

$$H_0 : \ \theta = \theta_0$$

dove θ indica il parametro della popolazione e θ_0 il valore che ci si attende.

Ipotesi H_1. È l'ipotesi alternativa, solitamente l'ipotesi di ricerca secondo la quale i risultati ottenuti **non sono casuali** ma sono spiegabili secondo una qualche regola o teoria. L'ipotesi alternativa può essere:

- **bidirezionale**: $\theta \neq \theta_0$;
- **monodirezionale sinistra**: $\theta < \theta_0$;
- **monodirezionale destra**: $\theta > \theta_0$.

Esempio

Si vuole stabilire, attraverso un esperimento, se una moneta sia truccata o meno. Si indica con π la probabilità di ottenere testa in un lancio. Prima di eseguire l'esperimento si formulano le due ipotesi relative al parametro π:

- $H_0 : \ \pi = .50$, la moneta non è truccata;
- $H_1 : \ \pi \neq .50$, la moneta è truccata.

Il problema è stabilire se i risultati dell'esperimento (ad esempio, lanciare una moneta 30 volte) falsificano o meno l'ipotesi. I valori empirici possono considerarsi dovuti a fluttuazioni casuali intorno al valore atteso, e di conseguenza non confutano H_0? Oppure le fluttuazioni non sono casuali ma sistematiche, e di conseguenza H_0 è confutata?

La decisione si basa sul calcolo di un test statistico e sulla probabilità associata al valore di tale test.

Test statistico

Valore di una variabile casuale che può assumere i valori di una distribuzione campionaria caratterizzata da una determinata distribuzione di probabilità.

Ogni test statistico divide lo spazio campionario in due regioni: la **regione di non rifiuto** di H_0 e la **regione di rifiuto** di H_0. In base alla regione in cui cade il valore campionario, si prende una decisione sull'ipotesi H_0. Le due regioni corrispondono ad aree di probabilità sottese alla curva (Figure 4.2):

- **regione di non rifiuto**: valori delle statistiche campionarie con probabilità maggiori di verificarsi *data* H_0 *vera*;
- **regione di rifiuto**: valori delle statistiche campionarie con probabilità molto basse di verificarsi *data* H_0 *vera*.

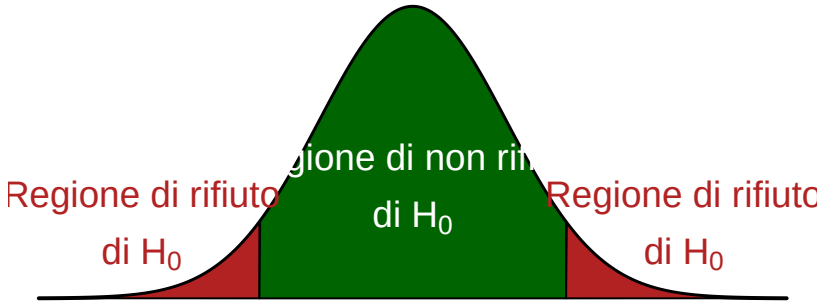


Figure 4.2: Regioni di rifiuto e di non rifiuto di H_0

4.6 Valore critico

4.6.1 Livello di significatività

α (errore di I tipo)

Il **livello di significatività** α è la probabilità di rifiutare H_0 quando H_0 è vera. Si fissa **prima** di raccogliere i dati (valori convenzionali: .05, .01).

- α è l'area della **regione di rifiuto** sotto la distribuzione campionaria costruita assumendo vera H_0;
- $1 - \alpha$ è l'area della **regione di non rifiuto**.

Una volta scelto α, la regione di rifiuto è fissata e con essa il **valore critico**, ovvero il valore che separa le due regioni.

Per stabilire se il valore di un test è coerente o meno con l'ipotesi nulla è necessario verificare che il suo valore sia compreso all'interno della **regione di non rifiuto**. Se il valore campionario cade nella **regione di rifiuto** c'è da ritenere che le osservazioni campionarie si discostino dai valori più probabili della distribuzione; in tal caso si può decidere di rifiutare H_0.

p-value

Il *p*-value si ricava dal valore osservato della statistica test, dalla sua distribuzione sotto H_0 e dalla direzione di H_1. Viene poi confrontato con α per prendere la decisione (Section 4.6.4).

4.6.2 Valore critico e direzione di H_1

La posizione della regione di rifiuto dipende da H_1 (Figura 4.3). Con la normale standard e $\alpha = .05$:

- H_1 **bidirezionale**: $\alpha/2 = .025$ in ciascuna coda;
- H_1 **sinistra**: $\alpha = .05$ nella coda sinistra;
- H_1 **destra**: $\alpha = .05$ nella coda destra.

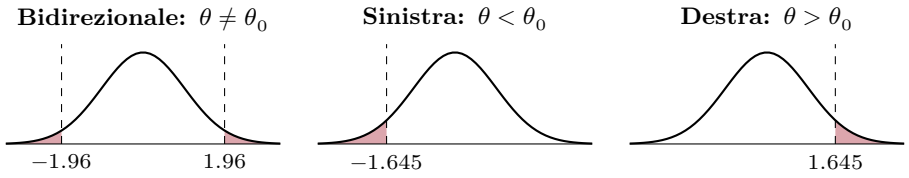


Figure 4.3: Valori critici e regioni di rifiuto (in rosso) al variare della direzione di H_1, con $\alpha = .05$

In `R` i valori critici si ottengono con `qnorm()`:

```
qnorm(.975) # bidirezionale, coda destra (-1.96 per simmetria)
```

```
[1] 1.959964
```

```
qnorm(.05)  # sinistra
```

```
[1] -1.644854
```

```
qnorm(.95)  # destra
```

```
[1] 1.644854
```

I valori delle statistiche campionarie che cadono nella **zona di rifiuto** non sono impossibili se H_0 è vera, ma la loro probabilità è così bassa ($\leq \alpha$) che si accetta il rischio di rifiutare H_0.

Table 4.3: Decisioni corrette ed errori nel test di ipotesi

		Ipotesi	
		H_0 vera	H_0 falsa
Decisione	Non si rifiuta H_0	Corretta $(1-\alpha)$	Errore di II tipo (β)
	Si rifiuta H_0	Errore di I tipo (α)	Corretta $(1-\beta)$

4.6.3 Errori di I e II tipo

Non è mai possibile sapere con certezza se H_0 sia vera: l'unica cosa che si può fare è **minimizzare** la probabilità di prendere una decisione sbagliata.

La probabilità di non rifiutare H_0 quando è vera è $1-\alpha$ (l'area della regione di non rifiuto). Facendo un ragionamento analogo su H_1 e definendo β la probabilità di non rifiutare H_0 quando è falsa, si ottiene $1-\beta$: la probabilità di rifiutare H_0 quando è falsa, detta **potenza** del test (Tabella 4.3).

Quello che si controlla è α, la probabilità di commettere un errore di I tipo. Quello che viene ignorato è β, la probabilità di commettere un errore di II tipo.

Relazione tra α e β. La Figura 4.4 e la Table 4.4 mostrano un esempio con $\mu_0 = 0$ e $\mu_1 = 3$ e test unilaterale destro: la curva bianca è la distribuzione sotto H_0, quella colorata la distribuzione sotto H_1. Se α diminuisce, β aumenta e la potenza $1-\beta$ diminuisce.

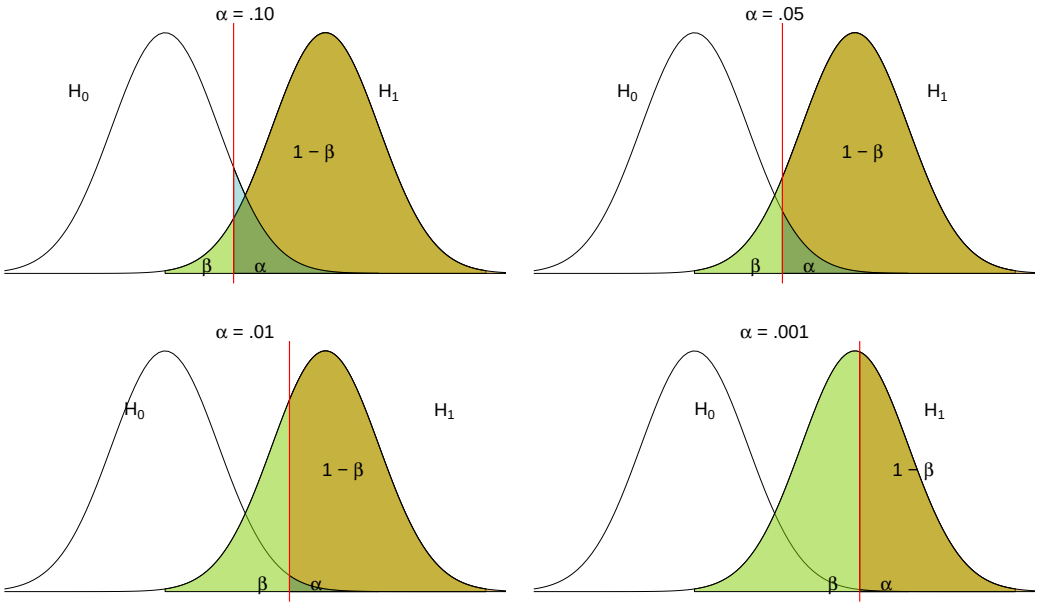


Figure 4.4: Relazione tra α, β e potenza del test

Table 4.4: Valori di β e potenza al variare di α ($\mu_0 = 0$, $\mu_1 = 3$, test unilaterale destro)

α	β	$1 - \beta$
.10	.04	.96
.05	.09	.91
.01	.25	.75
.001	.54	.46

4.6.4 Regola decisionale

Valore critico e p-value

In generale, se indichiamo con ψ_c e ψ_o rispettivamente il **valore critico** e il **valore osservato** di una statistica ψ, le due regole seguenti sono equivalenti.

Regola basata sul p-value:

$$p\text{-value} < \alpha \Rightarrow H_1 \qquad p\text{-value} \geq \alpha \Rightarrow \neg H_1$$

Regola basata sul valore critico:

Bidirezionale: $|\psi_o| > |\psi_c| \Rightarrow H_1$ Destra: $\psi_o > \psi_c \Rightarrow H_1$ Sinistra: $\psi_o < \psi_c \Rightarrow H_1$

Significatività statistica

Statisticamente significativo (si rifiuta H_0): ψ_o cade nella regione di rifiuto definita da ψ_c, cioè p-value $< \alpha$.
Statisticamente non significativo (non si rifiuta H_0): ψ_o cade nella regione di non rifiuto, cioè p-value $\geq \alpha$.

4.7 Cos'è il p-value?

Il *p-value* indica la probabilità di osservare un valore uguale o più estremo rispetto a quello osservato, **posto che sia vera** H_0:

- unilaterale destro: $\Pr[T \geq T_0 \mid H_0]$;
- unilaterale sinistro: $\Pr[T \leq T_0 \mid H_0]$;
- bidirezionale: $\Pr[|T| \geq |T_0| \mid H_0]$.

Un esempio

Test bidirezionale, $T_0 = 2.70$, p-value $= .0073$ ($p < .01$).
Se H_0 fosse vera e si replicasse l'esperimento moltissime volte, quante volte si otterrebbe un valore della statistica uguale o più estremo di 2.70?
$\Pr[|T| \geq 2.70 \mid H_0] = .0073$: se fosse vera H_0, il risultato osservato sarebbe estremamente poco probabile, e si osserverebbe meno dell'1% delle volte.

Alcuni dettagli importanti sul p-value:

- Il p-value è la probabilità di ottenere un valore uguale o più estremo rispetto a T_0 *se* H_0 *fosse vera*. **Non** è la probabilità che H_0 sia vera, e non può quindi essere usato come indicatore della verità o falsità di H_0.
- Il p-value è sensibile all'ampiezza campionaria: se H_0 è falsa, all'aumentare dell'ampiezza campionaria il p-value tende a diminuire e aumenta la probabilità di rifiutare H_0 (anche differenze molto piccole diventano significative con campioni grandi). Se H_0 è vera, aumentare n non rende il p-value più piccolo.
- Il p-value permette solo di prendere una decisione qualitativa nei termini di "non rifiuto H_0" o "rifiuto H_0": **non è una misura dell'evidenza statistica**.

4.7.1 Calcolo del p-value

Il p-value è l'area oltre la statistica osservata, nella direzione indicata da H_1 (Figura 4.5). Ad esempio, con $z_{oss} = 2.1$:

- bidirezionale: $p = 2 \cdot \Pr[Z \geq |z_{oss}|]$;
- sinistra: $p = \Pr[Z \leq z_{oss}]$;
- destra: $p = \Pr[Z \geq z_{oss}]$.

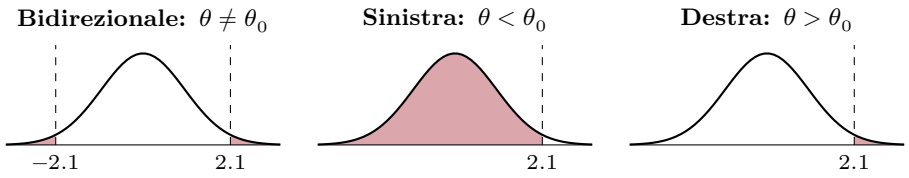


Figure 4.5: Il p-value (area in rosso) per $z_{oss} = 2.1$ al variare della direzione di H_1

```
2 * (1 - pnorm(2.1)) # bidirezionale
```

```
[1] 0.03572884
```

```
pnorm(2.1)           # sinistra
```

```
[1] 0.9821356
```

```r
1 - pnorm(2.1)        # destra
```

```
[1] 0.01786442
```

Stesso z_{oss}, tre p-value diversi: conta la direzione di H_1.

`pnorm(q)` restituisce $\Pr[Z \leq q]$, cioè l'area a sinistra di q sotto la densità, che corrisponde all'altezza della cumulata in q (Figura 4.6). La funzione `qnorm()` è l'inversa di `pnorm()` e fa il percorso al contrario, da probabilità a quantile.

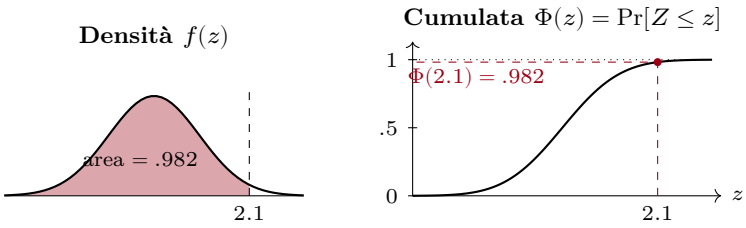


Figure 4.6: Area sotto la densità e valore della cumulata per $z = 2.1$

Da quantile a probabilità:

```r
pnorm(2.1)                    # coda sinistra
```

```
[1] 0.9821356
```

```r
1 - pnorm(2.1)                # coda destra
```

```
[1] 0.01786442
```

```r
pnorm(2.1, lower.tail = FALSE)    # coda destra, equivalente
```

```
[1] 0.01786442
```

Da probabilità a quantile:

```r
qnorm(.982)
```

```
[1] 2.096927
```

```r
qnorm(.95)
```

```
[1] 1.644854
```

5 Test statistici

5.1 Il workflow dell'inferenza

La Figura 5.1 riassume il percorso visto finora: dalla popolazione si estrae un campione, sul campione si calcola una statistica e la conoscenza della sua distribuzione campionaria permette di fare inferenza sul parametro, con una stima puntuale, una stima intervallare o una verifica d'ipotesi.

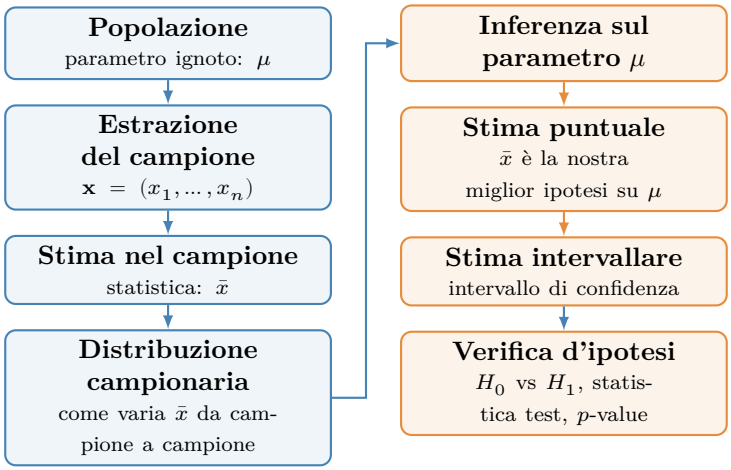


Figure 5.1: Il workflow dell'inferenza

La scelta del test dipende innanzitutto dal tipo di variabile misurata (Figura 5.2). Questo modulo riguarda le variabili quantitative e, di conseguenza, i test sulle medie.

5.2 Test su indici di tendenza centrale

5.2.1 Un campione

Si dispone di **un solo campione** di n unità statistiche, con media $\bar{x}$ (Figura 5.3).

La domanda del test

Il campione può provenire da una popolazione in cui $X \sim \mathcal{N}(\mu_0, \sigma^2)$? Se $\bar{x}$ è *troppo lontana* da μ_0, rifiutiamo H_0.

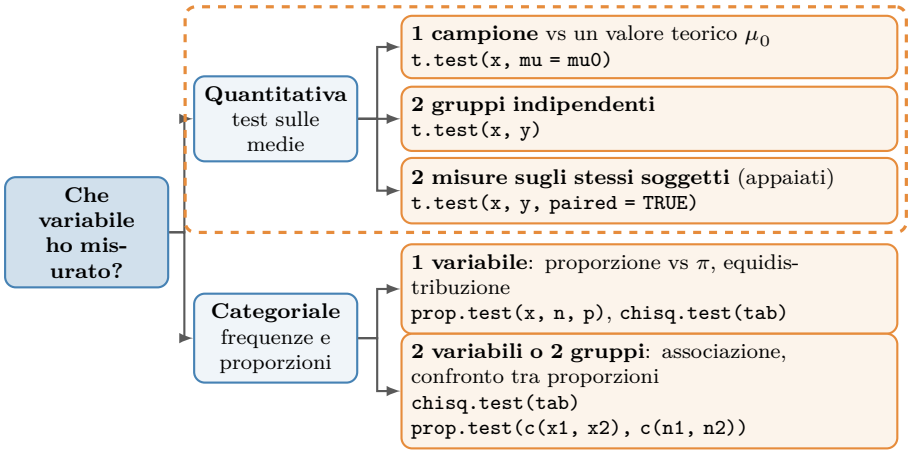


Figure 5.2: Come scegliere il test statistico. Il riquadro tratteggiato indica la parte trattata in questo modulo

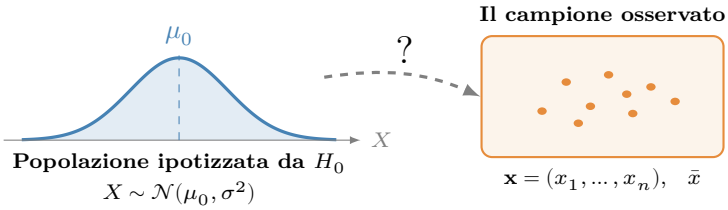


Figure 5.3: Test su un campione

5.2.1.1 Se conoscessimo σ: il test z

Se la deviazione standard della popolazione σ fosse **nota**, la distribuzione campionaria avrebbe

$$\mu_{\bar{x}} = \mu, \qquad \sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

e la statistica test sarebbe

$$z = \frac{\bar{x} - \mu_0}{\sigma_{\bar{x}}} \sim \mathcal{N}(0, 1)$$

I valori del test si confrontano con i quantili della normale standard (ad esempio, ± 1.96 per $\alpha = .05$ e H_1 a due code).

> Il problema
>
> σ è un **parametro della popolazione**: non si conosce quasi mai.

5.2.1.2 σ non nota: il test t

Non conoscendo σ della popolazione, $\sigma_{\bar{x}}$ viene stimato a partire dalla *deviazione standard campionaria*:

$$\sigma \text{ noto: } \sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} \qquad \sigma \text{ non noto: } \sigma_{\bar{x}} = \frac{\text{sd}(x)}{\sqrt{n}}$$

La statistica test mantiene la stessa forma:

$$\text{Statistica test} = \frac{\bar{x} - \mu_0}{\sigma_{\bar{x}}}$$

ma, sotto H_0, segue una distribuzione t di Student con $n-1$ gradi di libertà. La distribuzione t di Student ha **code più pesanti** della normale, e quanto più pesanti dipende dai gradi di libertà. Al crescere di n la t_{n-1} si avvicina alla $\mathcal{N}(0,1)$ (Figure 5.4): con campioni grandi test t e test z danno risultati praticamente uguali.

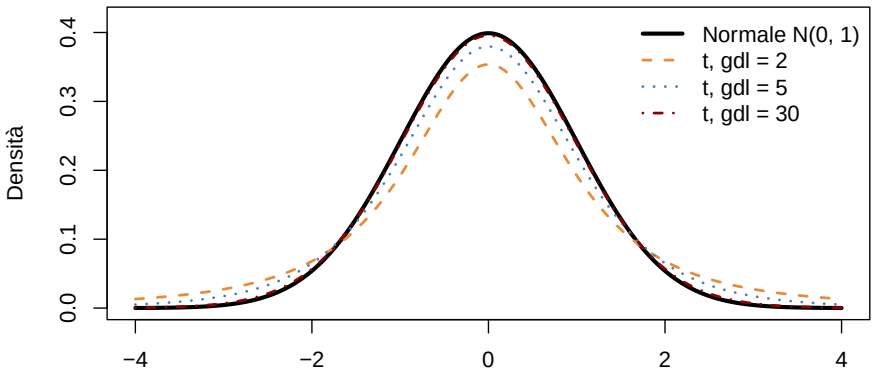


Figure 5.4: Distribuzione normale standard e distribuzioni t di Student con diversi gradi di libertà

In `R` base esiste `t.test()`, ma **non** esiste una funzione per il test z: il caso in cui σ è nota non capita quasi mai con dati reali e, quando n è grande, `t.test()` dà comunque risultati praticamente identici al test z. Se σ fosse davvero nota, il test z si calcolerebbe a mano in due righe, dove `mu0` è il parametro della popolazione definito in H_0:

```
z = (mean(x) - mu0) / (sigma / sqrt(length(x)))
2 * (1 - pnorm(abs(z)))  # p-value a due code
```

Il test t a un campione

Permette di valutare se la media μ della popolazione di un dato campione X sia significativamente differente (rispettivamente maggiore o minore) rispetto a una specifica soglia teorica μ_0.

Sia $\mathbf{x} = (x_1, x_2, \dots, x_n)$ un campione empirico di n osservazioni quantitative indipendenti tali che $x_i \sim \mathcal{N}(\mu, \sigma^2)$, dove μ e σ^2 sono parametri ignoti della popolazione di $\mathbf{x}$, e sia $\mu_0 \in \mathbb{R}$ il parametro della popolazione sotto H_0. La statistica test è

$$t = \frac{\bar{x} - \mu_0}{\sigma_{\bar{x}}}, \qquad \sigma_{\bar{x}} = \frac{\text{sd}(x)}{\sqrt{n}}$$

dove $\bar{x}$, la media campionaria di $\mathbf{x}$, è lo **stimatore** di μ, e $\text{sd}(x)$ è la deviazione standard campionaria di $\mathbf{x}$. Le ipotesi possono essere:

- test a due code (*two-sided*): $H_0 : \mu = \mu_0$, $H_1 : \mu \neq \mu_0$;
- test a una coda destra (*one-sided right*): $H_0 : \mu = \mu_0$, $H_1 : \mu > \mu_0$;
- test a una coda sinistra (*one-sided left*): $H_0 : \mu = \mu_0$, $H_1 : \mu < \mu_0$.

5.2.2 In R

La funzione `t.test(x, mu = 0, alternative = "two.sided")` svolge il test su un campione di osservazioni x, considerando di default $\mu_0 = 0$ (`mu = 0`) e un'ipotesi alternativa bidirezionale (`alternative = "two.sided"`). L'argomento `alternative` definisce H_1 (Table 5.1).

Table 5.1: Argomento `alternative` nel test t a un campione

Definizione dell'ipotesi in R	Significato
`alternative = "two.sided"`	H_1: $\mu \neq \mu_0$
`alternative = "greater"`	H_1: $\mu > \mu_0$
`alternative = "less"`	H_1: $\mu < \mu_0$

5.2.3 Esempi

Generiamo un campione di 11 osservazioni e verifichiamo se la media della popolazione sia diversa da $\mu_0 = 10$:

```
set.seed(999)
x = rnorm(11, mean = 12, sd = 7.5)
mu0 = 10
t.test(x, mu = mu0, alternative = "two.sided")
```

```
    One Sample t-test

data:  x
t = -0.72806, df = 10, p-value = 0.4833
```

```
alternative hypothesis: true mean is not equal to 10
95 percent confidence interval:
  3.50030 13.29817
sample estimates:
mean of x
 8.399236
```

Gli elementi dell'output sono:

```
> t.test(x, mu = mu0)
One Sample t-test

data:  x
t = -0.72806, df = 10, p-value = 0.4833
alternative hypothesis: true mean is not equal to 10
95 percent confidence interval:
 3.50030 13.29817
sample estimates:
mean of x
 8.399236
```

1. Tipo di test
2. Statistica test t_0
3. Gradi di libertà: $df = n - 1$
4. p-value
5. Ipotesi alternativa H_1: bidirezionale
6. Intervallo di confidenza al 95% per μ
7. Stimatore di μ: media campionaria $\bar{x}$

Nel test a due code il p-value è l'area sotto la distribuzione t nelle due code oltre $|t_0|$ (Figure 5.5):

$$
\begin{aligned}
p\text{-value} &= \int_{-\infty}^{-|t_0|} f_T(t \mid \theta)\, dt + \int_{|t_0|}^{\infty} f_T(t \mid \theta)\, dt \\
&= 2 \int_{|t_0|}^{\infty} f_T(t \mid \theta)\, dt
\end{aligned}
$$

dove t_0 è la statistica test osservata (qui -0.7281) e $f_T(t \mid \theta)$ è la distribuzione t di Student con parametro θ, ovvero i gradi di libertà.

```r
# calcolo del p-value
2 * (1 - pt(abs(-0.72806), 10))
```

```
[1] 0.4832762
```

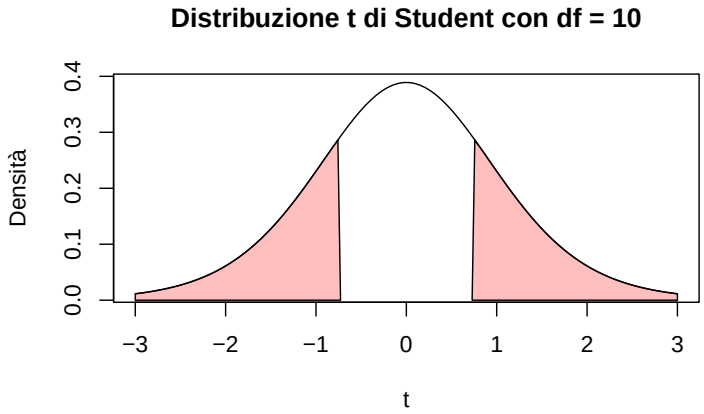


Figure 5.5: p-value del test a due code

Con un'ipotesi alternativa destra cambia il calcolo del p-value, non la statistica test:

```
> t.test(x, mu = mu0, alternative = "greater")
One Sample t-test

data:  x
t = -0.72806, df = 10, p-value = 0.7584
alternative hypothesis: true mean is greater than 10
95 percent confidence interval:
 4.414237      Inf
sample estimates:
mean of x
 8.399236
```

1. H_1: $\mu > \mu_0$
2. t_0 e gradi di libertà: **identici** al test a due code
3. $p = \Pr[T \geq t_0]$, area a destra di t_0: qui $t_0 < 0$ va nella direzione **opposta** a H_1, quindi p è grande
4. IC **unidirezionale**: solo il limite inferiore, l'altro estremo è `Inf`

$$p\text{-value} = \int_{t_0}^{\infty} f_T(t \mid \theta)\, dt$$

```r
# calcolo del p-value
1 - pt(-0.72806, 10)
```

```
[1] 0.7583619
```

Con un'ipotesi alternativa sinistra:

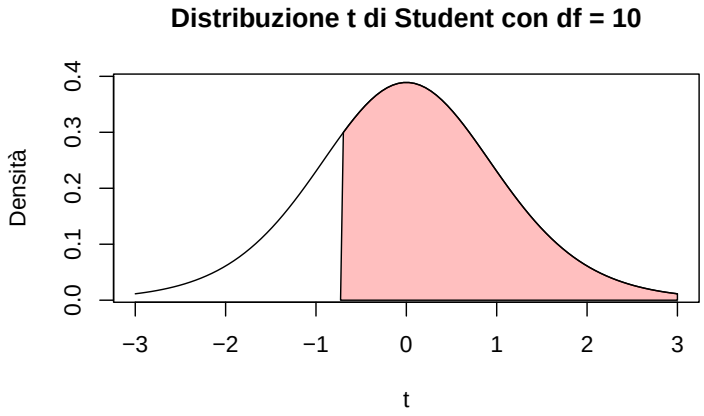


Figure 5.6: p-value del test a una coda destra

```
> t.test(x, mu = mu0, alternative = "less")
One Sample t-test

data:  x
t = -0.72806, df = 10, p-value = 0.2416
alternative hypothesis: true mean is less than 10
95 percent confidence interval:
 -Inf 12.38424
sample estimates:
mean of x
 8.399236
```

1. H_1: $\mu < \mu_0$
2. t_0 e gradi di libertà: **identici** al test a due code
3. $p = \Pr[T \leq t_0]$, area a sinistra di t_0: qui $t_0 < 0$ va nella **stessa** direzione di H_1, quindi p è dimezzato rispetto al test a due code
4. IC **unidirezionale**: solo il limite superiore, l'altro estremo è `-Inf`

$$p\text{-value} = \int_{-\infty}^{t_0} f_T(t \mid \theta)\, dt$$

```
# calcolo del p-value
pt(-0.72806, 10)
```

```
[1] 0.2416381
```

`t.test()` riporta sempre l'intervallo **coerente con** H_1: rifiutiamo H_0 ($\alpha = .05$) se e solo se μ_0 cade **fuori** dall'intervallo (Figura 5.8).

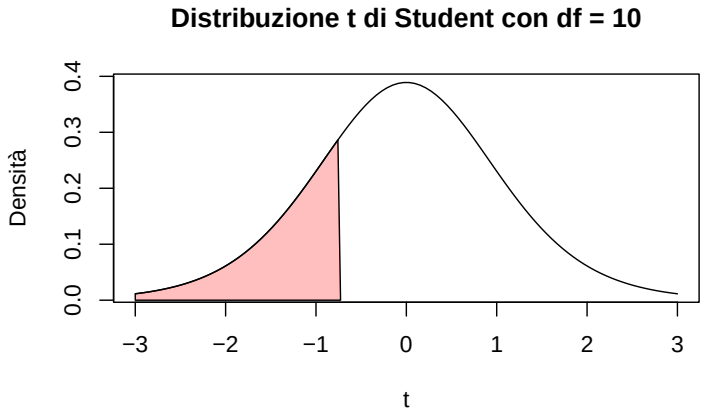


Figure 5.7: p-value del test a una coda sinistra

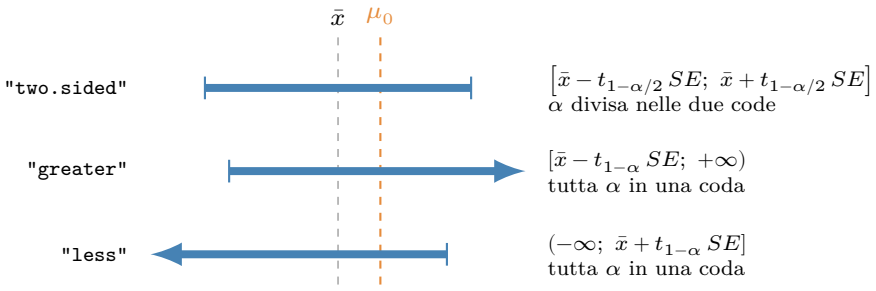


Figure 5.8: Intervallo di confidenza al variare della direzione di H_1

5.2.4 Due campioni indipendenti

Si dispone di **due campioni indipendenti** di n e m unità statistiche, con medie $\bar{x}$ e $\bar{y}$ (Figura 5.9).

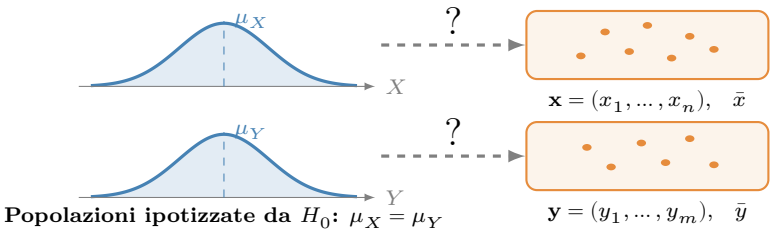


Figure 5.9: Test su due campioni indipendenti

La domanda del test

I due campioni possono provenire da popolazioni con la stessa media ($\mu_X = \mu_Y$)? Se $\bar{x} - \bar{y}$ è *troppo lontana* da 0, rifiutiamo H_0.

Scopo

Permette di valutare se la media μ_X della popolazione di un campione di dati x sia significativamente differente (rispettivamente maggiore o minore) rispetto alla media μ_Y della popolazione di un campione di dati y.

Sia $\mathbf{x} = (x_1, x_2, \dots, x_n)$ un campione empirico di n osservazioni quantitative indipendenti tali che $x_i \sim \mathcal{N}(\mu_X, \sigma^2)$ e sia $\mathbf{y} = (y_1, y_2, \dots, y_m)$ un campione empirico di m osservazioni quantitative indipendenti tali che $y_j \sim \mathcal{N}(\mu_Y, \sigma^2)$, dove σ^2 è la varianza comune a entrambe le popolazioni. La statistica test è

$$t = \frac{(\overline{x} - \overline{y}) - (\mu_X - \mu_Y)}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}}, \qquad s_p = \sqrt{\frac{(n-1)\text{var}(\mathbf{x}) + (m-1)\text{var}(\mathbf{y})}{n + m - 2}}$$

Lo **stimatore** di $\mu_X - \mu_Y$ è $\bar{x} - \bar{y}$, la differenza tra le medie campionarie. Le ipotesi possono essere:

- test a due code (*two-sided*): $H_0 : \mu_X = \mu_Y$, $H_1 : \mu_X \neq \mu_Y$, ovvero $H_0 : \mu_X - \mu_Y = 0$, $H_1 : \mu_X - \mu_Y \neq 0$;
- test a una coda destra (*one-sided right*): $H_0 : \mu_X = \mu_Y$, $H_1 : \mu_X > \mu_Y$, ovvero $H_0 : \mu_X - \mu_Y = 0$, $H_1 : \mu_X - \mu_Y > 0$;
- test a una coda sinistra (*one-sided left*): $H_0 : \mu_X = \mu_Y$, $H_1 : \mu_X < \mu_Y$, ovvero $H_0 : \mu_X - \mu_Y = 0$, $H_1 : \mu_X - \mu_Y < 0$.

5.2.4.1 In R

La funzione `t.test(x, y, var.equal = TRUE, alternative = "two.sided")` svolge il test su due campioni indipendenti di osservazioni x e y, assumendo che le varianze delle due popolazioni siano uguali (`var.equal = TRUE`), con ipotesi alternativa bidirezionale come default (Table 5.2).

Table 5.2: Argomento `alternative` nel test t a due campioni indipendenti

Definizione dell'ipotesi in R	Significato
`alternative = "two.sided"`	H_1: $\mu_X \neq \mu_Y$
`alternative = "greater"`	H_1: $\mu_X > \mu_Y$
`alternative = "less"`	H_1: $\mu_X < \mu_Y$

Il default di R è `var.equal = FALSE`: senza specificare `var.equal = TRUE`, R svolge il test di Welch, che non assume varianze uguali.

5.2.4.2 Gradi di libertà e `var.equal`

Con `var.equal = TRUE` si assume una varianza comune alle due popolazioni:

$$df = n + m - 2, \qquad SE = s_p\sqrt{\frac{1}{n} + \frac{1}{m}}, \qquad s_p = \sqrt{\frac{(n-1)\text{var}(\mathbf{x}) + (m-1)\text{var}(\mathbf{y})}{n+m-2}}$$

Con `var.equal = FALSE` (test di Welch) le varianze non sono assunte uguali:

$$df = \frac{\left(\frac{\text{var}(\mathbf{x})}{n} + \frac{\text{var}(\mathbf{y})}{m}\right)^2}{\frac{(\text{var}(\mathbf{x})/n)^2}{n-1} + \frac{(\text{var}(\mathbf{y})/m)^2}{m-1}}, \qquad SE = \sqrt{\frac{\text{var}(\mathbf{x})}{n} + \frac{\text{var}(\mathbf{y})}{m}}$$

Nell'esempio che segue ($n = 11$, $m = 8$): $df = 17$ con `var.equal = TRUE`, $df = 14.14$ con Welch.

5.2.5 Esempi

```r
x = c(12.2, 23.2, 14, 20.3, 9.2, 3.7, 8, 16.8, 3.7, 1.9, 20.5)
y = c(8.5, 3.2, 4, 10.5, 7.7, 3.1, 2, 3.9)
t.test(x, y, var.equal = TRUE, alternative = "two.sided")
```

```
    Two Sample t-test

data:  x and y
t = 2.4064, df = 17, p-value = 0.02776
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
  0.8349434 12.7127839
sample estimates:
mean of x mean of y
 12.13636   5.36250
```

```
> t.test(x, y, var.equal = TRUE)
Two Sample t-test

data:  x and y
t = 2.4064, df = 17, p-value = 0.02776
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 0.8349434 12.7127839
sample estimates:
mean of x mean of y
 12.13636   5.36250
```

1. Tipo di test
2. Statistica test t_0
3. Gradi di libertà: $df = n + m - 2$
4. p-value
5. Ipotesi alternativa H_1: bidirezionale ($\mu_X - \mu_Y \neq 0$)
6. Intervallo di confidenza al 95% per $\mu_X - \mu_Y$
7. Medie campionarie: stimatore $= \bar{x} - \bar{y}$

Con un'ipotesi alternativa destra:

```
> t.test(x, y, var.equal = TRUE, alternative = "greater")
Two Sample t-test

data:  x and y
t = 2.4064, df = 17, p-value = 0.01388
alternative hypothesis: true difference in means is greater than 0
95 percent confidence interval:
 1.877044      Inf
sample estimates:
mean of x mean of y
 12.13636   5.36250
```

1. H_1: $\mu_X > \mu_Y$ ($\mu_X - \mu_Y > 0$)
2. t_0 e gradi di libertà: **identici** al test a due code
3. $p = \Pr[T \geq t_0]$, area a destra di t_0: qui $\bar{x} > \bar{y}$ va nella **stessa** direzione di H_1, quindi p è dimezzato rispetto al test a due code
4. IC **unidirezionale**: solo il limite inferiore, l'altro estremo è `Inf`

Con `var.equal = FALSE` (test di Welch, il default di `R`):

```
> t.test(x, y)
Welch Two Sample t-test

data:  x and y
t = 2.708, df = 14.144, p-value = 0.01687
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 1.413924 12.133803
sample estimates:
mean of x mean of y
 12.13636   5.36250
```

1. Test di Welch: le varianze delle due popolazioni **non** sono assunte uguali (default di `R`)
2. t_0 e gradi di libertà **diversi** dal test con `var.equal = TRUE`: i df sono corretti e non sono interi
3. p-value
4. Intervallo di confidenza al 95% per $\mu_X - \mu_Y$

5.2.6 Due campioni appaiati

Si dispone di **un solo campione** di n coppie di osservazioni: ogni coppia produce una differenza d_i (Figura 5.10).

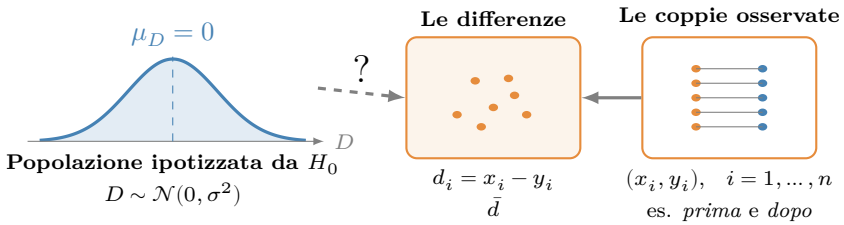


Figure 5.10: Test su due campioni appaiati

La domanda del test

Le differenze possono provenire da una popolazione in cui $D \sim \mathcal{N}(0, \sigma^2)$? Se $\bar{d}$ è *troppo lontana* da 0, rifiutiamo H_0.

Scopo

Permette di valutare se le medie μ_X e μ_Y delle popolazioni di due campioni di dati appaiati (x, y) siano significativamente differenti (rispettivamente maggiore o minore).

Sia $(\mathbf{x}, \mathbf{y}) = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$ un campione bivariato di n osservazioni (x_i, y_i) indipendenti. Inoltre sia $d_i \sim \mathcal{N}(\mu_D, \sigma^2)$ l'osservazione differenziale $d_i = x_i - y_i$ derivata da $(\mathbf{x}, \mathbf{y})$. I parametri μ_D e σ^2 sono i termini ignoti della variabile differenziale D. Lo **stimatore** di μ_D è $\bar{d}$, la media delle differenze (*prima* − *dopo*), e la statistica test è

$$t = \frac{\overline{d}}{\sqrt{\text{var}(\mathbf{d})/n}}$$

Le ipotesi possono essere:

- test a due code (*two-sided*): $H_0 : \mu_D = 0$, $H_1 : \mu_D \neq 0$;
- test a una coda destra (*one-sided right*): $H_0 : \mu_D = 0$, $H_1 : \mu_D > 0$;
- test a una coda sinistra (*one-sided left*): $H_0 : \mu_D = 0$, $H_1 : \mu_D < 0$.

Il test lavora su una sola variabile, le differenze $d_i = x_i - y_i$, quindi è un test t a un campione su $\mathbf{d}$:

$$df = n - 1, \qquad n = \text{numero di coppie}$$

Abbiamo infatti n differenze, non $2n$ osservazioni indipendenti, e si stima un solo parametro, μ_D, per cui si perde un solo grado di libertà. Nell'esempio che segue ci sono 8 coppie, quindi $df = 8 - 1 = 7$.

5.2.6.1 In R

La funzione `t.test(x, y, paired = TRUE, alternative = "two.sided")` svolge il test su due campioni appaiati di osservazioni x e y (`paired = TRUE`), cioè un test t a un campione sulle differenze $d_i = x_i - y_i$ con $\mu_0 = 0$, con ipotesi alternativa bidirezionale come default (Table 5.3).

Table 5.3: Argomento `alternative` nel test t a due campioni appaiati

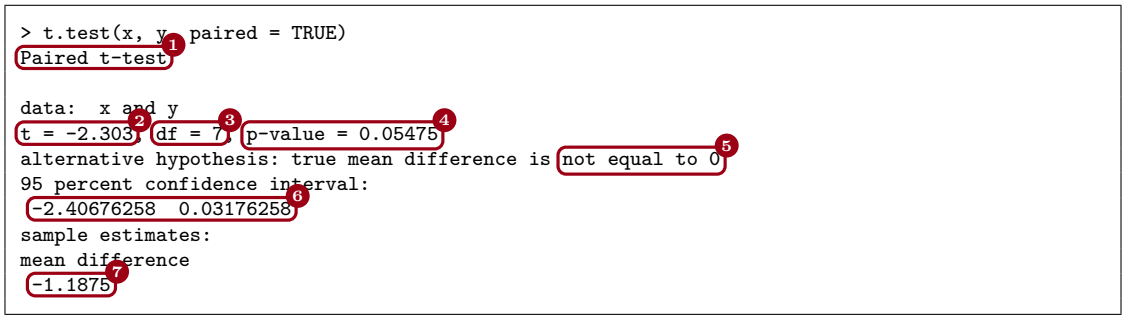
Definizione dell'ipotesi in R	Significato
`alternative = "two.sided"`	H_1: $\mu_D \neq 0$
`alternative = "greater"`	H_1: $\mu_D > 0$
`alternative = "less"`	H_1: $\mu_D < 0$

5.2.6.2 Esempi

```r
x = c(5.2, 3.5, 3.4, 7.1, 6.2, 3.0, 1, 4)
y = c(8.5, 3.2, 4, 10.5, 7.7, 3.1, 2, 3.9)
t.test(x, y, paired = TRUE, alternative = "two.sided")
```

```
    Paired t-test

data:  x and y
t = -2.303, df = 7, p-value = 0.05475
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 -2.40676258  0.03176258
sample estimates:
mean difference
        -1.1875
```



1. Tipo di test
2. Statistica test t_0
3. Gradi di libertà: $df = n - 1$ (n = numero di coppie)
4. p-value
5. Ipotesi alternativa H_1: bidirezionale ($\mu_D \neq 0$)
6. Intervallo di confidenza al 95% per μ_D
7. Stimatore di μ_D: media delle differenze $\bar{d}$

Con un'ipotesi alternativa sinistra:

```
> t.test(x, y, paired = TRUE, alternative = "less")
Paired t-test

data:  x and y
t = -2.303, df = 7, p-value = 0.02737
alternative hypothesis: true mean difference is less than 0
95 percent confidence interval:
 -Inf -0.2106053
sample estimates:
mean difference
 -1.1875
```

1. H_1: $\mu_D < 0$
2. t_0 e gradi di libertà: **identici** al test a due code
3. $p = \Pr[T \leq t_0]$, area a sinistra di t_0: qui $\bar{d} < 0$ va nella **stessa** direzione di H_1, quindi p è dimezzato rispetto al test a due code
4. IC **unidirezionale**: solo il limite superiore, l'altro estremo è `-Inf`

5.2.7 Intervalli di confidenza

Su infinite ripetizioni dell'esperimento, il 95% degli intervalli di confidenza al 95% contiene θ. Il singolo intervallo lo contiene oppure no (Figura 5.11). L'intervallo si può usare anche per decidere ($\alpha = .05$): se θ_0 cade **dentro** l'intervallo non si rifiuta H_0, se cade **fuori** si rifiuta H_0.



Figure 5.11: A sinistra, un intervallo per ogni campione: 19 contengono θ, 1 no. A destra, l'uso dell'intervallo per decidere su H_0

L'intervallo di confidenza viene calcolato come:

$$IC_{1-\alpha} = \hat{\theta} \pm c_{1-\alpha/2} \cdot SE(\hat{\theta})$$

dove:

- $\hat{\theta}$ è lo stimatore generico del parametro θ, ad esempio $\bar{x}$ per μ;
- $c_{1-\alpha/2}$ è il valore critico della distribuzione di riferimento, ad esempio z o t;

- $SE(\hat{\theta})$ è l'errore standard dello stimatore.

> Significato
>
> Un IC al x% è costruito con un metodo che, su infinite ripetizioni dell'esperimento, produce intervalli che contengono il vero valore di θ nel x% dei casi.
> θ è fisso, mentre i limiti dell'intervallo variano da campione a campione: il singolo intervallo calcolato contiene θ oppure no.

5.2.8 L'oggetto di `t.test()`

L'oggetto restituito da `t.test()` contiene tutti gli elementi necessari per calcolare l'intervallo. In particolare:

- `parameter`: i gradi di libertà, per ricavare il valore critico $c_{1-\alpha/2}$;
- `estimate`: lo stimatore $\hat{\theta}$, il valore attorno a cui si vuole costruire l'intervallo. Con due campioni indipendenti contiene $\bar{x}$ e $\bar{y}$, e $\hat{\theta} = \bar{x} - \bar{y}$;
- `stderr`: l'errore standard dello stimatore $SE(\hat{\theta})$.

```r
set.seed(999)
x = rnorm(11, mean = 12, sd = 7.5)
res = t.test(x, mu = 10)
str(res, give.attr = FALSE)
```

```
List of 10
 $ statistic  : Named num -0.728
 $ parameter  : Named num 10
 $ p.value    : num 0.483
 $ conf.int   : num [1:2] 3.5 13.3
 $ estimate   : Named num 8.4
 $ null.value : Named num 10
 $ stderr     : num 2.2
 $ alternative: chr "two.sided"
 $ method     : chr "One Sample t-test"
 $ data.name  : chr "x"
```

5.2.9 Costruzione dell'intervallo

Applicando la formula:

```r
alpha = .05 # cambiando il valore di alpha cambia l'ampiezza dell'intervallo
valoriCritici = c(qt(alpha/2, df = res$parameter),    # valore negativo
                  qt(1-alpha/2, df = res$parameter)) # valore positivo
valoriCritici
```

```
[1] -2.228139  2.228139
```

```
res$estimate + res$stderr * valoriCritici
```

```
[1]  3.50030 13.29817
```

```
res$conf.int # confronto con i valori calcolati da R
```

```
[1]  3.50030 13.29817
attr(,"conf.level")
[1] 0.95
```

Un campione.

```
set.seed(999)
x = rnorm(11, mean = 12, sd = 7.5)
mu0 = 10
res1campione = t.test(x, mu = mu0, alternative = "two.sided")
# calcolo valori critici per intervallo 95%
(t_c = c(qt(c(.025, .975),
            df = res1campione$parameter)))
```

```
[1] -2.228139  2.228139
```

```
res1campione$estimate + res1campione$stderr * t_c
```

```
[1]  3.50030 13.29817
```

Due campioni indipendenti.

```
set.seed(999)
x = rnorm(11, mean = 12, sd = 7.5)
y = rnorm(15, mean = 8, sd = 2.5)
res2campioni = t.test(x, y)
hat = res2campioni$estimate[1] - res2campioni$estimate[2]
(t_c = c(qt(c(.025, .975),
            df = res2campioni$parameter)))
```

```
[1] -2.188171  2.188171
```

```
hat + res2campioni$stderr * t_c
```

```
[1] -4.377724  5.608877
```

```
res2campioni$conf.int # confronto
```

```
[1] -4.377724  5.608877
attr(,"conf.level")
[1] 0.95
```

Due campioni dipendenti.

```
set.seed(999)
x = rnorm(11, mean = 12, sd = 7.5)
y = rnorm(11, mean = 8, sd = 2.5)
res2dipendenti = t.test(x, y, paired = TRUE)
(t_c = c(qt(c(.025, .975),
            df = res2dipendenti$parameter)))
```

```
[1] -2.228139  2.228139
```

```
res2dipendenti$estimate + res2dipendenti$stderr * t_c
```

```
[1] -4.289977  5.429044
```

```
res2dipendenti$conf.int # confronto
```

```
[1] -4.289977  5.429044
attr(,"conf.level")
[1] 0.95
```

6 Funzioni riassuntive dei moduli

6.1 Calcolo combinatorio

Funzione	Descrizione
`factorial(n)`	Fattoriale $n!$
`choose(n, x)`	Coefficiente binomiale $\binom{n}{x}$

6.2 Distribuzioni di probabilità

Prefisso	Restituisce	Esempio
`d*`	Massa (discrete) o densità (continue)	`dbinom(3, 10, .25)`
`p*`	Probabilità cumulata $\Pr[X \leq q]$ (`lower.tail = FALSE` per $\Pr[X > q]$)	`pnorm(1.85)`
`q*`	Quantile associato a una probabilità cumulata	`qnorm(.275)`
`r*`	Campione casuale di `n` osservazioni	`rnorm(100, 0, 1)`

Distribuzione	Nome in `R`	Parametri
Binomiale	`binom`	`size` (n), `prob` (π)
Normale	`norm`	`mean` (μ), `sd` (σ)
t di Student	`t`	`df`
χ^2	`chisq`	`df`
Esponenziale	`exp`	`rate`
Uniforme	`unif`	`min`, `max`
Gamma	`gamma`	`shape`, `scale`

6.3 Test sulle medie

Funzione	Descrizione
`t.test(x, mu = mu0)`	Test t a un campione
`t.test(x, y, var.equal = TRUE)`	Test t a due campioni indipendenti, varianze assunte uguali
`t.test(x, y)`	Test di Welch a due campioni indipendenti (default di `R`)
`t.test(x, y, paired = TRUE)`	Test t a due campioni appaiati

L'argomento `alternative` (`"two.sided"`, `"greater"`, `"less"`) definisce H_1. Se `res` è l'oggetto restituito da `t.test()`, `res$statistic`, `res$parameter`, `res$p.value`, `res$conf.int`, `res$estimate` e `res$stderr` contengono rispettivamente statistica test, gradi di libertà, p-value, intervallo di confidenza, stima ed errore standard.