

```
[1] 0
> mean(z)
[1] 1.8
```

Come curiosità possiamo segnalare che le tre medie in questione rispettano sempre la disuguaglianza

$$x_a \leq x_g \leq \bar{x}$$

come anche nel nostro esempio.

```
# media armonica
mean.a <- function(x) {
  length(x) / sum(1/x)
}

# media geometrica
mean.g <- function(x) {
  prod(x)^(1/length(x))
}
```

Codice 2.15 Comandi per il calcolo della media armonica `mean.a` e geometrica `mean.g`.

2.6 Indici di dispersione

Si supponga di aver rilevato i seguenti dati:

```
30 40 50 60 70 80 90
```

otteniamo i seguenti valori degli indici: $Q1 = 40$, $Me = 60$, $Q3 = 80$, $\bar{x}_n = 60$, range: $90 - 30 = 60$, e $Q3 - Q1 = 80 - 40 = 40$. Ancora una volta effettuiamo spostamenti di un solo valore estremo

```
30 40 50 60 70 80 900
```

otteniamo i seguenti valori degli indici: $Q1 = 40$, $Me = 60$, $Q3 = 80$, $\bar{x}_n = 175.7$, range: $900 - 30 = 870$, e $Q3 - Q1 = 80 - 40 = 40$ e ancora

```
0 40 50 60 70 80 90
```

otteniamo i seguenti valori degli indici: $Q1 = 40$, $Me = 60$, $Q3 = 80$, $\bar{x}_n = 55.7$, range: $90 - 0 = 90$, e $Q3 - Q1 = 80 - 40 = 40$. Quello che è accaduto è che sia il range che la media hanno fortemente risentito dello spostamento di un solo dato 0, con un linguaggio più appropriato, hanno risentito della presenza di

outlier nella distribuzione, mentre lo scarto interquartile e la mediana sono rimasti invariati.

Questo vuol dire che piccole variazioni nei dati possono comportare notevoli variazioni nei valori degli indici che, abbiamo detto, sono tra i più usati in statistica. Poiché lo sperimentatore si troverà di volta in volta a trattare con dati di natura differente oppure della stessa natura ma raccolti in momenti o su popolazioni differenti, nasce l'esigenza di costruire un indicatore che valuti la variabilità all'interno dei dati. Sia il range che lo scarto interquartile sono indicatori, anche se grossolani, della variabilità dei nostri dati.

2.6.1 La varianza

Consideriamo le due distribuzioni di dati della Tabella 2.8. Calcoliamo media, moda e mediana delle due distribuzioni e tracciamone i grafici.

```
> x <- c(rep(1,5), rep(2,10), rep(3,20), rep(4,30),
+       rep(5,20), rep(6,10), rep(7,5))
> y <- c(rep(1,15), rep(2,20), rep(3,15),
+       rep(5,15), rep(6,20), rep(7,15))
> summary(x)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
    1         3         4         4         5         7
> summary(y)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
    1         2         4         4         6         7
> plot(table(x), ylab="freq", lwd=10)
> plot(table(y), ylab="freq", lwd=10)
```

Nella distribuzione a) la moda è 4, così come la media e la mediana. La distribuzione b) ha due mode in corrispondenza di 2 e 6. La media e la mediana sono uguali al caso a). Inoltre, dai grafici delle due distribuzioni è evidente che i dati in un caso si concentrano attorno al valore 4 (caso a)) nell'altro tendono invece a allontanarsi da tale valore (caso b)). Guarda caso il valore 4 è proprio la media (e la mediana) delle due distribuzioni. L'idea è quindi quella di costruire un indice che tenga conto di come i valori si distribuiscono attorno alla propria media per misurare in modo oggettivo quello che ci appare graficamente.

L'indice che presentiamo è costruito per tener conto della distanza delle x_i dalla propria media $\bar{x}_n$. Come distanza potremmo pensare di usare gli scarti dalla media cioè: $x_i - \bar{x}_n$. Proviamo quindi a definire un indice basato sugli scarti dalla media.

$$\sum_{i=1}^n (x_i - \bar{x}_n) = \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x}_n = n \cdot \bar{x}_n - n \cdot \bar{x}_n = 0$$

quindi un tale indice non funzionerebbe perché qualsiasi siano i dati la somma degli scarti dei valori x_i dalla propria media $\bar{x}_n$ è sempre nulla. Si può allora

x_i	n_i	y_i	n_i
1	5	1	15
2	10	2	15
3	20	3	15
4	30	4	15
5	20	5	15
6	10	6	15
7	5	7	15
	100		100




Tabella 2.8 Due distribuzioni di dati con la stessa media (4) e mediana (4) ma con variabilità differente.

pensare di utilizzare un indice basato sulla somma degli scarti al quadrato. Tale indice, che chiameremo **varianza**, è dato dalla formula

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2.$$

Se i dati provengono da un campione casuale⁶, si preferisce, per ragioni che saranno note in seguito, utilizzare un altro indice, per altro simile, che viene chiamato

⁶La nozione di campione casuale verrà spiegata nel seguito, per ora si può pensare ad un insieme di dati estratti da una popolazione di riferimento con un criterio di scelta casuale.

varianza campionaria

$$\hat{s}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2.$$

Si noti che l'unica differenza è il numero di termini per cui si divide la somma degli scarti al quadrato: $n-1$ anziché n . Questo è l'indice che usualmente viene calcolato dai software statistici quali R. Il comando implementato in R è `var`. Se si vuole ottenere σ^2 al posto di $\hat{s}_n^2$ si deve tener presente la relazione

$$\sigma^2 = \frac{n-1}{n} \cdot \hat{s}_n^2.$$

Nel Codice 2.16 abbiamo riportato due formule equivalenti per il calcolo della varianza. Se n è grande i due indici σ^2 e $\hat{s}_n^2$ coincidono, quindi converrà utilizzare direttamente il comando `var`. Calcoliamo ora le varianze delle due distribuzioni della Tabella 2.8:

```
> sigma2(x)
[1] 2.1
> sigma2(y)
[1] 4.6
```

e come si vede la variabilità della distribuzione b), misurata in questo modo, risulta essere doppia rispetto a quella della distribuzione a). Concludiamo che c'è meno variabilità nella distribuzione a).

```
# prima versione
sigma2 <- function(x) {
  mean((x-mean(x))^2)
}

# seconda versione
sigma2 <- function(x) {
  var(x)*(length(x)-1)/length(x)
}

# coefficiente di variazione
cv <- function(x) {
  sqrt(sigma2(x))/abs(mean(x))
}
```

Codice 2.16 Due metodi alternativi per il calcolo della varianza e un esempio di calcolo del coefficiente di variazione. I due metodi non sono ottimizzati in funzione dell'ampiezza campionaria n . Ma al crescere di n i valori σ^2 e $\hat{s}_n^2$ diventano indistinguibili e quindi converrà utilizzare la funzione `var` di R.

2.6.2 Scarto quadratico medio e coefficiente di variazione

Se torniamo all'esempio dei pesi, cioè al fenomeno W del paragrafo sulla classificazione dei fenomeni, mentre W è espresso in kg, se calcoliamo la varianza di W questa sarà espressa in kg^2 . Cosa voglia dire kg^2 è assai oscuro. Per rendere più facilmente leggibile la variabilità di un fenomeno, si ricorre allo **scarto quadratico medio** σ

$$\sigma = \sqrt{\sigma^2}$$

come si vede σ è espresso nella stessa unità di misura dei dati originali. Esiste un risultato generale della statistica che afferma che la maggior parte dei dati di una distribuzione, qualsiasi essa sia, deve trovarsi in un intervallo del tipo $[\bar{x}_n - 3 \cdot \sigma, \bar{x}_n + 3 \cdot \sigma]$. Questa è nota come regola dei 3-sigma e per maggior parte dei dati si intende l'89% dei essi. A cosa serve questa informazione? Beh, se nel nostro campione troviamo dei dati fuori da tale intervallo concludiamo di essere in presenza di dati anomali, cioè i dati esterni a tale intervallo sono presumibilmente degli **outlier**. Si provi a verificare la validità della regola dei 3-sigma per le due distribuzioni della Tabella 2.8.

L'altro problema legato all'unità di misura riguarda i confronti di variabilità tra distribuzioni di fenomeni diversi o rilevati con differenti unità di misura. Supponiamo che X sia l'altezza di un gruppo di individui misurata in *cm* ed Y l'altezza degli stessi individui misurata in metri. Se guardiamo al grafico delle distribuzioni di X ed Y esse ci appariranno del tutto simili a parte il cambiamento di scala ma, se calcoliamo le varianze otteniamo un valore misurato in termini di cm^2 (per esempio 100 cm^2) per X e di m^2 per Y (1 m^2). Anche passando agli scarti quadratici medi otteniamo $\sigma_x = 10$ e $\sigma_y = 0.1$. Quindi sembrerebbe esserci una notevole differenza tra la variabilità dello stesso fenomeno semplicemente perché considerato su scale diverse. Per ovviare a questo problema si costruisce un indice di variabilità indipendente dall'unità di misura ottenuto dividendo lo scarto quadratico medio σ per il valore assoluto della media $\bar{x}_n$, cioè

$$CV = \frac{\sigma}{|\bar{x}_n|}$$

che viene detto **coefficiente di variazione**. Se lo calcoliamo per X ed Y dell'esempio e supponendo che le medie siano rispettivamente 170 cm e 1.7 m otteniamo

$$CV_x = \frac{10 \text{ cm}}{170 \text{ cm}} = 0.0589 \quad \text{e} \quad CV_y = \frac{0.1 \text{ m}}{1.7 \text{ m}} = \frac{0.1}{1.7} = 0.0589$$

Come si vede i conti ora tornano!

In generale il coefficiente di variazione non si usa in questo modo bensì per confrontare la variabilità di fenomeni realmente diversi come, per esempio, il peso e l'altezza. Il coefficiente di variazione è un numero puro poiché non dipende dalle unità di misura e tiene anche conto dell'eventuale effetto dovuto alla eventuale differente ampiezza campionaria. Nel Codice 2.16 è riportato un esempio di algoritmo per il calcolo del coefficiente di variazione.

2.7 La forma delle distribuzioni

Abbiamo visto che gli indici come media, moda e mediana possono fornire indicazioni utili sulla forma delle distribuzioni: forti scarti tra i valori dei tre indici possono indicare uno sbilanciamento eccessivo della distribuzione verso destra o verso sinistra. Abbiamo anche visto però che a parità di media e mediana la variabilità delle distribuzioni può essere sostanzialmente differente implicando una notevole differenza nella forma delle distribuzioni. Infine, quando abbiamo introdotto il boxplot, ci siamo soffermati brevemente sulle relazioni tra i quartili e la forma della distribuzione. Lo studio della forma di una distribuzione di dati può essere in alcuni casi molto informativo (si pensi al caso dei dati di trapianto di organo). Esistono quindi differenti indicatori che si occupano di misurare in modo oggettivo quando una distribuzione di dati sia "appiattita" o viceversa "appuntita" (si parla in questo caso di **curtosi**) oppure se questa presenta evidenti sbilanciamenti verso destra o sinistra (ovvero presenta **asimmetria**). Con γ_1 si indica l'indice di asimmetria di Pearson che ha la seguente espressione

$$\gamma_1 = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}_n}{\sigma} \right)^3$$

Se la distribuzione è simmetrica γ_1 assume valore 0, altrimenti $\gamma_1 > 0$ (asimmetria positiva) se la distribuzione ha la coda di sinistra molto lunga e in caso contrario $\gamma_1 < 0$ (asimmetria negativa). L'indice γ_1 è stato costruito tenendo presente che

$$\sum_{i=1}^n (x_i - \bar{x}_n)^k$$

sono nulle quando k è un numero dispari (in particolare per $k=3$) e la distribuzione è simmetrica. Il denominatore σ serve solo ad eliminare l'influenza dell'unità di misura (ragionando in modo analogo al caso del coefficiente di variazione). La Figura 2.18 riporta i boxplot appaiati dei due insiemi di dati. Il boxplot della distribuzione di Y denota uno sbilanciamento della coda di sinistra mentre quello della distribuzione di X un leggero sbilanciamento della coda di destra. Ci aspettiamo un valore di γ_1 negativo per Y e di poco positivo per X . Lo script che segue definisce i vettori X ed Y della Figura 2.18 ed esegue il calcolo dell'indice γ_1 attraverso la funzione `skew` (dal termine anglosassone *skewness*) definita nel Codice 2.17.

```
> x <- c(0.75, 2.27, 5.19, 4.8, 1.6, 3.5,
+       11.19, 3.42, 4.38, 6.64, 5.41,
+       3.12, 9.45, 4.38, 4.77, 4.98,
+       3.74, 2.81, 2.04, 8.34)
> y <- c(13.79, 12.11, 8.85, 14.01, 9.71,
+       11.08, 12.34, 12.16, 7.52, 14.02, 9.75,
+       14.15, 12.84, 14.73, 12.88, 10.40,
+       12.78, 13.19, 9.59, 12.16)
> boxplot(x,y, names=c("x", "y"))
```

```
> skew(x)
[1] 0.9566583
> skew(y)
[1] -0.5713037
```

```
skew <- function(x) {
  n <- length(x)
  s3 <- sqrt(var(x) * (n-1)/n) ^ 3
  mx <- mean(x)
  sk <- sum((x - mx) ^ 3) / s3
  sk/n
}
```

Codice 2.17 Algoritmo per il calcolo dell'indice di asimmetria γ_1 .

Una quantità atta a misurare la densità dei dati attorno alla propria media è l'indice di curtosi β_2 .

$$\beta_2 = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}_n}{\sigma} \right)^4$$

Questo indice è costruito per confrontare la distribuzione dei dati con una distribuzione di riferimento, la Gaussiana, la cui forma è ritenuta la "normalità". Per questa particolare distribuzione, che trova la sua principale collocazione nell'ambito del calcolo delle probabilità, l'indice di curtosi assume il valore 3. Se la distribuzione è molto appiattita o *platicurtica* l'indice vale un valore minore di 3, in caso contrario (*leptocurtismo*) l'indice β_2 assume valori maggiori di 3. La Figura 2.19 mostra due grafici (che possiamo interpretare come istogrammi lisciati) di due distribuzioni, quella di sinistra *platicurtica* e l'altra *leptocurtica*. La linea tratteggiata e quella della distribuzione di riferimento. La distribuzione *leptocurtica* presenta un addensamento dei valori attorno al valore centrale e code più esili. La distribuzione *platicurtica* è meno alta attorno al valore centrale ma presenta code più pesanti.

Osservando il grafico di destra della Figura 2.18 si nota come la distribuzione di Y sia più schiacciata attorno al valore centrale mentre quella di X risulta più ciottellata. Se effettuiamo il calcolo dell'indice di curtosi otteniamo una valutazione oggettiva di quanto osservato. Infatti

```
> kurt(x)
[1] 3.493081
> kurt(y)
[1] 2.334998
```

X presenta valore di curtosi maggiore di 3 e Y inferiore. Abbiamo utilizzato la funzione `kurt` da noi definita come nel Codice 2.20.




Figura 2.18 A sinistra: boxplot appaiati di due distribuzioni asimmetriche. Quella di X presenta leggera asimmetria positiva mentre quella di Y presenta asimmetria negativa. A destra: istogrammi lisciati delle due distribuzioni di dati.

Si noti che sia γ_1 che β_2 sono indici molto sensibili ai valori anomali. Spesso sono preferibili indici più robusti costruiti a partire dai quantili. Per un approfondimento sugli strumenti di statistica robusta si veda per esempio [19].

2.8 La concentrazione

In alcune particolari situazioni può non essere sufficiente basarsi sul calcolo di indici di variabilità per discriminare due popolazioni. In particolare questo è vero quando le unità statistiche sono identificate con gli individui e la caratteristica oggetto di studio è un bene condivisibile come, per esempio, la ricchezza. In queste circostanze può aver senso chiedersi se la ricchezza sia equamente distribuita tra gli individui oppure se essa è concentrata nelle mani di alcuni. Si dice allora che un carattere X è *equidistribuito* tra gli n individui della popolazione se ciascuno di essi ne possiede una quota pari $1/n$. In caso opposto, in cui tutte, o la maggior parte, delle quote di X sono nelle "mani" di uno o pochi degli n individui si parla di *concentrazione*. Ha senso parlare di concentrazione solo in presenza di fenomeni continui che sono intrinsecamente condivisibili tra gli individui di una popolazione. Il concetto di concentrazione potrebbe erroneamente essere interpretato come l'inverso di quello della variabilità ma ciò non è vero: la variabilità si manifesta nel modo in cui i valori di un dato carattere si disperdono attorno ad un centro comune (la media, la mediana ecc.) mentre la concentrazione si realizza quando il fenomeno si manifesta con maggiore intensità solo su un numero ridotto di

```

E <- function(x) {
  f <- table(x)/length(x)
  k <- length(f)
  if(k==1)
    return(0)
  k*(1-sum(f^2))/(k-1)
}

```

Codice 2.24 Codice per il calcolo dell'indice E di eterogeneità di Gini.

```

[1] 0.9666667
> E(Y)
[1] 0.9333333
> E(Z)
[1] 0.9875
> E(W)
[1] 1

```

A meno titolo di esempio possiamo calcolare il rapporto di concentrazione di Gini R per i fenomeni Z e W . Omettendo la parte irrilevante dell'output otteniamo

```

> gini(W)
$R
[1] 0.1271732
> gini(Z)
$R
[1] 0.4583333

```

Come era da aspettarsi W (che è il più eterogeneo) risulta essere meno concentrato di Z . **Attenzione:** il calcolo dell'indice di concentrazione R per W e Z è, dal punto di vista statistico, fuori luogo in quanto se in un'epoca *new age* può essere verosimile pensare di condividere i figli (Z) risulta meno intuitivo pensare di condividere il peso (W).

2.10 Dall'istogramma alla stima della densità

Benché tale argomento esuli un po' dal livello tecnico di questo volume, in ambito di analisi dei dati è molto utile, se il fenomeno oggetto di studio è di tipo quantitativo, ricorrere ad uno strumento più informativo del semplice istogramma. Il metodo più comune per ricostruire una curva che approssimi il più possibile la vera distribuzione di frequenza (continua) di tali fenomeni è il metodo dei nuclei.

Tale metodo consiste nel sovrapporre a ciascun punto x_i dei nostri dati osservati anziché un rettangolo di una certa altezza, una curva di cui i risultati essere più smussati. L'altezza di tale curva è proporzionale alla frequenza dei punti e la sua ampiezza dipende da un parametro chiamato **banda**. Queste curve K sono appunto detti **nuclei** o **kernel** e rispettano alcune proprietà elementari. Per esempio, $K(x) \geq 0$, $\int x^2 K(x) dx = 1$ e cose del genere. Non possiamo addentrarci nei dettagli, ma la sostanza è che il risultato grafico è una sorta di liscio dell'istogramma. A tale fine agisce la banda: se questa è troppo larga, il grafico risultante diviene una curva molto appiattita in cui non emergono più informazioni (l'analogo è un istogramma con pochissime classi). Al contrario, se la banda è troppo stretta, il grafico tende ad assomigliare ad un grafico a bastoncini. Esiste un valore ottimale della larghezza della banda che viene calcolato automaticamente da R. La funzione che viene utilizzata per rappresentare il grafico con il metodo kernel è sempre di questo tipo

$$f(x) = \frac{1}{nb} \sum_{i=1}^n K\left(\frac{x-x_i}{b}\right)$$

dove K è il kernel e b è la banda. Per maggiori dettagli si veda per esempio [39]. Vediamo un esempio di tale grafico applicato ai dati dei pesi W della Tabella 2.1. Il comando R per ottenere una stima di densità è `density`. Nelle linee di codice che seguono facciamo disegnare ad R l'istogramma classico, il poligono di frequenza e la stima di densità lasciando scegliere ad R la banda ottimale. Il risultato si può osservare in Figura 2.25

```

> load("dati1.rda")
> hist.pf(dati$W,br=c(40,50,58,70,95))
> lines(density(dati$W),lty=3)

```

Come si nota la stima della densità risulta essere un liscio del poligono di frequenza e, di conseguenza, dell'istogramma. Vediamo cosa accade variando la banda tramite l'opzione `bw`. Per prima cosa vediamo cosa si ottiene tramite il comando `density`

```

> density(dati$W)

Call:
density(x = dati$W)

```

```
Data: dati$W (20 obs.):      Bandwidth 'bw' = 7.281
```

x	y
Min. : 19.38	Min. : 3.752e-05
1st Qu.: 42.82	1st Qu.: 1.888e-03
Median : 66.25	Median : 1.046e-02
Mean : 66.25	Mean : 1.065e-02
3rd Qu.: 89.69	3rd Qu.: 1.873e-02
Max. : 113.13	Max. : 2.345e-02

Histogram of x




Figura 2.25 Stima della densità (linea tratteggiata) a confronto con l'istogramma e il poligono di frequenza.

L'informazione rilevante è il valore della banda Bandwidth $'bw' = 7.28$. I quantili non corrispondono ai veri quantili campionari ma sono calcolati sulla base della suddivisione dell'intervallo di variazione di W' operata da R. Proviamo ad aumentare e diminuire la banda e osserviamo cosa accade al grafico di $\text{density}(\text{dati\$W})$. Nella Figura 2.26 abbiamo ristretto la banda da 7.28, valore ottimale, a 3. Nel Grafico in Figura 2.27 lo abbiamo aumentato fino a 20. Risulta chiaro quindi che la stima di densità, così come ci siamo limitati ad introdurla, è uno strumento di analisi esplorativa che può essere di ausilio nel cercare eventuali ricorrenze all'interno dei dati soprattutto variando in modo opportuno sia il kernel utilizzato (vedere l'help della funzione density) che la banda bw . La Figura 2.26 è stata ottenuta con il codice seguente

```
> plot(density(dati$W), main = "stima della densita'",
+      xlab="W", ylim = c(0,0.03))
> lines(density(dati$W,bw=3),lty=3)
> legend(80,0.025,c("bw = ottimale", "bw = 3"),lty=c(1,3))
```

mentre la Figura 2.27 con le tre linee di codice

```
> plot(density(dati$W), main = "stima della densita'",
+      xlab="W", ylim = c(0,0.03))
> lines(density(dati$W,bw=20),lty=3)
> legend(80,0.025,c("bw = ottimale", "bw = 20"),lty=c(1,3))
```

stima della densita'




Figura 2.26 Stima della densità con banda ottimale e ristretta (linea tratteggiata) a confronto.

stima della densita'




Figura 2.27 Stima della densità con banda ottimale e allargata (linea tratteggiata) a confronto.