

di testo ASCII standard l'insieme dei comandi. Una volta in R sarà sufficiente utilizzare il comando `source`. Supponiamo di creare un file di testo `prova.R` in cui sono contenuti alcune delle funzioni da noi definite, ad esempio la funzione `somma`. Quindi il file conterrà le seguenti linee di testo

```
# La nostra strana funzione somma
somma <- function(a,b) {
  if(a>0 | b>0)
    a+b
  else
    -1
}
```

Supponiamo ora di aprire una nuova sessione di R e di voler ricaricare in memoria la funzione `somma` contenuta nel file `prova.R`. Sarà sufficiente scrivere

```
> source("prova.R")
> ls()
[1] "somma"
> somma(2,3)
[1] 5
```

1.2.9 Salvare l'output di R

A volte, anche in relazione all'utilizzo di script esterni, si rende necessario poter memorizzare l'output di una sessione di lavoro con R. Le versioni dotate di interfaccia grafica prevedono questa opzione tramite menu oppure con semplice copia e incolla della finestra R Console. Se però si vuole automatizzare anche questa funzionalità si può utilizzare il comando `sink`. Per esempio, la sequenza di comandi

```
> sink("output.txt")
> cat("\n Hello World!\n")
> sink()
```

apre un file "output.txt" nella directory corrente di lavoro e vi scrive il testo Hello World! Si noti che l'ultimo comando `sink`, senza argomenti, serve a chiudere il file di output.

1.2.10 La directory di lavoro

A seconda delle implementazioni di R utilizzare, la directory può essere differente da quella in cui si trova l'eseguibile di R (questo avviene quasi sempre sotto sistemi Unix). È possibile spostarsi da una directory all'altra attraverso il comando `setwd`, verificare la directory corrente di lavoro attraverso il comando `getwd` e visionarne il contenuto attraverso il comando `dir`. Spesso è conveniente tenere distinte le sessioni di lavoro lavorando su directory differenti e quindi salvare e caricare il contenuto del workspace in queste directory di lavoro.

2

Sintesi dei dati

In questo capitolo tratteremo di quella parte della statistica che si occupa di sintetizzare l'informazione contenuta nei dati grezzi: la statistica descrittiva. In questo contesto lo scopo principale è dare una lettura dei dati in nostro possesso che sia il più immediata possibile senza tentare di estendere i risultati ottenuti ad altre unità statistiche o popolazioni. Di questo genere di estensioni se ne occupa l'inferenza statistica e sarà oggetto dei capitoli successivi. Quindi, indipendentemente dal fatto che si tratti di rilevazioni complete o dati campionari, la nostra analisi si fermerà alla descrizione di questo insieme di dati. Gli strumenti fondamentali che incontreremo sono le distribuzioni di frequenza, le (loro) rappresentazioni grafiche e i principali indici di sintesi che le descrivono.

2.1 Tipologie di dati

In statistica esistono varie tipologie di dati che non corrispondono necessariamente alla natura dei fenomeni statistici cui fanno riferimento. I dati si dividono quindi in due gruppi principali: quelli qualitativi e quelli quantitativi. I qualitativi sono così chiamati perché i fenomeni statistici da cui derivano possono essere descritti attraverso attributi (per esempio il "sesso" può essere registrato attraverso i due attributi "maschio" e "femmina") eventualmente posti tra loro in qualche relazione d'ordine (per esempio l'"età": "giovane", "adulto", "anziano"). Si parla quindi di fenomeni qualitativi rilevati su scala **nominale** e **ordinale** rispettivamente. In R i dati di questo tipo sono rappresentati come `factor` ed eventualmente, se è presente un ordinamento, si deve specificare anche l'attributo `ordered`.

Supponiamo di avere un gruppo di sette persone, tre uomini e quattro donne, rispettivamente di 15, 16, 45, 55, 75, 15 e 70 anni. Costruiamo i due vettori in R ricodificando le età utilizzando la scala "giovane", "adulto", "anziano".

```
> sesso <- c("U", "U", "U", "D", "D", "D", "D")
> eta <- c("giovane", "giovane", "adulto", "adulto",
  "anziano", "giovane", "anziano")
> str(sesso)
chr [1:7] "U" "U" "U" "D" "D" "D" "D"
> str(eta)

```

```
chr [1:7] "giovane" "giovane" "adulto" "adulto"
      "anziano" "giovane" ...
```

Se non è necessario specificare un ordinamento tra le modalità di un carattere per R è più che sufficiente questo modo di memorizzare i dati come `chr` (character) poiché provvederà R stesso a trasformarli in `factor` nel momento del bisogno. Si noti che abbiamo utilizzato le virgolette "" per introdurre i valori delle variabili età e sesso come attributi. Un modo più elegante e corretto per dire ad R che i dati sono di tipo qualitativo è utilizzare il comando `factor`. Per esempio

```
> sesso2 <- factor(sesso)
> str(sesso2)
Factor w/ 2 levels "D","U": 2 2 2 1 1 1 1
> sesso2
[1] U U U D D D D
Levels: D U
```

Come si vede R ci informa che `sesso2` è un vettore di tipo qualitativo (`factor`) i cui diversi valori assunti dal carattere, le modalità, sono U e D. Questi valori sono denotati con `levels`. Come si nota gli indici in R partono dal valore 1. R pur non tenendo conto dell'ordine ha attribuito il valore numerico 1 a D e 2 a U, questo avviene perché in mancanza di altre indicazioni R utilizza l'ordinamento alfabetico. Se effettuiamo la stessa operazione con `eta` otteniamo quanto segue:

```
> eta2 <- factor(eta)
> str(eta2)
Factor w/ 3 levels "adulto","anziano",...: 3 3 1 1 2 3 2
> eta2
[1] giovane giovane adulto adulto anziano giovane anziano
Levels: adulto anziano giovane
```

Come si nota, i livelli sono stati ordinati in ordine alfabetico: 'adulto' < 'anziano' < 'giovane'. Se vogliamo imporre un particolare ordinamento si può usare il comando `ordered` specificando l'ordinamento nel modo seguente

```
> ordered(eta2, levels=c("giovane", "adulto", "anziano"))
[1] giovane giovane adulto adulto anziano giovane anziano
Levels: giovane < adulto < anziano
```

oppure direttamente nel comando `factor`

```
> eta2 <- factor(eta, levels=c("giovane", "adulto", "anziano"),
ordered=TRUE)
```

```
[1] giovane giovane adulto adulto anziano giovane anziano
Levels: giovane < adulto < anziano
```

o più semplicemente

¹ Il simbolo "<" indica l'ordine di precedenza. Per esempio, "a < b" vuol dire "a precede b".

```
> eta2 <- ordered(eta, levels=c("giovane", "adulto",
      "anziano"))
```

```
[1] giovane giovane adulto adulto anziano giovane anziano
Levels: giovane < adulto < anziano
```

Quando viene specificato l'attributo `ordered` R ci ricorda che i livelli delle variabili sono appunto su scala ordinale. In particolare modo, il comando `ordered` è molto utile qualora si vogliano ricodificare o riordinare le modalità di fenomeni qualitativi. Infatti, molto spesso anziché memorizzare gli attributi si preferisce registrare solo il codice relativo ad una certa modalità, ovvero: 1 = uomo, 2 = donna. Nell'esempio che segue la variabile `sesso3` contiene una sequenza di 1 e 2. Trasformiamo prima questa variabile in `sesso4` che risulta essere di tipo `factor` e poi rinominiamo i livelli 1 e 2 in U e D rispettivamente.

```
> sesso3 <- c(1,1,1,2,2,2,2)
> sesso3
[1] 1 1 1 2 2 2 2
> sesso4 <- factor(sesso3)
> sesso4
[1] 1 1 1 2 2 2 2
Levels: 1 2
> levels(sesso4) <- c("U", "D")
> sesso4
[1] U U U D D D D
Levels: U D
```

Abbiamo utilizzato la funzione `levels` che non fa altro che restituire le etichette assegnate a ciascun codice. Se invece delle etichette vogliamo risalire ai codici dobbiamo utilizzare `codes`.

```
> eta2
[1] giovane giovane adulto adulto anziano giovane anziano
Levels: giovane < adulto < anziano
> codes(eta2)
[1] 1 1 2 2 3 1 3
```

Per i fenomeni quantitativi non c'è distinzione per sotto-tipologie. Benché in ambito statistico si distingua tra fenomeni quantitativi discreti e continui, dal punto di vista dei dati grezzi, in R come in qualsiasi altro software, non vi è distinzione. In genere si parla di fenomeni quantitativi discreti quando ci si riferisce a caratteristiche osservate attraverso operazioni di conteggio (numero di figli per coppia, numero di automobili ecc.). Viceversa si attribuisce natura continua a quei dati che sono originati da operazioni di misura (lunghezza, peso ecc.). Si intuisce bene che nella pratica, pur avendo strumenti di misurazione molto precisi, esiste un limite fisico oltre il quale lo strumento, o chi registra i dati, è costretto a compilare una discretizzazione e quindi l'insieme dei dati non sarà altro che un insieme di numeri (magari con molte cifre decimali) che comunque non ha la potenza del continuo. Tornando all'esempio delle 7 persone viste all'inizio del paragrafo, possiamo memorizzare direttamente le loro età in anni anziché utilizzare la ricodifica vista sopra

```
> eta <- c(15, 16, 45, 55, 75, 15, 70)
> eta
[1] 15 16 45 55 75 15 70
> str(eta)
num [1:7] 15 16 45 55 75 15 70
```

Si noti che R ci segnala che i dati sono di tipo numerico.

2.2 La matrice dei dati

Nel Paragrafo 2.3 introdurremo le distribuzioni di frequenza. Queste sono un ottimo strumento di sintesi e sono anche molto semplici da ottenere attraverso R. Vedremo che spesso è utile presentare i dati anche in forma grafica (cfr. Paragrafo 2.4). Attraverso un esempio guida, mostreremo quali tipologie di grafici ed analisi è più opportuno utilizzare a seconda del tipo di dati a disposizione. Prima però di entrare nei dettagli di tipo statistico è bene introdurre un oggetto molto importante per R: la matrice dei dati o il **dataframe**. Come esempio guida utilizzeremo i dati della Tabella 2.1 relativi a diversi tipi di fenomeni statistici. Questa tabella riporta lo stato civile (X), il livello di scolarità (Y), il numero di figli a carico (Z) e il peso in kg (W) di 20 individui. Le variabili X e Y sono state ricodificate come segue

$X = \begin{cases} N & = \text{Nubile/celibe} \\ C & = \text{Coniugato} \\ V & = \text{Vedovo} \\ S & = \text{Separato e/o divorziato} \end{cases}$

$Y = \begin{cases} A & = \text{Analfabeta e alfabeto} \\ O & = \text{Scuola dell'obbligo} \\ S & = \text{Diploma di scuola superiore} \\ L & = \text{Laurea e superiore} \end{cases}$

e

Dobbiamo introdurre in R i dati. Ci sono vari modi per farlo: possiamo preparare un file di testo da far leggere successivamente a R, possiamo usare la funzione `dataentry3` o più semplicemente creare i quattro vettori X, Y, W e Z ed assemblarli in una matrice di dati che in R trova un utile rappresentazione come `data.frame`. Visto che si tratta dell'oggetto più utilizzato nelle analisi statistiche, cerchiamo di apprendere le modalità di costruzione e gestione di un `data.frame`. Iniziamo con l'inserire il nostro insieme di dati vettore per vettore.

³Non disponibile nella implementazione MacOS di R.

u	X	Y	Z	W
unità statistica	stato civile	grado di scolarità	numero di figli	peso in kg
1	N	L	0	72.50
2	S	O	1	54.28
3	V	A	3	50.02
4	V	O	4	88.88
5	C	L	1	62.30
6	N	S	1	45.21
7	C	S	0	57.50
8	C	O	2	78.40
9	V	L	3	75.13
10	N	O	0	58.00
11	N	S	1	53.70
12	N	A	0	91.29
13	S	S	1	74.70
14	C	S	4	41.22
15	N	S	3	65.20
16	C	L	0	63.58
17	V	O	2	48.27
18	S	O	2	52.52
19	C	S	4	69.50
20	C	S	4	85.98

Tabella 2.1 Dati relativi a 4 caratteristiche rilevate congiuntamente su 20 individui.

re. Ricordiamo che è possibile utilizzare la funzione `scan3`. Tale funzione non fa altro che memorizzare l'input di quanto scriviamo nella console di R, in un vettore. L'unico problema è che la funzione `scan` accetta in input solo valori numerici. Se ricodichiamo i livelli di X con i numeri da 1 a 4, possiamo velocemente inserire i dati in R come segue

```
> x <- scan()
1: 1 4 3 3 2 1 2 2 3 1 1 1 4 2 1 2 3 4 2 2
21:
Read 20 items
```

ricordando di terminare l'input con un 'invio' a vuoto. Basterà ora trasformare x in `factor` e ricodificarne i livelli come segue

```
> x <- factor(x)
> levels(x) <- c("N", "C", "V", "S")
> x
```

³Presentiamo la funzione `scan` solo a fini didattici. In realtà nella quasi totalità dei casi si usa leggere i dati che sono stati preventivamente archiviati su file. In tal caso è d'uso comune utilizzare la funzione `read.table` o suoi derivati. Per i dettagli si veda il Paragrafo A.2 dell'Appendice A.

```
[1] N S V V C N C C V N N N S C N C V S C C
Levels: N C V S
```

Procediamo in modo analogo per Y.

```
> y <- scan()
1: 4 2 1 2 4 3 3 2 4 2 3 1 3 3 3 4 2 2 3 3
21:
Read 20 items
> y <- factor(y)
> levels(y) <- c("A", "O", "S", "L")
> y
[1] L O A O L S S O L O S A S S S L O O S S
Levels: A O S L
> y <- ordered(y)
> y
[1] L O A O L S S O L O S A S S S L O O S S
Levels: A < O < S < L
```

A differenza di X che è un fenomeno qualitativo rilevato su scala nominale, per le modalità (i livelli) di Y esiste un ordine naturale rappresentato dal grado di istruzione e quindi abbiamo costruito Y di conseguenza. Per Z e W si procede in modo elementare come segue:

```
> z <- scan()
1: 0 1 3 4 1 1 0 2 3 0 1 0 1 4 3 0 2 2 4 4
21:
Read 20 items
> z
[1] 0 1 3 4 1 1 0 2 3 0 1 0 1 4 3 0 2 2 4 4
> w <- scan()
1: 72.5 54.28 50.02 88.88 62.3 45.21 57.5 78.4
9: 75.13 58.53 7 91.29 74.7 41.22 65.2 63.58
17: 48.27 52.52 69.5 85.98
21:
Read 20 items
> w
[1] 72.50 54.28 50.02 88.88 62.30 45.21 57.50
[8] 78.40 75.13 58.00 53.70 91.29 74.70 41.22
[15] 65.20 63.58 48.27 52.52 69.50 85.98
```

★ ★ Ora possiamo assemblare il tutto in un data.frame come segue e in modo immediato

```
> dati <- data.frame(X=x, Y=y, Z=z, W=w)
> dati
  X Y Z      W
1 N L 0 72.50
2 S O 1 54.28
3 V A 3 50.02
4 V O 4 88.88
```

```
5 C L 1 62.30
6 N S 1 45.21
7 C S 0 57.50
8 C O 2 78.40
9 V L 3 75.13
10 N O 0 58.00
11 N S 1 53.70
12 N A 0 91.29
13 S S 1 74.70
14 C S 4 41.22
15 N S 3 65.20
16 C L 0 63.58
17 V O 2 48.27
18 S O 2 52.52
19 C S 4 69.50
20 C S 4 85.98
```

★ ★ Il nuovo oggetto dati contiene ora l'intera matrice dei dati e possiamo anche rimuovere dal workspace i singoli vettori x, y, z e w con il comando rm(x, y, z, w). Abbiamo scelto di utilizzare le lettere maiuscole X, Y, Z e W solo perché lo sono nella Tabella 2.1 ma non c'è nessun'altra ragione.

Già che ci siamo, salviamo i dati del nostro dataset in un file esterno attraverso il comando save.

```
★ ★ > save(file="dati1.rda", dati)
★ ★
> rm(list=ls())
> ls()
character(0)
> load("dati1.rda")
> ls()
[1] "dati"
```

A questo punto, per allenarci con l'utilizzo dei dataset che seguirà, possiamo anche cancellare il contenuto del workspace e ricaricare i nostri dati

★ ★ Per accedere ai dati contenuti nei singoli vettori si procede come segue. Supponiamo di voler lavorare sul vettore x di dati. Per accedervi basterà richiamarlo con il nome dati\$x:

```
> dati$x
[1] N S V V C N C C V N N N S C N C V S C C
Levels: N C V S
```

★ ★ Questo modo di procedere può risultare scomodo quando si devono compiere operazioni articolate, converrebbe quindi sempre lavorare direttamente con le colonne del data.frame, cioè con i nomi delle variabili. Per fare questo si utilizza la coppia di comandi attach e detach. Il primo fa in modo che i vettori di un data.frame siano accessibili direttamente pur senza essere presenti nel workspace, il secondo ripristina il comportamento usuale di R. Quindi si procederà come segue

```

> attach(dati)
> ls()
[1] "dati"
> X
[1] N S V V C N C C V N N N S C N C V S C C
Levels: N C V S
> Y
[1] L O A O L S S O L O S A S S S L O O S S
Levels: A < O < S < L
> detach(dati)
> X
Error: Object "X" not found
> dati$X
[1] N S V V C N C C V N N N S C N C V S C C
Levels: N C V S

```

Come si vede, dopo l'utilizzo di `attach(dati)` le singole colonne di `dati` sono accessibili direttamente (pur non comparando nel workspace) e non appena utilizziamo il comando `detach(dati)` `R` non riesce più a trovare i vettori a meno di utilizzare `dati$X`. Si tenga presente che qualsiasi modifica apportata ad un data frame a seguito di un comando `attach` non modifica il data frame originale mentre genera una copia, questa volta modificata, dello stesso data frame. Questo può essere fonte di errori e può rendere complicato scovare gli errori stessi all'interno di un codice `R`. La funzione `attach` può essere utilizzata anche a partire di dati residenti su un file. Per esempio, la sequenza di comandi qui sotto permette di rendere disponibile un data frame registrato su file (con il comando `save`) pur senza caricarlo in memoria

```

> rm(list=ls())
> attach("dati1.rda")
> ls()
character(0)
> dati$X
[1] N S V V C N C C V N N N S C N C V S C C
Levels: N C V S
> X
Error: Object "X" not found
> detach()
> ls()
character(0)

```

Si noti la differenza di comportamento rispetto a quanto visto in precedenza: dopo il comando `attach` il workspace, preventivamente cancellato, risulta vuoto. Al contrario il data frame `dati` risulta ugualmente accessibile mentre non lo è più il semplice vettore `X`. Ricordiamo che il data frame è sostanzialmente una matrice le cui colonne non sono necessariamente di tipo numerico. È quindi possibile accedere ad una singola variabile con l'usuale manipolazione di indici, ovvero `dati[,1]` estrae la prima colonna del data frame `dati`.

2.3 Distribuzioni di frequenza

Consideriamo il fenomeno X e indichiamo con x_i i valori distinti assunti nel campione. Se contiamo quante volte ciascun valore x_i compare nell'insieme dei dati (cioè con quale *frequenza* compare) ed indichiamo con n_i tale numero, l'insieme dei valori $\{(x_i, n_i), i = 1, 2, \dots, k\}$ si chiama *distribuzione di frequenza*. Nel caso in esame lo stato civile X si presenta con $k = 4$ distinti valori

$$x_1 = N \quad x_2 = C \quad x_3 = V \quad x_4 = S$$

rispettivamente con frequenza $n_1 = 6$, $n_2 = 7$, $n_3 = 4$ e $n_4 = 3$. A meno di non avere dati mancanti, la somma delle frequenze è sempre pari alla numerosità campionaria (20 nel nostro caso)

$$n = \sum_{i=1}^k n_i.$$

Possiamo costruire anche la distribuzione di frequenza *relativa* calcolando le frequenze relative $f_i = n_i/n$ o le frequenze percentuali $p_i = f_i \cdot 100\%$. Per X otteniamo i dati come in Tabella 2.2. Il comando `R` per ottenere le distribuzioni di frequenza è `table`.

```

> table(X)
X
N C V S
6 7 4 3
> table(X)/length(X)
X
N C V S
0.30 0.35 0.20 0.15
> table(X)/length(X)*100
X
N C V S
30 35 20 15

```

Abbiamo utilizzato il comando `length` (che calcola semplicemente la lunghezza di un vettore) per ottenere la numerosità e tale informazione è stata utilizzata per ottenere le frequenze relative e percentuali.

Se abbiamo un fenomeno per il quale ha senso considerare un ordinamento, allora è utile considerare le *frequenze cumulative*. È il caso del fenomeno Y e, evidentemente, di Z e W .

x_i	n_i	f_i	$f_i \cdot 100\%$
N	6	0.30	30
C	7	0.35	35
V	4	0.20	20
S	3	0.15	15
$n = 20$		1.00	100

Tabella 2.2 Distribuzione di frequenza del fenomeno X.

x_i	n_i	f_i	$f_i \cdot 100\%$	N_i	F_i
A	2	0.1	10	2	0.1
O	6	0.3	30	8	0.4
S	8	0.4	40	16	0.8
L	4	0.2	20	20	1.0
20		1.0	100	—	—

Tabella 2.3 Distribuzione di frequenza del grado di scolarità Y.

Le frequenze cumulate sono definite come segue

$$N_i = \sum_{j=1}^i n_j = n_1 + n_2 + \dots + n_i : \text{cumulate assolute}$$

$$F_i = \sum_{j=1}^i f_j = f_1 + f_2 + \dots + f_i : \text{cumulate relative}$$

$$P_i = \sum_{j=1}^i p_j = p_1 + p_2 + \dots + p_i : \text{cumulate percentuali}$$

Nel caso di X non ha alcun senso effettuare il calcolo (ma questo R non può saperlo!). Vediamo di effettuare il calcolo per Y come riportato in Tabella 2.3 anche attraverso R.

```
> table(Y)
Y
A O S L
2 6 8 4
> table(Y)/length(Y)
Y
A O S L
0.1 0.3 0.4 0.2
```

x_i	n_i	f_i	$f_i \cdot 100\%$	N_i	F_i
0	5	0.25	25	5	0.25
1	5	0.25	25	10	0.50
2	3	0.15	15	13	0.65
3	3	0.15	15	16	0.80
4	4	0.20	20	20	1.00
20		1.00	100	—	—

Tabella 2.4 Distribuzione di frequenza per la variabile numero di figli Z.

```
> table(Y)/length(Y)*100
Y
A O S L
10 30 40 20
```

e per le frequenze cumulate si deve utilizzare la funzione `cumsum` che si occupa di fare le somme cumulate degli elementi di un vettore. Per esempio, il comando `cumsum(c(1,2,3))` restituisce il vettore (1,3,6). Basterà quindi applicare la funzione all'output del comando `table`.

```
> cumsum(table(Y))
[1] 2 8 16 20
> cumsum(table(Y)/length(Y))
[1] 0.1 0.4 0.8 1.0
> cumsum(table(Y)/length(Y)*100)
[1] 10 40 80 100
```

Come si vede, in tutti gli esempi precedenti si è persa l'istestazione della tabella che ci fornisce invece in comando `table`. Osservando le frequenze cumulate si possono ricavare informazioni del tipo "il 40% degli individui possiede un grado di istruzione al più pari a quello della scuola dell'obbligo".

Per i quantitativi discreti si procede in modo analogo a quanto visto sopra. Quindi per Z otteniamo

```
> table(Z)
Z
0 1 2 3 4
5 5 3 3 4
> table(Z)/length(Z) # frequenze relative
Z
0 1 2 3 4
0.25 0.25 0.15 0.15 0.20
```

e analogamente a quanto già visto ricaviamo tutte le quantità necessarie alla costruzione della Tabella 2.4.

Potremmo procedere in modo analogo anche per la variabile peso ma otteniamo una distribuzione senza senso poiché ogni valore comparirebbe con frequenza unitaria. Infatti,



Figura 2.1 Rappresentazione del fenomeno $X = \text{"stato civile"}$ tramite rettangoli (a sinistra) e tramite bastoncini (a destra). I rettangoli (e i bastoncini) sono equispaziati ed hanno tutti la stessa base. L'altezza è proporzionale alle frequenze.

ottenere che

$$\sum_{i=1}^k a_i \cdot d_i = \sum_{i=1}^k a_i \cdot \frac{n_i}{a_i} = \sum_{i=1}^k n_i = n$$

R invece fa in modo che quella sommatoria restituisca 1, quindi R di fatto divide le d_i per n nel calcolo delle densità di frequenza ovvero calcola le quantità $d'_i = f_i/a_i$.

2.4 Rappresentazioni grafiche

Benché le distribuzioni di frequenza siano strumenti esaurienti dal punto di vista dell'informazione che contengono spesso è molto meglio darne anche una rappresentazione grafica. Vediamo quindi come rappresentare in modo opportuno i diversi tipi di dati con R .

2.4.1 Grafico a barre e diagrammi a torta

Iniziamo dai fenomeni qualitativi. Sempre a partire dai dati della Tabella 2.1 consideriamo la variabile X . Si tratta di un fenomeno qualitativo le cui modalità non sono su una scala ordinale. In questo caso si costruisce un **grafico a**




Figura 2.2 Rappresentazione del fenomeno $X = \text{"stato civile"}$ tramite diagrammi a torta. I settori circolari hanno un'ampiezza proporzionale alle frequenze. L'ordine con cui si susseguono i settori circolari è irrilevante. Nel diagramma di sinistra è R a scegliere il tipo di torta, in quello di destra abbiamo scelto un tratteggio particolare (si confronti il testo).

barre nel seguente modo. Si dispongono lungo una linea orizzontale ed in modo equispaziato i valori di X . Si costruisce un asse verticale su cui riportiamo le frequenze. Si tracciano dei rettangoli centrati sui valori x_i tutti della stessa base e di altezza pari alle frequenze (assolute o relative che si voglia). In R si ottiene questo in modo veloce utilizzando il comando `plot(X)`. L'output è riportato in Figura 2.1 assieme a quello del **diagramma a bastoncini** che si ottiene con il comando `plot(table(X))`. Se si vuole un diagramma a bastoncini che riporti le frequenze relative anziché le frequenze assolute si può utilizzare `plot(table(X)/sum(table(X)))`. Un altro tipo di rappresentazione è quella tramite **diagrammi a torta** che consiste nell'attribuire ciascuna modalità della variabile in esame ad un settore circolare di un cerchio, la cui ampiezza è proporzionale alla frequenza. In R questo si ottiene attraverso il comando `pie` come segue

```
> pie(table(X))
> pie(table(X), density = 10, angle = 15 + 10 * (1:4))
```

i cui risultati riportiamo in Figura 2.2. Se il carattere è qualitativo rilevato su scala ordinale si utilizzano le stesse rappresentazioni avendo cura di rispettare l'ordinamento delle modalità del carattere. Se la variabile è stata introdotta correttamente in R , cioè se abbiamo ordinato i livelli della variabile `factor` in esame, allora la visualizzazione corrispondente sarà corretta.




Figura 2.3 Rappresentazione del fenomeno $Y = \text{"grado di scolarità"}$ tramite rettangoli. I rettangoli hanno tutti la stessa base e vengono rappresentati seguendo l'ordine naturale del fenomeno Y : $A < O < S < L$. L'altezza è proporzionale alle frequenze. Output dei comandi `plot(Y)` e `pie(table(Y))`.

2.4.2 Diagramma a bastoncini

Se il fenomeno è quantitativo discreto come Z allora il semplice comando `plot` porta a risultati non desiderati. R sa che Z è di tipo numerico e quanto si ottiene con il comando `plot(Z)` non è altro che un grafico in cui l'ordinata sono i valori di Z e in ascissa il numero progressivo dell'unità statistica (Figura 2.4 a sinistra). Per rappresentare correttamente la distribuzione di Z si deve utilizzare il comando `plot(table(Z))`. La Figura 2.4 (destra) mostra il grafico a bastoncini corretto. Se il fenomeno è quantitativo discreto questo vuol dire che Z assume esattamente i valori z_1 e non altri. Ciò implica che l'asse orizzontale sia un vero asse delle ascisse con la propria unità di misura contrariamente a quanto avviene per i fenomeni qualitativi. Anche una rappresentazione tramite diagrammi a torta sarebbe corretta (comando `pie(table(Z))`) ma si perderebbe l'informazione relativa al fatto che si tratta di un fenomeno quantitativo.

2.4.3 Istogrammi

Rimane da considerare il caso dei fenomeni quantitativi continui con dati raccolti in classi. In questo caso si usa una particolare rappresentazione a rettangoli chiamata **istogramma**. Negli istogrammi risulta fondamentale costruire un modo adeguato i rettangoli. L'asse delle ascisse è ancora una volta dotato di unità di misura e le basi dei rettangoli corrispondono agli estremi degli intervalli. Per le




Figura 2.4 Rappresentazione del fenomeno $Z = \text{"numero di figli"}$ tramite bastoncini. Il grafico di sinistra è errato ed è stato ottenuto con il comando `plot(Z)`. Quello di destra è invece corretto ed è stato ottenuto con il comando `plot(table(Z))`. Le aste hanno tutte ampiezza 1 punto e vengono posizionate sull'asse delle ascisse rispettando l'unità di misura. L'altezza è proporzionale alle frequenze. Attenzione: sarebbe errato dare un spessore alle barre verticali: si deve utilizzare solo e sempre una linea!

altezze degli intervalli si deve fare in modo che l'area del rettangolo risultante sia pari alla frequenza (relativa o assoluta) della classe stessa: cioè

$$\text{base} \cdot \text{altezza} = \text{frequenza}.$$

L'altezza dovrà quindi essere pari a $d_i = n_i/a_i$. Ecco il motivo per cui sono state introdotte le densità di frequenza. R disegna in modo automatico l'istogramma utilizzando le intensities (Figura 2.5 sinistra) però si può chiedere di forzare il grafico e produrre un istogramma errato le cui altezze dei rettangoli siano proporzionali alle frequenze (Figura 2.5 destra). Come si vede dalla Figura 2.5 nel grafico di sinistra l'ultima classe è sovrarappresentata e questo comporta una distorsione dell'informazione.

```
> hist(W, c(40,50,58,70,95), freq=TRUE) # Errato
Warning message:
the AREAS in the plot are wrong -- rather use 'freq=FALSE'!
in: plot.histogram(r, freq = freq, col = col,
border = border, angle = angle,
> hist(W, c(40,50,58,70,95)) # Corretto
```

il tentativo di utilizzare le frequenze anziché le densità di frequenza non sfugge ad R che segnala con un messaggio il problema. Se le classi sono tutte della stessa




Figura 2.5 Rappresentazione del fenomeno W = "peso" tramite istogramma. Gli istogrammi hanno la base corrispondente agli estremi delle classi e le altezze dei rettangoli sono proporzionali alla densità di frequenza e non alle frequenze assolute o relative. Il grafico di sinistra è sbagliato poiché sono state utilizzate le frequenze (assolute).

ampiezza i due istogrammi sono equivalenti e la base degli intervalli agisce solo come fattore di scala nella rappresentazione degli istogrammi. Nel caso specifico degli istogrammi si può anche lasciar scegliere ad R il numero di classi da utilizzare o fissare il numero di classi a priori ma senza specificare gli estremi degli intervalli. In entrambi i casi gli istogrammi avranno tutti la stessa base. È bene sottolineare che la scelta del numero delle classi può influenzare in modo determinante l'interpretazione dell'istogramma: troppe classi portano ad un istogramma simile ad un grafico a bastoncini e troppe poche classi rendono l'istogramma troppo "piatto". Esistono varie regole empiriche per determinare il numero di intervalli che vanno sotto il nome degli autori che le hanno proposte. R implementa la regola di Sturges, di Scott (si veda [38]) e di Freedman-Diaconis (cfr. [18]). La Tabella 2.6 riporta tali regole dove $x_{(n)} - x_{(1)}$ è il campo di variazione dei dati (massimo-minimo), s_n^2 è la varianza campionaria e $Q_3 - Q_1$ è il range interquartile, tutte misure di variabilità di cui si discuterà nel Paragrafo 2.6 e seguenti. Quello che si può segnalare è che la regola di Sturges risente di eventuali valori estremi o outlier mentre gli altri due metodi, soprattutto l'ultimo, sono meno sensibili a tali valori. I comandi che seguono generano la sequenza di istogrammi riportata in Figura 2.6 con il metodo Sturges, Scott, Freedman-Diaconis e infine utilizzando un numero eccessivo di classi (11).

```
> hist(W, main = "Sturges")
> hist(W, breaks = "Scott", main = "Scott")
```

Metodo

 h

Sturges

$$\frac{I_{(n)} - I_{(1)}}{\log_2 n + 1}$$

Scott

$$3.5 \sqrt{s_n^2} n^{-1/3}$$

Freedman-Diaconis

$$2(Q_3 - Q_1)n^{-1/3}$$

Tabella 2.6 Metodi empirici di scelta dell'ampiezza h delle classi in un istogramma.

```
> hist(W, breaks = "FD", main = "Freedman-Diaconis")
> hist(W, breaks = 11, main = "11 classi")
```

Dalle linee di codice appena viste notiamo che il parametro `breaks` è stato utilizzato in tre differenti modi sinora:

- per fornire il vettore degli estremi delle classi;
- per indicare il metodo empirico di scelta delle classi;
- per stabilire il numero delle classi.

Quando si fissa il numero delle classi R non lo interpreta come un ordine perentorio bensì come suggerimento. Per completezza segnaliamo che l'opzione `breaks` può essere utilizzata anche per specificare una funzione definita dall'utente per il calcolo delle classi. Si noti che la Figura 2.6 riporta in ordinata *frequency*. Questo è del tutto normale in quanto in tutti e quattro i casi gli istogrammi presentano ampiezza di classe costante. Inoltre abbiamo usato il parametro `main` per definire il titolo del grafico. Nell'Appendice A.5 spiegheremo in dettaglio come abbellire o, semplicemente, rendere più leggibili, i grafici e mostriamo come esportare i grafici in diversi formati utili per essere importati all'interno degli applicativi più comuni. Per ora ci accontenteremo di illustrare i comandi e le opzioni all'occorrenza specifica.

M 2.4.4 La funzione di ripartizione

Per i fenomeni quantitativi può risultare utile disegnare la funzione di ripartizione. Questa funzione nel caso discreto è definita a partire dalle frequenze cumulative. La funzione di ripartizione si indica con $F(x)$ ed è definita per ogni valore di x reale. Se indichiamo con $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ i valori distinti e ordinati di un carattere X , allora $F(x) = 0$ se $x < x_{(1)}$, $F(x) = 1$ se $x \geq x_{(n)}$ e invece vale F_i se $x_{(i)} \leq x < x_{(i+1)}$. Si tratta quindi di una funzione a gradini.

La dotazione standard di R prevede la disponibilità del pacchetto `stepfun` che fornisce una serie di comandi per trattare funzioni a gradini. In particolare la funzione `ecdf` (da empirical cumulative distribution function o **funzione di ripartizione empirica**) può essere impiegata per tracciare il grafico della funzione




Figura 2.9 Istogramma di W con sovrapposto il poligono di frequenza ottenuto tramite la funzione `hist.pf` definita nel Codice 2.10.

```
hist.pf <- function(x, br){
  if(missing(br))
    ist <- hist(x)
  else
    ist <- hist(x, breaks=br)
  if(ist$equidist)
    lines(c(min(ist$breaks), ist$mids, max(ist$breaks)),
          c(0, ist$counts, 0))
  else
    lines(c(min(ist$breaks), ist$mids, max(ist$breaks)),
          c(0, ist$intensities, 0))
}
```

Codice 2.10 Algoritmo per il disegno del poligono di frequenza sovrapposto all'istogramma.

Si noti che per il parametro `br` valgono le stesse regole di `hist`, cioè potremmo scrivere `hist.pf(W, "Sturges")` o anche `hist.pf(W, 9)`.

Porsi le domande giuste per il grafico giusto

- il fenomeno è qualitativo?
 - è su scala nominale?
 - * diagrammi a torta: `pie(table(x))`, a rettangoli: `plot(x)` ed eventualmente bastoncini: `plot(table(x))`;
 - è su scala ordinale?
 - * stesse possibilità del caso nominale, ma questa volta si devono ordinare i dati secondo l'ordine naturale del fenomeno statistico, quindi si usa preventivamente `ordered` per fissare un ordinamento tra i livelli (levels) della variabile qualitativa (`factor`);
- il fenomeno è quantitativo?
 - è di natura discreta?
 - * usare solo grafici a bastoncini: `plot(table(x))`, non ha senso utilizzare gli istogrammi. In alcuni casi si possono impiegare anche i grafici a torta: `pie(table(x))`;
 - è di natura continua?
 - * usare solo istogrammi (`hist(x)`) ricordando che le altezze degli istogrammi corrispondono a f_i/a_i . Attraverso l'opzione `breaks` si possono definire gli estremi delle classi, il numero delle classi o il metodo empirico da utilizzare per determinarle;
- non riesco a capire di che tipo di dati si tratta!
 - Torna a pagina 1 e ritenta!

2.5 Indici di posizione

Osservando il grafico di una particolare distribuzione (o confrontandolo con quello di un'altra distribuzione di dati) viene naturale descriverne alcune caratteristiche (o farne confronti) attraverso degli indici di sintesi. Quello che può interessare è capire se esistono un valore o dei valori attorno ai quali si aggregano i dati e, quando questo avviene, quanto i dati siano sparpagliati attorno a tali valori. Abbiamo visto come è possibile estrarre dai dati informazioni sempre più fini quando si passa da fenomeni qualitativi a fenomeni quantitativi. La stessa analogia si ritrova nel calcolo degli indici.

2.5.1 La moda

Il primo indice che può essere calcolato per qualsiasi tipo di distribuzione è la **moda**. La moda è definito come quel valore x_i di un fenomeno statistico che presenta frequenza (n_i o f_i) più elevata. Guardando un istogramma (correttamente disegnato), un diagramma a barre o un diagramma a torta è facile intuire quale sia

la moda: o è in corrispondenza della barra più elevata o del settore circolare più ampio.

Esistono delle eccezioni di cui bisogna tener conto: 1) se il fenomeno è raggruppato in classi (è il caso dell'istogramma) si devono considerare le densità di frequenza d_i , anziché le frequenze n_i (o f_i): in questo caso la moda è definita come punto medio dell'intervallo con densità di frequenza più elevata. 2) se ci sono più valori con frequenza più elevata, allora tutti vengono considerati mode e la distribuzione è detta *plurimodale*.

Non esiste in R un metodo per estrarre il valore modale da una distribuzione di dati in quanto la definizione stessa di moda è sufficiente per capire di cosa si tratti ma ovviamente si può costruire una, per quanto inutile, funzione moda a partire dal comando `table`. Per le variabili X , Y , Z e W considerate sinora un semplice sguardo ai grafici nelle Figure 2.1, 2.3, 2.4 e 2.5 ci dice che la moda di X è C (coniugato/a), quella di Y è S (diploma di scuola superiore), quella di Z è in corrispondenza dei valori 0 ed 1. In tal caso possiamo considerare entrambi i valori come mode. Guardando alla Figura 2.5, se ci si riferisce all'istogramma corretto di destra si vede che la moda è il punto centrale dell'intervallo 50 + 58, ovvero 54. Al contrario, se guardiamo all'istogramma sbagliato, quello di sinistra, l'intervallo con frequenza più elevata è quello di estremi 70 + 95 il cui punto centrale è 82.5!

2.5.2 La mediana, i quartili e i quantili

Si pensi ora al seguente esempio proveniente dal campo medico. In medicina spesso accade che per alcune patologie con esito fatale sia necessario avere un'indicazione di massima sul tempo di vita residuo dei pazienti. Abbiamo scelto il caso del trapianto⁴ di un organo vitale. L'istogramma della Figura 2.11 riporta in ascissa il tempo di vita (t) post-operatorio, in anni, di pazienti sottoposti ad un particolare trapianto di organo. In ordinata abbiamo le densità di frequenza. Per semplicità abbiamo tracciato una curva continua ed è sulla quella che andremo a ragionare. Tale curva può essere interpretata come un poligono di frequenza ottenuto a partire da un numero consistente di classi. Dall'istogramma si intuisce che il tempo di vita t non supera i 20 anni. Quindi l'intervallo di vita dei pazienti si riduce a 0-20 anni. Per un paziente sottoposto ad intervento è molto importante riuscire a capire dove collocarsi sotto tale curva. Se ci atteniamo all'intervallo osserviamo il grafico ci si rende subito conto che gran parte dei pazienti operati ha un tempo di vita inferiore o uguale a 5 anni con una moda, il valore più frequente, 10 anni⁵ è non solo poco informativa, ma addirittura fuorviante. L'informazione che si può correttamente dare è che "il 50% dei pazienti decede entro 4-5 anni".

Histogram of x




Figura 2.11 Distribuzione del tempo di vita dei pazienti che hanno subito un trapianto di organo vitale. In ordinata sono riportate le densità di frequenza d_i e in ascissa i tempi di vita t .

Benché la notizia sia negativa si tratta comunque di un'informazione corretta che ora andremo a circoscrivere con indice chiamato *mediana*.

La **mediana** è definita come quel valore (centrale) che, una volta ordinati i dati del campione, lascia alla sua sinistra e alla sua destra idealmente la metà del campione, cioè che divide a metà la distribuzione dei dati.

Mentre la moda è un concetto naturale qualsiasi sia la natura dei dati a disposizione, la mediana necessita del concetto di ordinamento. Quindi per la variabile X della Tabella 2.1 non avrebbe alcun senso calcolare una mediana.

Vediamo un esempio di calcolo di mediana. Indichiamo con $x_{(i)}$ il dato del campione che, una volta ordinati i dati x_i , occupa la posizione di posto i nella sequenza ordinata, cioè, se i dati x_i sono

$$x_1 = 4, \quad x_2 = 3, \quad x_3 = 4, \quad x_4 = 1, \quad x_5 = 7$$

i dati ordinati corrispondenti sono

$$x_{(1)} = 1, \quad x_{(2)} = 3, \quad x_{(3)} = 4, \quad x_{(4)} = 4, \quad x_{(5)} = 7$$

quindi il valore centrale dei 5 valori della sequenza ordinata è il terzo ($(n+1)/2 = 6/2 = 3$), $x_{(3)} = 4$, cioè la mediana è $Me = 4$. Se la sequenza ha un numero pari di termini, cioè n è pari come nel seguente esempio

$$x_1 = 4, \quad x_2 = 3, \quad x_3 = 1, \quad x_4 = 7$$

⁴Si tratta di dati fittizi creati al solo scopo di chiarire il significato degli indici che stiamo per introdurre.

x_i	n_i	N_i	F_i	x_i	n_i	N_i	F_i
A	2	2	0.1	A	4	4	0.2
O	6	8	0.4	O	6	10	0.5
S	8	16	0.8	S	8	18	0.9
L	4	20	1.0	L	2	20	1.0

20

20

Tabella 2.7 Nella distribuzione di sinistra la mediana è definita ma non lo è in quella di destra poiché le modalità di posto $n/2 = 10$ e $n/2 + 1 = 11$ nella prima tabella coincidono (sono entrambe S) ma non nella seconda tabella ($x_{(10)} = O$ e $x_{(11)} = S$).

con la rispettiva sequenza ordinata

$$x_{(1)} = 1, \quad x_{(2)} = 3, \quad x_{(3)} = 4, \quad x_{(4)} = 7$$

il valore centrale è quello che si trova tra $x_{(2)} = 3$ (posizione $n/2 = 4/2 = 2$) e $x_{(3)} = 4$ (posizione $n/2 + 1 = 4/2 + 1 = 3$). La mediana è allora definita come il valor medio tra i due numeri, quindi $Me = (3 + 4)/2 = 3.5$. Ovviamente tutto questo in R si fa con il semplice comando `median`:

```
> median(c(4, 3, 4, 1, 7))
[1] 4
> median(c(4, 3, 1, 7))
[1] 3.5
```

Se abbiamo a che fare con un fenomeno qualitativo rilevato su scala ordinale come Y è sempre possibile calcolare la mediana (anche attraverso R) ma con una piccola accortezza. Nella Tabella 2.7 sono riportate due differenti distribuzioni di dati per uno stesso fenomeno. Ordiniamo i dati della distribuzione di sinistra della Tabella 2.7

AAAAOOOOO|S|S|SSSSSLLLL

come si vede in posizione $n/2 = 10$ e posizione $n/2 + 1$ si trova la modalità S. Mentre, per la distribuzione di destra abbiamo

AAAAOOOOO|O|S|SSSSSSSL

quindi in posizione $n/2 = 10$ troviamo O ma in posizione $n/2 + 1$ c'è S. Poiché $O \neq S$ concludiamo che la mediana risulta *indeterminata*. Se i dati sono in numero n dispari, la mediana è sempre determinabile.

Proviamo a calcolare la mediana per la variabile Y attraverso R. Il comando `median(Y)` fallirà miseramente perché R si aspetta come argomento di `median` un vettore di numeri. Infatti,

```
> median(Y)
Error in Summary.factor(..., na.rm = na.rm) :
  "sum" not meaningful for factors
```

ma si può comunque ottenere il risultato voluto passando ai codici (`codes`) associati ai livelli di Y . Basterà scrivere

```
> me <- median(codes(Y))
> me
[1] 3
> levels(Y) [me]
[1] "S"
```

Il comando `levels(Y) [me]` non fa altro che prendere il livello di Y di posizione `me`. Se il numero `me` risulta non essere intero, vuol dire che siamo in una situazione in cui la mediana è indeterminata. Prediamo un esempio analogo a quello della distribuzione di destra della Tabella 2.7.

```
> Y2 <- c("L", "O", "A", "O", "L", "S", "S", "O")
> Y2 <- ordered(Y2, levels=c("A", "O", "S", "L"))
> sort(Y2)
[1] A O O S S L L
Levels: A O S L
> me <- median(codes(Y2))
> me
[1] 2.5
> levels(Y2) [me] # R approssima 2.5 a 2
[1] "O" # risultato errato!
```

come si vede $n = 8$ e $x_{(n/2)} = O$ mentre $x_{(n/2+1)} = S$, il valore di `me` è pari a 2.5 e quindi la mediana risulterebbe indeterminata. **Attenzione**: l'istruzione `levels(Y2) [me]` ci restituisce un valore non corretto per il fatto che R trasforma in numeri interi gli argomenti che corrispondono ad indici di vettori. Nella sequenza di comandi qui sopra abbiamo utilizzato il comando `sort` che si occupa semplicemente di ordinare i valori di un vettore. Possiamo a questo punto costruirci una funzione di R per il calcolo della mediana che lavori a partire da qualsiasi tipo di dati come viene riportato nel Codice 2.12.

La funzione `me` così creata è ora in grado di districarsi tra le diverse possibilità. Il flusso dell'algoritmo (cf. Codice 2.12) è il seguente: si verifica se il vettore in input è una variabile qualitativa o meno attraverso il comando `is.factor(x)`. Se è qualitativa si controlla se è anche ordinale, se non lo è `me` ci avverte che non si può calcolare la mediana altrimenti si tenta il calcolo della mediana come visto sopra. Ottenuto il valore `me` si verifica se si tratta di un numero con decimali o meno (non si può utilizzare la funzione `is.integer` perché il risultato di `median` è sempre un numero reale). Se è un numero intero la funzione restituisce il valore della mediana altrimenti ci avverte che si tratta di un caso in cui la mediana risulta indeterminata. Se la verifica attraverso `is.factor(x)` fallisce vuol dire che si tratta di un vettore di numeri e quindi si lascia ad R il calcolo della mediana tramite l'istruzione `median`. Ecco come si comporta `me` con i dati a nostra disposizione

```

Me <- function(x){
  if(is.factor(x)){
    if(!is.ordered(x)){
      warning("La mediana non si puo' calcolare!!!")
      return(NA)
    }
    me <- median(codes(x))
    if(me - floor(me) != 0){
      warning("Mediana indeterminata")
      return(NA)
    }
  } else{
    levels(x)[me]
  }
} else{
  median(x)
}

```

Codice 2.12 Algoritmo per il calcolo della mediana anche per variabili qualitative.

```

> Me(X)
[1] NA
Warning message:
La mediana non si puo' calcolare!!! in: Me(X)
> Me(Y)
[1] "S"
> Me(Y2)
[1] NA
Warning message:
Mediana indeterminata in: Me(Y2)
> Me(Z)
[1] 1.5
> Me(W)
[1] 62.94

```

La mediana è legata al concetto di funzione di ripartizione. In particolare la mediana è quel valore tale per cui $F(Me) = 0.5$, cioè cumulando i valori del campione sino a Me si arriva a considerare il primo 50% di tutte le osservazioni. Con questo criterio si definiscono anche i *quartili* e in generale i *quantili*. Si chiama **primo quartile** quel valore Q_1 tale per cui $F(Q_1) = 0.25$, cioè il valore tale per cui alla sua sinistra troviamo il 25% dei dati e il restante 75% è a destra. Analogamente il **terzo quartile** è definito come il valore Q_3 tale per cui $F(Q_3) = 0.75$. Ovviamente il secondo quartile è la mediana, $Q_2 = Me$. In generale un **quantile** di una distribuzione di dati è quel valore x_p tale per cui $F(x_p) = p$ con $p \in (0, 1)$. È evidente che $Q_1 = x_{0.25}$, $Me = Q_2 = x_{0.5}$ e $Q_3 = x_{0.75}$, cioè tutto può essere ricondotto al calcolo dei quantili. La funzione di R che si occupa di tale calcolo è

quantile. Prima di introdurre la funzione di R, alta allo scopo notiamo che tra Q_1 e Q_3 vi si trova il 50% dei dati ma, a differenza di quanto avviene per la mediana, questo 50% è il 50% *centrale* dell'intera distribuzione dei dati. Passiamo ora ad un esempio di calcolo dei quantili:

```

> quantile(w)
 0%      25%      50%      75%     100%
41.2200 53.4050 62.9400 74.8075 91.2900
> quantile(w, probs=c(.3,.72))
 30%      72%
54.106 73.996

```

La funzione *quantile* applicata ad un vettore numerico restituisce il minimo, il massimo e i 3 quartili principali ma è anche possibile far calcolare ad R i quantili che per qualche motivo ci interessano, come per esempio il quantile $x_{0.3}$ e $x_{0.72}$. Per quanto riguarda il peso W si può dire che il 75% degli individui del campione ha un peso inferiore o uguale a 74.8 kg o che solo il 25% degli individui ha un peso inferiore a 53.4 kg.

Torniamo ora all'esempio dei dati della Figura 2.11. La mediana di tali dati risulta essere pari a 2.3, quindi possiamo concludere che il 50% dei pazienti operati sopravvive all'intervento 2.3 anni cioè 2 anni e poco più di 3 mesi (0.3 parti di un anno). Per questi stessi dati si ottengono valori pari a $Q_1 = 1.21$ e $Q_3 = 4.12$. Quindi, come si vede, il 75% dei pazienti sopravvive al più 4 anni (circa) e solo un 25% di fortunati può sperare in tempi vita più lunghi. Si osservi in proposito la Figura 2.13.

2.5.3 Il boxplot

Nella Figura 2.13 abbiamo anche riportato un grafico schematico dei quartili chiamato **boxplot**. Il boxplot non è altro che il disegno di una scatola, i cui estremi sono Q_1 e Q_3 , tagliata da una linea orizzontale in corrispondenza di Q_2 , cioè della mediana. Come si nota in Figura 2.13, sia dalla distribuzione che dal boxplot, è evidente uno sbilanciamento verso il basso del tempo di vita (il 25% tra Q_1 e Q_2 è più concentrato del 25% che va da Q_2 a Q_3). In basso ed in alto ci sono altre due linee orizzontali (i "baffi") vengono poste ad una distanza da Q_1 e da Q_3 , pari a 1.5 volte la distanza che c'è tra Q_3 e Q_1 . Se oltre quella distanza non ci sono dati campionari o se tutti i dati rientrano negli intervalli così costruiti, il baffo viene posto in corrispondenza del valore più piccolo (quello inferiore) o più grande (quello superiore) del campione. Nel nostro caso, $Q_3 - Q_1 = 4.12 - 1.21 = 2.91$. Se calcoliamo $1.21 - 1.5 \cdot 2.91 = -3.15$. Poiché il tempo di vita non può essere inferiore a 0, la barra orizzontale è stata posta in 0. Per la barra superiore invece: $4.12 + 1.5 \cdot 2.91 = 8.48$. Il resto dei dati campionari che non rientrano nell'intervallo

$$Q_1 - 1.5 \cdot (Q_3 - Q_1); Q_3 + 1.5 \cdot (Q_3 - Q_1)$$

vengono segnati individualmente con dei puntini e rispettando l'unità di misura sull'asse verticale. Tali punti vengono chiamati *valori anomali* o *outlier*. In pre-

senza di outlier, i baffi vengono accorciati all'ultima osservazione campionaria interna all'intervallo sopra definito.

La Figura 2.14 riporta il disegno del boxplot per la variabile W ottenuta con il comando `boxplot(W)`. È evidente che il boxplot può essere disegnato solo per fenomeni continui, infatti, benché i quartili possano essere calcolati anche per i fenomeni qualitativi ordinali, non ha senso calcolare quantità come $Q3 - Q1$ non essendo queste numeriche.

Nel disegnare il boxplot abbiamo discusso le relazioni tra i quartili ed il minimo $x_{(1)}$ e il massimo $x_{(n)}$. Le quantità $Q3 - Q1$ e $x_{(n)} - x_{(1)}$ sono chiamate rispettivamente **intervallo interquartile** e **campo di variazione** (o più semplicemente **range**). Per tutti questi indici esistono dei comandi in R, eccoli in sequenza

```
> min(W)
[1] 41.22
> max(W)
[1] 91.29
> range(W)
[1] 41.22 91.29
```

L'informazione congiunta che ci forniscono riguarda il modo in cui i dati sono dispersi o, viceversa, concentrati. Vedremo tra poco in dettaglio questo concetto.

2.5.4 La media aritmetica

Ogni studente sa calcolare la media dei propri voti senza necessariamente aver frequentato un corso di statistica o aver installato R sul proprio computer. La **media aritmetica** o semplicemente la **media** è uno degli indici maggiormente impiegati dagli statistici. La definizione è molto semplice: si fa la somma di tutte le osservazioni x_i e poi si divide il risultato per il numero di addendi, cioè

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} (x_1 + x_2 + \dots + x_n).$$

È evidente che non si può calcolare la media per un fenomeno qualitativo ma solo per dati numerici, cioè per i fenomeni quantitativi. Se prendiamo quindi i fenomeni Z , numero di figli, e W , il peso, siamo in grado di calcolarne subito il valore. Sarà vero? Prendiamo Z , la sua media si calcola come segue

$$\begin{aligned} \bar{z}_n &= \frac{0+0+0+0+0+1+1+1+1+1+1+2+2+2+2+3+3+3+3+4+4+4+4}{20} \\ &= \frac{5+6+9+16}{20} = \frac{36}{20} = 1.8 \end{aligned}$$

in conclusione, quelli insieme di 20 persone ha **mediamente** 1.8 figli! Si può discutere se arrotondare 1.8 a 2 dicendo "quegli individui hanno circa 2 figli in media"




Figura 2.13 Dati come in Figura 2.11 dove per necessità tipografiche, abbiamo rappresentato solo l'intervallo di tempo 0-10 anni. Tra 0 e $Q1$ si trova il 25% dei dati, così come tra $Q1$ e la mediana $Q2$, tra $Q2$ e $Q3$ e da $Q3$ in poi. Sotto abbiamo riportato anche il boxplot. Il baffo superiore del boxplot è $Q3 + 1.5 \cdot (Q3 - Q1)$ mentre quello inferiore è pari 0, in quanto $Q1 - 1.5 \cdot (Q3 - Q1) < 0$ e i nostri dati sono tutti positivi. I punti fuori dal baffo superiore sono detti **outlier**.




Figura 2.14 Il boxplot per la variabile W . Non ci sono outlier e i due baffi corrispondono con il minimo e il massimo del campione.

oppure lasciare il numero con i suoi decimali a seconda del tipo di informazione che si vuole trasmettere⁵.

Quel tasso (2.1 per l'Italia) è più o meno lo stesso per tutti i paesi, quindi è chiaro che, comunicare un dato come "1,8 figli per donna" significa voler comunicare che se quello fosse il tasso di riproduzione della popolazione, a lungo andare sarebbe una popolazione di persone sempre più anziane per poi estinguersi in assenza di flussi migratori. Attualmente alcuni paesi europei hanno un numero di figli per coppia inferiore a 2. In R il comando da usare è `mean`. Per Z e W otteniamo

```
> mean(Z)
[1] 1.8
> mean(W)
[1] 64.409
```

Abbiamo ottenuto $\bar{w} = 64.409$ a fronte di un valore della mediana (calcolato in precedenza) di $Me = 62.94$, cioè la media è più spostata verso destra. Per analizzare le relazioni che intercorrono tra media e mediana analizziamo il seguente

⁵Circa venti anni fa, in un paese del nord Europa, venne calcolato che per mantenere stabile l'ammontare della popolazione totale, ogni donna doveva generare 2,2 figli. La cosa, chiaramente impossibile da attuare, venne regolata dai servizi sociali nel seguente modo: ogni donna riceveva in età fertile 22 bollini. Ogni volta che generava un figlio o una figlia, cedeva allo stato 10 bollini. Dopo aver generato 2 figli le rimanevano "in tasca" 2 bollini. Poteva decidere se cederli ad un'altra donna o recuperarne 8 da altre donne e quindi generare lei stessa un terzo figlio!

esempio. Supponiamo di avere 3 valori

10 20 30

se calcoliamo la media otteniamo $(10+20+30)/3 = 20$ e per la mediana otteniamo ancora 20. Cambiamo ora un solo valore

10 20 300

la media diventa $(10+20+300)/3 = 110$, mentre la mediana resta sempre pari a 20. Lo stesso accade se cambiamo il valore di sinistra come segue

0 20 30

la media diventa $(0+20+30)/3 = 16.6\bar{6}$ mentre la mediana continua a restare costante. Morale: quando variano i valori estremi di una distribuzione, la media aritmetica ne risente mentre la mediana no. Si dice allora che la mediana è un indice del centro di una distribuzione più robusto della media aritmetica. Per ovviare a questo inconveniente è possibile utilizzare la media troncata (*trimmed*) che è una media aritmetica calcolata non su tutti i dati ma sui dati depurati dai valori estremi. Il comando da utilizzare in R è sempre `mean` ma questa volta si deve specificare l'opzione `trim`. Il valore di `trim` è un numero compreso tra 0 e 0.5 e consiste nella proporzione di osservazioni che R scarta da ciascuna coda della distribuzione prima di effettuare il calcolo della media.

Nell'esempio dei pesi W della Tabella 2.1, si può notare che la coda destra (cioè la parte di estrema destra della distribuzione) è molto allungata, quindi ci saranno dei valori piuttosto elevati che tenderanno a trascinare la media verso destra. Quando le code di una distribuzione sono sbilanciate si parla di *asimmetria*. In assenza di asimmetria, la moda e la mediana sono in genere valori molto vicini tra loro (quando non coincidono addirittura). Si guardi per esempio cosa accade alla media troncata per W

```
> mean(W)
[1] 64.409
> mean(W, trim = 0.1)
[1] 63.84875
> mean(W, trim = 0.3)
[1] 62.8575
> mean(W, trim = 0.5)
[1] 62.94
```

In R esiste un comando molto versatile che agisce sui differenti oggetti fornendo le statistiche principali per quegli oggetti. La funzione in questione si chiama `summary` e il suo output fornisce la maggior parte delle informazioni che abbiamo sin qui visto. Eccone un esempio d'utilizzo per i due fenomeni Z e W il cui output non non merita particolari commenti.

```
> summary(Z)
Min. 1st Qu. Median Mean 3rd Qu. Max.
```

```
> summary(w)
0.00 0.75 1.50 1.80 3.00 4.00
Min. 1st Qu. Median Mean 3rd Qu. Max.
41.22 53.41 62.94 64.41 74.81 91.29
```

Esiste un'ulteriore possibilità in R per analizzare complessivamente un dataframe. Questo modo di procedere è molto utile quando si entra in possesso di un dataset di cui non conosciamo completamente la natura. Si tratta della coppia di comandi `summary` e `str`.

```
> str(data1)
'data.frame':    20 obs. of  4 variables:
 $ X: Factor w/ 4 levels "N","C","V","S": 1 4 3 3 2 1 ...
 $ Y: Factor w/ 4 levels "A","O","S","L": 4 2 1 2 4 3 ...
 $ Z: num 0 1 3 4 1 1 0 2 3 0 ...
 $ W: num 72.5 54.3 50.0 88.9 62.3 ...

> summary(data1)
      X      Y      Z      W
N:6   A:2   Min.   :0.00   Min.   :41.22
C:7   O:6   1st Qu.:0.75   1st Qu.:53.41
V:4   S:8   Median :1.50   Median :62.94
S:3   L:4   Mean   :1.80   Mean   :64.41
      3rd Qu.:3.00   3rd Qu.:74.81
      Max.   :4.00   Max.   :91.29
```

Mentre `str` ci informa sulla natura della matrice dei dati (4 variabili rilevate su 20 osservazioni) il comando `summary` ci elenca le statistiche di interesse principale.

Che strumenti si possono usare?

Indice	Carattere qualitativo nominale	Carattere qualitativo ordinale	Carattere quantitativo
moda	SI	SI	SI
mediana	NO	SI	SI
quantili	NO	SI	SI
boxplot	NO	NO	SI
media	NO	NO	SI
range	NO	NO	SI

2.5.5 Altre medie

Accanto alla media aritmetica vi sono anche altri due tipi di medie che portano il nome di *media armonica* e *geometrica*. In genere i pacchetti statistici non hanno le funzioni predefinite per calcolare tali medie ed R è tra questi, quindi ne scriviamo noi il codice. L'impiego di queste medie è spesso circoscritto ad ambiti molto

particolari per cui ne forniamo solo la formula e il relativo codice senza fornire specifici esempi con il solo scopo di presentare nuove funzioni di R. Per la **media armonica** la formula assume il seguente aspetto

$$x_a = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

ed è chiaro che i valori campionari x_i non ha senso che siano nulli, in tal caso x_a varrebbe 0. Per **media geometrica** si ha invece

$$x_g = \left(\prod_{i=1}^n x_i \right)^{\frac{1}{n}}$$

anche in questo caso valori di x_i nulli rendono poco significativo il calcolo della media geometrica. Nel Codice 2.15 abbiamo usato la funzione `prod` che si occupa di effettuare la produttoria degli elementi del vettore di input. Inoltre, nel caso della media armonica, il codice non verifica se le x_i siano 0 o meno. Questo con R si può fare perché `1/0` è definito come `Inf` che è un oggetto di R ben definito con cui R si comporta in modo appropriato: se c'è almeno un valore $x_i = 0$ nel vettore di input il termine `sum(1/x)` assume il valore `Inf`, quindi nell'eseguire `length(x)/Inf` R restituirà il valore 0 essendo `length(x)` finito e diverso da 0. Si osservi il seguente comportamento di R in presenza infiniti:

```
# R gestisce correttamente gli infiniti
> 3/Inf
[1] 0
> -2/Inf
[1] 0
> 4/Inf
[1] 0
> -5/Inf
[1] 0
> Inf/0
[1] Inf
> Inf/Inf
[1] NaN
```

Ecco ora un esempio di utilizzo delle due medie appena introdotte:

```
> mean.a(w)
[1] 61.2759
> mean.g(w)
[1] 62.82501
> mean(w)
[1] 64.409
> mean.a(z)
[1] 0
> mean.g(z)
```