




Figura 3.19 Retta di regressione $y^* = 0.349 + 2.805x$ sovrapposta alle coppie di punti (x_i, y_i) della Tabella 3.10 ottenuta con il comando `abline(lm(y~x))`.

In questo modo R disegna in rosso la retta di regressione come si vede in Figura 3.19 in cui abbiamo aggiunto anche l'equazione della retta di regressione. Si noti che sia il coefficiente di correlazione che quello della retta dei minimi quadrati dipendono dalla covarianza σ_{xy} , infatti

$$\rho = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y} \quad b = \frac{\sigma_{xy}}{\sigma_x^2}$$

Essendo le quantità al denominatore sempre positive, è evidente che il segno del coefficiente di correlazione e quello del coefficiente della retta dei minimi quadrati sono identici. Se c'è relazione diretta tra X ed Y allora anche la retta dei minimi quadrati dovrà avere inclinazione positiva e viceversa. Inoltre, se il coefficiente di correlazione è nullo questo accade perché σ_{xy} ad essere nulla e quindi anche $b = 0$, ovvero le Y teoriche sono tutte pari ad $a = \bar{y}$ qualsiasi sia il valore di X , ciò sta ad indicare una sostanziale non dipendenza lineare tra le due variabili. Si veda l'esempio alla fine della precedente sezione e si tenga presente il concetto di dipendenza in media.

3.3.3 Previsioni

Una volta in possesso della formula della retta di regressione siamo in grado di descrivere la relazione lineare tra le due variabili e quindi disponiamo di un modello interpretativo per il fenomeno nel suo complesso. Se riteniamo attendibile

il modello, tramite la retta di regressione⁴ sappiamo calcolare quali valori assume Y in corrispondenza di ogni valore di X , cioè siamo in grado di fare *previsioni* o ricostruire i valori mancanti per Y .

Per come è stato costruito, il modello basato sulla retta dei minimi quadrati fornisce risultati attendibili solo per i valori di X compresi nell'intervallo $(x_{\min}, x_{\max})$, cioè tra il valore minimo e massimo dei dati per cui abbiamo calcolato il modello. Se ci spingiamo con la previsione sotto $x_{\min}$ o sopra $x_{\max}$ il metodo dei minimi quadrati non ci fornisce alcuna sicurezza sulla attendibilità dei valori y^* che determiniamo. Prendiamo l'esempio appena svolto. L'intervallo di valori accettabili è $(x_{\min}, x_{\max}) = (3, 29)$. Se prendiamo un valore di X negativo (età negativa?) otteniamo un valore di Y negativo (peso negativo?) entrambi valori privi di alcuna utilità. E ancora, se prendiamo un valore di X molto grande, per esempio $X = 50$ anni, otteniamo un valore di Y pari a $y_{50} = 0.349 + 2.805 \cdot 50 \approx 141$ chilogrammi, e ancora per $X = 70$, $y_{70} \approx 197$ valori decisamente poco credibili poiché è sensato supporre che esista un limite fisico al peso di un individuo della specie umana. Ovviamente non è necessario eseguire manualmente i conti appena visti. Per la previsione dei modelli, e non solo quello di regressione, esiste una funzione apposita in R chiamata `predict`. Nel caso specifico della regressione, la funzione necessita di due parametri: il modello e la nuova matrice dei dati. Anche se se si tratta di un solo numero, la funzione `predict` necessita in input un oggetto di tipo `data.frame`. Per esempio, per ottenere i valori della retta di regressione in corrispondenza di $x = 50$ e $x = 70$ scriveremo

```
> predict(model, data.frame(x=50))
[1] 140.5974
> predict(model, data.frame(x=70))
[1] 196.6967
> predict(model, data.frame(x=c(50, 70)))
      1      2
140.5974 196.6967
```

quindi, come si vede, anche uno scalare deve essere convertito in `data.frame`. Se vogliamo calcolare i valori della retta y_i^* in corrispondenza dei dati campionari, basterà scrivere

```
> predict(model, data.frame(x))
      1      2      3      4      5
31.203651 22.788749 78.888097 48.033455 25.593716
      6      7      8      9     10
11.568879 78.888097 14.373847 34.008618 64.863260
      11     12     13     14     15
17.178814 67.668227 50.838423 59.253325 17.178814
      16     17     18     19     20
62.058292 76.083129 48.033455 76.083129 17.178814
```

⁴L'analisi di regressione deve il suo nome ai primi studi di questo tipo condotti da Galton. Lo studioso era interessato a prevedere l'altezza di alcuni individui primogeniti in relazione a quella dei propri padri. Sulla base di un cospicuo campione, Galton determinò che padri alti generavano in media figli più bassi e padri bassi figli più alti concludendo che l'altezza media *regrediva* di padre in figlio. E a ben pensarci se non fosse così saremmo ora tutti esseri giganti o microscopici!

21	22	23	24	25
81.693064	25.593716	8.763912	34.008618	25.593716
26	27	28	29	30
64.863260	14.373847	76.083129	56.448358	36.813586

Questa procedura può apparire un poco macchinosa, ma in realtà risulta del tutto naturale quando si tratta con grosse moli di dati e più variabili contemporaneamente come vedremo nel Paragrafo 5.7.

Chiudiamo il paragrafo sottolineando che la retta di regressione passa sempre per il baricentro della nuvola di punti, ovvero il punto di coordinate $(\bar{x}, \bar{y})$. Infatti, se pensiamo alla formula del termine noto della retta di regressione: $a = \bar{y} - b\bar{x}$, si ricava direttamente che $\bar{y} = a + b\bar{x}$ e dunque che il punto $(\bar{x}, \bar{y})$ è un punto che si trova sulla retta di regressione.

3.3.4 Bontà di adattamento

Supponendo di dover fare un uso corretto del modello di regressione si può valutare in modo semplice e rapido se il modello così costruito è un *buon* modello applicato ai nostri dati. Sappiamo che, per costruzione, la retta dei minimi quadrati è sicuramente la migliore che passa per i punti su cui è calcolata ma possiamo ulteriormente verificare se i nostri dati sono ben spiegati da questo modello o, viceversa, se il nostro modello è un buon modello per i nostri dati. Come strumento interpretativo utilizziamo i **residui**, cioè gli scarti $e_i = y_i - y_i^*$. Ci dobbiamo aspettare che questi non siano troppo elevati (in termini dell'unità di misura di Y) e che ve ne siano un po' positivi ed un po' negativi ma senza troppa regolarità. La Figura 3.20 mostra i residui calcolati per il nostro modello. Per esempio, quando $x_i = 6$: $y_i^* = 0.349 + 2.805 \cdot 6 = 17.179$ mentre i nostri dati contengono l'informazione $y_i = 14$. Quindi il residuo è pari a $e_i = y_i - y_i^* = 14 - 17.179 = -3.179$. La Figura 3.20 evidenzia un buon comportamento dei residui: ve ne sono alternativamente sopra e sotto lo zero e distribuiti in modo non sistematico. Situazioni in cui i residui con lo stesso segno si concentrano tutti in una zona oppure si ripetono in modo sistematico (come mostrato in Figura 3.21) sono indicatori di una distorsione indotta dal modello matematico della retta di regressione. In tal caso, benché la retta di regressione sia la migliore tra quelle passanti per i punti, è probabilmente un modello interpretativo sbagliato per i nostri dati. Questa analisi grafica dei residui è sempre consigliabile in prima battuta ma, al solito, vedremo come quantificarla con un opportuno indice.

Come ultima nota ricordiamo che mentre il coefficiente di correlazione lineare segnala solo il segno e l'intensità di una eventuale relazione lineare (bidirezionale) tra Y ed X , quando si studia la regressione, cioè si costruisce un modello attraverso la retta dei minimi quadrati, si sottintende implicitamente una relazione di *causalità* tra X ed Y ⁵.

⁵Deve essere ben chiaro che le relazioni $Y = f(X)$ e $X = f(Y)$ non sono la stessa relazione poiché nel primo caso è X a determinare i valori di Y attraverso $f(\cdot)$ mentre nel secondo caso la relazione causale è esattamente opposta. Immaginiamo che X rappresenti la statura e Y il peso




Figura 3.20 Grafico dei residui $e_i = y_i^* - y_i$ per i dati (x_i, y_i) della Tabella 3.10 e la retta di regressione $y^* = 0.349 + 2.805x$.


Un altro tipico tranello dell'analisi di regressione è che il metodo non permette di stabilire se la relazione funzionale (di causa-effetto) che si sta studiando ha realmente significato. Un classico esempio che, dati alla mano, ognuno può verificare, è che la correlazione tra la crescita giornaliera dei capelli di un individuo e la deriva dei continenti, cioè lo scorrere delle placche terrestri sul fondo magmatico, è molto elevata. Si potrebbe quindi creare un modello per spiegare la deriva dei continenti scegliendo come X la crescita giornaliera dei capelli ed Y lo spostamento annuale delle placche continentali. Benché il modello sia palesemente privo di significato, il metodo dei minimi quadrati ci fornisce comunque una soluzione. Questo accade sempre purché si scelgano dati di grandezza sempre crescenti e/o decrescenti. Ricordiamo che la varianza di Y contiene i termini del tipo $(y_i - \bar{y})^2$. Aggiungendo e sottraendo i valori y_i^* otteniamo

$$(y_i - \bar{y} \pm y_i^*)^2 = ((y_i^* - \bar{y}) + (y_i - y_i^*))^2$$

ora, senza entrare nei dettagli, con alcuni passaggi algebrici si ricava che

$$\sigma_y^2 = \sigma_{y^*}^2 + \sigma_e^2 = \frac{1}{n} \sum_{i=1}^n (y_i^* - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (y_i - y_i^*)^2$$

e che il coefficiente di correlazione sia molto prossimo ad 1. È lecito aspettarsi che il peso sia funzione della statura ($Y = f(X)$) ma è molto meno verosimile credere, o far credere, che sia la statura a dipendere dal peso ($X = f(Y)$).



(*) **Figura 3.21** Grafici dei residui "sospetti": in quello di sinistra il modello prima sovrastima ($y_i^* > y_i$) e poi sottostima ($y_i^* < y_i$) i dati reali; nell'altro il modello sovrastima al centro e sottostima negli estremi.

chiamate rispettivamente *varianza dovuta alla regressione* ($\bar{\sigma}_y^2$) e *varianza dei residui* (σ_e^2). Se il modello è un *buon* modello, la varianza di regressione dovrebbe essere il più elevata possibile in quanto, minimizzando la funzione $g(\cdot)$ non abbiamo fatto altro se non minimizzare la varianza dei residui. Ci aspettiamo quindi che sia prossimo ad 1 il valore

$$\frac{\bar{\sigma}_y^2}{\sigma_y^2} \simeq 1$$

e invece prossimo allo 0

$$\frac{\sigma_e^2}{\sigma_y^2} \simeq 0.$$

Dunque, l'indicatore da scegliere per misurare la bontà di adattamento (della retta di regressione ai dati) è

$$R^2 = 1 - \frac{\sigma_e^2}{\sigma_y^2}.$$

Tanto più è alto, tanto più ci riterremo soddisfatti del nostro modello. Si può mostrare che R^2 è pari proprio a ρ^2 , cosa che fa risparmiare parecchi conti! Nel nostro esempio, se calcoliamo tutte le quantità $e_i = y_i - y_i^*$, la varianza dei residui risulta pari a

$$\sigma_e^2 = \frac{1}{n} \sum_{i=1}^n (y_i - y_i^*)^2 = 67.7$$

mentre $\sigma_y^2 = 19284.8/30 = 664.83$. In R si ottiene semplicemente attraverso

```
> predict(model, data.frame(x)) -> yy
> sum((yy-y)^2)/length(y)
[1] 67.69615
> var(y) * (length(y) - 1) / length(y)
[1] 642.8267
```

Otteniamo dunque

$$R^2 = 1 - \frac{67.7}{664.83} = 0.8947 = \rho^2$$

un valore decisamente alto. La regola empirica vuole che valori di $\rho^2 > 0.7$ sia indice di un buon adattamento del modello ai dati⁶. Questi sono strumenti minimi di un'analisi di regressione e non è possibile immaginare un software statistico che non proceda in modo automatico ad eseguire questi calcoli per noi. Infatti, l'output di `lm` è molto essenziale ma contiene invece molte altre informazioni. Per ottenere tali informazioni si deve utilizzare il comando `summary()`.

```
> summary(model)

Call:
lm(formula = y ~ x)

Residuals:
    Min       1Q   Median       3Q      Max
-15.8881  -4.6496   0.3212   3.0091  19.9665

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.3490      3.2406   0.108   0.915
x            2.8050      0.1819  15.423 3.25e-15 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.517 on 28 degrees of freedom
Multiple R-Squared:  0.8947,
Adjusted R-Squared:  0.8909
F-statistic: 237.9 on 1 and 28 DF, p-value: 3.247e-15
```

Il coefficiente R^2 viene indicato da `R` con `Multiple R-Squared`. Il resto dell'output per ora non lo commentiamo ma ci riserviamo di farlo quando avremo in mano strumenti di calcolo delle probabilità ed inferenza statistica adeguati. Per ottenere un grafico dei residui si può applicare in comando `plot` all'output di

⁶ Si noti che questa soglia è del tutto arbitraria e la sua attendibilità dipende dall'applicazione specifica che si sta considerando. Alcuni insiemi di dati possono condurre a valori di R^2 molto più bassi pur essendo propri di buoni modelli di regressione per il semplice fatto che la variabilità interna ai dati può essere molto elevata. Questo è generalmente il caso di dati biomedici.

`lm`, ovvero digitare `plot(model)` nel nostro caso. R riporta una sequenza di quattro grafici, il primo dei quali è quello dei residui. Gli altri grafici verranno commentati più avanti.

3.3.5 Effetto degli outlier sulla retta di regressione

Si consideri il seguente esempio: supponiamo di aver rilevato i dati su 4 aziende relativamente a due variabili X ed Y . Riportiamo i dati nella tabella sottostante e calcoliamo la relativa retta di regressione.

x_i	y_i
1	4
1	3
2	3
2	2

```
> x <- c(1,1,2,2)
> y <- c(4,3,3,2)
> cor(x,y)
[1] -0.7071068
> lm(y~x) -> model
> model
```

```
Call:
lm(formula = y ~ x)
```

```
Coefficients:
(Intercept)      x
         4.5          -1.0
```

```
> abline(model)
> summary(model)
```

```
Call:
lm(formula = y ~ x)
```

```
Residuals:
    1     2     3     4 
0.5 -0.5  0.5 -0.5
```

```
Coefficients:
```

```
Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.5000      1.1180    4.025  0.0565
x          -1.0000      0.7071   -1.414  0.2929

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05
'.' 0.1 '.' 1
```

```
Residual standard error: 0.7071 on 2 degrees of freedom
Multiple R-Squared:  0.5,
Adjusted R-Squared:  0.25
F-statistic:  2 on 1 and 2 DF,  p-value: 0.2929
```

Supponiamo ora di aggiungere un ulteriore dato ai 4 rilevati ottenendo la seguente tabella

x_i	y_i
1	4
1	3
2	3
2	2
8	8

ricalcoliamo tutto quanto ci serve per fare l'analisi di regressione

```
> x <- c(x,8)
> y <- c(y,8)
> cor(x,y)
[1] 0.9035227
> lm(y~x) -> model
> model
```

```
Call:
lm(formula = y ~ x)
```

```
Coefficients:
(Intercept)      x
    1.9885      0.7184
```

```
> abline(model)
> summary(model)
```

```
Call:
lm(formula = y ~ x)
```

```
Residuals:
    1     2     3     4     5 
1.2931  0.2931 -0.4253 -1.4253  0.2644
```

```
Coefficients:
```

```
Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.9885      0.7568    2.628  0.0785
x           0.7184      0.1967    3.652  0.0354 *

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05
'.' 0.1 '.' 1
```