

Relazioni tra variabili e insiemi di dati

3.1 Analisi di dipendenza: la connessione

Sinora ci siamo occupati dello studio di distribuzioni per singoli fenomeni statistici. Ne abbiamo studiato alcuni valori caratteristici e le possibili rappresentazioni grafiche. Abbiamo anche visto come in alcuni casi sia stato possibile, nonché utile, effettuare confronti tra distribuzioni relative allo stesso carattere su diverse popolazioni di individui o di diversi caratteri rilevati sulle stesse unità.

Il passo successivo e naturale è quello di vedere se esistono legami tra due (o più) fenomeni rilevati congiuntamente sugli stessi individui. Per esempio, il peso degli individui dipende dalle loro abitudini alimentari? Oppure, l'incidenza di tumori al polmone è prevalente negli individui fumatori? Ancora, due fenomeni si manifestano in un particolare modo sugli individui, per effetto del caso oppure perché esiste una regolarità (di tipo statistico) non direttamente rilevabile?

Introduciamo delle notazioni che ci serviranno per leggere correttamente i dati relativi a più variabili e a costruire un indice statistico per misurare il grado di legame tra due fenomeni. La Tabella 3.1 è una rappresentazione simbolica di una tabella a doppia entrata o **tabella di contingenza** per due generici fenomeni X ed Y . Vedremo subito un esempio di come si costruisce una tale tabella, ma la lettura dovrebbe essere chiara a tutti. L'idea di una tabella di questo tipo è quella di contare quante volte una particolare coppia di valori (x_i, y_j) si presenta sugli individui. Questo numero è la **frequenza congiunta** e viene indicata con il simbolo n_{ij} .

La prima riga della tabella $(y_1, y_2, \dots, y_k)$ e l'ultima riga $(n_{1.}, n_{2.}, \dots, n_{k.})$ di una tabella di contingenza costituiscono la **distribuzione di frequenza marginale** di Y , che altro non è se non la distribuzione di frequenza di Y . Analogamente, la prima colonna della tabella $(x_1, x_2, \dots, x_h)$ e l'ultima colonna $(n_{.1}, n_{.2}, \dots, n_{.h})$ formano la **distribuzione di frequenza marginale** di X che, anche in questo caso, è semplicemente la distribuzione di frequenza di X . Si noti che le frequenze marginali di X sono state indicate con $n_{.}$. Il "." viene usato come notazione per indicare che si è eseguita la sommatoria dei valori rispetto al secondo indice j ,


```

> rownames(tab)
NULL
> rownames(tab) <- c("S", "B", "O")
> tab
  [,1] [,2] [,3]
S     1     3     0
B     1     3     2
O     2     1     2
> colnames(tab) <- c("S", "B", "O")
> tab
  S B O
S 1 3 0
B 1 3 2
O 2 1 2

```

Ciascuna delle righe e colonne interne alla tabella sono le frequenze che compaiono a quelle che sono chiamate **distribuzioni condizionate**. Consideriamo la prima riga interna della Tabella 3.2:

Y	S	B	O
X = S	1	3	0

Quella che abbiamo scritto qui sopra è la distribuzione di Y limitatamente (cioè, *condizionatamente o subordinatamente*) al sottogruppo di individui che presentano il valore $X = S$. Cioè abbiamo evidenziato la distribuzione condizionata di Y ad $X = S$ che si può indicare come $Y|X = S$. Costruiamo le seguenti due distribuzioni $Y|X = O$ e $X|Y = S$. La frequenza della distribuzione di Y condizionata ad $X = O$ si trovano nella terza riga della tabella mentre quelle di X condizionata ad $Y = S$ sono nella prima colonna. Quindi

Y X = O	S	B	O
$n_{j i=3}$	2	1	2

X Y = S	S	B	O
$n_{i j=1}$	1	1	2

In R è molto semplice estrarre le distribuzioni condizionate da una tabella di contingenza. Infatti, operando direttamente sulle righe e colonne della tabella come se si trattasse di una matrice possiamo ricavarle come segue

```

> table(x,y) -> tabella
> tabella
  Y
  S B O
S 1 3 0
B 1 3 2
O 2 1 2
> # condizionate di Y ad X
> tabella[1,] # Y | X=S
S B O
1 3 0
> tabella[2,] # Y | X=B
S B O
1 3 2
> tabella[3,] # Y | X=O
S B O
2 1 2
> # condizionate di X ad Y
> tabella[,1] # X | Y=S
S B O
1 1 2
> tabella[,2] # X | Y=B
S B O
3 3 1
> tabella[,3] # X | Y=O
S B O
0 2 2

```

Ma esistono anche altre due funzioni di R che ci permettono di estrarre alcune utili distribuzioni. Per esempio, il comando `margin.table` restituisce la distribuzione marginale di X o di Y semplicemente specificando 1 o 2 come secondo argomento. Ovvero

```

> tabella
  S B O
S 1 3 0
B 1 3 2
O 2 1 2
> margin.table(tabella,1)
S B O
4 6 5
> margin.table(tabella,2)
S B O
4 7 4

```

Dove con 1 si specifica la marginale del primo carattere (quello che si trova in colonna) e con 2 l'altro.

Le distribuzioni condizionate di Y ad X possono essere pensate come le distribuzioni del fenomeno Y rilevate su i sottogruppi di individui stratificati secondo i valori assunti dalla variabile X . Quindi, come nella sezione precedente, può avere senso studiare se esistono differenze nel fenomeno Y all'interno dei sottogruppi. Per poter fare dei confronti conviene quindi riscrivere le distribuzioni in termini di frequenze relative. Indichiamo con $f_{ij} = n_{ij}/n$ le frequenze congiunte relative e con $f_{j.} = n_{j.}/n$ e $f_{.i} = n_{.i}/n$ rispettivamente le frequenze relative marginali di Y e di X . Le frequenze condizionate relative si ottengono dividendo ogni frequenza condizionata per il totale (di riga o colonna). Nel caso delle due distribuzioni viste sopra otteniamo

$Y X = 0$	S	B	O	
$f_{j i=3} = \frac{n_{ji}}{n_{.i}}$	2/5	1/5	2/5	1

e in R

```
> tabella[3,]/sum(tabella[3,])
S B O
0.4 0.2 0.4
```

mentre la condizionata di X al sottogruppo $Y = S$ è

$X Y = S$		$f_{i j=1} = \frac{n_{ij}}{n_{.j}}$
S	1/4	
B	1/4	
O	2/4	1

```
> tabella[,1]/sum(tabella[,1])
S B O
0.25 0.25 0.50
```

La Tabella 3.3 riporta le distribuzioni condizionate di X e di Y che possono essere ottenute con R nel seguente modo

Y	S	B	O	
$X = S$	1/4	3/4	0	1
$X = B$	1/6	3/6	2/6	1
$X = O$	2/5	1/5	2/5	1

X	$Y = S$	$Y = B$	$Y = O$
S	1/4	3/7	0
B	1/4	3/7	2/4
O	2/4	1/7	2/4
	1	1	1

Tabella 3.3 Tabella delle distribuzioni condizionate di Y ad X (sopra) e di X ad Y (sotto).

```
> tab2 <- tabella
> tab2[1,] <- tab2[1,]/sum(tab2[1,])
> tab2[2,] <- tab2[2,]/sum(tab2[2,])
> tab2[3,] <- tab2[3,]/sum(tab2[3,])
> print(tab2,digits=2)
```

```
Y
S B O
S 0.25 0.75 0.00
B 0.17 0.50 0.33
O 0.40 0.20 0.40
```

```
attr(,"class")
[1] "table"
> tab3 <- tabella
> tab3[,1] <- tab3[,1]/sum(tab3[,1])
> tab3[,2] <- tab3[,2]/sum(tab3[,2])
> tab3[,3] <- tab3[,3]/sum(tab3[,3])
> print(tab3,digits=2)
```

```
Y
S B O
S 0.25 0.43 0.0
B 0.25 0.43 0.5
O 0.50 0.14 0.5
attr(,"class")
[1] "table"
```

Analogamente a quanto già visto sopra, si possono utilizzare dei comandi di R specifici come `prop.table` il quale calcola le distribuzioni condizionate e la distribuzione congiunta relative per una tabella.

```
> # distribuzione doppia relativa
```

```

> prop.table(tabella)
      S      B      O
S 0.06666667 0.20000000 0.00000000
B 0.06666667 0.20000000 0.13333333
O 0.13333333 0.06666667 0.13333333
> # marginali relative di Y condizionate ad X
> prop.table(tabella,1)
      S      B      O
S 0.25000000 0.75 0.00000000
B 0.16666667 0.50 0.33333333
O 0.40000000 0.20 0.40000000
> # marginali relative di X condizionate ad Y
> prop.table(tabella,2)
      S      B      O
S 0.25 0.4285714 0.0
B 0.25 0.4285714 0.5
O 0.50 0.1428571 0.5

```

Osserviamo le distribuzioni condizionate di Y ad X (Tabella 3.3). Si nota che le tre distribuzioni sono tutte diverse. Se, viceversa, fossero tutte uguali vorrebbe dire che la distribuzione di Y non varia all'interno dei sottogruppi formati dagli individui ripartiti secondo X , cioè, per i dati dell'esempio, il risultato della prova Y non dipende da quanto ottenuto nella prova X . Al contrario, nel nostro caso, una certa forma di dipendenza sembra esistere. Si noti, per esempio, che prendere S nella prova X implica che nella prova Y non si possa ottenere un punteggio O . Possiamo quindi ora introdurre il concetto di **indipendenza**. L'idea è la seguente: se tutte le distribuzioni condizionate sono uguali (per riga e conseguentemente per colonna) allora il presentarsi di una particolare modalità di un fenomeno, non è influenzata dal presentarsi dell'altro. Se tutte le distribuzioni condizionate di X sono uguali, allora sono necessariamente uguali alla distribuzione marginale di X . Viceversa, se tutte le distribuzioni condizionate di Y sono uguali tra loro, allora esse sono necessariamente uguali alla distribuzione marginale di Y . In simboli ciò vuol dire che, per le distribuzioni condizionate di X si ha

$$\left(\text{freq. rel. cond. di } X \text{ ad } Y = y_j \right) \quad \frac{n_{ij}}{n_j} = \frac{n_{i.}}{n} \quad \left(\text{freq. marg. di } X \right)$$

ovvero

$$n_{ij} = \frac{n_{i.} \cdot n_{.j}}{n}$$

e per le distribuzioni condizionate di Y si ha

$$\left(\text{freq. rel. cond. di } Y \text{ ad } X = x_i \right) \quad \frac{n_{ij}}{n_i} = \frac{n_{.j}}{n} \quad \left(\text{freq. marg. di } Y \right)$$

ovvero, ancora una volta,

$$n_{ij} = \frac{n_{i.} \cdot n_{.j}}{n}.$$

In sintesi, se i fenomeni X ed Y sono indipendenti tra loro, la frequenza congiunta n_{ij} deve essere pari al prodotto delle frequenze marginali ($n_{i.} \cdot n_{.j}$) fratto il totale delle osservazioni n . Quindi se X ed Y sono indipendenti, si deve verificare che

$$n_{ij}^* = \frac{n_{i.} \cdot n_{.j}}{n} \quad \text{per ogni } i = 1, \dots, h \quad j = 1, \dots, k.$$

A questo punto viene naturale costruire un indice per misurare quanto le frequenze congiunte di una tabella di contingenza n_{ij} siano vicine (o lontane) a quelle (che ora chiameremo teoriche) di indipendenza n_{ij}^* . Si chiamano **contingence** le distanze $c_{ij} = n_{ij} - n_{ij}^*$. L'indice che viene proposto in letteratura si chiama del Chi-quadrato (χ^2) ed è costruito come segue

$$\chi^2 = \sum_{i=1}^h \sum_{j=1}^k \frac{\left(n_{ij} - n_{ij}^* \right)^2}{n_{ij}^*} = n \cdot \left(\sum_{i=1}^h \sum_{j=1}^k \frac{n_{ij}^2}{n_{i.} \cdot n_{.j}} - 1 \right)$$

come si vede l'indice è costruito per valere 0 quando le frequenze osservate n_{ij} e quelle teoriche n_{ij}^* coincidono, cioè X ed Y sono indipendenti. Viceversa sarà un numero positivo. Per risolvere il problema di capire quando un valore positivo sia realmente dovuto ad un'effettiva forma di dipendenza tra X ed Y si divide l'indice per il suo massimo che è legato al numero di righe e di colonne della tabella. Infatti, si può dimostrare che

$$\chi_{\max}^2 = \max \chi^2 = n \cdot \min(h-1, k-1)$$

L'indice da impiegare sarà quindi dato dalla formula

$$0 \leq \tilde{\chi}^2 = \frac{\chi^2}{\chi_{\max}^2} \leq 1$$

In R si può ottenere il calcolo dell'indice χ^2 in modo immediato: è sufficiente applicare il comando `summary` all'output del comando `table`. Infatti,

```

> summary(tabella)
Number of cases in table: 15
Number of factors: 2
Test for independence of all factors:
  Chisq = 3.527, df = 4, p-value = 0.4738
Chi-squared approximation may be incorrect

```

Il valore che ci interessa è `Chisq = 3.527` che ci basterà dividere per n moltiplicato il minimo tra il numero di righe della tabella meno 1 e il numero di colonne della tabella meno 1, nel nostro caso il valore di normalizzazione è 30, quindi $\tilde{\chi}^2 = 3.527/30 = 0.117$. Tale numero è sufficientemente vicino a 0 per ritenere che l'entità della dipendenza tra i due fenomeni X ed Y sia irrilevante. Nella parte relativa alla verifica di ipotesi vedremo che questa considerazione di tipo qualitativo può essere supportata da uno strumento più preciso per decidere se, a fronte

di un valore pari a 0.117, siamo in presenza di indipendenza oppure no. Possiamo costruire una funzione per il calcolo di χ^2 che chiameremo `chi2`. Quello che ci interessa dell'output di `summary(tabella)` è solo di valore di χ^2 . Per capire come si fa ad estrarlo usiamo il comando `str`

```
> str(summary(tabella))
List of 7
 $ n.vars      : int 2
 $ n.cases     : int 15
 $ statistic   : num 3.53
 $ parameter   : num 4
 $ approx.ok   : logi FALSE
 $ p.value     : num 0.474
 $ call        : NULL
 - attr(*, "class")= chr "summary.table"
```

come si vede, il valore che ci interessa è contenuto in `$statistic`. Quindi costruiamo la funzione `chi2` come riportato nel Codice 3.1. La funzione dimensiona un vettore con le dimensioni di riga e colonna della tabella, mentre il valore `n` corrisponde all'elemento `$n.cases` dell'output di `summary(tabella)`. Quindi otteniamo

```
> chi2(x,y)
[1] 0.1175595
```

```
chi2 <- function(x,y){
  tab <- table(x,y)
  out <- summary(tab)
  out$statistic / ( out$n.cases * min(dim(tab)-1) )
}
```

Codice 3.1 Algoritmo per il calcolo dell'indice di connessione relativo χ^2 .

3.1.1 Rappresentazioni grafiche di tabelle

Le tabelle di contingenza possono essere rappresentate in vari modi. Per esempio, il semplice comando `plot` applicato all'output del comando `table` fornisce una rappresentazione che può essere molto intuitiva da interpretare quando le dimensioni della tabella sono ridotte. Nell'esempio visto precedentemente con il comando `plot(table(x,y))` si ottiene quanto appare in Figura 3.2 (sinistra). In Figura 3.2 sono rappresentati una serie di rettangoli. L'idea è che l'area totale dei rettangoli sia proporzionale all'ammontare dei casi n . Ogni rettangolo rappresenta un incrocio della tabella di contingenza e la sua area rappresenta il peso relativo della coppia dei valori di X ed Y all'interno della distribuzione congiunta. Scorrendo il grafico per riga o per colonna si riconoscono le distribuzioni




Figura 3.2 Rappresentazione grafica di una tabella di contingenza ottenuta tramite il comando `plot(table(x,y))` a sinistra e `plot(table(y,x))` a destra.

condizionate. Nella Figura 3.2 abbiamo riportato due rappresentazioni della stessa distribuzione doppia. La differenza sostanziale è che sull'asse orizzontale è possibile identificare la distribuzione marginale di X nel grafico di sinistra e quella di Y in quella di destra.

Un altro tipo di rappresentazione grafica della tabella di contingenza è il grafico a bolle o `bubbleplot`. Si tratta di un grafico in cui sono presenti due assi che rappresentano le due variabili della tabella di contingenza. Sul grafico si riportano equispaziate in ascissa e ordinata le modalità delle variabili. All'incrocio delle modalità di $X = x_i$ ed $Y = y_j$ si disegna un cerchio di area proporzionale alla frequenza relativa n_{ij}/n . **R** non permette di eseguire direttamente questo tipo di grafici quindi ne proponiamo due versioni che chiameremo `bubbleplot1` i cui algoritmi sono riportati nel Codice 3.3.

```
> x <- c("O", "O", "S", "B", "S", "O", "B", "B", "S",
+       "B", "O", "B", "B", "S", "S", "O", "O", "B",
+       "O", "B", "B", "S", "S", "S", "O", "O", "B",
+       "B", "O", "S", "B", "S", "B")
> y <- c("O", "B", "B", "B", "S", "S", "O", "O", "B",
+       "B", "O", "S", "B", "S", "B")
> x <- ordered(x, levels=c("S", "B", "O"))
> y <- ordered(y, levels=c("S", "B", "O"))
> table(x,y)
  Y
X  S B O
S 1 3 0
B 1 3 2
O 2 1 2
```

Trattamento	Deceduti	Sopravvissuti	Totali
A	175	125	300
B	270	330	600
	445	455	900

Tabella 3.8 Efficacia dei trattamenti A e B a partire dai dati raggruppati.

La Tabella 3.8 mostra che 600 individui sono stati trattati con la terapia B e di questi bene 330 sono sopravvissuti, quindi

$$\text{Trattamento B: } \frac{330}{600} = 55\%$$

mentre delle 300 persone trattate con B, solo 125 risultano curati

$$\text{Trattamento A: } \frac{125}{300} = 42\%.$$

Come si vede ora sembra essere il trattamento B quello più efficace. Questo appare decisamente controintuitivo: se guardiamo ai dati generali osserviamo che B è preferibile ad A, mentre se ci limitiamo all'analisi separata per i due ospedali perveniamo a decisioni opposte. Questo effetto, che può destabilizzare le nostre convinzioni, è noto come **paradosso di Simpson**. In realtà quello che accade è che l'andamento generale del legame tra due fenomeni statistici può apparire alterato (addirittura può cambiare direzione) se ci limitiamo ad analizzarlo in sottogruppi per il semplice motivo che la composizione tra i sottogruppi è molto eterogenea oppure perché c'è un'altra variabile che interagisce con i sottogruppi.

3.1.4 Il paradosso di Simpson (II)

Vediamo ancora un esempio di inversione di direzione nel legame tra due variabili. Presso un grande ateneo americano si ebbe la seguente contestazione: di 1000 posti disponibili per le facoltà di Economia e Lettere, 819 studenti maschi ottennero l'ammissione a fronte di solo 181 studentesse. Le domande inviate erano però 1000 da parte di aspiranti maschi e 1000 da parte delle donne. Ci si chiede se vi sia stata discriminazione.

A ben vedere le domande erano suddivise in due gruppi omogenei: 50% maschi e 50% donne. Mentre gli ammessi sono stati 81.9% maschi e 18.1% donne. L'amministrazione sostiene che non fu così e per dimostrarlo spiegò che in realtà l'apparente discriminazione viene generata da un'aggregazione eccessiva dei dati. Infatti, se guardiamo alla Tabella 3.9 notiamo che maschi e femmine hanno inviato le loro domande in proporzioni diverse alle due facoltà. I maschi hanno scelto

Facoltà (posti)	Maschi:		
	Domande	Ammessi	% Ammessi
Economia (900)	950	814	86%
Lettere (100)	50	5	10%
	1000	819	81.9%

Facoltà (posti)	Femmine:		
	Domande	Ammesse	% Ammesse
Economia (900)	100	86	86%
Lettere (100)	900	95	11%
	1000	181	18.1%

Tabella 3.9 Distribuzione di invio delle domande suddivise in maschi e femmine.

in maggioranza Economia mentre le femmine Lettere. Delle 950 domande inviate dai maschi l'86% di queste sono state accettate. La stessa percentuale si ha per le ragazze che hanno scelto Economia: delle 100 ragazze che hanno fatto domanda 86 di queste sono state ammesse. Analogamente per la facoltà di Lettere. Visto da questo punto di vista si può concludere che non vi sia stata discriminazione. Si imputa quindi ad una forma di autoselezione degli studenti la disparità nel numero di studenti ammessi. La morale è che nella lettura delle tabelle di contingenza si deve fare molta attenzione ad attribuire in modo automatico relazioni ed eventuali direzioni di queste relazioni. Questo tipo di analisi deve quindi essere accompagnato da altre strumenti di indagine non necessariamente di natura esclusivamente statistica.

3.2 Dipendenza in media

Quando uno dei due fenomeni è di tipo quantitativo si può utilizzare questa informazione per eseguire un'analisi più accurata di dipendenza. L'analisi che più correntemente viene utilizzata è quella della **dipendenza in media** che si basa, anziché sul confronto tra le distribuzioni condizionate di un fenomeno Y ai livelli x_i di X, sulla distanza delle medie di Y in ciascuna distribuzione condizionata a $X = x_i$. Si consideri il seguente esempio: è noto che i cuculi depositano le proprie uova in nidi di uccelli ospite. Questi uccelli ospite, se "ingannati" dal cuculo, portano a termine la covata. È evidente che il cuculo riesce ad ingannare solo gli uccelli ospite che hanno uova per dimensione, colore e forma simile a quelle del

cuculo stesso. Accade però che in alcuni territori i cuculi preferiscano, per esempio, gli scriccioli, in altri i pettirossi. Poiché questi due tipi di uccelli hanno uova di lunghezza diversa, ci si deve aspettare che anche le uova dei cuculi nei diversi territori abbiano lunghezza diversa pur trattandosi dello stesso uccello: il cuculo. Se così avviene siamo in presenza di un evidente effetto di selezione naturale per buona pace di Darwin. I dati che riportiamo sono il risultato della misurazione delle uova di cuculo depositate nei nidi di scricciolo e di pettirosso

```
> scricciolo <- c(19.85, 20.05, 20.25, 20.85, 20.85, 20.85,
+ 21.05, 21.05, 21.05, 21.05, 21.25, 21.45, 22.05,
+ 22.05, 22.05, 22.25)
> pettirosso <- c(21.05, 21.85, 22.05, 22.05, 22.05, 22.25,
+ 22.45, 22.45, 22.65, 23.05, 23.05, 23.05, 23.05,
+ 23.05, 23.05, 23.25, 23.85)
> boxplot(scricciolo,pettirosso, names=c("scricciolo",
+ "pettirosso"))
> summary(scricciolo)
  Min. 1st Qu. Median      Mean 3rd Qu.      Max.
 19.85  20.85  21.05  21.13  21.75  22.25
> summary(pettirosso)
  Min. 1st Qu. Median      Mean 3rd Qu.      Max.
 21.05  22.05  22.55  22.58  23.05  23.85
```

La Figura 3.8 riporta i boxplot per i due insiemi di dati. Come si nota la distribuzione della lunghezza delle uova di pettirosso è tutta spostata verso destra (alto). Chiamiamo Y la variabile che rappresenta la lunghezza delle uova e indichiamo con X il tipo di uccello ospite. Osserviamo allora che $\mu_y(x=1) = 21.13$ (scricciolo) mentre $\mu_y(x=2) = 22.58$ (pettirosso), per contro le variabilità nei due gruppi è molto simile

```
> sqrt(sigma2(scricciolo))
[1] 0.718517
> sqrt(sigma2(pettirosso))
[1] 0.6628537
```

e la differenza tra le medie è consistente poiché è circa il doppio dello scarto quadratico medio dei singoli gruppi:

```
> 22.58 - 21.13
[1] 1.45
```

Il grafico in Figura 3.9 riporta le distribuzioni dei due insiemi di lunghezze assieme alle medie di gruppo e alla media generale ottenuto con i seguenti comandi

```
> lunghezza <- c(scricciolo, pettirosso)
> plot(rep(1,length(scricciolo)), scricciolo, xaxt="n",
+      xlim=c(0,3), ylim=c(18,25), xlab="", ylab="lunghezza")
> axis(1,c(1,2),c("scricciolo", "pettirosso"))
> points(rep(2,length(pettirosso)), pettirosso)
> abline(h=mean(lunghezza))
> points(1,mean(scricciolo), pch=4, cex=4, lwd=1.5)
> points(2,mean(pettirosso), pch=4, cex=4, lwd=1.5)
```




Figura 3.8 Boxplot della distribuzione della lunghezza delle uova di cuculo depositate nei nidi di due uccelli ospite: i pettirossi e gli scriccioli. Misure in millimetri.

Per valutare l'entità di tali differenze si utilizza un indice basato proprio sulla distanza delle medie dalla media generale. Per arrivare alla formulazione dell'indice si deve introdurre qualche notazione. Abbiamo già indicato con $\mu_y(x_i)$ la media di Y nel sottogruppo per cui si ha $X = x_i$. In modo analogo si indica con $\sigma_y^2(x_i)$ la varianza all'interno di quel sottogruppo di numerosità n_i . La varianza di Y , σ_y^2 si può riscrivere in termini delle varianze e delle medie dei gruppi. Indicando con μ_y la media di Y si ha, ed è semplice dimostrarlo, che

$$\begin{aligned}\sigma_y^2 &= \frac{1}{n} \sum_{i=1}^h (\mu_y(x_i) - \mu_y)^2 n_i + \frac{1}{n} \sum_{i=1}^h \sigma_y^2(x_i) n_i \\ &= \sigma_y^2 + \mu_y \sigma_y^2(x).\end{aligned}$$

Come si vede, se le medie condizionate fossero tutte uguali tra loro e quindi alla media generale, si osserverebbe un'assenza di dipendenza di Y dai sottogruppi $X = x_i$, ovvero l'appartenenza ad un particolare sottogruppo generato da X non influenza il valor medio di Y . Se invece fossero tutte le varianze condizionate ad essere uguali tra loro, tutta la variabilità di Y sarebbe spiegata in termini di differenza tra le medie e la loro media generale. Sulla base di tali considerazioni viene proposto l'indice di **dipendenza in media**, dovuto ancora una volta a Pearson, e




Figura 3.9 Distribuzione della lunghezza delle uova di cuculo depositate nei nidi di due uccelli ospite: i pettirossi e gli scriccioli. Medie di gruppo "x" e media generale (linea continua). Misure in millimetri.

definito come segue

$$\eta_{y|x}^2 = \frac{\sigma_y^2}{\sigma_y^2 + \sigma_x^2}$$

Quindi $\eta_{y|x}^2$ si annulla in caso di assenza di dipendenza in media e vale 1 quando tutte le varianze condizionate sono nulle. Quest'ultimo caso si verifica solo quando in ogni sottogruppo $X = x_i$ c'è un solo valore di Y e tali valori di Y sono non tutti uguali tra loro, altrimenti $\eta_{y|x}^2$ diventa la forma indeterminata 0/0. Abbiamo costruito la funzione `eta` per il calcolo dell'omonimo indice nel Codice 3.11. L'unica particolarità è l'utilizzo della funzione `by` che si occupa di eseguire una particolare funzione, nel nostro caso la media, su un vettore suddividendolo per gruppi. Nel vettore `my` memorizziamo le medie per gruppo e in quello `ny` le numerosità dei gruppi. Il calcolo dell'indice η^2 segue in modo naturale. La funzione `eta` non verifica se la variabile Y in input sia di tipo numerico.

In modo simmetrico si può definire l'indice $\eta_{x|y}^2$ ammesso però che anche X sia una variabile di tipo numerico. Calcoliamo ora il valore di $\eta_{y|x}^2$ per i dati dei cuculi.

```
> ospite <- c(rep(1, length(scriciolo)),
+             rep(2, length(pettirosso)))
> eta(ospite, lunghezza)
[1] 0.5224852
```




Figura 3.10 Disegno della funzione di regressione. Nel grafico di sinistra l'indice η^2 assume valore elevato in quello di sinistra no.

che è un valore, anche se di poco, superiore a 0.5. L'esempio che segue calcola e disegna (Figura 3.10) la **funzione di regressione** (cioè la spezzata che congiunge i punti del grafico rappresentati dalle medie dei gruppi) in due casi di elevata dipendenza in media e sostanziale indipendenza.

```
> x <- c(rep(1,10), rep(0,23), rep(2,15))
> y <- c(rnorm(10, mean=7), rnorm(23, mean=19),
+       rnorm(15, mean=17))
> eta(x,y)
[1] 0.957145
> y <- c(rnorm(10, mean=8), rnorm(23, mean=7),
+       rnorm(15, mean=6.5))
> eta(x,y)
[1] 0.2116974
```

La funzione `rnorm` genera³ una sequenza di numeri (casuali) centrati attorno al valore mean. In un caso abbiamo generato gruppi di dati con medie molto diverse, nel secondo con medie molto simili.

Ancora sul Titanic e le altre storie Prendiamo ancora una volta i dati del Titanic. Possiamo pensare ad Y come la variabile che vale 1 per ogni individuo morto e 0 per ogni individuo sopravvissuto. Quindi, la media di X non è altro che

³La generazione di numeri casuali viene trattata in dettaglio nel Capitolo 4.

```

eta <- function(x,y){
  plot(x,y, axes=FALSE, main="Dipendenza in media")
  dt <- sort(unique(x))
  axis(2)
  axis(1, dt, dt)
  box()
  my <- by(y,x,mean)
  ny <- by(y,x,length)
  points(dt, my, pch=4, cex=3)
  lines(dt, my, pch=4, cex=3)
  abline(h=mean(y), lty=2)
  sm <- sum((my - mean(y))^2 * ny) / length(y)
  sm/mean((y-mean(y))^2)
}

```

Codice 3.11 Comandi per il tracciamento della funzione di regressione e per il calcolo dell'indice $\eta_{y|x}^2$.

La proporzione di individui morti nel disastro del Titanic $\hat{y}_n = 1490/2201 = 0.68$. Possiamo analizzare la media di Y nei sottogruppi formati dalle classi di imbarco (passaggi di prima, seconda, terza ed equipaggio)

```

> t(as.table(apply(Titanic,c(1,4), sum))) -> tabclass
> tabclass
      Class
Survived 1st 2nd 3rd Crew
No      122 167 528  673
Yes     203 118 178  212
> tabclass[1,]/(tabclass[1,]+tabclass[2,]) -> reg
> reg
      1st      2nd      3rd      Crew
0.3753846 0.5859649 0.7478754 0.7604520

```

Quindi le tre medie sono $\mu_y(x=1) = 0.37$, $\mu_y(x=2) = 0.59$, $\mu_y(x=3) = 0.75$, $\mu_y(x=E) = 0.76$ con notazione ovvia. Possiamo quindi rappresentare su un grafico (Figura 3.12) tali medie

```

> plot(reg, axes=FALSE, type="b")
> abline(h=1490/2201, lty=2)
> axis(1, 1:length(reg), names(reg))
> axis(2)
> box()

```

Il grafico della Figura 3.12 mette bene in evidenza la distanza che c'è tra la percentuale di morti generale e quella delle singole tipologie di imbarco. Calcoliamo direttamente il valore dell'indice




Figura 3.12 Percentuale di morti nel disastro del Titanic al variare della tipologia di imbarco. La linea orizzontale tratteggiata rappresenta la percentuale di morti generale.

```

> n <- sum(tabclass)
> md <- 1490/n
> sy <- md*(1-md)
> nx <- apply(tabclass,2,sum)
> sm <- sum((reg-md)^2 * nx) / n
> sm/sy
[1] 0.08650663

```

cioè $\eta_{y|x}^2 = 0.086$ un valore sufficientemente basso da indurci a pensare ad una sostanziale non dipendenza della variabile "morte" (Y) dalla classe di imbarco (X). Concludiamo la sezione calcolando l'indice η^2 per i dati della Tabella 2.1.

```

> eta(dati$X, dati$W)
[1] 0.01446442
> eta(dati$Y, dati$W)
[1] 0.05075049
> eta(dati$Z, dati$W)
[1] 0.1342489

```

Vale la pena di osservare i grafici della Figura 3.13. Se condizioniamo ad un fenomeno qualitativo R disegna i boxplot, altrimenti un grafico con i punti.

3.2.1 Analisi per gruppi

Molto spesso quando si hanno dati del tipo appena visto, ovvero in cui una delle variabili in gioco è di fatto una variabile di gruppo, è molto utile fare i confronti




Figura 3.13 Disegno della funzione di regressione nel caso dei dati della Tabella 2.1. Sono rappresentati di grafici di W condizionatamente a X , Y e Z . Si noti che R disegna un boxplot quando i dati sono di tipo qualitativo (X e Y) e dei punti se i dati sono di tipo numerico (Z). Gli indici valgono $\eta_{W|X}^2 = 0.014$, $\eta_{W|Y}^2 = 0.051$, $\eta_{W|Z}^2 = 0.134$.

delle diverse analisi per gruppo. Per esempio, si può fare una serie di istogrammi, boxplot, calcolo di indici ecc. gruppo per gruppo. In R tutto questo è molto immediato e si ottiene con una chiamata alla funzione `by` come abbiamo incidentemente fatto notare poco sopra quando abbiamo definito la funzione `eta`. La funzione `by` vuole come primo argomento il vettore di dati su cui eseguire l'eventuale analisi. Il secondo argomento è la variabile di stratificazione o di gruppo e il terzo argomento indica la funzione da utilizzare. Torniamo ai dati dei cuculi.

```
> by(lunghezza, ospite, mean)
INDICES: 1
[1] 21.13

INDICES: 2
[1] 22.575

> sqrt(by(lunghezza, ospite, var))
INDICES: 1
[1] 0.7437357

INDICES: 2
[1] 0.6845923

> par(mfrow=c(1,2))
> by(lunghezza, ospite, boxplot)
> par(mfrow=c(1,1))
```

Si noti che l'ultima chiamata comando `by` produce un output molto lungo che è stato omissso. Ovviamente si può sempre redirigere l'output di `by` in una variabile quando questo non interessa come nel caso dei grafici.

3.3 Analisi di regressione

L'analisi di dipendenza non prevede particolari assunzioni sulle tipologie dei caratteri impiegati dal momento che gli unici ingredienti utilizzati nel calcolo dell'indice di connessione $\tilde{\chi}^2$ sono le frequenze (n_{ij} , $n_{i.}$ e $n_{.j}$). Nel parlare di dipendenza in media abbiamo assunto che uno dei due caratteri sia di tipo quantitativo (per poterne calcolare media e varianza). Passiamo ora all'analisi congiunta di due fenomeni di tipo quantitativo (meglio se continui). Come prima cosa introduciamo un nuovo tipo di grafico, poi estendiamo il concetto di variabilità al caso di due variabili e infine studieremo un caso particolare di dipendenza: la relazione lineare.

3.3.1 I grafici di dispersione e la covarianza

Supponiamo di avere due fenomeni X ed Y di tipo quantitativo e di aver raccolto su n individui le coppie di valori (x_i, y_i) . Abbiamo già visto come raccogliere i dati in tabelle di contingenza come per l'analisi di connessione. Se i dati sono di tipo quantitativo continuo, spesso ogni coppia compare con frequenza unitaria e si avrebbe quindi un'immensa tabella di contingenza (n righe per n colonne) piena di 0 ed 1. L'alternativa è quindi quella di presentare i dati uno di seguito all'altro (se n è piccolo) o meglio rappresentare i dati su grafico detto di **dispersione** (se n è grande) o semplicemente nel rappresentare le coppie di punti su di un piano euclideo. Si sceglie quale variabile mettere in ascissa e quale in ordinata ed una volta fissate le unità di misura sugli assi, si disegnano dei punti in corrispondenza delle coppie (x_i, y_i) . Supponiamo di aver raccolto i seguenti dati

x_i	2	3	4	2	5	4	5	3	4	1
y_i	5	4	3	6	2	5	3	5	3	3

Scegliamo di porre la variabile X sull'asse delle ascisse e la Y sull'asse delle ordinate. Prendiamo la prima coppia di valori $(x_1, y_1) = (2, 5)$. In corrispondenza di $x = 2$ ed $y = 5$ tracciamo un punto. Si procede poi con le altre coppie di punti. Il risultato finale è la **nuvola di punti** che può essere ottenuto con il semplice comando `plot`.

```
> x <- c(2,3,4,2,5,4,5,3,4,1)
> y <- c(5,4,3,6,2,5,3,5,3,3)
> plot(x, y)
```

La Figura 3.14, decisamente più "rifinita", è stata invece ottenuta come segue

```

> x <- c(2,3,4,2,5,4,5,3,4,1)
> y <- c(5,4,3,6,2,5,3,5,3,3)
> plot(x, y, axes=FALSE)
> axis(1, c(mean(x), 0:6),
+      c(expression(bar(x)), 0:6))
> axis(2, c(mean(y), 0, 1, 2, 3, 5, 6),
+      c(expression(bar(y)), 0, 1, 2, 3, 5, 6))
> box()
> lines(c(2,2,0), c(0,5,5), lty=2)
> points(2,5, pch = 3, cex = 3, col = "red", lty=2)
> lines(c(3,3,3,3,0), c(0,3,9,3,9), lty=3)
> text(3.6, 3.9, expression(list(bar(x)[n], bar(y)[n])))
> points(mean(x), mean(y), pch = 4, cex = 3, col = "red")

```

Nella precedente sequenza di comandi l'unica nuova funzione introdotta è `text`. Il comando `text` si occupa in modo ovvio di scrivere un testo su un grafico preesistente e i primi due parametri della funzione sono le coordinate (ascissa e ordinata) del punto in cui si vuole far comparire il testo. Tali coordinate sono espresse nelle rispettive unità di misura degli assi. Il terzo argomento è il testo che, nel caso specifico, è stato introdotto come `expression`. Per chi mastica un po' di TeX possiamo dire che `expression` è un modo versatile di introdurre notazione matematica non banale in un grafico di R. Ne ripareremo più avanti. Ricordiamo che il comando `points` si occupa di rappresentare dei simboli in corrispondenza di specificate coordinate (nel nostro caso un "+" in corrispondenza del punto (2,5) e un "x" in corrispondenza di $(\bar{x}_n, \bar{y}_n)$).




Figura 3.14 Esempio di grafico di dispersione. A titolo di esempio abbiamo segnato con il "+" il punto di coordinate $(x_i, y_i) = (2, 5)$ e con il simbolo "x" il baricentro della nuvola dei punti, cioè il punto di coordinate $(\bar{x}_n, \bar{y}_n) = (3.3, 3.9)$.

Il grafico di dispersione è così chiamato perché è pensato con l'idea di verificare, graficamente, se le coppie di punti (e quindi i fenomeni statistici), presentano una qualche forma di regolarità ed in particolare, per vedere come i punti si disperdono attorno ad un particolare punto. Il punto di riferimento scelto è detto **baricentro** della nuvola dei punti e corrisponde al punto di coordinate $(\bar{x}_n, \bar{y}_n)$. Nel nostro esempio $\bar{x}_n = 3.3$ e $\bar{y}_n = 3.9$. Per dare una valutazione analitica di quanto si può osservare dal grafico si introduce un indice che serve a misurare la dispersione dei punti dal proprio centro, tale indice è la **covarianza**. Il nome dell'indice lascia intuire che si tratta di un'estensione al caso di due fenomeni della varianza. La covarianza si basa sulla misura degli scarti delle x_i dalla propria media $(x_i - \bar{x}_n)$ e delle y_i dalla propria media $\bar{y}_n$, cioè: $y_i - \bar{y}_n$. La covarianza, al contrario della varianza, si occupa anche di misurare l'eventuale direzione del legame ovvero, se i due fenomeni si muovono nella stessa direzione o in direzioni opposte. In sintesi, quando X tende a crescere lo stesso accade anche per Y o invece questa tende a decrescere? Guardiamo ai punti della Figura 3.14. Quello che si vede è che quando X passa da 3 a 4 (cioè cresce) la Y decresce. Quindi, si può notare che la X ed la Y si muovono, tendenzialmente, in direzioni opposte. La covarianza segnala una concordanza (sia X che Y crescono o crescono) con un segno "+" e una discordanza (quando X cresce Y decresce o viceversa) con il segno "-". L'indice è definito come segue

$$\sigma_{xy} = \text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)(y_i - \bar{y}_n)$$

e si può riscrivere in forma equivalente come segue

$$\sigma_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i \cdot y_i) - \bar{x}_n \cdot \bar{y}_n$$

formula molto meno dispendiosa in termini numerici. La Figura 3.15 mette in evidenza l'idea con cui è costruito l'indice quindi rimandiamo alla didascalia della figura stessa per l'interpretazione della covarianza. Si noti che $\text{Cov}(X, X) = \sigma_{xx} = \sigma_x^2$. Dalla lettura del grafico di dispersione ci si rende facilmente conto di quale segno sarà la covarianza: positivo per i dati della Figura 3.15 e negativo per i dati della Figura 3.14. In R è già definita la funzione `cov` che però è costruita dividendo la sommatoria per $n-1$ anziché per n . Quindi scriviamo noi stessi (cfr. Codice 3.16) una funzione per il calcolo della covarianza che chiameremo `COV` (poiché in R `CIAO` e `CLAO` sono due nomi diversi). Per i nostri dati otteniamo

```

> COV(x, y)
[1] -0.77
> cov(x, y)
[1] -0.8555556

```

Come si vede quando n è piccolo, come in questo caso, si possono ottenere risultati differenti con le due formule. Quello che però emerge è che la covarianza




Figura 3.15 Sul grafico di dispersione abbiamo rappresentato le coppie di punti (x_i, y_i) . Abbiamo quindi diviso il grafico in quattro quadranti tracciando le medie di X ed di Y . Quello che si nota è che per ogni coppia di punti del quadrante I si ha che $(x_i - \bar{x}) > 0$ e congiuntamente $(y_i - \bar{y}) > 0$. Il prodotto dei due termini $(x_i - \bar{x})(y_i - \bar{y})$ sarà quindi un valore positivo. Abbiamo evidenziato con un tratteggio quanto detto. Per i punti nel quadrante II osserviamo che $(x_i - \bar{x}) < 0$ mentre $(y_i - \bar{y}) > 0$ quindi il prodotto dei termini è negativo. Per il quadrante III entrambi i termini sono negativi quindi il prodotto è positivo. Infine, per i punti nel quadrante IV, si ha un termine positivo $(x_i - \bar{x})$ ed uno negativo $(y_i - \bar{y})$ e quindi ancora un prodotto negativo.

assume segno negativo avvalorando l'ipotesi iniziale di relazione inversa tra le variabili. Resta il problema di come interpretare il valore di σ_{xy} che si risolve passando ad un indice relativo basato sulla seguente osservazione che riguarda le relazioni tra varianze e covarianza, infatti si può mostrare che

$$-\sigma_x \cdot \sigma_y \leq \sigma_{xy} \leq \sigma_x \cdot \sigma_y.$$

Il che vuol dire che possiamo costruire un indice relativo semplicemente dividendo σ_{xy} per il prodotto degli scarti quadratici medi di X ed Y . L'indice così ottenuto assumerà valori tra -1 ed 1. Tale indice si chiama **coefficiente di correlazione** e si indica con ρ , la lettera "r" dell'alfabeto greco. Si ha dunque

$$\rho_{xy} = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y} \quad -1 \leq \rho_{xy} \leq 1$$

In particolare

$$\rho_{xy} = \begin{cases} 0, & \text{solo se } X \text{ ed } Y \text{ sono incorrelate} \\ 1, & \text{solo se } X \text{ ed } Y \text{ sono legate da una relazione lineare diretta} \\ -1, & \text{solo se } X \text{ ed } Y \text{ sono legate da una relazione lineare inversa} \end{cases}$$

Qui sopra viene espressamente citato il termine **relazione lineare**. In effetti, l'indice ρ è in grado di misurare se vi è o meno una relazione lineare tra X ed Y cioè se le coppie di valori (x_i, y_i) sono allineate lungo una retta del tipo $y_i = a + b \cdot x_i$. Quando tra X ed Y non si presenta una regolarità di quelle viste sinora (se X cresce allora Y cresce in modo proporzionale o viceversa) si rileva un'assenza di relazione lineare tra X ed Y e il valore dell'indice ρ è circa pari a 0. Quando siamo in questa condizione si dice che X ed Y sono incorrelate. Il comando R da utilizzare è `cor`.

```
COV <- function(x,y){
  sum(x*y)/length(x) - mean(x)*mean(y)
}
# definizione alternativa
# da utilizzare preferibilmente
COV <- function(x,y){
  cov(x,y)*(length(x)-1)/length(x)
}
```

Codice 3.16 Funzione per il calcolo della covarianza. Nella prima non vi è alcun controllo sulla conformità dei vettori x ed y mentre, nel secondo caso, il controllo viene effettuato dalla funzione interna di R `COV`.

Si noti che l'assenza di relazione lineare non implica che non siano presenti altri tipi di relazione. Consideriamo il seguente esempio

x_i	-2	-1	0	0	1	2
y_i	4	1	0	0	1	4

```
> x <- c(-2, -1, 0, 0, 1, 2)
> y <- c(4, 1, 0, 0, 1, 4)
> plot(x,y, main="parabola")
> cor(x,y)
[1] 0
```

quindi

$$\rho_{xy} = \frac{1}{6} \sum_{i=1}^6 x_i y_i - \bar{x}_n \bar{y}_n = \frac{0}{6} - 0 \cdot 0 = 0,$$




Figura 3.17 Controesempio: $\rho = 0$ ma $\bar{\chi}^2 = 1$. C'è massima dipendenza di Y da X , infatti $Y = X^2$.

ovvero c'è assenza di relazione lineare tra X ed Y . Ed infatti la relazione è di tipo quadratico essendo $y_i = x_i^2$ (si osservi il grafico in Figura 3.17). Costruiamo la tabella a doppia entrata e calcoliamo l'indice di connessione per verificare che X ed Y non sono indipendenti

```
> table(x,y)
      y
x      0  1  4
-2  0  0  1
-1  0  1  0
 0  2  0  0
 1  0  1  0
 2  0  0  1
```

e quindi calcoliamo il valore di χ^2 che risulta essere pari a

```
> summary(table(x,y))
Number of cases in table: 6
Number of factors: 2
Test for independence of all factors:
  ChiSq = 12, df = 8, p-value = 0.1512
Chi-squared approximation may be incorrect
```

cioè $\chi^2 = 12$ ma la costante di normalizzazione di χ^2 è proprio 12, quindi $\bar{\chi}^2 = 1$.

(x_i, y_i)	(x_i, y_i)	(x_i, y_i)	(x_i, y_i)	(x_i, y_i)
(11, 28)	(6, 14)	(29, 95)	(8, 21)	(24, 58)
(9, 12)	(28, 63)	(18, 54)	(3, 1)	(17, 42)
(21, 67)	(12, 30)	(9, 28)	(6, 18)	(9, 34)
(4, 2)	(22, 64)	(23, 67)	(28, 80)	(27, 65)
(5, 20)	(5, 19)	(17, 68)	(27, 75)	(12, 33)
(27, 77)	(20, 59)	(23, 60)	(6, 17)	(13, 55)

Tabella 3.10 Rilevazione statistica di $n = 30$ coppie di valori (x_i, y_i) per le variabili $X = \text{età}$ ed $Y = \text{peso}$.

3.3.2 La retta di regressione

Ricordiamo che mentre l'indipendenza è una relazione simmetrica, la dipendenza non lo è. L'analisi che stiamo per condurre riguarda un particolare tipo di relazione tra una variabile X ed una Y : quella lineare. Metteremo anche in risalto l'asimmetria di tale relazione.

Se abbiamo rilevato X ed Y su n individui della popolazione avremo a disposizione n coppie di numeri (x_i, y_i) , $i = 1, \dots, n$ (che, per semplicità, supponiamo distinti) come quelli riportati nella Tabella 3.10. Abbiamo già visto che possiamo rappresentare graficamente queste coppie di numeri in un grafico di dispersione ponendo la variabile X in ascissa ed Y in ordinata, così come mostra la Figura




Figura 3.18 Rappresentazione delle coppie di punti (x_i, y_i) sul piano cartesiano relativi alla Tabella 3.10.

3.18. Dal grafico di dispersione ci aspettiamo un valore positivo per la covarianza e quindi per ρ . Quello che ci chiediamo ora è se esiste una qualche relazione funzionale tra la variabile X e la variabile Y del tipo $Y = f(X)$. Dalla figura si può notare che al crescere dei valori di X crescono, tendenzialmente, anche i valori di Y . Questa relazione di proporzionalità ricorda quella della retta di equazione $Y = f(X) = a + b \cdot X$ e, a meno di una certa variabilità intrinseca in essi, i dati sembrano proprio disporsi su una retta crescente ed uscente dall'origine. Cerchiamo allora di vedere quali siano i valori di a e b che rendono la retta $Y = a + b \cdot X$ la più vicina alle coppie dei punti di coordinate (x_i, y_i) . Cerchiamo dunque una retta che passi più o meno vicino a tutti i punti. I punti della eventuale retta $Y = a + b \cdot X$ sono le coppie di punti $(x_i, a + b \cdot x_i)$ che, per comodità, indichiamo con (x_i, y_i^*) . Gli y_i^* sono i valori, che chiameremo d'ora in avanti, teorici o previsti che la variabile Y dovrebbe assumere quando la X assume il valore x_i se il vero modello, cioè la vera relazione tra X ed Y , fosse quello ipotizzato: $Y = a + b \cdot X$. Il coefficiente di correlazione ρ_{xy} misura appunto quanto bene i dati sono allineati lungo una tale retta. Quando abbiamo introdotto l'indice abbiamo detto che il suo valore è pari a 1 se i dati sono esattamente allineati lungo una retta crescente e vale -1 in caso contrario (la retta è decrescente). A parte il valore 0 che indica incorrelazione, tutti gli altri valori tra -1 e 0 e tra 0 e 1 sono in generale difficilmente interpretabili. Come regola empirica si può assumere che valori da 0.85 ad 1 (rispettivamente da -1 a -0.85) fanno sospettare di una relazione lineare di tipo diretto (rispettivamente inverso), negli altri casi si sospende il giudizio.

Ricordiamo che quando $\rho_{xy} = 0$ ciò non esclude che X ed Y non possano essere legate da altre relazioni come per esempio $Y = \log(x) + \sin(x^3)$ o altre mostruosità del genere. Inoltre, un valore non nullo di ρ non implica che vi sia una relazione funzionale tra X ed Y ma solo che i due fenomeni variano in modo concorde (segno "+") o discorde (segno "-").

```
> x <- c(11, 8, 28, 17, 9, 4, 28, 5, 12, 23, 6, 24, 18, 21, 6, 22,
+       27, 17, 27, 6, 29, 9, 3, 12, 9, 23, 5, 27, 20, 13)
> y <- c(28, 21, 63, 42, 28, 2, 80, 19, 33, 60, 14, 58, 54, 67,
+       18, 64, 65, 68, 77, 17, 95, 12, 1, 30, 34, 67, 20, 75, 59, 55)
> plot(x, y)
> cor(x, y)
[1] 0.9458805
```

Il coefficiente di correlazione ρ , nel caso dei punti considerati, assume il valore 0.95, un valore dunque molto elevato che giustifica l'obiettivo della ricerca della retta interpolante i nostri dati. Ma in che termini cerchiamo "la retta migliore" passante per i punti (x_i, y_i) ? Se y_i sono i punti effettivamente osservati e y_i^* quelli che dovremmo aspettarci dal modello $Y = a + b \cdot X$, allora le quantità $y_i - y_i^*$ sono tutti indicatori della distanza tra i punti osservati e quelli teorici. Per motivi di ordine analitico è conveniente scegliere la distanza detta *quadratica*, cioè $(y_i - y_i^*)^2$ un po' come abbiamo fatto quando abbiamo definito la varianza. Ne consegue che la distanza totale tra tutte le coppie di punti è data

dalla funzione

$$\sum_{i=1}^n (y_i - y_i^*)^2 = \sum_{i=1}^n (y_i - (a + b \cdot x_i))^2 = g(a, b).$$

Questa funzione dipende solo dalle quantità a e b dato che le coppie di valori x_i ed y_i sono state osservate, cioè sono dei numeri e non più delle variabili. Il nostro scopo è quello di determinare i valori di a e b che rendono minima la funzione $g(a, b)$. È molto semplice far vedere che i coefficienti a e b della retta di regressione che stiamo cercando sono i seguenti

$$b = \frac{\sigma_{xy}}{\sigma_x^2} \quad a = \bar{y} - b \cdot \bar{x}$$

In R esiste una funzione molto versatile per la stima dei parametri di un modello di regressione lineare (cioè dei coefficienti della retta di regressione) e si tratta del comando `lm` dove "l" ed "m" sono le iniziali di linear model. Spesso in statistica si indica un modello del tipo

$$Y = a + b \cdot X$$

con la notazione

$$Y \sim a + b \cdot X$$

R rispetta questa convenzione per specificare i modelli: il comando da utilizzare è semplicemente `lm(y~x)` dove, se la tastiera non prevede un tasto apposito, il simbolo `~` si inserisce tramite tastiera digitando la sequenza di tasti `alt 1 2 6`. Otteniamo dunque quanto segue

```
> lm(y~x)
Call:
lm(formula = y ~ x)

Coefficients:
(Intercept)          x 
      0.349         2.805
```

dove `Intercept` è il valore dell'intercetta a della retta di regressione e il numero sotto ad x è il coefficiente angolare b della stessa retta. Nel nostro esempio quindi, la retta di regressione assume la forma

$$Y = 0.349 + 2.805 \cdot X.$$

Possiamo ora tracciare tale retta sul grafico utilizzando il comando `abline` passando `lm(y~x)` come argomento. Quindi

```
> lm(y~x) -> model
> plot(x, y)
> abline(model, col="red", lwd=2)
> text(10, 80, expression(y[1]=0.349 + 2.805*x[1]))
```




Figura 3.19 Retta di regressione $y^* = 0.349 + 2.805x$ sovrapposta alle coppie di punti (x_i, y_i) della Tabella 3.10 ottenuta con il comando `abline(lm(y~x))`.

In questo modo R disegna in rosso la retta di regressione come si vede in Figura 3.19 in cui abbiamo aggiunto anche l'equazione della retta di regressione. Si noti che sia il coefficiente di correlazione che quello della retta dei minimi quadrati dipendono dalla covarianza σ_{xy} , infatti

$$\rho = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y} \quad b = \frac{\sigma_{xy}}{\sigma_x^2}$$

Essendo le quantità al denominatore sempre positive, è evidente che il segno del coefficiente di correlazione e quello del coefficiente della retta dei minimi quadrati sono identici. Se c'è relazione diretta tra X ed Y allora anche la retta dei minimi quadrati dovrà avere inclinazione positiva e viceversa. Inoltre, se il coefficiente di correlazione è nullo questo accade perché è σ_{xy} ad essere nulla e quindi anche $b = 0$, ovvero le Y teoriche sono tutte pari ad $a = \bar{y}$ qualsiasi sia il valore di X , ciò sta ad indicare una sostanziale non dipendenza lineare tra le due variabili. Si veda l'esempio alla fine della precedente sezione e si tenga presente il concetto di dipendenza in media.

3.3.3 Previsioni

Una volta in possesso della formula della retta di regressione siamo in grado di descrivere la relazione lineare tra le due variabili e quindi disponiamo di un modello interpretativo per il fenomeno nel suo complesso. Se riteniamo attendibile

il modello, tramite la retta di regressione⁴ sappiamo calcolare quali valori assume Y in corrispondenza di ogni valore di X , cioè siamo in grado di fare *previsioni* o ricostruire i valori mancanti per Y .

Per come è stato costruito, il modello basato sulla retta dei minimi quadrati fornisce risultati attendibili solo per i valori di X compresi nell'intervallo $(x_{\min}, x_{\max})$, cioè tra il valore minimo e massimo dei dati per cui abbiamo calcolato il modello. Se ci spingiamo con la previsione sotto $x_{\min}$ o sopra $x_{\max}$ il metodo dei minimi quadrati non ci fornisce alcuna sicurezza sulla attendibilità dei valori y^* che determiniamo. Prendiamo l'esempio appena svolto, l'intervallo di valori accettabili è $(x_{\min}, x_{\max}) = (3, 29)$. Se prendiamo un valore di X negativo (età negativa?) otteniamo un valore di Y negativo (peso negativo?) entrambi valori privi di alcuna utilità. E ancora, se prendiamo X molto grande, per esempio $X = 50$ anni, otteniamo un valore di Y pari a $y_{50} = 0.349 + 2.805 \cdot 50 \approx 141$ *chilogrammi*, e ancora per $X = 70$, $y_{70} \approx 197$ valori decisamente poco credibili poiché è sensato supporre che esista un limite fisico al peso di un individuo della specie umana. Ovviamente non è necessario eseguire manualmente i conti appena visti. Per la previsione dei modelli, e non solo quello di regressione, esiste una funzione apposita in R chiamata `predict`. Nel caso specifico della regressione, la funzione necessita di due parametri: il modello e la nuova matrice dei dati. Anche se se si tratta di un solo numero, la funzione `predict` necessita in input un oggetto di tipo `data.frame`. Per esempio, per ottenere i valori della retta di regressione in corrispondenza di $x = 50$ e $x = 70$ scriveremo

```
> predict(model, data.frame(x=50))
[1] 140.5974
> predict(model, data.frame(x=70))
[1] 196.6967
> predict(model, data.frame(x=c(50, 70)))
 1      2
140.5974 196.6967
```

quindi, come si vede, anche uno scalare deve essere convertito in `data.frame`. Se vogliamo calcolare i valori della retta y_i^* in corrispondenza dei dati campionari, basterà scrivere

```
> predict(model, data.frame(x))
 1      2      3      4      5
31.203651 22.788749 78.888097 48.033455 25.593716
 6      7      8      9     10
11.568879 78.888097 14.373847 34.008618 64.863260
 11     12     13     14     15
17.178814 67.668227 50.838423 59.253325 17.178814
 16     17     18     19     20
62.058292 76.083129 48.033455 76.083129 17.178814
```

⁴L'analisi di regressione deve il suo nome ai primi studi di questo tipo condotti da Galton. Lo studioso era interessato a prevedere l'altezza di alcuni individui primogeniti in relazione a quella dei propri padri. Sulla base di un cospicuo campione, Galton determinò che padri alti generavano in media figli più bassi e padri bassi figli più alti concludendo che l'altezza media *regrediva* di padre in figlio. E a ben pensarci se non fosse così saremmo ora tutti esseri giganti o microscopici!