

```

> VRpa <- function(a, vx, vy, mx, my, rxy) {
+   vv <- sqrt(a^2*vx+(1-a)^2*vy+
+   2*a*(1-a)*rxy*sqrt(vx)*sqrt(vy))
+   mm <- a*mx+(1-a)*my
+   return(list(vv=vv, mm=mm))
+ }
>
> a <- seq(0,1,0.1)
> mx <- 0.10
> my <- 0.08
> vx <- 0.0872^2
> vy <- 0.0841^2
>
> rr1 <- VRpa(a, vx, vy, mx, my, 0.2)
> rr2 <- VRpa(a, vx, vy, mx, my, -0.3)
> rr3 <- VRpa(a, vx, vy, mx, my, -1)
> rr4 <- VRpa(a, vx, vy, mx, my, 1)
> rr5 <- VRpa(a, vx, vy, mx, my, 0)
> plot(c(rr4$vv, rr3$vv), c(rr4$mm, rr3$mm), type="l",
+       xlim=c(0,0.10), lwd=2, xlab=expression(sigma(R[p])),
+       ylab=expression(E(R[p])))
> lines(rr1$vv, rr1$mm)
> lines(rr2$vv, rr2$mm)
> lines(rr3$vv, rr3$mm)
> lines(rr5$vv, rr5$mm, lty=3, lwd=2)
> text(0.06, 0.09, expression(rho==0))
> text(0.04, 0.09, expression(rho==+0.2))
> text(0.075, 0.09, expression(rho==+0.3))
> text(0.02, 0.095, expression(rho=-1))
> text(0.02, 0.085, expression(rho=-1))
> text(0.095, 0.09, expression(rho==+1))

```

4.2.3 Esperimento di Bernoulli e variabili casuali derivate

Un esperimento casuale che consiste in un insieme di **prove ripetute** con le seguenti caratteristiche:

- ad ogni singola prova si hanno solo 2 esiti possibili, chiamati "successo" ed "insuccesso",
- la probabilità dell'evento che da origine al "successo" è costante,
- i risultati delle prove sono indipendenti.

è detto un **esperimento Bernoulliano**.

È importante sapere riconoscere quando si è in presenza di questo tipo di esperimento. Facciamo alcuni esempi. Se lanciamo ripetutamente una moneta e registriamo come "successo" il risultato T, siamo realisticamente in presenza




Figura 4.7 Trade-off media e varianza del rendimento al variare del legame lineare tra R_X e R_Y .

di un esperimento Bernoulliano. Se pensiamo alle chiamate che giungono ad un centralino telefonico in una certa fascia oraria e indichiamo con "successo" l'evento "chiamata da telefonia mobile" e con "insuccesso" l'evento "chiamata da telefonia fissa", siamo ancora in presenza di esperimento di Bernoulli in quanto possiamo supporre che i vari utenti agiscano indipendentemente l'uno dall'altro e che, nell'ambito di una data fascia oraria, rimanga costante la frequenza con cui gli utenti chiamano da un cellulare o da un telefono di rete fissa.

Pensiamo all'esito di un sondaggio referendario. Supponiamo che siano possibili solo 2 esiti: successo = "SI" e insuccesso = "NO". Ogni elettore vota in modo indipendente l'uno dall'altro (se pensiamo a due elettori consecutivi). Supponiamo di prendere un campione di schede votate. Se ne prendiamo una a caso possiamo immaginare che su quella scheda troveremo un "SI" con una probabilità pari alla frequenza con cui (tutti) gli elettori si sono espressi per il "SI".

L'esperimento Bernoulliano deve il suo nome alla variabile casuale che descrive ogni singola prova, la variabile di Bernoulli, che a sua volta porta il nome del matematico che l'ha introdotta nel calcolo delle probabilità.

Variabile casuale di Bernoulli Una variabile casuale discreta che assume solo due valori 0 ed 1 con probabilità rispettivamente p ed $1-p$, con $0 < p < 1$, è detta variabile casuale di Bernoulli. Si scrive anche $X \sim \text{Ber}(p)$. Tale variabile ha le seguenti proprietà

$$X : P(X = 1) = p; \quad P(X = 0) = 1 - p \quad 0 < p < 1$$

$$E(X) = p \quad \text{e} \quad \text{Var}(X) = p(1-p)$$

Infatti si ha che

$$E(X) = 1 \cdot P(X=1) + 0 \cdot P(X=0) = 1 \cdot p + 0 \cdot (1-p) = p$$

e per la varianza

$$\begin{aligned} \text{Var}(X) &= (1 - E(X))^2 P(X=1) + (0 - E(X))^2 P(X=0) \\ &= (1-p)^2 p + (0-p)^2 (1-p) = (1-p)(1-p)p + pp(1-p) \\ &= p(1-p)(1-p+p) = p(1-p) \end{aligned}$$

Il valore atteso della Bernoulliana ha una lettura intuitiva. Supponiamo di effettuare un numero elevato di esperimenti, per esempio il lancio di una moneta regolare ($p = 0.5$). Dopo un numero elevato di lanci ci si può aspettare di aver ottenuto circa il 50% di successi. Il valore atteso della Bernoulliana può quindi leggersi come la frequenza attesa del numero di successi che otteniamo in un numero di prove elevato.

Variable casuale Binomiale Spesso nell'ambito di un esperimento Bernoulliano si è interessati a sapere quante volte si ottiene un successo su n prove, cioè per esempio, si è interessati a conoscere il numero di chiamate di telefonia mobile o il numero di "SI" nell'esempio del referendum. In particolare, essendo l'esperimento di tipo casuale, siamo interessati a conoscere la probabilità con cui si ottengono un certo numero k di successi su n prove. Chiaramente k può essere pari a 0, se non vi sono successi, e poi 1, 2 ecc. fino ad n . Prendiamo il seguente esempio del lancio di una moneta 6 volte. Chiediamoci con quale probabilità possiamo ottenere 2 successi (T) in 6 prove. Abbiamo diversi risultati possibili. Indichiamo con 1 il successo, cioè $X = 1$ quando esce T , e con 0 l'insuccesso. La sequenza di lanci

110000

è una sequenza in cui abbiamo 2 successi e 4 insuccessi, ma anche

100100

è una sequenza analoga. Ciascuna di quelle due sequenze ha la stessa probabilità di verificarsi. Infatti, indichiamo con X_i la variabile di Bernoulli che vale 1, con probabilità p , se alla prova numero i otteniamo un successo:

$$\begin{aligned} P("110000") &= P(X_1=1, X_2=1, X_3=0, X_4=0, X_5=0, X_6=0) \\ &= P(X_1=1)P(X_2=1)P(X_3=0)P(X_4=0) \\ &\quad P(X_5=0)P(X_6=0) \\ &= pp(1-p)(1-p)(1-p)(1-p) \\ &= p^2(1-p)^4 \end{aligned}$$

Mentre per la seconda sequenza si ha

$$\begin{aligned} P("100100") &= P(X_1=1, X_2=0, X_3=0, X_4=1, X_5=0, X_6=0) \\ &= P(X_1=1)P(X_2=0)P(X_3=0)P(X_4=1) \\ &\quad P(X_5=0)P(X_6=0) \\ &= p(1-p)(1-p)p(1-p)(1-p) \\ &= p^2(1-p)^4 \end{aligned}$$

cioè esattamente lo stesso risultato. Ma in totale abbiamo un numero molto elevato di sestine composte da due soli "1" e quattro "0". Le elenchiamo di seguito:

110000 101000 100100 100010 100001
011000 010100 010010 010001 001100
001010 001001 000110 000101 000011

Come si vede sono in tutto 15, risultato che si poteva ottenere con l'utilizzo del coefficiente binomiale. Infatti, spostare i due "1" all'interno di una sestina, coincide con l'estrarre 2 elementi da un gruppo di 6, cioè scegliere casualmente 2 tra i 6 posti all'interno della sestina. Quindi in totale sono

$$\binom{6}{2} = \frac{6 \cdot 5 \cdot 4!}{4! \cdot 2!} = 3 \cdot 5 = 15$$

In definitiva, la probabilità di ottenere 2 successi su 6 prove corrisponde alla probabilità del realizzarsi di una delle 15 sestine che abbiamo elencato, ciascuna con la stessa probabilità di realizzarsi e quindi

$$\begin{aligned} P(2 \text{ successi su } 6 \text{ lanci}) &= P("110000") + \dots + P("000011") \\ &= p^2(1-p)^4 + p^2(1-p)^4 + \dots + p^2(1-p)^4 \\ &= \binom{6}{2} p^2(1-p)^4 \\ &= \binom{6}{2} p^2(1-p)^{6-2} \end{aligned}$$

La variabile che in generale descrive il numero di successi che si possono ottenere in n prove di Bernoulli, è la variabile casuale **Binomiale**: se abbiamo un esperimento Bernoulliano costituito da n prove in cui la probabilità del successo è pari a p , $0 < p < 1$, la variabile casuale X che conta il numero di successi in n prove si chiama Binomiale e si scrive $X \sim \text{Bin}(n, p)$. Tale variabile assume tutti i valori interi da 0 ad n con la seguente distribuzione di probabilità

$$P(X=k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k=0, 1, \dots, n.$$

Tale variabile ha le seguenti proprietà

$$E(X) = np \quad e \quad \text{Var}(X) = np(1 - p)$$

Se guardiamo al valore atteso della variabile casuale Binomiale possiamo interpretarlo come numero di medio di successi che ci aspettiamo si realizzi se ripetiamo varie volte l'esperimento di Bernoulli. Infatti, supponiamo che la probabilità di successo sia 0.3 e di avere un esperimento composto da $n = 100$ prove di Bernoulli. Se ripetiamo diverse volte l'esperimento, è lecito aspettarsi che in media il numero di successi sia circa 30. Ovvero, in ogni singola sequenza di Bernoulli avremo un numero di successi pari, per esempio, a 30, 29, 27, 31, 33 ecc. La media aritmetica di questi valori dovrebbe essere 30 se l'esperimento ha funzionato a dovere.

Non è necessario scrivere delle routine per calcolare le probabilità relative ad eventi che coinvolgono variabili casuali di tipo Binomiale o Bernoulli. Se vogliamo calcolare la probabilità $P(X \leq 3)$ dove $X \sim \text{Bin}(n = 10, p = 0.3)$ si può usare il comando `pbinom(3, 10, 0.3)`

```
> pbinom(3, 10, 0.3)
[1] 0.6496107
> pbinom(3, 10, 0.3, lower.tail=FALSE)
[1] 0.3503893
```

L'opzione `lower.tail=FALSE` serve per calcolare la probabilità $P(X > 3)$. Infatti,

$$P(X < 3) + P(X > 3) = P(\Omega) = 1$$

```
> pbinom(3, 10, 0.3) + pbinom(3, 10, 0.3, lower.tail=FALSE)
[1] 1
```

Se invece vogliamo calcolare la densità di probabilità di X in un punto $x = 3$ possiamo utilizzare la funzione `dbinom` come segue

```
> dbinom(3, 10, 0.3)
[1] 0.2668279
```

Se vogliamo calcolare probabilità relative alla variabile di Bernoulli, basta ricordarsi che $X \sim \text{Ber}(p) \sim \text{Bin}(n = 1, p)$.

Il prefisso "d" di `dbinom` serve a ricordarci che stiamo calcolando la densità di probabilità della variabile casuale. Questo prefisso, come vedremo è comune a tutte le altre variabili aleatorie. Se invece vogliamo calcolare la funzione di ripartizione il prefisso è "p". Se aggiungiamo l'opzione `lower.tail=F`, R calcola la probabilità dell'evento complementare: $P(X > x)$.

Variabile casuale Geometrica In un esperimento Bernoulliano ci si può chiedere quanto tempo si deve aspettare per avere il primo successo. Se per esempio vogliamo sapere con quale probabilità si avrà la prima T nel lancio di una




Figura 4.8 Probabilità di avere il primo successo in dopo k prove, con $k = 0, 1, \dots, 10$ e probabilità di successo in ogni prova di Bernoulli pari a $p = \frac{1}{8}$.

moneta truccata, tale per cui $1 - p = P(C) = \frac{7}{8}$ e $p = P(T) = \frac{1}{8}$ allora la risposta si ottiene nel seguente modo

$$(1 - p)^k \cdot p, \quad k = 0, 1, \dots$$

In tal caso l'esperimento potrebbe anche avere durata infinita o comunque non prevedibile al contrario del modello Binomiale in cui viene fissato il numero di prove n a priori. La variabile tempo di attesa per il primo successo è chiamata variabile casuale **geometrica**. Il seguente codice disegna la densità di probabilità di una geometrica con $p = \frac{1}{8}$. Il grafico è riportato in Figura 4.8

```
> k <- 0:10
> p <- dgeom(k, 1/8)
> plot(k, p, type="h", lwd=10)
```

Il nome della distribuzione deriva dal fatto che la sua densità di probabilità ha un nucleo che è una successione geometrica del tipo $1 + x + x^2 + \dots$ con $x = 1 - p$. Essendo

$$P(X = k) = p(1 - p)^k$$

si ha che

$$\sum_{k=0}^{\infty} P(X = k) = p \sum_{k=0}^{\infty} (1 - p)^k = p \frac{1}{1 - (1 - p)} = \frac{p}{p} = 1$$




Figura 4.9 Grafico della densità di probabilità della distribuzione di Poisson di parametro $\lambda = 5$.

10 minuti si abbiamo al più 10 chiamate. Se il tempo di riferimento è 1h = 60m, noi sappiamo che ogni minuto arrivano mediamente $20/60 = 0.3$ chiamate. Se ci concentriamo sull'intervallo 0-5m allora il numero medio di chiamate nell'intervallo è pari $0.3 \cdot 5 = 1.5 = \lambda$. Quindi, posto $X \sim \text{Poi}(20/60 \cdot 5)$ dobbiamo calcolare $P(X=0)$. Utilizziamo R

```
> dpois(0,20/60*5)
[1] 0.1888756
> ppois(10,20/60*5)
[1] 0.99993085
```

In 10 minuti arriveranno mediamente $20/60 \cdot 10 = \lambda$ chiamate quindi, posto $X \sim \text{Poi}(20/60 \cdot 10)$ dobbiamo calcolare $P(X \leq 10)$, che risulta pari a

4.2.6 Schema riassuntivo per variabili casuali discrete

Le Tabelle 4.1 e 4.2 riportano l'elenco dei comandi per ottenere le densità di probabilità, le funzioni di ripartizione e i quantili delle distribuzioni viste. Il **quantile** di una variabile casuale è definito esattamente come nel caso della statistica descrittiva, ovvero il quantile x_p di una variabile casuale X è definito dalla formula $p = P(X \leq x_p)$.

Per ottenere i quantili delle distribuzioni si utilizza il comando con il prefisso "q" così che `qbinom(alpha,n,p)` fornisce il α -esimo quantile relativo alla probabilità (o alle probabilità) specificate nel vettore `alpha`.

Variabile casuale	Bin(n,p)	Bin Neg(n,p)	Geom(p)
Densità	<code>dbinom(k,n,p)</code>	<code>dnbinom(k,n,p)</code>	<code>dgeom(k,p)</code>
Ripartizione	<code>pbinom(x,n,p)</code>	<code>pnbinom(x,n,p)</code>	<code>pgeom(x,p)</code>
Quantili	<code>qbinom(α,n,p)</code>	<code>qnbinom(α,n,p)</code>	<code>qgeom(α,p)</code>

Tabella 4.1 n = numero di prove di Bernoulli, p = probabilità di un successo, α = vettore di probabilità.

Variabile casuale	lperg(N,K,n)	Poisson(λ)
Densità	<code>lhyper($k,K,N-K,n$)</code>	<code>dpois(k,λ)</code>
Ripartizione	<code>phyper($x,K,N-K,n$)</code>	<code>ppois(x,λ)</code>
Quantili	<code>qhyper($\alpha,K,N-K,n$)</code>	<code>qpois(α,λ)</code>

Tabella 4.2 N = numero complessivo di oggetti, K = numerosità del sottogruppo, n = numero di estrazioni, α = vettore di probabilità, λ = media.

4.2.7 Variabili casuali continue

Ci sono esperimenti casuali che non sempre generano valori discreti o comunque in quantità numerabile. Si consideri l'esempio che potremmo chiamare della *Ruota della Fortuna*. Possiamo pensare ad una sorta di roulette/bussola con un ago centrale. Se facciamo ruotare l'ago, questo terminerà la sua corsa ponendosi in una certa posizione che possiamo registrare come il numero di gradi x_1 da una linea prefissata (cfr. Figura 4.10). Se facciamo ruotare ancora l'ago otterremo un nuovo valore x_2 e così via. Nella sostanza possiamo ottenere un numero infinito di valori diversi x_i quindi l'esperimento ci porta ad un insieme Ω che corrisponde a tutte le possibili posizioni assumibili dall'ago della roulette. Se indichiamo con X la variabile casuale che registra i gradi x_i , allora la variabile casuale X assumerà tutti valori nell'intervallo $(0, 360)$.

Proviamo a calcolare la probabilità con cui la variabile casuale X assume un particolare valore x_1 . Poiché supponiamo di non barare nel far ruotare la freccia, possiamo utilizzare l'usuale formula del caso di eventi elementari (i gradi di inclinazione) equiprobabili

$$P(X = x_1) = \frac{\text{\# casi favorevoli}}{\text{\# casi possibili}} = \frac{1}{\infty} = 0$$

cioè ciascuno dei risultati $X = x_i$ ha probabilità nulla di verificarsi! Questo è quindi un problema se pensiamo alla definizione di variabile casuale come nel caso discreto. Però non è impossibile calcolare le probabilità relative ad eventi che coinvolgono variabili casuali continue. Per esempio, con quale probabilità la variabile casuale X , cioè l'ago, misurerà un'inclinazione compresa tra 0 e 90° ?




Figura 4.10 La Ruota della Fortuna: La variabile casuale X segna i gradi x_i in corrispondenza dei quali l'ago della ruota si ferma. Nel disegno l'ago si ferma in posizione $X = x_1$. Poiché si tratta di uno degli infiniti valori tra 0 e 360° , avremo $P(X = x_1) = 1/\infty = 0$.

Poiché si tratta della quarta parte di un cerchio (confronta la Figura 4.11), viene naturale rispondere che $P(X \leq 90) = 1/4 = 0.25$.

In generale, le variabili casuali continue vengono sempre definite a partire dall'insieme dei valori assumibili e dalle probabilità del tipo $P(X \leq x)$, cioè della funzione di ripartizione. Queste probabilità possono in genere essere espresse attraverso un'altra funzione $f(\cdot)$, detta **densità di probabilità**, nella seguente forma

$$P(X \leq x) = \int_{-\infty}^x f(u) du.$$

L'integrale qui sopra non deve preoccupare poiché P penserà a calcolarlo al nostro posto, ma deve essere interpretato come un'estensione della formula (4.1) dove l'integrale $\int$ sostituisce la sommatoria e la funzione di densità $f(\cdot)$ sostituisce i termini $P(X = x_i)$.

Valore atteso e varianza delle variabili casuali continue In analogia a quanto visto nel caso discreto, per le variabili casuali continue abbiamo che

$$\mu = E(X) = \int_{-\infty}^{\infty} x f(x) dx$$




Figura 4.11 Ancora la Ruota della Fortuna: Con quale probabilità l'ago della Ruota si ferma in punto compreso tra 0 e 90° ? Questo accade una volta su 4, cioè nel 25% dei casi, dunque $P(X \leq 90) = 0.25$.

e per la varianza

$$\sigma^2 = \text{Var}(X) = E(X - E(X))^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx$$

La covarianza può invece scriversi come

$$\sigma_{xy} = \text{Cov}(X, Y) = E(X - E(X))(Y - E(Y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu)(y - \nu) f(x, y) dx dy$$

dove $f(x, y)$ è la densità di probabilità congiunta. Come per il caso discreto la condizione necessaria e sufficiente di indipendenza è la seguente

$$f(x, y) = f(x) \cdot f(y), \quad \forall x, y.$$

Se X ed Y sono indipendenti allora $\sigma_{xy} = 0$.

4.2.8 Variabile casuale Uniforme

Se $[a, b]$ è un intervallo finito, la variabile casuale che assume un qualsiasi valore di tale intervallo con uguale probabilità è detta variabile casuale **uniforme** e si indica

con $X \sim U(a, b)$. L'esempio della nota della fortuna può essere modellato con una variabile casuale uniforme sull'intervallo $[0, 360]$. La sua densità è definita da

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in (a, b) \\ 0, & \text{altrimenti} \end{cases}$$

e la sua funzione di ripartizione è

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & x \in [a, b] \\ 1, & x > b \end{cases}$$

Media e varianza dell'uniforme si calcolano facilmente e sono pari a

$$E(X) = \frac{a+b}{2} \quad \text{Var}(X) = \frac{(b-a)^2}{12}$$

La densità, la funzione di ripartizione e i quantili si calcolano attraverso i comandi `dunif`, `punif` e `qunif`. Si rimanda alla Tabella 4.5 per i dettagli.

4.2.9 Variabile casuale esponenziale

Questa variabile modella i tempi di arrivo di eventi indipendenti e come tale è legata alla variabile di Poisson. A differenza della variabile casuale di Poisson che conta il numero di arrivi in un intervallo di tempo, la variabile esponenziale misura il tempo che intercorre tra due di tali eventi successivi. Si tratta quindi di una variabile casuale continua a valori positivi. Si dice che X è di tipo esponenziale di parametro λ , e si indica con $X \sim \text{Exp}(\lambda)$, se ha densità e funzione di ripartizione seguenti

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & \text{altrimenti} \end{cases}$$

$$F(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x > 0 \end{cases}$$

Se prendiamo una variabile casuale di Poisson Y di parametro λ , allora

$$P(Y = 0) = \frac{\lambda^0 e^{-\lambda}}{\lambda^0} = e^{-\lambda} = 1 - P(X < 1) = P(X > 1)$$

Cioè dire che "nell'intervallo di tempo unitario non si verificano eventi" è equivalente a dire che "il primo evento si verifica dopo 1 unità di tempo". In generale se x è un ammontare di tempo fissato, dire che $P(Y = 0)$ per $Y \sim \text{Poi}(\lambda x)$ equivale a calcolare $P(X > x)$ con $X \sim \text{Exp}(\lambda)$. Al solito `dexp`, `pexp` e `qexp` sono le funzioni di `R` per il calcolo della densità, della funzione di ripartizione e dei quantili dell'esponenziale (si veda Tabella 4.5). Media e varianza della distribuzione esponenziale sono

$$E(X) = \frac{1}{\lambda} \quad \text{Var}(X) = \frac{1}{\lambda^2}.$$

4.2.10 Variabile casuale Normale

Uno degli aspetti più inquietanti del caso è che esso sembra pervadere il mondo fisico più di quanto non si immagini. Sembra proprio che la variabile casuale fisico (chiamata anche *Normale*, *degli errori accidentali* ecc.) regni sovrana tanto che biologi, fisici e sociologi ne rivendicano la paternità. Tra le ricorrenze importanti della Normale c'è quella che riguarda la distribuzione delle misure di quantità fisiche del mondo animale, ed in particolare umane, come la distribuzione delle altezze, della lunghezza di parti anatomiche (avambracci, femori, orecchie, mignoli della mano sinistra e quant'altro).

Ricordiamo che una variabile casuale continua è ben definita quando: i) si specifica l'intervallo di valori che può assumere e ii) viene indicata la sua funzione di densità. Per la variabile casuale **Normale standard** si ha che la densità assume la seguente forma

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad -\infty < x < \infty, \quad (4.3)$$

dove la funzione $f(x)$ è definita per ogni numero reale x .

La formula contiene due delle più importanti costanti matematiche: il numero e che è la base dei logaritmi naturali e il numero π noto dalle scuole medie inferiori attraverso la formula del calcolo dell'area di un cerchio di raggio r : $A = \pi r^2$.

La variabile casuale Normale standard si indica generalmente con la lettera Z dell'alfabeto. Abbiamo visto che può dunque assumere qualunque valore dell'asse reale z anche se gli eventi di cui ha senso calcolare le probabilità sono gli intervalli del tipo $P(a < Z < b)$ poiché, come per tutte le variabili aleatorie continue, si ha sempre $P(Z = z) = 0$ per ogni valore di z (si ricordi l'esempio della Ruota della Fortuna).

Gauss è sicuramente uno dei padri di tale distribuzione e ne fornì una derivazione partendo dall'osservazione di misure fisiche. Si accorse che misurando più volte una certa quantità può accadere che la misura dell'oggetto vari di poco. Se m è la vera misura dell'oggetto e x_1 è la misurazione i -esima eseguita, gli errori di misura sono definiti, come i residui nell'analisi di regressione, dalla differenza $e_i = x_i - m$. A volte risulteranno errori per eccesso a volte per difetto. Se consideriamo la media di tutte le misure x_i ci aspettiamo che sia pari ad m . Se gli errori di misurazione che commettiamo sono di tipo casuale (cioè non indotti sistematicamente dalla nostra sbadataggine per esempio) e tracciamo la distribuzione di frequenza dei valori e_i ci accorgiamo che la maggior parte dei valori si concentra attorno allo 0 e poi pochi valori saranno positivi e molto grandi e altrettanti molto grandi ma con segno negativo. Cioè l'aspetto della distribuzione di frequenza "lasciata" dovrebbe apparire come nel grafico in Figura 4.12 che è esattamente il grafico della densità di una variabile casuale Gaussiana standard.

Per la variabile casuale Normale standard si hanno due proprietà fondamentali: i) il valore atteso è pari a 0 ($E(Z)=0$) e la sua varianza è pari ad 1 ($\text{Var}(X) = 1$). La notazione utilizzata per indicare che una variabile è di tipo gaussiano è la seguente: $Z \sim N(\mu = 0, \sigma^2 = 1)$ dove μ indica il valore atteso e σ^2 la varianza




Figura 4.12 Grafico della densità di probabilità della variabile casuale Gaussiana (o Normale) standard

della variabile in questione. Questa notazione lascia intuire che esistono diversi tipi di variabili gaussiane al variare di μ e σ^2 .

Infatti, la variabile casuale **Gaussiana** può essere definita in modo più generale da una densità del tipo che segue

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (4.4)$$

(si noti che ponendo $\mu = 0$ e $\sigma = 1$ la (4.4) coincide con la (4.3).) La densità (4.4) appena scritta è la densità di una variabile Gaussiana X di media μ e varianza σ^2 e si scriverà $X \sim N(\mu, \sigma^2)$. I parametri μ e σ^2 della Gaussiana hanno un'interpretazione molto diretta. Abbiamo visto che la $N(0, 1)$ ha una densità campanulare simmetrica attorno allo 0 che è anche la sua media, mediana (per la simmetria) e la moda. Una normale di media μ avrà le stesse proprietà solo che questa volta il punto di simmetria è proprio μ , ovvero μ è contemporaneamente la media, la moda e la mediana della variabile casuale.

Il grafico in Figura 4.13 mostra la densità di due variabili gaussiane di media rispettivamente $\mu = -4$ e $\mu = 7$ con varianza pari ad 1 (Grafico (a)) e di altre due gaussiane di media nulla ma varianze rispettivamente 1 e 4 (Grafico (b)). Come si vede la media μ è il centro della distribuzione mentre il fattore σ^2 , cioè la dispersione, agisce come un fattore di scala ovvero, più è piccola la varianza più la distribuzione è concentrata attorno alla media e dunque la distribuzione risulta anche essere più "appuntita", viceversa più aumenta la varianza, più i valori tendono a disperdersi attorno alla media così che il grafico della densità della




Figura 4.13 Grafico delle densità di gaussiane al variare dei parametri μ e σ^2 . A sinistra due variabili normali di varianza pari ad 1 e medie $\mu = -4$ e $\mu = 7$. A destra due gaussiane di media nulla ma varianze σ^2 pari ad 1 e 4.

Normale risulta essere più "appiattito". Il termine "standard" viene riservato alla Gaussiana di parametri $\mu = 0$ e $\sigma^2 = 1$. Questa variabile casuale gioca un ruolo fondamentale nel calcolo delle probabilità. Sappiamo che per una variabile casuale continua, calcolare probabilità del tipo $P(X < x)$ vuol dire eseguire il calcolo di un integrale, cioè

$$P(X < x) = \int_{-\infty}^x f(u) du$$

che spesso non è risolvibile in modo esplicito ma solo per via numerica. Se X è la variabile casuale Normale standard, cioè $X \sim N(0, 1)$, quelle probabilità ci vengono fornite da algoritmi standard come quelli utilizzati da R. In particolare, se Z è la variabile Gaussiana standard si usa per convenzione la notazione $P(Z < z) = \Phi(z)$. Dunque se X è una variabile Gaussiana di parametri $E(X) = \mu$ e $\text{Var}(X) = \sigma^2$, cioè $X \sim N(\mu, \sigma^2)$ ci si può ricondurre alla variabile normale standard Z tramite l'operazione di **standardizzazione**

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

R predispone funzioni per il calcolo della densità, della funzione di ripartizione e dei quantili della Gaussiana (sia quella standard che quella generica di parametri

μ e σ^2). Le funzioni sono rispettivamente `dnorm`, `pnorm` e `qnorm`. Infatti, se vogliamo calcolare $P(X < 3)$ con $X \sim N(3, 2)$ possiamo scrivere

```
> pnorm(3, mean=5, sd=sqrt(3))
[1] 0.1241065
```

oppure passando alla standardizzazione

```
> pnorm((3-5)/sqrt(3))
[1] 0.1241065
```

Se vogliamo disegnare il grafico della densità della Gaussiana, come quelli in Figura 4.13 possiamo usare i comandi

```
> curve(dnorm(x, mean=-4), -10, 12, ylab="", axes=FALSE)
> curve(dnorm(x, mean=7), -10, 12, ylab="", add=TRUE)
```

Calcolo (grafico) delle probabilità per v.c. continue Se vogliamo calcolare le probabilità del tipo $P(a < Z < b)$, cioè Z assume valori nell'intervallo di estremi a e b , possiamo aiutarci con i grafici. Infatti, rappresentando graficamente $P(a < Z < b)$ notiamo che,

$$P(a < Z < b) = P(Z < b) - P(Z < a)$$

come è evidente dalla Figura 4.14.

Intervalli notevoli Proviamo ora a calcolare le seguenti probabilità

$$P(\mu - \sigma < X < \mu + \sigma), \quad P(\mu - 2\sigma < X < \mu + 2\sigma), \quad P(\mu - 3\sigma < X < \mu + 3\sigma)$$

dove $X \sim N(\mu, \sigma^2)$. Otteniamo i seguenti risultati

$$\begin{aligned} P(\mu - \sigma < X < \mu + \sigma) &= P\left(\frac{\mu - \mu - \sigma}{\sigma} < \frac{X - \mu}{\sigma} < \frac{\mu + \sigma - \mu}{\sigma}\right) \\ &= P(-1 < Z < 1) = \Phi(1) - \Phi(-1) \\ &= 0.84134 - 0.15866 \approx 0.68 \end{aligned}$$

In R si può eseguire il calcolo come segue

```
> mu <- 5
> sigma <- 2
> pnorm(mu+sigma, mean=mu, sd=sigma) -
+ pnorm(mu-sigma, mean=mu, sd=sigma)
[1] 0.6826895
> pnorm(1) - pnorm(-1)
[1] 0.6826895
```




Figura 4.14 Calcolo di $P(a < Z < b) = P(Z < b) - P(Z < a)$. Nell'esempio abbiamo utilizzato la distribuzione Gaussiana, ma la relazione vale per ogni distribuzione continua per il teorema fondamentale del calcolo integrale.

ovvero il 68% di tutti i valori possibili di una Gaussiana si realizzano all'interno dell'intervallo $\mu \pm \sigma$. Per gli altri intervalli otteniamo

```
> pnorm(mu+2*sigma, mean=mu, sd=sigma) -
+ pnorm(mu-2*sigma, mean=mu, sd=sigma)
[1] 0.9544997
> pnorm(2) - pnorm(-2)
[1] 0.9544997
```

cioè

$$P(\mu - 2\sigma < X < \mu + 2\sigma) = 0.954$$

e infine

```
> pnorm(mu+3*sigma, mean=mu, sd=sigma) -
+ pnorm(mu-3*sigma, mean=mu, sd=sigma)
[1] 0.9973002
> pnorm(3) - pnorm(-3)
[1] 0.9973002
```

ovvero

$$P(\mu - 3\sigma < X < \mu + 3\sigma) = 0.997$$

In sostanza oltre ($\pm$) 3 volte lo scarto quadratico medio la probabilità che si realizzi un evento della variabile casuale Gaussiana è praticamente nulla. Dal punto




Figura 4.15 Proprietà di simmetria della densità della variabile casuale Gaussiana: $f(z) = f(-z)$ e quindi $\Phi(-z) = 1 - \Phi(z)$.

di vista statistico ciò vuol dire che se in un campione troviamo valori esterni all'intervallo $(\bar{x}_n \pm 3\sqrt{\bar{s}_n^2})$, questi valori verranno considerati degli *outlier* (si ricordi in proposito l'effetto degli outlier sulla retta di regressione).

Terminiamo con qualche proprietà utile che riguarda la variabile aleatoria Normale. Questa volta però utilizziamo un'altra proprietà della curva normale: la *simmetria rispetto alla propria media* μ . Se prendiamo un numero $z > 0$ qualsiasi, possiamo calcolare la $P(|Z| < z) = P(-z < Z < z)$ come segue

$$P(|Z| < z) = P(-z < Z < z) = \Phi(z) - \Phi(-z) = 2\Phi(z) - 1$$

poiché $\Phi(-z) = 1 - \Phi(z)$ essendo la densità $f(\cdot)$ una funzione simmetrica rispetto allo 0 (la Figura 4.15 illustra questa proprietà). Dal fatto che $P(|Z| < z) = 2\Phi(z) - 1$ deriva anche che

$$P(|Z| > z) = P(Z > z, Z < -z) = 1 - (2\Phi(z) - 1) = 2(1 - \Phi(z)).$$

Infine, se $X \sim N(\mu_1, \sigma_1^2)$ e $Y \sim N(\mu_2, \sigma_2^2)$ sono indipendenti allora la variabile casuale $W = X + Y$ è ancora una variabile Gaussiana del tipo $W \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

Proprietà utili per la variabile casuale Gaussiana

Se $X \sim N(\mu, \sigma^2)$ allora:

i) Se a e b sono due numeri non aleatori si ha che

$$a + bX \sim N(a + b\mu, b^2\sigma^2)$$

ii) per il calcolo delle probabilità si deve ricordare che

$$P(X < x) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

iii) per le proprietà di simmetria si ha che

$$\Phi(-z) = 1 - \Phi(z)$$

e quindi

$$P(|Z| < z) = P(-z < Z < z) = 2\Phi(z) - 1$$

e

$$P(|Z| > z) = P(Z > z, Z < -z) = 2(1 - \Phi(z))$$

iv) se $X \sim N(\mu_1, \sigma_1^2)$ e $Y \sim N(\mu_2, \sigma_2^2)$ sono indipendenti allora

$$W = X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

4.2.11 Approssimazione della Binomiale con la Gaussiana

Un altro modo di derivare la variabile casuale Gaussiana è come limite della variabile casuale Binomiale. Il problema con cui ci si scontra di frequente è che spesso il numero di prove n è piuttosto elevato. Quando si effettuano i calcoli con la variabile casuale Binomiale, si incappa necessariamente nel calcolo dei coefficienti binomiali che, abbiamo già visto, quando i valori sono molto elevati diventano numeri intattabili. De Moivre, si accorse che quando $p = 0.5$, la distribuzione della variabile Binomiale X è simmetrica rispetto alla sua media, cioè np . Effettuando l'operazione di standardizzazione sulla X in analogia a quanto già visto, si ottiene che

$$Z = \frac{X - E(X)}{\sqrt{\text{Var}(X)}} = \frac{X - np}{\sqrt{np(1-p)}} \simeq N(0, 1)$$

cioè siamo ancora in presenza di una Gaussiana. L'approssimazione si può ritenere valida se n supera 30. Più tardi ci si accorse che l'approssimazione vale

anche quando $p \neq 0.5$, infatti benché in tal caso la distribuzione sia asimmetrica, quando il numero delle prove n cresce molto viene ad affievolirsi l'effetto dell'asimmetria e vale ancora l'approssimazione alla Gaussiana della Binomiale standardizzata. La regola empirica dice che quando $np \geq 5$ e $n(1-p) \geq 5$ allora può ritenersi valida l'approssimazione.

Il risultato è in realtà molto più generale e prende il nome di Teorema del Limite Centrale³. Questo teorema afferma che se abbiamo delle X_i i.i.d. (indipendenti ed identicamente distribuite), con stessa media μ e varianza σ^2 finite, allora la distribuzione di probabilità di $Y = \sum_{i=1}^n X_i$, opportunamente standardizzata, può essere approssimata con quella di una Gaussiana, cioè

$$Z = \frac{Y - E(Y)}{\sqrt{\text{Var}(Y)}} \simeq N(0, 1)$$

4.2.12 Variabile Chi-quadrato (χ^2)

Se $Z \sim N(0, 1)$, allora la variabile casuale Y ottenuta tramite la trasformazione $Y = Z^2$ si distribuisce con una legge nota col nome di distribuzione di Chi-quadrato con 1 grado di libertà. Questa distribuzione viene derivata in statistica quando si calcola la varianza campionaria di variabili casuali X_i che sono di tipo Z . In tal caso, vedremo, si ottiene una distribuzione χ^2 con g gradi di libertà che sono in relazione al numero di osservazioni campionarie n . La distribuzione χ_g^2 assume solo valori positivi ed è fortemente asimmetrica quando g è piccolo. La Figura 4.16, che mostra il grafico della densità di χ_g^2 al variare del numero di gradi di libertà g , è stata ottenuta con il seguente codice

```
> curve(dchisq(x, df=3), 0., 20, ylab="densita'")
> curve(dchisq(x, df=5), 0., 20, add=TRUE, lty=2)
> curve(dchisq(x, df=7), 0., 20, add=TRUE, lty=3)
> legend(10, 0.2, c("gdl = 3", "gdl = 5", "gdl = 7"),
+       lty=c(1, 2, 3))
```

Per il comando `legend` si consulti l'Appendice A. Media e varianza della variabile χ_g^2 sono rispettivamente pari a g e $2g$. Inoltre vale l'approssimazione asintotica

$$\chi_g^2 \simeq g + \sqrt{2g} \cdot Z$$

quando g è sufficientemente elevato.

³Qualsiasi modello probabilistico si scelga, sotto ipotesi molto generali, al crescere del numero delle replicazioni, la somma standardizzata di variabili casuali tende a distribuirsi come una Normale. L'aggettivo "centrale" è quindi riferito al ruolo cruciale che la distribuzione Gaussiana riveste nella teoria della probabilità. In alcuni testi si parla di teorema centrale del limite, si sposta quindi l'aggettivo sul sostantivo teorema per indicare che questo risultato è uno tra i fondamentali, forse il più importante, in tutta la teoria asintotica della probabilità. Entrambe le interpretazioni-collocazioni del termine "centrale" appaiono giustificate.




Figura 4.16 Aspetto della densità di χ_g^2 al variare del numero g di gradi di libertà.

4.2.13 Variabile t di Student

Dalla distribuzione χ^2 si passa alla distribuzione detta t di Student tramite la trasformazione seguente

$$t = \frac{Z}{\sqrt{\frac{\chi_g^2}{g}}}$$

dove $Z \sim N(0, 1)$ ed indipendente da χ_g^2 . Questa distribuzione, come la precedente e la seguente, sono ampiamente utilizzate nella statistica inferenziale anche se ora non se ne apprezzano le proprietà. Quello che si può dire della distribuzione t di Student è che anch'essa è caratterizzata dai gradi di libertà g ed ha un aspetto simile alla variabile casuale Normale con la differenza che le code della distribuzione della t di Student sono leggermente più alte di quelle della Gaussiana. Si confronta la Figura 4.17 ottenuta con il seguente codice

```
> curve(dnorm(x), -5, 5, ylab="densita'")
> curve(dt(x, df=1), -6, 6, lty=3, add=TRUE)
> legend(2, 0.3, c("Z", "t"), lty=c(1, 3))
```

La media della t di Student è sempre pari a 0 mentre la varianza risulta definita solo per $g > 2$ ed è pari a $g/(g-2)$.




Figura 4.17 Aspetto della densità di una t di Student rispetto a quello di una Normale standard Z .

4.2.14 Variabile F di Fisher

Date due variabili $X \sim \chi_m^2$ e $Y \sim \chi_n^2$ indipendenti, il rapporto

$$F = \frac{\frac{\chi_m^2}{m}}{\frac{\chi_n^2}{n}}$$

ha una distribuzione nota come F di Fisher con m ed n gradi di libertà. La Figura 4.18 mostra il grafico della densità di una F di Fisher con 3 e 2 gradi libertà ed è stato ottenuto con il seguente codice

```
> curve(df(x, df1=3, df2=1), 0, 2, ylab="densita'")
```

La media risulta definita solo per $n > 2$ ed è pari a $n/(n-2)$ mentre la varianza è definita solo per $n > 4$ ed è pari a $2n^2(m+n-2)/(m(n-2))^2(n-4)$.

4.2.15 Variabili casuali Gamma e Beta

Altre due variabili casuali di largo utilizzo in ambito statistico sono la Gamma e la Beta. Entrambe devono il loro nome alle costanti di normalizzazione delle relative funzioni di densità chiamate rispettivamente **funzione Gamma** e **funzione Beta**. La funzione Gamma è definita in forma integrale nel seguente modo

$$\Gamma(\alpha) = \int_0^{\infty} t^{\alpha-1} e^{-t} dt$$




Figura 4.18 Aspetto della densità di una F di Fisher con 3 e 2 gradi di libertà.

e possiede alcune proprietà quali per esempio

$$\Gamma(\alpha + 1) = \alpha \Gamma(\alpha), \quad \alpha > 0, \quad (4.5)$$

che ricorda molto da vicino la definizione per ricorrenza di n fattoriale, solo che α non deve necessariamente essere un numero intero come nel caso di n ! In realtà però si ha che se $\alpha = n$ è un numero intero, allora

$$\Gamma(n) = (n-1)!$$

per cui la relazione (4.5) diventa

$$\Gamma(n+1) = n! = n(n-1)! = n\Gamma(n)$$

In alcuni contesti viene quindi interpretata come versione generalizzata del fattoriale. A titolo di curiosità ricordiamo la relazione

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}.$$

La funzione Beta è invece una funzione di due variabili e può essere definita in termini della funzione Gamma come segue

$$\text{Beta}(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)} = \int_0^1 x^{\alpha-1}(1-x)^{\beta-1} dx.$$

ottenere i quantili in corrispondenza di un vettore α di probabilità. Le Tabelle da 4.3 a 4.7 riassumono i comandi R necessari al calcolo delle quantità suddette. Si faccia attenzione all'utilizzo delle funzioni che coinvolgono la variabile casuale Gamma. Per esempio la funzione `pgamma` prevede 3 parametri in input oltre al primo: il secondo è `shape` che coincide con α , il terzo è `rate` e il quarto è `scale` che coincide con β . Il parametro `scale` coincide con $1/\text{rate}$, quindi

```
> dgamma(1, 2, 3)
[1] 0.4480836
```

non è il valore, nel punto $x = 1$ di una densità $\text{Gamma}(\alpha = 2, \beta = 3)$ ma bensì di una $\text{Gamma}(\alpha = 2, \beta = 1/3)$. Infatti si dovrebbe scrivere correttamente

```
> dgamma(1, 2, scale=3)
[1] 0.07961459
```

o in modo equivalente

```
> dgamma(1, 2, 1/3)
[1] 0.07961459
```

Variabile casuale

Normale(μ, σ)

t_ν

Densità `dnorm(x, mean =  $\mu$ , sd =  $\sigma$ )` `dt(x, df =  $\nu$ )`
Ripartizione `pnorm(x, mean =  $\mu$ , sd =  $\sigma$ )` `pt(x, df =  $\nu$ )`
Quantili `qnorm( $\alpha$ , mean =  $\mu$ , sd =  $\sigma$ )` `qt( $\alpha$ , df =  $\nu$ )`

Tabella 4.3 μ = media, σ^2 = varianza, ν = gradi di libertà, α = vettore di probabilità.

Variabile casuale

χ^2_ν

$F(\nu_1, \nu_2)$

Densità `dchisq(x, df =  $\nu$ )` `df(x, df1 =  $\nu_1$ , df1 =  $\nu_2$ )`
Ripartizione `pchisq(x, df =  $\nu$ )` `pf(x, df1 =  $\nu_1$ , df1 =  $\nu_2$ )`
Quantili `qchisq( $\alpha$ , df =  $\nu$ )` `df( $\alpha$ , df1 =  $\nu_1$ , df1 =  $\nu_2$ )`

Tabella 4.4 ν_1 e ν_2 gradi di libertà, α = vettore di probabilità.

Variabile casuale

Exp(λ)

$U(a, b)$

Densità `dexp(x, rate =  $\lambda$ )` `dunif(x, min =  $a$ , max =  $b$ )`
Ripartizione `pexp(x, rate =  $\lambda$ )` `punif(x, min =  $a$ , max =  $b$ )`
Quantili `qexp( $\alpha$ , rate =  $\lambda$ )` `qunif( $\alpha$ , min =  $a$ , max =  $b$ )`

Tabella 4.5 α = vettore di probabilità, λ tasso dell'esponenziale, a e b estremi dell'intervallo di definizione dell'uniforme.

Variabile casuale

Gamma(α, β)

Densità `dgamma(x, shape =  $\alpha$ , rate =  $1/\beta$ , scale =  $\beta$ )`
Ripartizione `pgamma(x, shape =  $\alpha$ , rate =  $1/\beta$ , scale =  $\beta$ )`
Quantili `qgamma( $q$ , shape =  $\alpha$ , rate =  $1/\beta$ , scale =  $\beta$ )`

Tabella 4.6 α e β i parametri e p un vettore di probabilità.

Variabile casuale

Beta(α, β)

Densità `dbeta(x, shape1 =  $\alpha$ , shape2 =  $\beta$ )`
Ripartizione `pbeta(x, shape1 =  $\alpha$ , shape2 =  $\beta$ )`
Quantili `qbeta(p, shape1 =  $\alpha$ , shape2 =  $\beta$ )`

Tabella 4.7 α e β i parametri e p un vettore di probabilità.

4.3 Generazione di numeri pseudocasuali

La generazione di numeri casuali o in genere di realizzazioni di variabili casuali ha diverse motivazioni. In particolar modo in statistica spesso è utile per testare modelli teorici su dati non reali perché non facilmente disponibili, oppure nel calcolo di integrali (metodi Monte Carlo ed analoghi) o nel calcolo delle probabilità in situazioni in cui è molto difficile pervenire al calcolo esatto di quantità di interesse. Non ci dilungheremo su tutti questi aspetti ma ne vedremo alcune applicazioni. Le variabili casuali possono essere generate a partire dalla simulazione di numeri **pseudo casuali**. Si parla di numeri pseudo casuali e non puramente casuali poiché la loro generazione avviene attraverso algoritmi ben definiti. Ciò implica che a partire da uno stesso valore iniziale, detto **seme**, l'algoritmo genera sempre la stessa sequenza di numeri pseudo casuali. Da una sequenza di numeri pseudo casuali, noto l'algoritmo si può prevedere il successivo numero generato, mentre noto un numero non si può risalire al precedente. Inoltre ogni generatore di numeri casuali ha un periodo finito, ovvero da un certo punto in poi la sequenza di numeri ricomincia dal punto di partenza. È quindi importante conoscere sia il **ciclo** (o il **periodo**) del generatore che la sua affidabilità valutata rispetto ad una serie di test standard.

Anche le variabili aleatorie generate da questi dovrebbero a rigor di logica chiamarsi pseudo casuali. Per numero pseudo casuale o casuale, si intende comunemente un numero aleatorio compreso tra 0 ed 1 cioè l'estrazione di una realizzazione della variabile casuale uniforme su (0, 1). Questi metodi sono ben codificati e dei più disparati. R implementa una serie di generatori di numeri pseudo casuali standard. Ne elenchiamo alcuni

- "Wichmann-Hill". Questo generatore ha un ciclo lungo 6.9536×10^{12} .
- "Marsaglia-Multicarry": ciclo di lunghezza maggiore di 2^{60} ed è uno dei più "sicuri" in quanto passa tutti i test di casualità standard.