

Esempio numerico della stima della densità con il Metodo del Kernel Gaussiano

Luigi Lombardi - UNITN

Ottobre 2024

Esempio numerico

Immaginiamo, per semplicità di calcolo, di utilizzare come campione empirico di dati 10 osservazioni indipendenti estratte da una distribuzione di tipo normale con media e deviazione standard nella popolazione pari a $\mu = 100$ e $\sigma = 25$, rispettivamente (Tab. 1):

X	Valore Numerico
x_1	101.8
x_2	70.4
x_3	61.5
x_4	46.5
x_5	30.0
x_6	34.3
x_7	73.5
x_8	49.3
x_9	9.3
x_{10}	33.0

Tabella 1: Tabella dei valori empirici con etichette simboliche e valori numerici associati.

Nel grafico in Figura 1 viene mostrato il risultato dell'applicazione del metodo del Kernel (con componente Gaussiana) sui 10 valori di $\mathbf{X}$ utilizzando come valore di banda $h = 14.77$. In Figura 1 i 10 punti empirici di $\mathbf{X}$ vengono rappresentati nelle loro posizioni in ascissa con dei piccoli cerchi dal contorno nero. In aggiunta nello stesso grafico vengono illustrati altri due punti con contorno di colore rosso ($x = 48$) e blu ($x = 100$) rispettivamente indicanti due valori teorici della variabile quantitativa su cui calcolare la stima del punto di densità utilizzando la tecnica del Kernel.




Figura 1: Grafico della distribuzione della variabile quantitativa X stimata utilizzando il metodo del Kernel Gaussiano.

L'equazione generale per la stima di densità di un valore quantitativo $X = x$ generico secondo il metodo del Kernel è:

$$\hat{f}(x) = \frac{1}{n \cdot h} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right) \quad (1)$$

Nell'equazione (1) il termine n è la numerosità campionaria (nel nostro caso $n = 10$), x_i è l'osservazione i -esima del campione empirico $\mathbf{X}$ ed infine $h > 0$ è il valore associato alla banda. Il termine K rappresenta la componente Gaussiana specificata secondo l'equazione:

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}$$

dove $K(u)$ è il valore del kernel per l'input u . Nello specifico, $u = \frac{x - x_i}{h}$ è lo scarto normalizzato tra il punto di valutazione x e l'osservazione x_i del campione, diviso per la larghezza di banda h . Si noti che essendo K una funzione Gaussiana centrata sullo zero, questa restituirà valori più alti per tutte quelle osservazioni x_i nel campione che saranno molto vicine al punto di valutazione x . In altre parole, il valore di K sarà tanto più alto quanto più piccolo (in valore assoluto) è lo scarto tra x_i e x .

Sostituendo il termine u :

$$K\left(\frac{x - x_i}{h}\right) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x - x_i)^2}{2h^2}}$$

che è alla fine l'equazione specifica utilizzata.

A questo punto possiamo riscrivere l'intera Equazione (1) come:

$$\hat{f}(x) = \frac{1}{n \cdot h \cdot \sqrt{2\pi}} \sum_{i=1}^n e^{-\frac{(x - x_i)^2}{2h^2}}$$

Calcolo per $x = 48$

Per $x = 48$, con $h = 14.77$, $n = 10$, e i valori x_i come indicato nella Tabella 1, abbiamo:

$$\hat{f}(48) = \frac{1}{10 \cdot 14.77 \cdot \sqrt{2\pi}} \sum_{i=1}^{10} e^{-\frac{(48 - x_i)^2}{2 \cdot (14.77)^2}}$$

Calcoliamo i termini della somma:

1. $x_1 = 101.8 \Rightarrow e^{-\frac{(48-101.8)^2}{2 \cdot 14.77^2}} = e^{-5.678} = 0.0034$
2. $x_2 = 70.4 \Rightarrow e^{-\frac{(48-70.4)^2}{2 \cdot 14.77^2}} = e^{-1.578} = 0.2061$
3. $x_3 = 61.5 \Rightarrow e^{-\frac{(48-61.5)^2}{2 \cdot 14.77^2}} = e^{-0.835} = 0.4333$
4. $x_4 = 46.5 \Rightarrow e^{-\frac{(48-46.5)^2}{2 \cdot 14.77^2}} = e^{-0.015} = 0.9851$
5. $x_5 = 30.0 \Rightarrow e^{-\frac{(48-30.0)^2}{2 \cdot 14.77^2}} = e^{-1.355} = 0.2580$
6. $x_6 = 34.3 \Rightarrow e^{-\frac{(48-34.3)^2}{2 \cdot 14.77^2}} = e^{-0.836} = 0.4330$
7. $x_7 = 73.5 \Rightarrow e^{-\frac{(48-73.5)^2}{2 \cdot 14.77^2}} = e^{-1.772} = 0.1699$
8. $x_8 = 49.3 \Rightarrow e^{-\frac{(48-49.3)^2}{2 \cdot 14.77^2}} = e^{-0.004} = 0.9960$
9. $x_9 = 9.3 \Rightarrow e^{-\frac{(48-9.3)^2}{2 \cdot 14.77^2}} = e^{-4.507} = 0.0111$
10. $x_{10} = 33.0 \Rightarrow e^{-\frac{(48-33.0)^2}{2 \cdot 14.77^2}} = e^{-1.282} = 0.2767$

La somma dei termini è quindi:

$$\sum_{i=1}^{10} e^{-\frac{(48-x_i)^2}{2 \cdot 14.77^2}} = 3.7726$$

Applicando il fattore di normalizzazione:

$$\hat{f}(48) = \frac{1}{10 \cdot 14.77 \cdot \sqrt{2\pi}} \cdot 3.7726 = 0.0134$$

Calcolo per $x = 100$

Analogamente, per $x = 100$:

$$\hat{f}(100) = \frac{1}{10 \cdot 14.77 \cdot \sqrt{2\pi}} \sum_{i=1}^{10} e^{-\frac{(100-x_i)^2}{2 \cdot 14.77^2}}$$

Calcoliamo i termini della somma:

1. $x_1 = 101.8 \Rightarrow e^{-\frac{(100-101.8)^2}{2 \cdot 14.77^2}} = e^{-0.015} = 0.9851$
2. $x_2 = 70.4 \Rightarrow e^{-\frac{(100-70.4)^2}{2 \cdot 14.77^2}} = e^{-2.669} = 0.0695$
3. $x_3 = 61.5 \Rightarrow e^{-\frac{(100-61.5)^2}{2 \cdot 14.77^2}} = e^{-5.227} = 0.0054$
4. $x_4 = 46.5 \Rightarrow e^{-\frac{(100-46.5)^2}{2 \cdot 14.77^2}} = e^{-8.748} = 0.0002$
5. $x_5 = 30.0 \Rightarrow e^{-\frac{(100-30.0)^2}{2 \cdot 14.77^2}} = e^{-11.438} = 0.00001$
6. $x_6 = 34.3 \Rightarrow e^{-\frac{(100-34.3)^2}{2 \cdot 14.77^2}} = e^{-10.931} = 0.00002$
7. $x_7 = 73.5 \Rightarrow e^{-\frac{(100-73.5)^2}{2 \cdot 14.77^2}} = e^{-2.473} = 0.0845$
8. $x_8 = 49.3 \Rightarrow e^{-\frac{(100-49.3)^2}{2 \cdot 14.77^2}} = e^{-7.012} = 0.0009$
9. $x_9 = 9.3 \Rightarrow e^{-\frac{(100-9.3)^2}{2 \cdot 14.77^2}} = e^{-17.218} \approx 0$
10. $x_{10} = 33.0 \Rightarrow e^{-\frac{(100-33.0)^2}{2 \cdot 14.77^2}} = e^{-11.063} = 0.00002$

La somma dei termini è quindi:

$$\sum_{i=1}^{10} e^{-\frac{(100-x_i)^2}{2 \cdot 14.77^2}} = 1.1456$$

Applicando il fattore di normalizzazione:

$$\hat{f}(100) = \frac{1}{10 \cdot 14.77 \cdot \sqrt{2\pi}} \cdot 1.1456 = 0.0037$$

Si osservi che le stime calcolate su $x = 48$ e $x = 100$ sono esattamente quelle riportate nel grafico di Figura 1.