

Laboratorio di analisi dei dati con R — Traccia esercizi

Ottavia Epifania

Case Study A: Test di selezione universitario

Il case study richiede di eseguire delle procedure di analisi dei dati su un insieme di variabili associate a 70 candidati di un corso di laurea del nord-est.

Esercizio 1

Scaricare il file `datiTestCR2005.csv` (moodle del corso) e caricarlo nella variabile (data frame) `datitest` in R. Il file contiene un database con 70 osservazioni misurate su 7 variabili distinte:

- `DIPAA` indica l'anno in cui lo studente ha ottenuto il suo diploma di scuola superiore;
- `VOTO` è il voto di diploma ottenuto dallo studente (espresso in centesimi);
- `SESSO` codifica il sesso dello studente (1: maschio, 2: femmina);
- `D1` punteggio complessivo ad un test per la misura del ragionamento deduttivo [0,17];
- `D2` punteggio complessivo ad un test per la misura del ragionamento spaziale [0,20];
- `D3` punteggio complessivo ad un test per la misura del pensiero creativo [0,4];
- `D4` punteggio complessivo ad un test per la comprensione di testi, grafici e tabelle [0,12].

Si eseguano i seguenti controlli.

1. Verificare che **tutte** le variabili non contengano dei valori scorretti.
2. Se vi sono delle variabili che presentano dei valori scorretti, sostituire le osservazioni in `datitest` che presentano tali valori scorretti con la media della variabile di riferimento, escludendo dal calcolo della media i dati scorretti.
3. Visualizzare le statistiche descrittive di base (`summary()`) delle variabili `VOTO` e `D1`, ..., `D4`.
4. Costruire ed assegnare una variabile `votomedioM` che contiene il voto medio dei candidati maschi. Creare un'analoga variabile `votomedioF` per le femmine.

5. Verificare se il voto medio delle femmine è superiore a quello dei maschi.
6. Verificare se la deviazione standard del voto delle femmine è superiore a quella dei maschi.
7. Verificare se il voto medio dei diplomati nel 2005 è superiore rispetto a quello dei diplomati nel 2004.
8. Verificare se il voto medio dei diplomati maschi nel 2005 è superiore rispetto a quello dei diplomati maschi nel 2004.
9. Verificare se il punteggio medio del ragionamento spaziale nei maschi è superiore rispetto a quello delle femmine.
10. Verificare se il punteggio medio del ragionamento deduttivo nei maschi è superiore rispetto a quello delle femmine.
11. Verificare se il punteggio medio del pensiero creativo nelle femmine è superiore rispetto a quello dei maschi.
12. Verificare se il punteggio medio del ragionamento deduttivo nei maschi che hanno avuto un voto di diploma superiore a 80 è superiore rispetto a quello delle femmine con voto di diploma superiore a 90.
13. Verificare se il punteggio medio del ragionamento deduttivo nei maschi che hanno avuto un voto di diploma superiore a 80 e che hanno avuto un punteggio inferiore a 2 nel test per la misura del pensiero creativo è superiore rispetto a quello delle femmine con voto di diploma superiore a 85.
14. Visualizzare la distribuzione del voto di diploma attraverso un istogramma. Chiudere la finestra del grafico.
15. **Nota 1:** utilizzando il comando `par(mfrow=c(n1,n2))` è possibile cambiare i parametri grafici perché appaiano più grafici. Ad esempio, `par(mfrow=c(2,3))` produce una finestra suddivisa in due righe e tre colonne, ogni cella della finestra può contenere un grafico diverso.
16. Produrre due boxplot dei voti, uno per i maschi ed uno per le femmine. Devono apparire nello stesso grafico (usare il comando `par(mfrow=c(n1,n2))`)
17. Creare quattro grafici di boxplot (disponendoli in una unica finestra grafica) contenenti:
 - i punteggi del ragionamento deduttivo per i maschi con voto di diploma inferiore a 75,
 - i punteggi del ragionamento deduttivo per le femmine con voto di diploma inferiore a 75,
 - i punteggi del ragionamento deduttivo per i maschi con voto di diploma superiore o uguale a 75,
 - i punteggi del ragionamento deduttivo per le femmine con voto di diploma superiore o uguale a 75.

18. Creare una nuova variabile `PTOT` contenente il punteggio complessivo (calcolato come somma dei singoli test `D1`, ..., `D4`) per ogni studente.
19. Creare una nuova variabile `PTOTc` che contiene il punteggio totale `PTOT` corretto per il voto di diploma secondo la seguente formula:

$$PTOTc = PTOT \times \log_2 \left(\frac{100}{VOTO} \right)$$

20. Visualizzare il grafico di dispersione tra `VOTO` e `PTOT`. Il grafico può essere ottenuto con la funzione `plot(X, Y)`, dove `X` è la variabile che si vuole rappresentare sul grafico delle `X` e `Y` la variabile che si vuole rappresentare sull'asse delle `Y`.
21. Ripetere la procedura utilizzando `PTOTc` al posto di `PTOT`.