

Analisi dei Dati con
Applicazioni Informatiche di Base

Laboratorio di analisi dei dati con R
Esercizi ed approfondimenti
(3)

Luigi Lombardi
Dipartimento di Psicologia e Scienze Cognitive
Università di Trento

6/10/2017

Gli esercizi di seguito presentati devono essere svolti usando il pacchetto statistico R.

1 Case Study A: Test di selezione universitario

Il case study richiede di eseguire delle procedure di analisi dei dati su un insieme di variabili associate a 70 candidati di un corso di laurea del nord-est.

Esercizio 1 Scaricare il file `datiTestCR2005.csv` e caricarlo nella variabile (data frame) `DATITEST` in R. Il file contiene un database con 70 osservazioni misurate su 7 variabili distinte:

- *DIPAA* indica l'anno in cui lo studente ha ottenuto il suo diploma di scuola superiore;
- *VOTO* è il voto di diploma ottenuto dallo studente (espresso in centesimi);
- *SESSO* codifica il sesso dello studente (1: maschio, 2: femmina);
- *D1* punteggio complessivo ad un test per la misura del ragionamento deduttivo [0,17];
- *D2* punteggio complessivo ad un test per la misura del ragionamento spaziale [0,20];
- *D3* punteggio complessivo ad un test per la misura del pensiero creativo [0,4];
- *D4* punteggio complessivo ad un test per la comprensione di testi, grafici e tabelle [0,12].

Si eseguano i seguenti controlli.

1. Verificare che le variabili *VOTO*, *SESSO*, *D1*, ..., *D4* non contengano dei valori scorretti.
2. Se vi sono delle variabili che presentano dei valori scorretti, sostituire le osservazioni in `DATITEST` che presentano tali valori scorretti con la media della variabile di riferimento, escludendo dal calcolo della media i dati scorretti.
3. Visualizzare le statistiche descrittive di base [`summary()`] delle variabili *VOTO* e *D1*, ..., *D4*.
4. Costruire ed assegnare una variabile `votomedioM` che contiene il voto medio dei candidati maschi. Creare un'analogia variabile `votomedioF` per le femmine.
5. Verificare se il voto medio delle femmine è superiore a quello dei maschi.
6. Verificare se la deviazione standard del voto delle femmine è superiore a quella dei maschi.
7. Verificare se il voto medio dei diplomati nel 2005 è superiore rispetto a quello dei diplomati nel 2004.
8. Verificare se il voto medio dei diplomati maschi nel 2005 è superiore rispetto a quello dei diplomati maschi nel 2004.
9. Verificare se il punteggio medio del ragionamento spaziale nei maschi è superiore rispetto a quello delle femmine.
10. Verificare se il punteggio medio del ragionamento deduttivo nei maschi è superiore rispetto a quello delle femmine.
11. Verificare se il punteggio medio del pensiero creativo nelle femmine è superiore rispetto a quello dei maschi.

12. Verificare se il punteggio medio del ragionamento deduttivo nei maschi che hanno avuto un voto di diploma superiore a 80 è superiore rispetto a quello delle femmine con voto di diploma superiore a 90.
13. Verificare se il punteggio medio del ragionamento deduttivo nei maschi che hanno avuto un voto di diploma superiore a 80 e che hanno avuto un punteggio inferiore a 2 nel test per la misura del pensiero creativo è superiore rispetto a quello delle femmine con voto di diploma superiore a 85.
14. Visualizzare la distribuzione del voto di diploma attraverso un istogramma. Chiudere la finestra del grafico.
15. **Nota 1:** utilizzando il comando `par(mfrow=c(n1,n2))` è possibile aprire una finestra che può contenere dei grafici multipli. Ad esempio, `par(mfrow=c(2,3))` produce una finestra suddivisa in due righe e tre colonne, ogni cella della finestra può contenere un grafico diverso. Attenzione i grafici che vengono creati sono inseriti di volta in volta nella finestra multipla. Se si commette un errore nella produzione del singolo grafico è necessario chiudere la finestra multipla e ripetere l'intera procedura. Per tale motivo è consigliabile scrivere su un documento di testo la sintassi di R, per evitare di reinserirla più volte.
16. Produrre due boxplot dei voti, uno per i maschi ed uno per le femmine. Inserire ciascun grafico in una finestra multipla appositamente progettata. (Suggerimento: per ottenere delle informazioni su qualunque funzione di R, digitare `?nomefunzione`; es `?boxplot`).
17. **Nota 2:** Se una finestra grafica singola o multipla (ma opportunamente riempita dei singoli grafici) è già presente nell'interfaccia di R, allora per produrre dei nuovi grafici è necessario chiudere la finestra grafica aperta.
18. Creare quattro grafici di boxplot (disponendoli in una unica finestra grafica) contenenti:
 - i punteggi del ragionamento deduttivo per i maschi con voto di diploma inferiore a 75,
 - i punteggi del ragionamento deduttivo per le femmine con voto di diploma inferiore a 75,
 - i punteggi del ragionamento deduttivo per i maschi con voto di diploma superiore o uguale a 75,
 - i punteggi del ragionamento deduttivo per le femmine con voto di diploma superiore o uguale a 75.
19. Creare una nuova variabile `PTOT` contenente il punteggio complessivo (calcolato come somma dei singoli test $D1, \dots, D4$) per ogni studente.
20. Creare una nuova variabile `PTOTc` che contiene il punteggio totale `PTOT` corretto per il voto di diploma secondo la seguente formula:

$$PTOTc = PTOT \times \log_2 \left(\frac{100}{VOTO} \right).$$

21. Visualizzare il grafico di dispersione tra `VOTO` e `PTOT`. Il grafico di dispersione può essere ottenuto utilizzando la funzione grafica `plot(X,Y)` dove `X` è la variabile da rappresentare in ascissa e `Y` è la variabile da rappresentare in ordinata.
22. Ripetere la procedura utilizzando `PTOTc` al posto di `PTOT`.