

Laboratorio di analisi dei dati con R — Soluzioni

Ottavia Epifania

Case Study A: Test di selezione universitario

Il case study richiede di eseguire delle procedure di analisi dei dati su un insieme di variabili associate a 70 candidati di un corso di laurea del nord-est.

Esercizio 1

Scaricare il file `datiTestCR2005.csv` (moodle del corso) e caricarlo nella variabile (data frame) `datitest` in R. Il file contiene un database con 70 osservazioni misurate su 7 variabili distinte:

- `DIPAA` indica l'anno in cui lo studente ha ottenuto il suo diploma di scuola superiore;
- `VOTO` è il voto di diploma ottenuto dallo studente (espresso in centesimi, voto minimo = 60);
- `SESSO` codifica il sesso dello studente (1: maschio, 2: femmina);
- `D1` punteggio complessivo ad un test per la misura del ragionamento deduttivo [0,17];
- `D2` punteggio complessivo ad un test per la misura del ragionamento spaziale [0,20];
- `D3` punteggio complessivo ad un test per la misura del pensiero creativo [0,4];
- `D4` punteggio complessivo ad un test per la comprensione di testi, grafici e tabelle [0,12].

```
datitest <- read.csv2("datiTestCR2005.csv")
```

```
Warning in scan(file = file, what = what, sep = sep, quote = quote, dec = dec,  
: embedded nul trovati in input
```

Appare un warning relativo all'importazione del file. Per controllare se tutto però è andato bene:

```
head(datitest)
```

	DIPAA	VOTO	SESSO	D1	D2	D3	D4
1	2005	63	2	9	17	2	11
2	1999	80	1	12	18	2	8
3	2005	64	1	11	17	2	5
4	2005	95	1	9	14	3	3
5	2005	93	2	13	18	4	12
6	2005	65	2	7	11	0	12

Si eseguano i seguenti controlli.

1. Verificare che **tutte** le variabili non contengano dei valori scorretti.

```
# Voto
datitest$VOTO >= 60 & datitest$VOTO <= 100
```

[1]	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE
[13]	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE
[25]	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE
[37]	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE
[49]	TRUE	FALSE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE
[61]	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE	TRUE

Attenzione! c'è un valore che FALSE, va trovato con la funzione `which()`

```
which(datitest$VOTO < 60 | datitest$VOTO > 100)
```

```
[1] 50
```

```
# che voto ha preso?
index = which(datitest$VOTO < 60 | datitest$VOTO > 100)
datitest$VOTO[index]
```

```
[1] 39
```

```
# sesso
datitest$SESSO == 1 | datitest$SESSO == 2
```

```
[1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
[16] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
[31] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
[46] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
[61] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
```

```
# per fare prima: sappiamo che ci sono 70 osservazioni. Se tutti i risultati del
# test sono veri, il risultato sarà 70, per cui:
sum(datitest$SESSO == 1 | datitest$SESSO == 2) == nrow(datitest)
```

```
[1] TRUE
```

```
# controlla le altre variabili
sum((datitest$D1 >= 0) & (datitest$D1 <= 17)) == nrow(datitest)
```

```
[1] TRUE
```

```
sum((datitest$D2 >= 0) & (datitest$D2 <= 20)) == nrow(datitest)
```

```
[1] TRUE
```

```
sum((datitest$D3 >= 0) & (datitest$D3 <= 4)) == nrow(datitest)
```

```
[1] TRUE
```

```
sum((datitest$D4 >= 0) & (datitest$D4 <= 12)) == nrow(datitest)
```

```
[1] TRUE
```

2. Se vi sono delle variabili che presentano dei valori scorretti, sostituire le osservazioni in `datitest` che presentano tali valori scorretti con la media della variabile di riferimento, escludendo dal calcolo della media i dati scorretti.

```
# Setp1: calcolare la media della variabile voto SENZA l'osservazione sbagliata
media_corretta = mean(datitest$VOTO[-index])
# Setp 2: sostituire il valore
datitest$VOTO[index] = media_corretta
# step 3: controllare che abbia funzionato:
which(datitest$VOTO < 60 | datitest$VOTO > 100)
```

```
integer(0)
```

3. Visualizzare le statistiche descrittive di base (`summary()`) delle variabili VOTO e D1, ..., D4.

```
summary(datitest[, c("VOTO", "D1", "D2", "D3", "D4")])
```

VOTO	D1	D2	D3
Min. : 60.00	Min. : 5.00	Min. : 7.00	Min. : 0.000
1st Qu.: 69.25	1st Qu.: 9.00	1st Qu.: 13.00	1st Qu.: 1.000
Median : 78.84	Median : 11.00	Median : 14.00	Median : 2.000
Mean : 78.68	Mean : 10.79	Mean : 14.36	Mean : 2.057
3rd Qu.: 87.00	3rd Qu.: 13.00	3rd Qu.: 17.00	3rd Qu.: 3.000
Max. : 100.00	Max. : 15.00	Max. : 20.00	Max. : 4.000

D4

Min. : 3.000
1st Qu.: 9.000
Median : 10.000
Mean : 9.686
3rd Qu.: 11.000
Max. : 12.000

4. Costruire ed assegnare una variabile `votomedioM` che contiene il voto medio dei candidati maschi. Creare un'analogia variabile `votomedioF` per le femmine.

```
votoM = datitest$VOTO[datitest$SESSO == 1]
votomedioM = mean(votoM)

votoF = datitest$VOTO[datitest$SESSO == 2]
votomedioF = mean(votoF)
```

5. Verificare se il voto medio delle femmine è superiore a quello dei maschi.

```
votomedioF > votomedioM
```

```
[1] TRUE
```

6. Verificare se la deviazione standard del voto delle femmine è superiore a quella dei maschi.

```
sdvotoM = sd(votoM)
sdvotoF = sd(votoF)

sdvotoF > sdvotoM
```

```
[1] TRUE
```

7. Verificare se il voto medio dei diplomati nel 2005 è superiore rispetto a quello dei diplomati nel 2004.

```
voto2005 = datitest$VOTO[datitest$DIPAA == 2005]
voto2004 = datitest$VOTO[datitest$DIPAA == 2004]

media2005 = mean(voto2005)
media2004 = mean(voto2004)
media2005 > media2004
```

```
[1] TRUE
```

8. Verificare se il voto medio dei diplomati maschi nel 2005 è superiore rispetto a quello dei diplomati maschi nel 2004.

```
M2005 = datitest$VOTO[datitest$DIPAA==2005 & datitest$SESSO==1]
M2004 = datitest$VOTO[datitest$DIPAA==2004 & datitest$SESSO==1]

media_m2005 = mean(M2005)
media_m2004 = mean(M2004)

media_m2005 > media_m2004
```

```
[1] TRUE
```

9. Verificare se il punteggio medio del ragionamento spaziale nei maschi è superiore rispetto a quello delle femmine.

```
votomedioD2M <- mean(datitest$D2[datitest$SESSO==1])
votomedioD2F <- mean(datitest$D2[datitest$SESSO==2])

votomedioD2M > votomedioD2F
```

```
[1] TRUE
```

10. Verificare se il punteggio medio del ragionamento deduttivo nei maschi è superiore rispetto a quello delle femmine.

```
votomedioD1M <- mean(datitest$D1[datitest$SESSO==1])
votomedioD1F <- mean(datitest$D1[datitest$SESSO==2])

votomedioD1M > votomedioD1F
```

[1] FALSE

11. Verificare se il punteggio medio del pensiero creativo nelle femmine è superiore rispetto a quello dei maschi.

```
votomedioD3M <- mean(datitest$D3[datitest$SESSO==1])
votomedioD3F <- mean(datitest$D3[datitest$SESSO==2])

votomedioD3M < votomedioD3F
```

[1] FALSE

12. Verificare se il punteggio medio del ragionamento deduttivo nei maschi che hanno avuto un voto di diploma superiore a 80 è superiore rispetto a quello delle femmine con voto di diploma superiore a 90.

```
votomedioD1Ms80 <- mean(datitest$D1[datitest$SESSO==1 & datitest$VOTO>80])
votomedioD1Fs90 <- mean(datitest$D1[datitest$SESSO==2 & datitest$VOTO>90])

votomedioD1Ms80 > votomedioD1Fs90
```

[1] FALSE


13. Verificare se il punteggio medio del ragionamento deduttivo nei maschi che hanno avuto un voto di diploma superiore a 80 e che hanno avuto un punteggio inferiore a 2 nel test per la misura del pensiero creativo è superiore rispetto a quello delle femmine con voto di diploma superiore a 85.

```
mediaF85 = mean(datitest$VOTO[datitest$SESSO == 2 & datitest$VOTO > 85])
maschi = datitest[datitest$SESSO == 1, ]
mediaM80 = mean(maschi$D3 < 2 & maschi$VOTO > 80, "D1")
mediaM80 > mediaF85
```


[1] FALSE

14. Visualizzare la distribuzione del voto di diploma attraverso un istogramma.

```
hist(datitest$VOTO)
```




```
hist(datitest$VOTO, freq = FALSE)  
lines(density(datitest$VOTO))
```




15. **Nota 1:** utilizzando il comando `par(mfrow=c(n1,n2))` è possibile cambiare i parametri grafici perché appaiano più grafici. Ad esempio, `par(mfrow=c(2,3))` produce una finestra suddivisa in due righe e tre colonne, ogni cella della finestra può contenere un grafico diverso.
16. Produrre due boxplot dei voti, uno per i maschi ed uno per le femmine. Devono apparire nello stesso grafico (usare il comando `par(mfrow=c(n1,n2))`)

```
par(mfrow=c(1,2))
boxplot(datitest$VOTO[datitest$SESSO ==1], main = "Voto dei maschi")
boxplot(datitest$VOTO[datitest$SESSO ==2], main = "Voto delle femmine")
```



Voto dei maschi



Voto delle femmine



```
par(mfrow=c(1,1)) # riporta normale la finestra
boxplot(datitest$VOTO ~ datitest$SESSO,
        col = c("seagreen", "orchid"),
        xlab = "Sesso", ylab="Voto")
```



17. Creare quattro grafici di boxplot (disponendoli in una unica finestra grafica) contenenti:

- i punteggi del ragionamento deduttivo per i maschi con voto di diploma inferiore a 75,
- i punteggi del ragionamento deduttivo per le femmine con voto di diploma inferiore a 75,
- i punteggi del ragionamento deduttivo per i maschi con voto di diploma superiore o uguale a 75,
- i punteggi del ragionamento deduttivo per le femmine con voto di diploma superiore o uguale a 75.

```
par(mfrow=c(2,2))
boxplot(datitest$D1[datitest$SESSO==1 & datitest$VOTO<75],xlab="D1 Maschi con voto < 75")
boxplot(datitest$D1[datitest$SESSO==2 & datitest$VOTO<75],xlab="D1 Femmine con voto < 75")
boxplot(datitest$D1[datitest$SESSO==1 & datitest$VOTO>=75],xlab="D1 Maschi con voto >= 75")
boxplot(datitest$D1[datitest$SESSO==2 & datitest$VOTO>=75],xlab="D1 Femmine con voto >= 75")
```



D1 Maschi con voto < 75



D1 Femmine con voto < 75



D1 Maschi con voto >= 75



D1 Femmine con voto >= 75

18. Creare una nuova variabile `PTOT` contenente il punteggio complessivo (calcolato come somma dei singoli test D1, ..., D4) per ogni studente.

```
datitest$PTOT = apply(datitest[, c("D1", "D2", "D3", "D4")], 1, sum)
# la funzione rowSums() avrebbe prodotto lo stesso risultato
# datitest$PTOT = rowSums(datitest[, c("D1", "D2", "D3", "D4")])
```

19. Creare una nuova variabile `PTOTc` che contiene il punteggio totale `PTOT` corretto per il voto di diploma secondo la seguente formula:

$$PTOTc = PTOT \times \log_2 \left(\frac{100}{VOTO} \right)$$

```
datitest$PTOTc <- datitest$PTOT*log2(100/datitest$VOTO)


datitest$PTOTc
```

```
[1] 25.996474 12.877124 22.534967  2.146017  4.920777 18.644651 27.267727
[8]  0.000000 15.045290  0.000000 15.082786  7.634682 22.534967 29.478624
[15]  3.952080 20.635037 12.877124 21.752093 10.375937 26.896735 21.413269
[22]  6.454860  7.565524  2.179066  8.440749 10.623627 13.842908 33.900417
[29]  9.378610  0.000000 14.526312 16.691800 14.328647  9.139770 11.738472
```

```
[36]  5.472111  9.979771 18.244919 20.981172  0.000000 21.246690 12.187435
[43]  9.448038  7.043085 18.010061  1.669847 29.478624  5.320108 11.911340
[50] 13.144575 24.827756  0.000000 16.345139  5.306400 14.696613 16.072904
[57]  0.000000  8.244441 15.437075 12.242716  4.090004 19.982530  2.960023
[64] 10.623627 10.313089 21.955146 17.846612 26.530761  8.036508 27.098516
```

20. Visualizzare il grafico di dispersione tra VOTO e PTOT. Il grafico può essere ottenuto con la funzione `plot(X, Y)`, dove X è la variabile che si vuole rappresentare sul grafico delle X e Y la variabile che si vuole rappresentare sull'asse delle Y.

```
par(mfrow=c(1,1))
plot(datitest$VOTO, datitest$PTOT, pch = 19,
     col = ifelse(datitest$SESSO == 1, "seagreen", "orchid"))
```



21. Ripetere la procedura utilizzando PTOTc al posto di PTOT.

```
plot(datitest$VOTO, datitest$PTOTc, pch = 19,
     col = ifelse(datitest$SESSO == 1, "seagreen", "orchid"))
```

