

Modulo Didattico 2 – Statistiche descrittive e illustrazioni

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

A.A. 2026/2027

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

- 1 File esterni di dati
 - Working Directories (wd)
 - Caricare
 - Sintesi di strutture tabellari
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

`getwd()`

①

- ① Restituisce la wd in cui ci si trova (default: cartella dove si trova l'installazione di R)

```
[1] "C:/Users/Ottavia/Documents/GitHub/stpc-analisi-dati/slides/modulo2"
```

`setwd("C/Documenti/I-miei-file")`

②

- ② Permette di settare una nuova wd

`dir()`

③

- ③ Vettore che indica tutti i file/sottorcartelle presenti nella wd ottenuta con `getwd()`

```
[1] "img" "Kernel_esempio_di_calcolo.pdf"
[3] "Laboratorio" "lezione-2-ottobre.25.R"
[5] "Modulo2.log" "Modulo2.qmd"
[7] "Modulo2_Script_1_1.R" "Modulo2_Script_1_1.R"
```

Esercizio

- ① Aprire un nuovo script in Rstudio
 - File, New File, R script oppure tasti `shift + ctrl + n`
- ② Determinare in che wd ci si trova (copia & incolla il risultato del comando `getwd()` nello script sottoforma di commento)
- ③ Creare una nuova cartella sul desktop dal nome `corso-analisi`
- ④ Usare il comando `setwd()` per spostarsi in quella cartella

- 1 File esterni di dati
 - Working Directories (wd)
 - Caricare
 - Sintesi di strutture tabellari
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

```
read.csv2("file_path")
```

Se si possiede un dataset chiamato “Dati” nella cartella “EXP”, questo codice lo importerà all’interno dell’ambiente

```
# Lettura file dati esterni  
DATI <- read.csv2("C:\\EXP\\Dati.csv")
```

- 1 File esterni di dati
 - Working Directories (wd)
 - Caricare
 - Sintesi di strutture tabellari
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

summary()

```
summary(data)
```

Riassume il contenuto di strutture di dati

```
summary(data)
```

Riassume il contenuto di strutture di dati

```
summary(rock)
```

area		peri		shape		perm	
Min.	: 1016	Min.	: 308.6	Min.	:0.09033	Min.	: 6.30
1st Qu.:	5305	1st Qu.:	1414.9	1st Qu.:	0.16226	1st Qu.:	76.45
Median	: 7487	Median	:2536.2	Median	:0.19886	Median	: 130.50
Mean	: 7188	Mean	:2682.2	Mean	:0.21811	Mean	: 415.45
3rd Qu.:	8870	3rd Qu.:	3989.5	3rd Qu.:	0.26267	3rd Qu.:	777.50
Max.	:12212	Max.	:4864.2	Max.	:0.46413	Max.	:1300.00

str()

```
str(data)
```

Fornisce informazioni circa la struttura generale di un oggetto:

str()

```
str(data)
```

Fornisce informazioni circa la struttura generale di un oggetto:

```
str(rock)
```

```
'data.frame':   48 obs. of  4 variables:
 $ area : int   4990 7002 7558 7352 7943 7979 9333 8209 8393 6425
 $ peri : num   2792 3893 3931 3869 3949 ...
 $ shape: num    0.0903 0.1486 0.1833 0.1171 0.1224 ...
 $ perm : num    6.3 6.3 6.3 6.3 17.1 17.1 17.1 17.1 119 119 ...
```

Le prime 6 osservazioni del dataset

le ultime 6 osservazioni del dataset

apply()

```
apply(data, MARGIN, FUN)
```

data: i dati su cui si vuole lavorare

MARGIN: 1 applica la funzione sulle righe (attraverso le colonne), 2 applica la funzione sulle colonne (attraverso le righe)

FUN: la funzione che si vuole applicare

```
apply(rock, 1, sum)    # Somma per riga
```

```
[1] 7788.290 10901.049 11495.143 11227.737 11908.762 12006.417 13696.040
[8] 12571.014 12194.244 9642.812 13963.201 12729.388 14770.169 12468.672
[15] 13498.943 12585.623 15629.464 15589.483 16801.020 14405.155 11408.854
[22] 16371.431 17051.890 11893.602 9077.671 6312.529 10072.432 7571.553
[29] 9250.435 7025.001 9393.452 10245.336 8356.958 7258.715 9692.914
[36] 10305.336 4945.877 2044.761 4813.624 7012.214 7289.872 2624.872
[43] 8051.154 12373.910 5229.311 2829.071 7550.062 11783.780
```

```
apply(rock, 2, mean)  # Media per colonna
```

```
      area      peri      shape      perm
7187.7291667 2682.2119375 0.2181104 415.4500000
```

- 1 File esterni di dati
- 2 Variabili**
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

Scale di misura

Scala Rapporto



Scala Intervallo



Scala Ordinale



Scala Nominale



Tipologia variabili in R

`as.numeric(A)`

`factor(A, ..., ordered=TRUE)`

`as.factor(A)`

- 1 File esterni di dati
- 2 Variabili
 - Categoricali - Nominali
 - Categoricali - Ordinali
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

as.factor()

as.factor(): Converte una variabile in una variabile di tipo **categoriale/nominale** con tanti livelli quanti sono i valori unici nel vettore

Due livelli

```
Genere <- c("m", "f", "f", "m", "f", "m")
```

Genere

```
[1] "m" "f" "f" "m" "f" "m"
```

as.factor()

as.factor(): Converte una variabile in una variabile di tipo **categoriale/nominale** con tanti livelli quanti sono i valori unici nel vettore

Due livelli

```
Genere <- c("m", "f", "f", "m", "f", "m")
```

Genere

```
[1] "m" "f" "f" "m" "f" "m"
```

```
as.factor(Genere)
```

```
[1] m f f m f m
```

```
Levels: f m
```

Più livelli

```
diagnosi <- c("schizo", "dep", "narc", "schizo", "dep", "narc")  
diagnosi
```

```
[1] "schizo" "dep"    "narc"   "schizo" "dep"    "narc"
```

Più livelli

```
diagnosi <- c("schizo", "dep", "narc", "schizo", "dep", "narc")  
diagnosi
```

```
[1] "schizo" "dep"      "narc"     "schizo" "dep"      "narc"
```

```
as.factor(diagnosi)
```

```
[1] schizo dep      narc      schizo dep      narc  
Levels: dep narc schizo
```

- 1 File esterni di dati
- 2 Variabili
 - Categoricali - Nominali
 - Categoricali - Ordinali
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

```
factor(A,levels=c("a1","a2",..., "ak"),
       ordered=TRUE)
```

Converte la variabile in una variabile con tanti livelli quanti sono i valori unici e viene forzato un ordine su questi livelli:

```
Voto <- c("alto","medio","medio","basso","alto")
Voto
```

```
[1] "alto" "medio" "medio" "basso" "alto"
```

```
factor(Voto,levels=c("basso","medio","alto"), ordered=TRUE)
```

```
[1] alto medio medio basso alto
Levels: basso < medio < alto
```

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base**
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base**
 - Tavole di frequenza
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

```
table(variabile)
```

Calcola le occorrenze (frequenze) per ogni categoria. Funziona sia per le variabili categoriali sia per le variabili numeriche

```
table(Genere)
```

```
Genere
```

```
f m
```

```
3 3
```

```
table(diagnosi)
```

```
diagnosi
```

```
dep
```

```
narc
```

```
schizo
```

```
2
```

```
2
```

```
2
```

Altre funzioni

Funzione	Significato
<code>mean()</code>	Media
<code>min(), max()</code>	Minimo, Massimo
<code>range()</code>	Range di valori entro cui varia la variabile
<code>quantile(x, probs)</code>	Calcola il quantile $p=\text{probs}$ della variabile numerica X
<code>sd(), var()</code>	Deviazione st., Varianza
<code>sum()</code>	Somma

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali**
- 5 Grafici
- 6 Da Excel a R

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali**
 - `set.seed()`
- 5 Grafici
- 6 Da Excel a R

```
set.seed()
```

Permette di settare un seed comune a tutt

Garantisce la perfetta replicabilità dei risultati

Garantisce che se tutt settiamo questo seed, otteniamo gli stessi grafici

```
set.seed(999)
```

```
set.seed()
```

`rnorm(n, mean = 0, sd = 1)` :Genera n valori casuali e indipendenti da una variabile casuale normale con media `mean` 0 e deviazione standard `sd` 1 (normale standard)

```
set.seed()
```

`rnorm(n, mean = 0, sd = 1)` :Genera `n` valori casuali e indipendenti da una variabile casuale normale con media `mean` 0 e deviazione standard `sd` 1 (normale standard)

`runif(n, min = 0, max = 1)` Genera `n` valori casuali e indipendenti da una variabile casuale uniforme, dove i valori sono compresi tra 0 (`min`) e 1 (`max`)


A set of navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
- 6 Da Excel a R


- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
 - Istogrammi
 - Boxplot
 - Boxplot – Calcolo degli outlier
 - Istogramma con kernel
 - Utilizzare i kernel

Istogrammi

`hist(x, breaks)` Produce un istogramma a partire da un vettore `x` di osservazioni quantitative. `breaks` definisce la larghezza delle singole barre, secondo diverse regole





(a) $n = 500$




(a) $n = 50$

Istogrammi con n diverso







(a) Sturges - Default



(a) FD



(a) Scott



(a) User defined (145)

Sturges:

$$\frac{\max(x) - \min(x)}{\log_2(n + 1)}$$

Scott:

$$3.5 \sqrt{\text{var}(x)} n^{-1/3}$$

Freedman-Diaconis

$$2 (Q_3 - Q_1) n^{-1/3}$$


User defined:

$$\frac{\max(x) - \min(x)}{\text{breaks}}$$

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
 - Istogrammi
 - Boxplot
 - Boxplot – Calcolo degli outlier
 - Istogramma con kernel
 - Utilizzare i kernel

Boxplot

`boxplot(x)` Produce un boxplot a partire da un vettore X di osservazioni quantitative



- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
 - Istogrammi
 - Boxplot
 - Boxplot – Calcolo degli outlier
 - Istogramma con kernel
 - Utilizzare i kernel

La lunghezza dei baffi (e di conseguenza la definizione degli outliers) è definita attraverso il metodo Tukey:


$$[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$$

dove $IQR = Q_3 - Q_1$ (Inter-quartile range)


Settando l'argomento `range = x` si può cambiare il modo in cui vengono calcolati i baffi:

```
boxplot(x, range = 2)
```

```
boxplot(x, range = 0)
```



(a) range = 2 - Meno Conservativo




(a) range = 0 - Minimo e Massimo

Calcolo degli outlier

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
 - Istogrammi
 - Boxplot
 - Boxplot – Calcolo degli outlier
 - Istogramma con kernel
 - Utilizzare i kernel

Istogramma con kernel

kernel density estimation, KDE: Metodo non parametrico per *stimare* la funzione di densità di probabilità di una variabile casuale continua a partire da un campione di dati




Funzione che “assegna” una probabilità attorno a ogni singolo dato osservato

`density(X, bw)`: Stima della densità di una variabile a partire da un vettore `X` di osservazioni quantitative. `bw`: Larghezza della banda con cui viene stimato il kernel attorno a ogni dato:

Istogramma con kernel

Più è stretto attorno al dato: Si vede bene la struttura del dato, ma si rischia di essere in overfitting (quella stima va bene SOLO per quel dato)


Più è largo attorno al dato: La curva è ben definita e liscia, ma si rischia di perdere dettagli per questi specifici dati (underfitting)



- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
 - Istogrammi
 - Boxplot
 - Boxplot – Calcolo degli outlier
 - Istogramma con kernel
 - Utilizzare i kernel


La funzione calcola la densità, per vedere la densità va usata insieme alla funzione `plot()`

```
x = rnorm(200)
plot(density(x))
```



va imposto all'istogramma che costruisca i bin con la densità $d_i = \frac{f_i}{n * w_i}$

```
hist(x, freq = FALSE)
lines(density(x), lwd = 2, col = "blue")
```




- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**
 - Crea
 - Salva
 - Importa
 - Importa alternativa 1

[illegible]

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**
 - Crea
 - Salva
 - Importa
 - Importa alternativa 1

Salva



- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**
 - Crea
 - Salva
 - Importa
 - Importa alternativa 1

```
dati = read.csv2("C:/Users/Ottavia/Documents/GitHub/stpc-analisi-dati/s  
head(dati)
```

	ID	eta	sex	regione
1	sb1	18	M	nord
2	sb2	19	F	nord
3	sb3	21	F	nord
4	sb4	18	F	nord
5	sb5	19	M	centro
6	sb6	22	M	sud

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**
 - Crea
 - Salva
 - Importa
 - Importa alternativa 1

File esterni di dati
oooooooooooo

Variabili
oooooooo


Statistiche descrittive di base
oooo

Generazione di variabili casuali
oooo


Grafici
oooooooooooooooooooo

Da Excel a R
ooooooooo●oooooooo


Importa alternativa 1



Importa alternativa 1



Importa alternativa 1



Cancel

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**
 - Crea
 - Salva
 - Importa
 - Importa alternativa 1

	ID	eta	sezzo	regione
1	sb1	18	M	nord
2	sb2	19	F	nord
3	sb3	21	F	nord
4	sb4	18	F	nord
5	sb5	19	M	centro
6	sb6	22	M	sud