

Modulo Didattico 2 – Costruire ed importare dati esterni, funzioni per la sintesi di strutture tabellari

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

A.A. 2025/2026

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

- 1 File esterni di dati
 - Working Directories (wd)
 - Caricare
 - Sintesi di strutture tabellari

2 Variabili

3 Statistiche descrittive di base

4 Generazione di variabili casuali

5 Grafici

6 Da Excel a R

©

○

○

“

○

[illegible][1] [img](#) kernel_esempio_di_calcolo.pdf

[2] "Literaturverzeichnis" "Module2.pdf"

[3] "Laboratorio" "Modulo2.pdf"

[5] "M. 1. 3. 0. 11" "M. 1. 3. 0. 11" "

```
[5] "Modulo2.qmd"      "Modulo2.rmarkdown" 
```

Esercizio

- ① Aprire un nuovo script in Rstudio
 - File, New File, R script oppure tasti `shift + ctrl + n`
- ② Determinare in che wd ci si trova (copia & incolla il risultato del comando `getwd()` nello script sottoforma di commento)
- ③ Creare una nuova cartella sul desktop dal nome `corso-analisi`
- ④ Usare il comando `setwd()` per spostarsi in quella cartella

- 1 File esterni di dati
 - Working Directories (wd)
 - Caricare
 - Sintesi di strutture tabellari

2 Variabili

3 Statistiche descrittive di base

4 Generazione di variabili casuali

5 Grafici

6 Da Excel a R

- 1 File esterni di dati
 - Working Directories (wd)
 - Caricare
 - Sintesi di strutture tabellari

2 Variabili

3 Statistiche descrittive di base

4 Generazione di variabili casuali

5 Grafici

6 Da Excel a R

summary()

summary(data)

Riassume il contenuto di strutture di dati

summary(rock)

area	peri	shape	perm
Min. : 1016	Min. : 308.6	Min. : 0.09033	Min. : 6.30
1st Qu.: 5305	1st Qu.: 1414.9	1st Qu.: 0.16226	1st Qu.: 76.45
Median : 7487	Median : 2536.2	Median : 0.19886	Median : 130.50
Mean : 7188	Mean : 2682.2	Mean : 0.21811	Mean : 415.45
3rd Qu.: 8870	3rd Qu.: 3989.5	3rd Qu.: 0.26267	3rd Qu.: 777.50
Max. : 12212	Max. : 4864.2	Max. : 0.46413	Max. : 1300.00

str()

```
str(data)
```

Fornisce informazioni circa la struttura generale di un oggetto:

str()

```
str(data)
```

Fornisce informazioni circa la struttura generale di un oggetto:

```
str(rock)
```

```
'data.frame':   48 obs. of  4 variables:
 $ area : int   4990 7002 7558 7352 7943 7979 9333 8209 8393 6425
 $ peri : num   2792 3893 3931 3869 3949 ...
 $ shape: num   0.0903 0.1486 0.1833 0.1171 0.1224 ...
 $ perm : num    6.3  6.3  6.3  6.3 17.1 17.1 17.1 17.1 119 119 ...
```

`head()` (α) and `tail()` (ω)

head()

Le prime 6 osservazioni del dataset

```
head(rock)
```

	area	peri	shape	perm
1	4990	2791.90	0.0903296	6.3
2	7002	3892.60	0.1486220	6.3
3	7558	3930.66	0.1833120	6.3
4	7352	3869.32	0.1170630	6.3
5	7943	3948.54	0.1224170	17.1
6	7979	4010.15	0.1670450	17.1

tail()

le ultime 6 osservazioni del dataset

```
tail(rock)
```

	area	peri	shape	perm
43	5605	1145.690	0.464125	1300
44	8793	2280.490	0.420477	1300
45	3475	1174.110	0.200744	580
46	1651	597.808	0.262651	580
47	5514	1455.880	0.182453	580
48	9718	1485.580	0.200447	580

apply()

`apply(data, MARGIN, FUN)`

data: i dati su cui si vuole lavorare

MARGIN: 1 applica la funzione sulle righe (attraverso le colonne), 2 applica la funzione sulle colonne (attraverso le righe)

FUN: la funzione che si vuole applicare


```
apply(rock, 1, sum) # Somma per riga
```

```
[1] 7788.290 10901.049 11495.143 11227.737 11908.762 12006.417 13696.040
[8] 12571.014 12194.244 9642.812 13963.201 12729.388 14770.169 12468.672
[15] 13498.943 12585.623 15629.464 15589.483 16801.020 14405.155 11408.854
[22] 16371.431 17051.890 11893.602 9077.671 6312.529 10072.432 7571.553
[29] 9250.435 7025.001 9393.452 10245.336 8356.958 7258.715 9692.914
[36] 10305.336 4945.877 2044.761 4813.624 7012.214 7289.872 2624.872
[43] 8051.154 12373.910 5229.311 2829.071 7550.062 11783.780
```

```
apply(rock, 2, mean) # Media per colonna
```

```
      area      peri      shape      perm
7187.7291667 2682.2119375 0.2181104 415.4500000
```

- 1 File esterni di dati
- 2 Variabili**
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R



1 File esterni di dati

2 Variabili

- Categoricali - Nominali
- Categoricali - Ordinali

3 Statistiche descrittive di base

4 Generazione di variabili casuali

5 Grafici

6 Da Excel a R

[illegible]

as.factor()

as.factor(): Converte una variabile in una variabile di tipo **categoriale/nominale** con tanti livelli quanti sono i valori unici nel vettore

Due livelli

```
Genere <- c("m", "f", "f", "m", "f", "m")
```

Genere

```
[1] "m" "f" "f" "m" "f" "m"
```

```
as.factor(Genere)
```

```
[1] m f f m f m
```

```
Levels: f m
```


Più livelli

```
diagnosi <- c("schizo", "dep", "narc", "schizo", "dep", "narc")
```

```
diagnosi
```

```
[1] "schizo" "dep"      "narc"     "schizo" "dep"      "narc"
```

```
as.factor(diagnosi)
```

```
[1] schizo dep      narc  schizo dep      narc
```

```
Levels: dep narc schizo
```

1 File esterni di dati

2 Variabili

- Categoricali - Nominali
- Categoricali - Ordinali

3 Statistiche descrittive di base

4 Generazione di variabili casuali

5 Grafici

6 Da Excel a R

```
factor(A,levels=c("a1","a2",..., "ak"),
       ordered=TRUE)
```

Converte la variabile in una variabile con tanti livelli quanti sono i valori unici e viene forzato un ordine su questi livelli:

```
Voto <- c("alto","medio","medio","basso","alto")
```

```
Voto
```

```
[1] "alto" "medio" "medio" "basso" "alto"
```

```
factor(Voto,levels=c("basso","medio","alto"), ordered=TRUE)
```

```
[1] alto medio medio basso alto
```

```
Levels: basso < medio < alto
```

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base**
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base**
 - Tavole di frequenza
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R

```
table(variabile)
```

Calcola le occorrenze (frequenze) per ogni categoria. Funziona sia per le variabili categoriali sia per le variabili numeriche

```
table(Genere)
```

```
Genere
```

```
f m
```

```
3 3
```

```
table(diagnosi)
```

```
diagnosi
```

```
dep
```

```
narc
```

```
schizo
```

```
2
```

```
2
```

```
2
```

Altre funzioni

Funzione	Significato
<code>mean()</code>	Media
<code>min(), max()</code>	Minimo, Massimo
<code>range()</code>	Range di valori entro cui varia la variabile
<code>quantile(x, probs)</code>	Calcola il quantile $p=\text{probs}$ della variabile numerica X
<code>sd(), var()</code>	Deviazione st., Varianza
<code>sum()</code>	Somma

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali**
- 5 Grafici
- 6 Da Excel a R

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
 - `set.seed()`
- 5 Grafici
- 6 Da Excel a R

```
set.seed()
```

Permette di settare un seed comune a tutt

Garantisce la perfetta replicabilità dei risultati

Garantisce che se tutt settiamo questo seed, otteniamo gli stessi grafici

```
set.seed(999)
```

```
set.seed()
```

`rnorm(n, mean = 0, sd = 1)` :Genera n valori casuali e indipendenti da una variabile casuale normale con media `mean` 0 e deviazione standard `sd` 1 (normale standard)

```
set.seed()
```

`rnorm(n, mean = 0, sd = 1)` :Genera n valori casuali e indipendenti da una variabile casuale normale con media `mean` 0 e deviazione standard `sd` 1 (normale standard)


`runif(n, min = 0, max = 1)` Genera n valori casuali e indipendenti da una variabile casuale uniforme, dove i valori sono compresi tra 0 (`min`) e 1 (`max`)

```
set.seed()
```


`rnorm(n, mean = 0, sd = 1)` :Genera n valori casuali e indipendenti da una variabile casuale normale con media mean 0 e deviazione standard sd 1 (normale standard)

`runif(n, min = 0, max = 1)` Genera n valori casuali e indipendenti da una variabile casuale uniforme, dove i valori sono compresi tra 0 (min) e 1 (max)

```
x = rnorm(500, mean = 0, sd = 1)
```



```
y = runif(500, min = -4, max = 4)
```



- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
- 6 Da Excel a R


Graphs remind us that the process of statistical inference is not mechanical. This process often involves subjective decisions (e.g., the evaluation, exploration, and/or deletion of outliers) which are an integral part of the analysis. Thus, graphs are among the most appropriate tools to enhance transparency and confer plausibility to such decisions.

Pastore et al. (2017)


- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
 - Istogrammi
 - Boxplot
 - Boxplot – Calcolo degli outlier
 - Istogramma con kernel
 - Utilizzare i kernel

Istogrammi

`hist(x, breaks)` Produce un istogramma a partire da un vettore `x` di osservazioni quantitative. `breaks` definisce la larghezza delle singole barre, secondo diverse regole





(a) $n = 500$




(a) $n = 50$

Istogrammi con n diverso







(a) Sturges - Default



(a) FD



(a) Scott



(a) User defined (145)

Sturges:

$$\frac{\max(x) - \min(x)}{\log_2(n + 1)}$$

Scott:

$$3.5\sqrt{\text{var}(x)}\,n^{-1/3}$$

Freedman-Diaconis


$$2(Q_3 - Q_1)n^{-1/3}$$

User defined:


$$\frac{\max(x) - \min(x)}{\text{breaks}}$$

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
 - Istogrammi
 - Boxplot
 - Boxplot – Calcolo degli outlier
 - Istogramma con kernel
 - Utilizzare i kernel

`boxplot(x)` Produce un boxplot a partire da un vettore X di osservazioni quantitative



Boxplot



- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
 - Istogrammi
 - Boxplot
 - Boxplot – Calcolo degli outlier
 - Istogramma con kernel
 - Utilizzare i kernel

La lunghezza dei baffi (e di conseguenza la definizione degli outliers) è definita attraverso il metodo Tukey:


$$[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$$

dove $IQR = Q_3 - Q_1$ (Inter-quartile range)

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
 - Istogrammi
 - Boxplot
 - Boxplot – Calcolo degli outlier
 - Istogramma con kernel
 - Utilizzare i kernel

Istogramma con kernel

kernel density estimation, KDE: Metodo non parametrico per *stimare* la funzione di densità di probabilità di una variabile casuale continua a partire da un campione di dati




Funzione che “assegna” una probabilità attorno a ogni singolo dato osservato

`density(X, bw)`: Stima della densità di una variabile a partire da un vettore `X` di osservazioni quantitative. `bw`: Larghezza della banda con cui viene stimato il kernel attorno a ogni dato:

Più è stretto attorno al dato: Si vede bene la struttura del dato, ma si rischia di essere in overfitting (quella stima va bene SOLO per quel dato)


Più è largo attorno al dato: La curva è ben definita e liscia, ma si rischia di perdere dettagli per questi specifici dati (underfitting)



- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici**
 - Istogrammi
 - Boxplot
 - Boxplot – Calcolo degli outlier
 - Istogramma con kernel
 - Utilizzare i kernel


La funzione calcola la densità, per vedere la densità va usata insieme alla funzione `plot()`

```
x = rnorm(200)  
plot(density(x))
```



va imposto all'istogramma che costruisca i bin con la densità $d_i = \frac{f_i}{n * w_i}$


```
hist(x, freq = FALSE)
lines(density(x), lwd = 2, col = "blue")
```



- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**
 - Crea
 - Salva
 - Importa

Crea



The screenshot shows the Microsoft Excel interface with the following data:

ID	eta	sesso	regione
sb1	18	M	nord
sb2	19	F	nord
sb3	21	F	nord
sb4	18	F	nord
sb5	19	M	centro
sb6	22	M	sud
sb7	18	M	centro
sb8	20	F	sud
sb9	18	F	nord
sb10	19	F	centro
sb11	20	M	nord
sb12	18	M	sud
sb13	18	M	sud
sb14	19	F	centro
sb15	21	F	centro
sb16	20	F	nord
sb17	22	M	sud


- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**
 - Crea
 - Salva
 - Importa


- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**
 - Crea
 - Salva
 - Importa

```
dati = read.csv2("C:/Users/Ottavia/Documents/GitHub/stpc-analisi-dati/s  
head(dati)
```


	ID	eta	sex	regione
1	sb1	18	M	nord
2	sb2	19	F	nord
3	sb3	21	F	nord
4	sb4	18	F	nord
5	sb5	19	M	centro
6	sb6	22	M	sud

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**
 - Crea
 - Salva
 - Importa





Importa alternativa 1



Import Dataset

Name:

Encoding:

Heading: ☒ Yes ☐ No

Row names:

Separator:

Decimal:

Quote:

Comment:

na.strings:

☐ Strings as factors

Input File

```
ID;eta; Sesso; regione
sb1;18;M;nord
sb2;19;F;nord
sb3;21;F;nord
sb4;18;F;nord
sb5;19;M;centro
sb6;22;M;sud
sb7;18;M;centro
sb8;20;F;sud
sb9;18;F;nord
sb10;19;F;centro
sb11;20;M;nord
sb12;18;M;sud
sb13;18;M;sud
sb14;19;F;centro
sb15;21;F;centro
```

Data Frame

ID	eta	Sesso	regione
sb1	18	M	nord
sb2	19	F	nord
sb3	21	F	nord
sb4	18	F	nord
sb5	19	M	centro
sb6	22	M	sud
sb7	18	M	centro
sb8	20	F	sud
sb9	18	F	nord
sb10	19	F	centro
sb11	20	M	nord
sb12	18	M	sud
sb13	18	M	sud
sb14	19	F	centro
sb15	21	F	centro

Import Cancel

- 1 File esterni di dati
- 2 Variabili
- 3 Statistiche descrittive di base
- 4 Generazione di variabili casuali
- 5 Grafici
- 6 Da Excel a R**
 - Crea
 - Salva
 - Importa

```
dati = read.csv("C:/Users/Ottavia/Documents/GitHub/stpc-analisi-c  
               sep = ";", dec = ".", header = TRUE)  
head(dati)
```

	ID	eta	sezzo	regione
1	sb1	18	M	nord
2	sb2	19	F	nord
3	sb3	21	F	nord
4	sb4	18	F	nord
5	sb5	19	M	centro
6	sb6	22	M	sud