

Modulo Didattico 2 – Statistiche descrittive e illustrazioni

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
`ottavia.epifania@unitn.it`

A.A. 2026/2027

1 Variabili

2 Frequenze

3 Indici di posizione

QUALITATIVE / CATEGORIALI

- sconnesse: $\{a, b, c\}$
- ordinate: $\{a, b, c\}$ con $a < b < c$ (oppure $a > b > c$)

QUANTITATIVE / METRICHE

- Discrete: $\mathbb{Z}$
- Continue: $\mathbb{R}$

Stevens (1946)

Si differenziano in base alla quantità di informazione che può essere ricavata

- Variabili qualitative
 - **Nominale:** Distingue un insieme di dati in diverse categorie
 - **Ordinale:** Distingue un insieme di dati in diverse categorie che sono ordinabili a seconda della quantità di caratteristica posseduta
- Variabili quantitative
 - **Intervalli equivalenti** Distingue un insieme di dati in diverse categorie ordinabili. La distanza tra le categorie è nota perché c'è un'unità di misura
 - **A rapporti equivalenti:** Come la scala ad intervalli...ma lo 0 indica assenza di caratteristica (non è arbitrario ma è assoluto)


1 Variabili

- Categoricali - Nominali
- Categoricali - Ordinali
- Quantitative – Scala ad intervalli equivalenti
- Metriche – Scala a rapporti equivalenti

2 Frequenze

3 Indici di posizione

Comune di residenza, genere, patologia clinica ecc. Vale solo l'equivalenza (= o $\neq$)



Al posto di A ' ' , B ' ' , "C ' ' si poteva scrivere α , β γ , 1,2,3 (ma i numeri valgono solo come etichette!)

Caratteristiche:

- Categorie **distintive**: gli elementi che appartengono a categorie differenti vengono considerati di tipo diverso
- Categorie **mutualmente escludentesi**: ogni elemento può rientrare in una ed una sola categoria
- Categorie **Collettivamente esaustive**: tutti gli elementi vengono classificati nelle categorie della variabile, nessuno escluso

as.factor()

as.factor(): Converte una variabile in una variabile di tipo **categoriale/nominale** con tanti livelli quanti sono i valori unici nel vettore

Due livelli

```
Genere <- c("m", "f", "f", "m", "f", "m")
```

Genere

```
[1] "m" "f" "f" "m" "f" "m"
```

```
as.factor(Genere)
```

```
[1] m f f m f m
```

```
Levels: f m
```

as.character() produce una variabili categoriale, ma senza i livelli che caratterizzano i factor

Più livelli

```
diagnosi <- c("schizo", "dep", "narc", "schizo", "dep", "narc")  
diagnosi
```

```
[1] "schizo" "dep"    "narc"   "schizo" "dep"    "narc"
```

Più livelli

```
diagnosi <- c("schizo", "dep", "narc", "schizo", "dep", "narc")  
diagnosi
```

```
[1] "schizo" "dep"      "narc"     "schizo" "dep"      "narc"
```

```
as.factor(diagnosi)
```

```
[1] schizo dep      narc  schizo dep      narc  
Levels: dep narc schizo
```

1 Variabili

- Categoricali - Nominali
- Categoricali - Ordinali
- Quantitative – Scala ad intervalli equivalenti
- Metriche – Scala a rapporti equivalenti

2 Frequenze

3 Indici di posizione

Titolo di studio, gradimento di un prodotto, valutazione di una malattia (e.g., alto, medio, basso) ecc. Vale sia l'equivalenza ($=$ o $\neq$) sia l'ordinamento ($<$ o $>$)



Attenzione!

Si conosce l'ordine tra le categorie, non si conosce la distanza.
Le etichette numeriche valgono per il loro ordine (non ha senso compiere operazioni tra di loro)

```
factor(A,levels=c("a1","a2",..., "ak"),  
        ordered=TRUE)
```

Converte la variabile in una variabile con tanti livelli quanti sono i valori unici e viene forzato un ordine su questi livelli:

```
Voto <- c("alto","medio","medio","basso","alto")  
Voto
```

```
[1] "alto" "medio" "medio" "basso" "alto"
```

```
factor(Voto,levels=c("basso","medio","alto"), ordered=TRUE)
```

```
[1] alto medio medio basso alto  
Levels: basso < medio < alto
```

1 Variabili


- Categoricali - Nominali
- Categoricali - Ordinali
- Quantitative – Scala ad intervalli equivalenti
- Metriche – Scala a rapporti equivalenti

2 Frequenze


3 Indici di posizione

Lo 0 è arbitrario, ma c'è un'*unità di misura* per cui le categorie si trovano alla stessa distanza. Temperatura in Celsius, Q.I., scale di atteggiamento ecc. Vale equivalenza ($=$ o $\neq$), ordinamento ($<$ o $>$) e differenza ($+$ o $-$):

-3	-2	-1	0	1	2	3
----	----	----	---	---	---	---



Quantitative – Scala ad intervalli equivalenti



Se ci sono 0°C , non vuol dire che non c'è calore!

Se ieri c'erano 5°C e oggi ce ne sono 10°C , possiamo dire che oggi fa più caldo di ieri e che ci sono 5°C più di ieri

Il fatto che lo 0 non sia arbitrario non ci permette di dire che oggi c'è il doppio del caldo di ieri!

Trasformando le due temperature in Fahrenheit si ottiene 41°F e 50°F ... e la seconda non è più il doppio della prima!

1 Variabili

- Categoricali - Nominali
- Categoricali - Ordinali
- Quantitative – Scala ad intervalli equivalenti
- Metriche – Scala a rapporti equivalenti

2 Frequenze

3 Indici di posizione

Lo 0 è assoluto, indica assenza del fenomeno. Peso, altezza, valori diagnostici. Vale equivalenza ($=$ o $\neq$), ordinamento ($<$ o $>$), differenza ($+$ o $-$) e rapporto ($\times$ o $\div$)

0	1	2	3
---	---	---	---



numeric, integer()

Le **variabili metriche** in R sono variabili di tipo `numeric` o `integer`, a seconda che siano continue o discrete

Attenzione!

In R non esiste una distinzione tra variabili a intervalli equivalenti e variabili a rapporti equivalenti – Sta a voi capire che tipo di variabile sia

Metriche – Scala a rapporti equivalenti

```
x = seq(-3, 3, length.out = 10); x
y = rnorm(10, mean = 3, sd=2); y
z = 1:15; z
```

①

②

③

```
[1] -3.0000000 -2.3333333 -1.6666667 -1.0000000 -0.3333333  0.3333333
[7]  1.0000000  1.6666667  2.3333333  3.0000000
[1]  3.5979459  1.4915652  1.9334480  4.5939649  3.4467646  3.4391241
[7]  1.9195516  2.8674221  5.4013721 -0.7036661
[1]  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15
```

- ① La funzione `seq()` genera un vettore di numeri da un minimo a un massimo, di lunghezza definita dall'utente
- ② La funzione `rnorm()` genera un vettore di lunghezza definita estraendo a caso da una distribuzione normale
- ③ L'operatore `:` genera una sequenza unitaria di valori da un minimo a un massimo

1 Variabili

2 Frequenze

3 Indici di posizione

1 Variabili

2 Frequenze

- Assolute e relative
- Cumulate

3 Indici di posizione

Categoria x_i	n_i	$\%_i = \frac{n_i}{n} \cdot 100$
x_1	n_1	$\%_1$
x_2	n_2	$\%_2$
$\vdots$	$\vdots$	$\vdots$
x_k	n_k	$\%_k$
Totale	n	100

Frequenza assoluta: $n_i \geq 0$, con $n_i \in \mathbb{N}$ e $\sum_{i=1}^k n_i = n$

Frequenza percentuale: $\%_i = \frac{n_i}{n} \cdot 100$, con $0 \leq \%_i \leq 100$ e

$$\sum_{i=1}^k \%_i = 100$$

```
table(variabile)
```

Calcola le frequenze per ogni categoria. Funziona sia per le variabili categoriali sia per le variabili metriche

```
table(Genere)
```

```
Genere
```

```
f m
```

```
3 3
```

```
table(diagnosi)
```

```
diagnosi
```

```
  dep  narc schizo  
    2    2      2
```

1 Variabili

2 Frequenze

- Assolute e relative
- Cumulate

3 Indici di posizione

Frequenza cumulata: numero o percentuale di unità statistiche che presentano una modalità “minore o uguale” alla modalità corrente.

Frequenze assolute cumulate

$$N_i = n_1 + n_2 + \cdots + n_i = \sum_{j=1}^i n_j$$

con

$$N_1 = n_1 \quad \text{e} \quad N_k = n.$$

Frequenze percentuali cumulate

$$N_i \% = n_1 \% + n_2 \% + \cdots + n_i \% = \sum_{j=1}^i n_j \%$$

con

Le frequenze cumulate possono essere definite **ricorsivamente**:

$$N_i = N_{i-1} + n_i, \quad N_i\% = N_{i-1}\% + n_i\%$$

Attenzione

Le frequenze cumulate si calcolano **solo quando le modalità del carattere presentano un ordinamento**.

Non hanno quindi senso per caratteri qualitativi sconnessi (nominali).

Esprimi l'accordo con l'affermazione:

Insegnare statistica a psicologia è una buona idea

Modalità x_i	n_i	N_i	$n_i\%$	$N_i\%$
Totalmente in disaccordo	10	10	24.4%	24.4%
Abbastanza in disaccordo	8	18	19.5%	43.9%
Indifferente	6	24	14.6%	58.5%
Abbastanza d'accordo	14	38	34.2%	92.7%
Totalmente d'accordo	3	41	7.3%	100.0%
Totale	41		100.0%	

cumsum()

```
opinione = data.frame(  
  categoria = c(  
    "Totalmente in disaccordo",  
    "Abbastanza in disaccordo",  
    "Indifferente",  
    "Abbastanza d'accordo",  
    "Totalmente d'accordo"  
  ),  
  n = c(10, 8, 6, 14, 3)  
)
```


```
opinione$N = cumsum(opinione$n)  
opinione
```

categoria	n	N
-----------	---	---

- 1 Variabili
- 2 Frequenze
- 3 Indici di posizione**

- moda
- mediana
- quartili/percentili
- media aritmetica

Ogni variabile statistica ha l'indice di posizione adeguato: non tutti gli indici si possono calcolare per ogni variabile → **indice di posizione adeguato**



Moda (Mo)

Categoria che presenta la massima frequenza

$$Mo(X) = \max(n_i)$$

(categoria con massimo valore di n_i)

Warning

N.B: Si può calcolare per le variabili misurate a qualsiasi livello, anche se di fatto viene calcolata solo per le variabile categoriali, in quanto per altri livelli di misurazione si possono calcolare altri indici più informativi

opinione

	categoria	n	N
1	Totalmente in disaccordo	10	10
2	Abbastanza in disaccordo	8	18
3	Indifferente	6	24
4	Abbastanza d'accordo	14	38
5	Totalmente d'accordo	3	41

```
max(opinione$n) # restituisce max(n_i)
```

```
[1] 14
```

```
opinione[opinione$n == max(opinione$n), "categoria"]
```

```
[1] "Abbastanza d'accordo"
```

Mediana

Categoria/valore che occupa la posizione centrale o mediana (Pos_{Me}) nella distribuzione ordinata dei dati

- preceduta da almeno 50% dei casi
- superata da almeno 50% dei casi

$$Pos_{Me} = \frac{(N + 1)}{2}$$

Il valore di Pos_{Me} va cercato nella distribuzione delle frequenze cumulate e si sceglie la categoria con $N_i \geq Pos_{Me}$

Quantili

Categorie/valori che dividono la distribuzione di frequenza ordinata in più parti.

Qual è il reddito familiare che divide il 25% dei più poveri dal restante 75% ?

Qual è la soglia di reddito oltre cui sta la fascia dei più abbienti ?

Quali sono le persone che hanno performato al meglio nell'ultimo semestre?

Il quantile x_p di ordine p è quella categoria/valore che è:

```
\begin{itemize}
\item preceduta da almeno  $p\%$  dei casi
\item superata da almeno  $(1-p)\%$  dei casi
\end{itemize}
```

QUARTILI

dividono la distribuzione in **4** parti

DECILI

dividono la distribuzione in **10** parti

PERCENTILI

dividono la distribuzione in **100** parti

La distribuzione è la stessa: cambia il modo in cui viene suddivisa

Quartili

25%

25%

25%

25%

Decili

10%

10%

10%

10%

10%

10%

10%

10%

10%

10%

Percentili

Per il calcolo dei quantili di diverso ordine, il procedimento è analogo a quello della Mediana, che di fatto è un caso particolare di questi indici. In generale la Posizione di ordine p (in centesimi) si ottiene:

$$Pos_p = \frac{n+1}{100} \cdot p$$

quantile()

```
quantile(x, probs = c(0, .25, .50, .75, 1))
```

Funzione per il calcolo dei quantili di diverso ordine (definito dall'argomento probs)

```
set.seed(123) # garantisce la replicabilità
x = rnorm(1000, mean = 0, sd = 1)
quantile(x)
```

0%	25%	50%	75%	100%
-2.809774679	-0.628324243	0.009209639	0.664601867	3.241039935


```
# calcola i decili
quantile(x, probs = seq(0,1, by = .10))
```

0%	10%	20%	30%	40%	50%
-2.809774679	-1.267328289	-0.788690220	-0.486452454	-0.214854912	0.009209639
60%	70%	80%	90%	100%	
0.242040647	0.513088142	0.841412710	1.254751947	3.241039935	

Media

La media è una sorta di baricentro della distribuzione dei dati. Data una variabile X composta da n valori:

$$\bar{X} = \frac{\sum_{i=1}^N x_i}{N}$$



I dati: $X = (0.8, 1.2, 1.6, 2.4, 2.7, 3.3, 3.6, 4.5, 5.2)$, la media $\bar{X} = 2.811$



I dati: $X =$
 $(1.18, 1.02, 1.10, 1.16, 1.01, 1.10, 1.05, 1.12, 1.45, 1.52, 1.54, 1.55, 10.06, 14.46)$,
 la media $\bar{X} = 2.809$

mean()

```
mean(x, na.rm = FALSE)
```

Funzione per calcolare la media di un vettore di valori `x`. L'argomento `na.rm = TRUE` serve per ottenere il calcolo della media nonostante la presenza di valori NA

`rowMeans()`: Calcola la media per ogni riga (quindi attraverso le colonne)

`colMeans()`: Calcola la media per ogni colonna (quindi attraverso le righe)

```
mean(x)
```

```
[1] 0.01612787
```