

Modulo Didattico 2 – Scale di misura e illustrazioni grafiche

Corso Analisi dei dati con applicazioni informatiche


Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

A.A. 2026/2027


Graphs remind us that the process of statistical inference is not mechanical. This process often involves subjective decisions (e.g., the evaluation, exploration, and/or deletion of outliers) which are an integral part of the analysis. Thus, graphs are among the most appropriate tools to enhance transparency and confer plausibility to such decisions.

Pastore et al. (2017)


Dataset	Media.X	Media.Y	Varianza.X	Varianza.Y	Correlazione
Dataset 1	9	7.5	11	4.13	0.82
Dataset 2	9	7.5	11	4.13	0.82
Dataset 3	9	7.5	11	4.12	0.82
Dataset 4	9	7.5	11	4.12	0.82




(a) Dataset 1



(b) Dataset 2



(c) Dataset 3



(d) Dataset 4

Figure 1: I grafici raccontano un'altra storia

1 Grafici

R fornisce uno strumento molto utile per la rappresentazione grafica dei dati e dei risultati già con il suo pacchetto base `graphics`

NB

Non avete bisogno di installarlo, è caricato automaticamente nel momento in cui scaricate R e le sue funzioni sono sempre disponibili

`ggplot2` è un pacchetto più avanzato per la creazione dei grafici. Non entreremo nel dettaglio del suo funzionamento perché è un po' più complicato

Alcune funzioni incluse nel pacchetto `graphics`:

`plot(x)`

①

`plot(x, y)`

②

`hist(x)`

③

`boxplot(x)`

④

`barplot(x)`

⑤

- ① Grafico di una variabile quantitativa
- ② Grafico a dispersione di due variabili quantitative
- ③ Istogramma di una variabile quantitativa
- ④ Boxplot della distribuzione quartile di una (o più) variabili
- ⑤ Grafico a barre per le frequenze delle variabili qualitative


1 Grafici

- Grafico a barre
- Istogrammi
- Boxplot
- Boxplot – Calcolo degli outlier
- Istogramma con kernel
- Utilizzare i kernel


1 Grafici

- Grafico a barre
- Istogrammi
- Boxplot
- Boxplot – Calcolo degli outlier
- Istogramma con kernel
- Utilizzare i kernel

`hist(x, breaks)` Produce un istogramma a partire da un vettore `x` di osservazioni quantitative. `breaks` definisce la larghezza delle singole barre, secondo diverse regole




(a) $n = 500$




(a) $n = 50$


Istogrammi con n diverso

Histogram of X







(a) Sturges - Default



(a) FD



(a) Scott



(a) User defined (145)

Sturges:

$$\frac{\max(x) - \min(x)}{\log_2(n + 1)}$$

Scott:

$$3.5 \sqrt{\text{var}(x)} n^{-1/3}$$

Freedman-Diaconis

$$2 (Q_3 - Q_1) n^{-1/3}$$


User defined:

$$\frac{\max(x) - \min(x)}{\text{breaks}}$$


1 Grafici

- Grafico a barre
- Istogrammi
- Boxplot
- Boxplot – Calcolo degli outlier
- Istogramma con kernel
- Utilizzare i kernel

`boxplot(x)` Produce un boxplot a partire da un vettore X di osservazioni quantitative



Boxplot



1 Grafici

- Grafico a barre
- Istogrammi
- Boxplot
- Boxplot – Calcolo degli outlier
- Istogramma con kernel
- Utilizzare i kernel

La lunghezza dei baffi (e di conseguenza la definizione degli outliers) è definita attraverso il metodo Tukey:


$$[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$$

dove $IQR = Q_3 - Q_1$ (Inter-quartile range)


Settando l'argomento `range = x` si può cambiare il modo in cui vengono calcolati i baffi:

```
boxplot(x, range = 2)
```

```
boxplot(x, range = 0)
```



(a) `range = 2` - Meno Conservativo




(a) `range = 0` - Minimo e Massimo

Calcolo degli outlier

1 Grafici

- Grafico a barre
- Istogrammi
- Boxplot
- Boxplot – Calcolo degli outlier
- Istogramma con kernel
- Utilizzare i kernel

kernel density estimation, KDE: Metodo non parametrico per *stimare* la funzione di densità di probabilità di una variabile casuale continua a partire da un campione di dati




Funzione che “assegna” una probabilità attorno a ogni singolo dato osservato

`density(X, bw)`: Stima della densità di una variabile a partire da un vettore `X` di osservazioni quantitative. `bw`: Larghezza della banda con cui viene stimato il kernel attorno a ogni dato:

Più è stretto attorno al dato: Si vede bene la struttura del dato, ma si rischia di essere in overfitting (quella stima va bene SOLO per quel dato)

Più è largo attorno al dato: La curva è ben definita e liscia, ma si rischia di perdere dettagli per questi specifici dati (underfitting)




1 Grafici

- Grafico a barre
- Istogrammi
- Boxplot
- Boxplot – Calcolo degli outlier
- Istogramma con kernel
- Utilizzare i kernel

La funzione calcola la densità, per vedere la densità va usata insieme alla funzione `plot()`

```
x = rnorm(200)
plot(density(x))
```



va imposto all'istogramma che costruisca i bin con la densità $d_i = \frac{f_i}{n * w_i}$

```
hist(x, freq = FALSE)  
lines(density(x), lwd = 2, col = "blue")
```

