

# Modulo Didattico 2 – Scale di misura e illustrazioni grafiche statistica univariata

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania  
University of Trento  
`ottavia.epifania@unitn.it`

A.A. 2026/2027


Graphs remind us that the process of statistical inference is not mechanical. This process often involves subjective decisions (e.g., the evaluation, exploration, and/or deletion of outliers) which are an integral part of the analysis. Thus, graphs are among the most appropriate tools to enhance transparency and confer plausibility to such decisions.

Pastore et al. (2017)


Data set di Anscombe: Quattro dataset, di seguito le statistiche descrittive relative alla variabile  $x$  e alla variabile  $y$  e la loro correlazione:

Table 1: Dataset di Anscombe


| Dataset   | Media.X | Media.Y | Varianza.X | Varianza.Y | Correlazione |
|-----------|---------|---------|------------|------------|--------------|
| Dataset 1 | 9       | 7.5     | 11         | 4.13       | 0.82         |
| Dataset 2 | 9       | 7.5     | 11         | 4.13       | 0.82         |
| Dataset 3 | 9       | 7.5     | 11         | 4.12       | 0.82         |
| Dataset 4 | 9       | 7.5     | 11         | 4.12       | 0.82         |




(a) Dataset 1



(b) Dataset 2



(c) Dataset 3



(d) Dataset 4

Figure 1: I grafici raccontano un'altra storia

1 Grafici

2 Esempi

R fornisce uno strumento molto utile per la rappresentazione grafica dei dati e dei risultati già con il suo pacchetto base `graphics`

NB

Non avete bisogno di installarlo, è caricato automaticamente nel momento in cui scaricate R e le sue funzioni sono sempre disponibili

`ggplot2` è un pacchetto più avanzato per la creazione dei grafici. Non entreremo nel dettaglio del suo funzionamento perché è un po' più complicato

Alcune funzioni incluse nel pacchetto `graphics`:

|                         |   |
|-------------------------|---|
| <code>plot(x)</code>    | ① |
| <code>plot(x, y)</code> | ② |
| <code>hist(x)</code>    | ③ |
| <code>boxplot(x)</code> | ④ |
| <code>barplot(x)</code> | ⑤ |

- ① Grafico di una variabile quantitativa
- ② Grafico a dispersione di due variabili quantitative
- ③ Istogramma di una variabile quantitativa
- ④ Boxplot della distribuzione quartile di una (o più) variabili
- ⑤ Grafico a barre per le frequenze delle variabili qualitative

## 1 Grafici

- Grafico a barre
- Istogrammi
- Boxplot
- Boxplot – Calcolo degli outlier

## 2 Esempi



Usato per variabili qualitative nominali o ordinali:

- Asse  $x$ : categoria  $k$
- Asse  $y$ : Frequenza  $n_k$  (vale anche per le frequenze percentuali)

L'altezza della barretta è proporzionale alla sua frequenza

`barplot(x)`

Dove  $x$  è il vettore delle frequenze (quello che si ottiene applicando la funzione `table()` a una variabile categoriale)

Grafico a barre




Table 2: Tabelle di frequenza per le categorie A, B, C.

| Categoria | $n_k$ |
|-----------|-------|
| A         | 21    |
| B         | 24    |
| C         | 22    |




Figure 2: Barplot delle tabelle

| Categoria | $n_k$ |
|-----------|-------|
| A         | 12    |
| B         | 35    |
| C         | 18    |




Figure 3: Barplot delle tabelle

```
[1] A A A A A A A A A A A B B B B B B B B B B B B B B B B B B B B B  
[39] B B B B B B B B C C C C C C C C C C C C C C C C C C C C  
Levels: A B C
```

```
dati
  A  B  C
12 35 18
```

| Category | Number of People |
|----------|------------------|
| A        | 55               |
| B        | 100              |
| C        | 75               |


## 1 Grafici

- Grafico a barre
- Istogrammi
- Boxplot
- Boxplot – Calcolo degli outlier


## 2 Esempi

## Istogrammi

`hist(x, breaks)` Produce un istogramma a partire da un vettore `x` di osservazioni quantitative. `breaks` definisce la larghezza delle singole barre, secondo diverse regole




(a)  $n = 500$




(a)  $n = 50$

## Istogrammi con n diverso


```
x = rnorm(500, mean = 0, sd = 1)
hist(x)
```




Histogram of X









(a) Sturges - Default



(b) FD



(c) Scott



(d) User defined (145)

Sturges:

$$\frac{\max(x) - \min(x)}{\log_2(n + 1)}$$

Scott:

$$3.5 \sqrt{\text{var}(x)} n^{-1/3}$$

Freedman-Diaconis

$$2 (Q_3 - Q_1) n^{-1/3}$$

User defined:

$$\frac{\max(x) - \min(x)}{\text{breaks}}$$


## 1 Grafici

- Grafico a barre
- Istogrammi
- Boxplot
- Boxplot – Calcolo degli outlier

## 2 Esempi


## Boxplot

`boxplot(x)` Produce un boxplot a partire da un vettore  $X$  di osservazioni quantitative



## Boxplot

Boxplot



## 1 Grafici

- Grafico a barre
- Istogrammi
- Boxplot
- Boxplot – Calcolo degli outlier

## 2 Esempi

La lunghezza dei baffi (e di conseguenza la definizione degli outliers) è definita attraverso il metodo Tukey:


$$[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$$

dove  $IQR = Q_3 - Q_1$  (Inter-quartile range)


Settando l'argomento `range = x` si può cambiare il modo in cui vengono calcolati i baffi:

```
boxplot(x, range = 2)
```

```
boxplot(x, range = 0)
```



(a) `range = 2` - Meno Conservativo



(a) `range = 0` - Minimo e Massimo

Calcolo degli outlier



1 Grafici

2 Esempi

# barplot()

```
voto = sample(rep(c("si", "no", "astenuti"),
                  c(12, 15, 2)))
voto = factor(voto, levels = c("si", "no", "astenuti"))
table(voto)


# le frequenze restituite dalla funzione table() vanno usate
# come vettore di base per il barplot

barplot(table(voto),
        col = c("darkgreen", "darkred", "darkblue"),
        ylim = c(0, 20))
```

```
voto
```

| si | no | astenuti |
|----|----|----------|
| 12 | 15 | 2        |

```
barplot(table(voto),  
  col = c("darkgreen", "darkred", "darkblue"),  
  ylim = c(0, 20))
```



## boxplot()





Figure 9: Distribuzioni a confronto

Figure 9a: La distribuzione è equilibrata attorno alla mediana, situata circa a metà della distribuzione tra il minimo e il massimo


Figure 9b: La distribuzione è squilibrata verso il basso, ovvero verso il minimo, presentando una coda più “pesante” verso il massimo

Figure 9c: La distribuzione è squilibrata verso l'alto, ovvero verso il massimo, presentando una coda più “pesante” verso il minimo


# hist()



(a) hist(x)




(b) hist(y)




(c) hist(z)

Figure 10: Distribuzioni a confronto - Le stesse dei boxplot

## Confronto boxplot vs istogramma



(a) boxplot(x)



(b) hist(x)

Figure 11: Boxplot vs Istogramma

# Confronto boxplot vs istogramma




Figure 12: Boxplot vs Istogramma

# Confronto boxplot vs istogramma




Figure 13: Boxplot vs Istogramma





```
boxplot(x, y, z, names = c("Normale", "Pavimento", "Soffitto"),
        col = c("darkorange", "lightblue", "gold"))
```

