

Laboratorio di Analisi dei Dati con R

Soluzioni modulo 3 - Seconda SERIE

Ottavia Epifania

Lista degli esercizi

Introduzione	2
Esercizio 1	2
1.	2
2.	4
3.	4
4.	5
Esercizio 2	6
1.	6
2.	6
3.	7
4.	7
5.	8
6.	9

Introduzione

Questa nuova serie di esercizi sul terzo modulo didattico sono divisi in due parti: 1) esercizi sulla regressione lineare 2) esercizi sulla statistica Chi quadrato.

Queste variabili sono ricavate dal famoso esempio di Anscombe (1973, Graphs in statistical analysis, The American Statistician).

```
X1 <- c(10,8,13,9,11,14,6,4,12,7,5)
Y1 <- c(8.04,6.95,7.58,8.81,8.33,9.96,7.24,4.26,10.84,4.82,5.68)
Y2 <- c(9.14,8.14,8.74,8.77,9.26,8.10,6.13,3.10,9.13,7.26,4.74)
Y3 <- c(7.46,6.77,12.74,7.11,7.81,8.84,6.08,5.39,8.15,6.42,5.73)
X2 <- c(8,8,8,8,8,8,8,19,8,8,8)
Y4 <- c(6.58,5.76,7.71,8.84,8.47,7.04,5.25,12.50,5.56,7.91,6.89)
```

Esercizio 1

1.

studiare la relazione tra le seguenti coppie di variabili attraverso dei modelli di regressione.

Visualizzare graficamente la relazione tra le variabili attraverso un grafico a dispersione: -

$(X1, Y1)$ (modello di regressione MR1) - $(X1, Y2)$ (modello di regressione MR2) - $(X1, Y3)$

(modello di regressione MR3) - $(X2, Y4)$ (modello di regressione MR4)

```
par(mfrow=c(2,2))

plot(X1,Y1, main = "X1,Y1")
```

```
MR1 <- lm(Y1 ~ X1)

abline(MR1)

plot(X1,Y2)

MR2 <- lm(Y2 ~ X1, main = "X1,Y2")

abline(MR2)

plot(X1,Y3, main = "X1,Y3")

MR3 <- lm(Y3 ~ X1)

abline(MR3)

plot(X2,Y4, main = "X2,Y4")

MR4 <- lm(Y4 ~ X2)

abline(MR4)
```

2.

Studia la relazione tra la variabile indipendente ed i residui per ciascun modello utilizzando dei grafici di dispersione. Che tipo di commenti puoi fare circa ciascun grafico di dispersione?

```
# calcolo dei residui per tutti i modelli con la funzione residulas()
e1 = residuals(MR1)
e2 = residuals(MR2)
e3 = residuals(MR3)
e4 = residuals(MR4)

par(mfrow = c(2,2))
plot(X1,e1)
abline(0,0)

plot(X1,e2)
abline(0,0)

plot(X1,e3)
abline(0,0)

plot(X2,e4)
abline(0,0)
```

3.

Calcola e visualizza la percentuale di varianza spiegata per ciascun modello

```

R2MR1 <- 1-(var(e1)/var(Y1))
# R2MR1 <- cor(X1,Y1)^2 # alternativa di calcolo
# R2MR1 <- summary(MR1)$r.squared # alternativa di calcolo
R2MR1

R2MR2 <- 1-(var(e2)/var(Y2))
# R2MR2 <- cor(X1,Y2)^2 # alternativa di calcolo
# R2MR2 <- summary(MR2)$r.squared # alternativa di calcolo
R2MR2

R2MR3 <- 1-(var(e3)/var(Y3))
# R2MR3 <- cor(X1,Y3)^2 # alternativa di calcolo
# R2MR3 <- summary(MR3)$r.squared # alternativa di calcolo
R2MR3

R2MR4 <- 1-(var(e4)/var(Y4))
# R2MR4 <- cor(X2,Y4)^2 # alternativa di calcolo
# R2MR4 <- summary(MR4)$r.squared # alternativa di calcolo
R2MR4

```

4.

Calcola i valori predetti dal primo modello di regressione (MR1) per $X1 = \{-25, 0.25, 44.9, 100.8\}$

```

predict(MR1,data.frame(X1=c(-25,0.25,44.9,100.8)))

# usando l'equazione della retta
coef(MR1)[1] + coef(MR1)[2]*c(-25,0.25,44.9,100.8)

```

Esercizio 2

1.

Si consideri la seguente coppia di variabili categoriali **A** e **B** con rispettivamente 3 e 2 livelli:

$A = (a1, a2, a2, a1, a3, a3, a3, a1, a2, a1, a2, a1, a3, a2, a2, a1, a3, a2, a1)$

$B = (b1, b1, b1, b1, b1, b1, b1, b1, b1, b1, b2, b2, b2, b2, b2, b2, b2, b2, b2, b2)$

Si costruisca la tabella di contingenza **f_o** associata alle due variabili **A** e **B**.

```
A <- factor(c("a1", "a2", "a2", "a1", "a3", "a3", "a3", "a1", "a2", "a1", "a2", "a1", "a3", "a2", "a2", "a1", "a3", "a2", "a1"))
B <- factor(c(rep("b1", 9), rep("b2", 10)))
f_o <- table(A, B)
f_o
```

2.

Costruire la tabella di contingenza, **f_t**, che contenga le frequenze teoriche associate al modello di indipendenza tra **A** e **B**.

```
mA <- margin.table(f_o, 1) # marginali di riga
mB <- margin.table(f_o, 2) # marginali di colonna
n <- sum(f_o) # totale osservazioni

f_t = matrix(nrow = 3, ncol = 2) # crea una matrice vuota da "riempire" con le frequenze teoriche

f_t[1,1] <- (mA[1]*mB[1])/n

f_t[1,2] <- (mA[1]*mB[2])/n
```

```

f_t[2,1] <- (mA[2]*mB[1])/n

f_t[2,2] <- (mA[2]*mB[2])/n

f_t[3,1] <- (mA[3]*mB[1])/n

f_t[3,2] <- (mA[2]*mB[1])/n
f_t

rownames(f_t) <- c("a1","a2","a3")
colnames(f_t) <- c("b1","b2")

# soluzione con ciclo for, solo se avete idea di come funzioni
# for(i in 1:nrow(f_t)) {
#   for (j in 1:ncol(f_o)) {
#     f_t[i, j] = (mA[i]*mB[j])/n
#   }
# }

```

3.

Calcola e visualizza il valore del Chi-quadrato osservato ottenuto sulla tabella di contingenza `f_o`.

```
chisq.test(f_o)$statistic
```

4.

Calcola l'indice normalizzato del Chi-quadrato osservato:

$$\chi_N^2 = \frac{\chi^2}{N \times \min[(r-1); (c-1)]}$$

Quale conclusione si può trarre dal risultato di tale indice?

```
MaxChiQ <- n*min(dim(f_o)[1]-1,dim(f_o)[2]-1)
```

```
ChiQOss <- chisq.test(f_o)$statistic
```

```
ChiQNorm <- ChiQOss/MaxChiQ
```

```
ChiQNorm
```

5.

Calcola il valore del Chi-quadrato osservato ottenuto sulla tabella di contingenza `f_o` limitata ai soli valori `a1` e `a3` della variabile categoriale `A`. Su questa nuova tabella di contingenza calcola l'indice normalizzato del Chi-quadrato.

```
f_o1 <- f_o[c(1,3),]
```

```
MaxChiQ2 <- n*min(dim(f_o1)[1]-1,dim(f_o1)[2]-1)
```

```
ChiQOss2 <- chisq.test(f_o1)$statistic
```

```
ChiQNorm2 <- ChiQOss2/MaxChiQ2
```

```
ChiQNorm2
```

6.

Costruisci una nuova tabella di contingenza sommando i valori della seconda e terza riga di `f_o`. Questa nuova tabella di contingenza esprime l'associazione tra i valori `b1` e `b2` della variabile categoriale `B` e i valori `a1` e `a2, a3` della nuova variabile categoriale `A2`.

Per questa nuova tabella di contingenza:

- deriva la tabella di contingenza associata alle frequenze teoriche del modello di indipendenza tra `A2` e `B`
- visualizza il valore del Chi-quadrato osservato
- calcola il valore del Chi-quadrato normalizzato.

```
A2 <- as.character(A)
A2[A2=="a2" | A2=="a3"] <- "a23"

f_o2 <- table(A2,B)

f_o2

mA2 <- margin.table(f_o2,1)
mB <- margin.table(f_o2,2)
n <- sum(f_o2)

f_t2 <- matrix(rep(0,4),2,2)
for(i in 1:nrow(f_t2)) {
  for (j in 1:ncol(f_t2)) {
    f_t2[i, j] = (mA2[i]*mB[j])/n
```

```
}  
}  
  
f_t2  
MaxChiQ3 <- n*min(dim(f_o2)[1]-1,dim(f_o2)[2]-1)  
  
ChiQOss3 <- chisq.test(f_o2)$statistic  
ChiQNorm3 <- ChiQOss3/MaxChiQ3  
  
ChiQNorm3
```