

Laboratorio di Analisi dei Dati con R

Esercizi legati al modulo 3 - PRIMA SERIE

Ottavia Epifania

Introduzione

Gli esercizi di seguito proposti sono relativi all'uso delle misure di associazione (covarianza e correlazione lineare) per le variabili quantitative. Lo studio delle misure di associazione sarà condotto utilizzando il dataset di Anscombe e riguarderà gli aspetti esclusivamente descrittivi (non inferenziali) di tali statistiche. Nello specifico:

Queste variabili sono ricavate dal famoso esempio di Anscombe (1973, Graphs in statistical analysis, The American Statistician).

```
X1 <- c(10,8,13,9,11,14,6,4,12,7,5)
Y1 <- c(8.04,6.95,7.58,8.81,8.33,9.96,7.24,4.26,10.84,4.82,5.68)
Y2 <- c(9.14,8.14,8.74,8.77,9.26,8.10,6.13,3.10,9.13,7.26,4.74)
Y3 <- c(7.46,6.77,12.74,7.11,7.81,8.84,6.08,5.39,8.15,6.42,5.73)
X2 <- c(8,8,8,8,8,8,8,19,8,8,8)
Y4 <- c(6.58,5.76,7.71,8.84,8.47,7.04,5.25,12.50,5.56,7.91,6.89)
```

Svolgere i seguenti esercizi:

1. Si costruisca un dataframe, D, che contenga le sei variabili del set di dati di Anscombe. Rimuovere dalla memoria tutte le variabili escluso il dataframe D.

2. Si calcoli il valore della covarianza tra **X1** e **Y1**. Nel calcolo della covarianza si utilizzi la formula matematica:

$$Cov(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Nel riprodurre tale formula si sostituisca il fattore moltiplicativo $\frac{1}{n}$ con il fattore moltiplicativo corretto $\frac{1}{n-1}$.

3. Ripetere l'esercizio 2, questa volta utilizzando la formula predefinita in R, `cov()`, per il calcolo della covarianza. Verificare che i risultati ottenuti con le due modalità (esercizio 2 e 3) siano uguali
4. Costruire un nuovo dataframe **Dcov** che contenga rispettivamente tre variabili (ovvero tre colonne):
- a) una variabile **scartiX1** contenente lo scarto dalla media di **X1** dei punteggi di **X1**,
 - b) una variabile **scartiY1** contenente lo scarto dalla media di **Y1** dei punteggi di **Y1**,
 - c) una variabile **prodScarti** contenente il prodotto degli scarti rispetto a **X1** e **Y1** (per maggiori dettagli si veda la formula a p. 113).
5. Visualizzare il contenuto di **Dcov** e concentrarsi sui valori di **prodScarti**. Quali osservazioni potresti fare circa i valori contenuti in **prodScarti**? Nello specifico circa il segno di tali scarti (quale è il loro significato e come vanno ad incidere sul risultato finale della misura di covarianza)?
6. Calcolare la covarianza della variabile **Y1** con se stessa. Nella procedura di calcolo utilizzare sia la modalità descritta nell'Es. 2 che quella indicata nell'Es. 3. Verificare la concordanza dei risultati delle due procedure. Infine tabulare i valori del dataframe corrispondente a **Dcov** per questa nuova coppia di variabili (variabile ripetuta). Quali osservazioni puoi fare sui risultati del valore della covarianza di **Y1** con se stessa? A cosa viene a coincidere tale particolare covarianza?

7. Calcolare la correlazione lineare tra **X1** e **Y1**. Per il calcolo della correlazione utilizzare la formula descritta a p. 114 del manuale:

$$\rho_{xy} = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$

e confrontarla con il calcolo della funzione predefinita in R, ovvero la funzione `cor(X1,Y1)` ($\sigma_{xy} = \text{Cov}(X, Y)$).