Modulo Didattico 3: Statistica descrittiva bivariata (Associazione tra variabili categoriali)

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

A.A. 2026/2027

1. Variabile statistica doppia
2. Tabella a doppia entrata – Tavola di contingenza
3. Connessione (Variabili qualitative)
4. Indipendenza stocastica e massima dipendenza

X: Istruzione	E	E	E	SI	SI	SI	SS	SS	SS	SS	SS
Y: Occupazione	DI	I	I	DI	I	I	D	I	I	D	D

categoria x_k	$n_{k.}$
Elementare (E)	3
Secondaria Inferiore (SI)	3
Secondaria Superiore (SS)	5

categoria y_j	$n_{.j}$
Disoccupato (DI)	2
Impiegato (I)	6
Dirigente (D)	3

	DI	I	D	
E	1	2	0	3
SI	1	2	0	3
SS	0	2	3	5
	2	6	3	**11**

Date due variabili X e Y e la loro distribuzione di frequenze congiunte n_{kj} (numero di unità statistiche che presentano la coppia di categorie (x_k, y_j))

Tip

L'insieme (X, Y) delle terne

$$(x_k, y_j, n_{kj}) \qquad (k = 1, \dots, h;\ j = 1, \dots, m)$$

è detto **variabile statistica doppia**.

1 Variabile statistica doppia

2 Tabella a doppia entrata – Tavola di contingenza

3 Connessione (Variabili qualitative)

4 Indipendenza stocastica e massima dipendenza

		Y						
		y_1	y_2	...	y_j	...	y_m	$n_{k.}$
X	x_1	n_{11}	n_{12}	...	n_{1j}	...	n_{1m}	$n_{1.}$
	x_2	n_{21}	n_{22}	...	n_{2j}	...	n_{2m}	$n_{2.}$
	$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
	x_k	n_{k1}	n_{k2}	...	n_{kj}	...	n_{km}	$n_{k.}$
	$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
	x_h	n_{h1}	n_{h2}	...	n_{hj}	...	n_{hm}	$n_{h.}$
		$n_{.1}$	$n_{.2}$	...	$n_{.j}$	...	$n_{.m}$	n

n_{kj}: **Frequenza congiunta**, definisce il numero di unità statistiche che possiedono congiuntamente la categoria x_k della variabile X e la categoria y_j della variabile Y

$n_{k.}$: **Frequenza marginale di** X, definisce il numero di unità statistiche che possiedono la categoria x_k della variabile X

$n_{.j}$: **Frequenza marginale di** Y, definisce il numero di unità statistiche che possiedono la categoria y_j della variabile Y

n: Numero totale di unità statistiche

$$n_{k.} = \sum_{j=1}^{m} n_{kj} \longrightarrow$$

Numero di unità statistiche che possiedono la categoria x_k della variabile X (**totale della riga** k)

$$n_{.j} = \sum_{k=1}^{h} n_{kj} \longrightarrow$$

Numero di unità statistiche che possiedono la categoria y_j della variabile Y (**totale della colonna** j)

$$\sum_{k=1}^{h} \sum_{j=1}^{m} n_{kj} = \sum_{k=1}^{h} n_{k.} = \sum_{j=1}^{m} n_{.j} = n$$

1. Variabile statistica doppia

2. Tabella a doppia entrata – Tavola di contingenza
   - `table()`
   - `margin.table()`
   - `prop.table()`
   - Frequenze percentuali
   - $P(\text{Istruzione} \mid \text{Occupazione})$ (Frequenze percentuali di **riga**)
   - $P(\text{Occupazione} \mid \text{Istruzione})$ (Frequenze percentuali di **colonna**)

3. Connessione (Variabili qualitative)

4. Indipendenza stocastica e massima dipendenza

`table(var1, var2)`: Produce la tabella di frequenza tra due variabili categoriali `var1` e `var2`

```
var1 <- as.factor(c("a1","a2","a1","a2","a1","a2","a1"))
var2 <- as.factor(c("b1","b1","b1","b2","b1","b2","b2"))
mytab = table(var1, var2); mytab
```

```
    var2
var1 b1 b2
  a1  3  1
  a2  1  2
```

```
sum(mytab) # permette di ottenere l'ampiezza campionaria
```

```
[1] 7
```

1. Variabile statistica doppia

2. Tabella a doppia entrata – Tavola di contingenza
   - `table()`
   - `margin.table()`
   - `prop.table()`
   - Frequenze percentuali
   - $P(\text{Istruzione} \mid \text{Occupazione})$ (Frequenze percentuali di **riga**)
   - $P(\text{Occupazione} \mid \text{Istruzione})$ (Frequenze percentuali di **colonna**)

3. Connessione (Variabili qualitative)

4. Indipendenza stocastica e massima dipendenza

`margin.table(table, margin)`: Frequenze marginali per la tabella a doppia entrata

Tip

`margin = 1`: Frequenze marginali calcolate **attraverso le colonne**
`margin = 2`: Frequenze marginali calcolate **attraverso le righe**

```
    var2
var1 b1 b2
  a1  3  1
  a2  1  2
```

```
margin.table(mytab,1)

var1
a1 a2
 4  3
```

```
margin.table(mytab,2)

var2
b1 b2
 4  3
```

1. Variabile statistica doppia

2. Tabella a doppia entrata – Tavola di contingenza
   - `table()`
   - `margin.table()`
   - `prop.table()`
   - Frequenze percentuali
   - $P(\text{Istruzione} \mid \text{Occupazione})$ (Frequenze percentuali di **riga**)
   - $P(\text{Occupazione} \mid \text{Istruzione})$ (Frequenze percentuali di **colonna**)

3. Connessione (Variabili qualitative)

4. Indipendenza stocastica e massima dipendenza

`prop.table(T, margin = NULL)`: Probabilità condizionate:

Tip

`margin = NULL`: Probabilità calcolate sul totale n, $p_{kj} = \frac{n_{kj}}{n}$

`margin = 1`: Probabilità condizionate di riga (**attraverso le colonne**), $p_{j|k} = \frac{n_{kj}}{n_{k.}}$

`margin = 2`: Probabilità condizionate di colonna (**attraverso le righe**), $p_{k|j} = \frac{n_{kj}}{n_{.j}}$

prop.table()

```
mytab
```

```
    var2
var1 b1 b2
  a1  3  1
  a2  1  2
```

```
prop.table(mytab,1)  # P(B|A)
```

```
    var2
var1        b1        b2
  a1 0.7500000 0.2500000
  a2 0.3333333 0.6666667
```

```
prop.table(mytab)
```

```
    var2
var1         b1         b2
  a1 0.4285714 0.1428571
  a2 0.1428571 0.2857143
```

```
prop.table(mytab,2)  # P(A|B)
```

```
    var2
var1        b1        b2
  a1 0.7500000 0.3333333
  a2 0.2500000 0.6666667
```

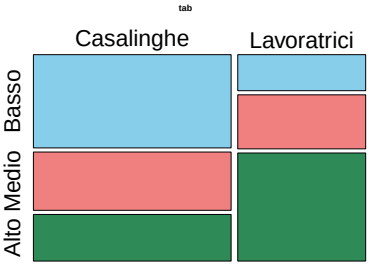
1. Variabile statistica doppia

2. Tabella a doppia entrata – Tavola di contingenza
   - `table()`
   - `margin.table()`
   - `prop.table()`
   - Frequenze percentuali
   - $P(\text{Istruzione} \mid \text{Occupazione})$ (Frequenze percentuali di **riga**)
   - $P(\text{Occupazione} \mid \text{Istruzione})$ (Frequenze percentuali di **colonna**)

3. Connessione (Variabili qualitative)

4. Indipendenza stocastica e massima dipendenza

	Basso	Medio	Alto	Totale
Casalinghe	40	25	20	85
Lavoratrici	10	15	30	55
Totale	50	40	50	140



1. Variabile statistica doppia

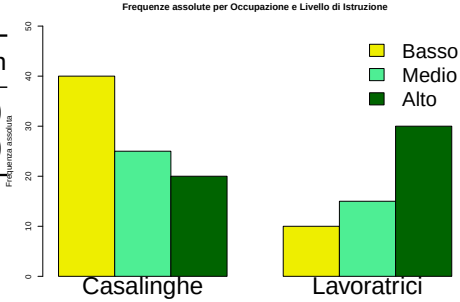
2. Tabella a doppia entrata – Tavola di contingenza
   - `table()`
   - `margin.table()`
   - `prop.table()`
   - Frequenze percentuali
   - $P(\text{Istruzione} \mid \text{Occupazione})$ (Frequenze percentuali di **riga**)
   - $P(\text{Occupazione} \mid \text{Istruzione})$ (Frequenze percentuali di **colonna**)

3. Connessione (Variabili qualitative)

4. Indipendenza stocastica e massima dipendenza

P(Istruzione | Occupazione) (Frequenze percentuali di **riga**)

	Basso	Medio	Alto	Sum
Casalinghe	47	29	24	100
Lavoratrici	18	27	55	100



Tra le donne lavoratrici/casalinghe, il X% ha un titolo di studio basso/medio/alto

1. Variabile statistica doppia

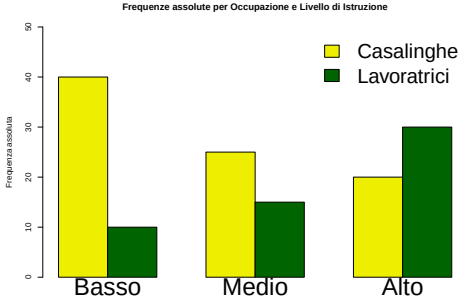
2. Tabella a doppia entrata – Tavola di contingenza
   - `table()`
   - `margin.table()`
   - `prop.table()`
   - Frequenze percentuali
   - $P(\text{Istruzione} \mid \text{Occupazione})$ (Frequenze percentuali di **riga**)
   - $P(\text{Occupazione} \mid \text{Istruzione})$ (Frequenze percentuali di **colonna**)

3. Connessione (Variabili qualitative)

4. Indipendenza stocastica e massima dipendenza

P(Occupazione | Istruzione) (Frequenze percentuali di **colonna**)

	Basso	Medio	Alto
Casalinghe	80	62	40
Lavoratrici	20	38	60
Sum	100	100	100



Tra le donne con titolo di studio basso/medio/alto, il X% è lavoratrice/casalinga

1 Variabile statistica doppia

2 Tabella a doppia entrata – Tavola di contingenza

3 Connessione (Variabili qualitative)

4 Indipendenza stocastica e massima dipendenza

La CONNESSIONE tra due variabili categoriali equivale alla NON INDIPENDENZA!

Tra le variabili X e Y c'è una forma di legame e **relazione** (**connessione**)
$\rightarrow$ il variare di una implica un qualche cambiamento **non casuale** nell'altra

1. Variabile statistica doppia
2. Tabella a doppia entrata – Tavola di contingenza
3. Connessione (Variabili qualitative)
   - χ^2
   - `chisq.test()`
4. Indipendenza stocastica e massima dipendenza

χ^2

Quantifica la DISTANZA DALL'INDIPENDENZA tra due variabili categoriali

- X con h categorie x_k, con $k = 1, \dots, h$,
- Y con m categorie y_j, con $j = 1, \dots, m$

Richiede il confronto tra **frequenze osservate** (n_{kj}) e **frequenze attese** o **frequenze teoriche** (n^*_{kj})

n_{kj}	$n_{k.}$
$n_{.j}$	

Frequenze osservate

VS.

n^*_{kj}	$n_{k.}$
$n_{.j}$	

Frequenze teoriche

$$n^*_{kj} = \frac{n_{k.} \times n_{.j}}{n}, \qquad n = \sum_{k=1}^{h} \sum_{j=1}^{m} n_{kj} = \sum_{k=1}^{h} \sum_{j=1}^{m} n^*_{kj}$$

n^*_{kj}: Significato

Data l'ampiezza campionaria n, quali sono le frequenze che avremmo dovuto osservare se le due variabili fossero state indipendenti, ovvero se non avessero alcuna relazione?

$$n^*_{kj} = \frac{n_{k.}\, n_{.j}}{n}$$

Table 4: Frequenze osservate

	Basso	Medio	Alto	Totale
Casalinghe	40	25	20	85
Lavoratrici	10	15	30	55
Totale	50	40	50	140

Table 5: Frequenze teoriche

	Basso	Medio	Alto	Totale
Casalinghe	$\frac{85 \times 50}{140} = 30.36$	$\frac{85 \times 40}{140} = 24.29$	$\frac{85 \times 50}{140} = 30.36$	85
Lavoratrici	$\frac{55 \times 50}{140} = 19.64$	$\frac{55 \times 40}{140} = 15.71$	$\frac{55 \times 50}{140} = 19.64$	55
Totale	50	40	50	**140**

$$\chi^2 = \sum_{k=1}^{h} \sum_{j=1}^{m} \frac{(n_{kj} - n^*_{kj})^2}{n^*_{kj}}$$

$\chi^2 = 0$: $n_{kj} = n^*_{kj}$ Indipendenza stocastica

$\chi^2 = \chi^2_{\max}$: Relazione di perfetta dipendenza (dove $\chi^2_{\max} = n \times \min[(h-1); (m-1)]$)

$$\tilde{\chi}^2 = \frac{\chi^2}{\chi^2_{\max}}$$

$\tilde{\chi}^2$ è il χ^2 normalizzato, permette di esprimere il grado di associazione tra due variabili categoriali secondo una scala di tipo $[0, 1]$

1. Variabile statistica doppia
2. Tabella a doppia entrata – Tavola di contingenza
3. Connessione (Variabili qualitative)
   - χ^2
   - `chisq.test()`
4. Indipendenza stocastica e massima dipendenza

`chisq.test(table)$statistic`: Calcola il χ^2 osservato a partire da una tavola di contingenza ottenuta con `table()`

```
mytab
```

```
    var2
var1 b1 b2
  a1  3  1
  a2  1  2
```

```
chisq.test(mytab)$statistic
```

```
X-squared
 0.109375
```

Calcolo $\chi^2_{\max}$

```
chiMax = sum(mytab) * min(c(nrow(mytab) - 1, ncol(mytab) - 1))
chiMax
```

```
[1] 7
```

```
chisq.test(mytab)$statistic/chiMax
```

```
X-squared
 0.015625
```

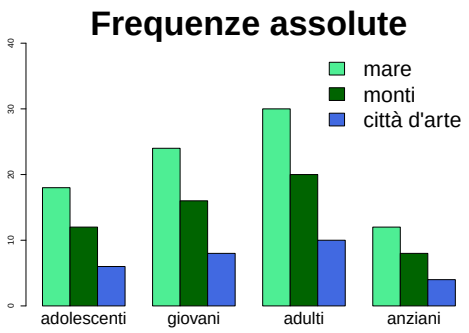
1 Variabile statistica doppia

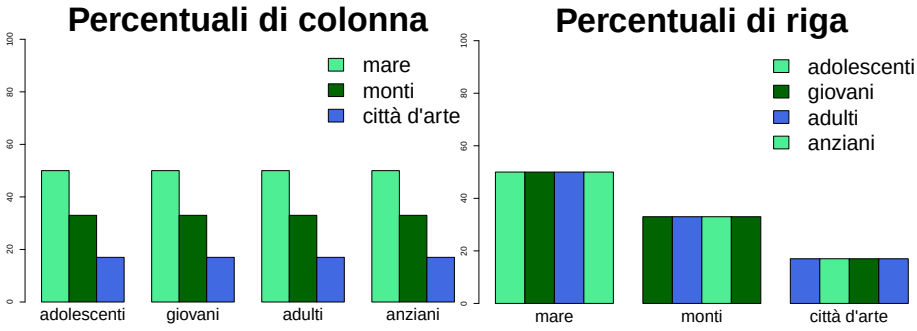
2 Tabella a doppia entrata – Tavola di contingenza

3 Connessione (Variabili qualitative)

4 Indipendenza stocastica e massima dipendenza

	adolescenti	giovani	adulti	anziani
mare	18	24	30	12
monti	12	16	20	8
città d'arte	6	8	10	4




Percentuali di colonna
mare
monti
città d'arte
0
20
40
60
80
100
adolescenti
giovani
adulti
anziani
Percentuali di riga
adolescenti
giovani
adulti
anziani
0
20
40
60
80
100
mare
monti
città d'arte

Frequenze osservate

```
obs_n = matrix(
  c(18, 24, 30, 12,    # mare
    12, 16, 20, 8,     # monti
    6, 8, 10, 4),      # città d'arte
  nrow = 3, byrow = TRUE) ; obs_n
```

```
     [,1] [,2] [,3] [,4]
[1,]   18   24   30   12
[2,]   12   16   20    8
[3,]    6    8   10    4
```

Frequenze teoriche

```
chisq.test(obs_n)$expected
```

```
     [,1] [,2] [,3] [,4]
[1,]   18   24   30   12
[2,]   12   16   20    8
[3,]    6    8   10    4
```

Calcolo χ^2

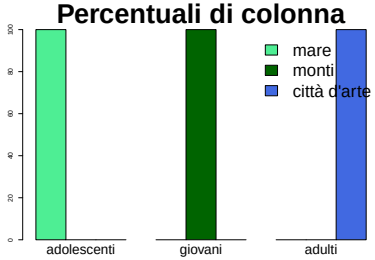
```
chisq.test(obs_n)$statistic
```

```
X-squared
        0
```

```
sum(obs_n) * min(c(nrow(obs_n) -1,
                   ncol(obs_n) - 1))
```

```
[1] 336
```

	adolescenti	giovani	adulti	Sum
mare	84	0	0	84
monti	0	64	0	64
città d'arte	0	0	20	20
Sum	84	64	20	168



Frequenze osservate

```
obs_n <- matrix(
  c(84, 0, 0,     # mare → solo adolescenti
    0, 64, 0,     # monti → solo giovani
    0, 0, 20),  # città d'arte → solo adulti
  nrow = 3, byrow = TRUE) ; obs_n
```

```
     [,1] [,2] [,3]
[1,]   84    0    0
[2,]    0   64    0
[3,]    0    0   20
```

Frequenze teoriche

```
chisq.test(obs_n)$expected
```

```
     [,1]       [,2]       [,3]
[1,]   42 32.000000 10.000000
[2,]   32 24.380952  7.619048
[3,]   10  7.619048  2.380952
```

Table 8: Frequenze osservate

84	0	0
0	64	0
0	0	20

Table 9: Frequenze Teoriche

42	32.000000	10.000000
32	24.380952	7.619048
10	7.619048	2.380952

```
chisq.test(obs_n)$statistic
```

```
X-squared
      336
```

```
sum(obs_n) * min(c(nrow(obs_n) -1,
                           ncol(obs_n) - 1))
```

```
[1] 336
```