

Modulo Didattico 3: Statistiche descrittive bivariata (Associazione tra variabili categoriali)

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

A.A. 2026/2027

- 1 Variabile statistica doppia
- 2 Tabella a doppia entrata – Tavola di contingenza
- 3 Connessione (Variabili qualitative)
- 4 Indipendenza stocastica e massima dipendenza

X : Istruzione	E	E	E	SI	SI	SI	SS	SS	SS	SS	SS
Y : Occupazione	DI	I	I	DI	I	I	D	I	I	D	D

categoria x_k	$n_{k.}$
Elementare (E)	3
Secondaria Inferiore (SI)	3
Secondaria Superiore (SS)	5

categoria y_j	$n_{.j}$
Disoccupato (DI)	2
Impiegato (I)	6
Dirigente (D)	3

	DI	I	D	
E	1	2	0	3
SI	1	2	0	3
SS	0	2	3	5
	2	6	3	11

Date due variabili X e Y e la loro distribuzione di frequenze congiunte n_{kj} (numero di unità statistiche che presentano la coppia di categorie (x_k, y_j))

Tip

L'insieme (X, Y) delle terne

$$(x_k, y_j, n_{kj}) \quad (k = 1, \dots, h; j = 1, \dots, m)$$

è detto **variabile statistica doppia**.

- 1 Variabile statistica doppia
- 2 Tabella a doppia entrata – Tavola di contingenza**
- 3 Connessione (Variabili qualitative)
- 4 Indipendenza stocastica e massima dipendenza

		Y						
		y_1	y_2	$\dots$	y_j	$\dots$	y_m	$n_{k.}$
X	x_1	n_{11}	n_{12}	$\dots$	n_{1j}	$\dots$	n_{1m}	$n_{1.}$
	x_2	n_{21}	n_{22}	$\dots$	n_{2j}	$\dots$	n_{2m}	$n_{2.}$
	$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
	x_k	n_{k1}	n_{k2}	$\dots$	n_{kj}	$\dots$	n_{km}	$n_{k.}$
	$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
	x_h	n_{h1}	n_{h2}	$\dots$	n_{hj}	$\dots$	n_{hm}	$n_{h.}$
		$n_{.1}$	$n_{.2}$	$\dots$	$n_{.j}$	$\dots$	$n_{.m}$	n

n_{kj} : **Frequenza congiunta**, definisce il numero di unità statistiche che possiedono congiuntamente la categoria x_k della variabile X e la categoria y_j della variabile Y

$n_{k.}$: **Frequenza marginale di X** , definisce il numero di unità statistiche che possiedono la categoria x_k della variabile X

$n_{.j}$: **Frequenza marginale di Y** , definisce il numero di unità statistiche che possiedono la categoria y_j della variabile Y

n : Numero totale di unità statistiche

$$n_{k.} = \sum_{j=1}^m n_{kj}$$



Numero di unità statistiche che possiedono la categoria x_k della variabile X (**totale della riga k**)

$$n_{.j} = \sum_{k=1}^h n_{kj}$$



Numero di unità statistiche che possiedono la categoria y_j della variabile Y (**totale della colonna j**)

$$\sum_{k=1}^h \sum_{j=1}^m n_{kj} = \sum_{k=1}^h n_{k.} = \sum_{j=1}^m n_{.j} = n$$

1 Variabile statistica doppia

2 Tabella a doppia entrata – Tavola di contingenza

- `table()`
- `margin.table()`
- `prop.table()`
- Frequenze percentuali
- $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
- $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)

3 Connessione (Variabili qualitative)

4 Indipendenza stocastica e massima dipendenza

`table()`

`table(var1, var2)`: Produce la tabella di frequenza tra due variabili categoriali `var1` e `var2`

```
var1 <- as.factor(c("a1", "a2", "a1", "a2", "a1", "a2", "a1"))
var2 <- as.factor(c("b1", "b1", "b1", "b2", "b1", "b2", "b2"))
mytab = table(var1, var2); mytab
```

```
      var2
var1 b1 b2
a1   3  1
a2   1  2
```

`sum(mytab)` # permette di ottenere l'ampiezza campionaria

```
[1] 7
```

1 Variabile statistica doppia

2 Tabella a doppia entrata – Tavola di contingenza

- `table()`
- `margin.table()`
- `prop.table()`
- Frequenze percentuali
- $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
- $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)

3 Connessione (Variabili qualitative)

4 Indipendenza stocastica e massima dipendenza

```
margin.table()
```

`margin.table(table, margin)`: Frequenze marginali per la tabella a doppia entrata

Tip

`margin = 1`: Frequenze marginali calcolate **attraverso le colonne**
`margin = 2`: Frequenze marginali calcolate **attraverso le righe**

```
      var2  
var1 b1 b2  
a1   3  1  
a2   1  2
```

```
margin.table(mytab,1)
```

```
var1  
a1 a2  
4  3
```

```
margin.table(mytab,2)
```

```
var2  
b1 b2  
4  3
```

1 Variabile statistica doppia

2 Tabella a doppia entrata – Tavola di contingenza

- `table()`
- `margin.table()`
- `prop.table()`
- Frequenze percentuali
- $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
- $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)

3 Connessione (Variabili qualitative)

4 Indipendenza stocastica e massima dipendenza

```
prop.table()
```

`prop.table(T, margin = NULL)`: Probabilità condizionate:

Tip

`margin = 1`: Probabilità condizionate di riga (**attraverso le colonne**)

`margin = 2`: Probabilità condizionate di colonna **attraverso le righe**

```
prop.table()
```

```
mytab
```

```
      var2  
var1 b1 b2  
a1   3  1  
a2   1  2
```

```
prop.table(mytab,1) # P(B|A)
```

```
      var2  
var1      b1      b2  
a1 0.7500000 0.2500000  
a2 0.3333333 0.6666667
```

```
prop.table(mytab)
```

```
      var2  
var1      b1      b2  
a1 0.4285714 0.1428571  
a2 0.1428571 0.2857143  
prop.table(mytab,2) # P(A|B)
```

```
      var2  
var1      b1      b2  
a1 0.7500000 0.3333333  
a2 0.2500000 0.6666667
```

1 Variabile statistica doppia

2 Tabella a doppia entrata – Tavola di contingenza


- `table()`
- `margin.table()`
- `prop.table()`
- Frequenze percentuali
- $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
- $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)

3 Connessione (Variabili qualitative)

4 Indipendenza stocastica e massima dipendenza

Frequenze percentuali

	Basso	Medio	Alto	Totale
Casalinghe	40	25	20	85
Lavoratrici	10	15	30	55
Totale	50	40	50	140



1 Variabile statistica doppia

2 Tabella a doppia entrata – Tavola di contingenza


- `table()`
- `margin.table()`
- `prop.table()`
- Frequenze percentuali
- $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
- $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)

3 Connessione (Variabili qualitative)

4 Indipendenza stocastica e massima dipendenza

$P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di riga)

	Basso	Medio	Alto	Sum
Casalinghe	47	29	24	100
Lavoratrici	18	27	55	100



X% delle donne lavoratrici/casalinghe hanno un titolo di studio basso/medio/alto

1 Variabile statistica doppia

2 Tabella a doppia entrata – Tavola di contingenza


- `table()`
- `margin.table()`
- `prop.table()`
- Frequenze percentuali
- $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
- $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)

3 Connessione (Variabili qualitative)

4 Indipendenza stocastica e massima dipendenza

$P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)

	Basso	Medio	Alto
Casalinghe	80	62	40
Lavoratrici	20	38	60
Sum	100	100	100



X% delle donne con titolo di studio basso/medio/alto che sono lavoratrici/casalinghe

- 1 Variabile statistica doppia
- 2 Tabella a doppia entrata – Tavola di contingenza
- 3 Connessione (Variabili qualitative)**
- 4 Indipendenza stocastica e massima dipendenza

◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ≡ ≡ ↺ 🔍 ↻

- 1 Variabile statistica doppia
- 2 Tabella a doppia entrata – Tavola di contingenza
- 3 Connessione (Variabili qualitative)
 - χ^2
 - `chisq.test()`
- 4 Indipendenza stocastica e massima dipendenza

χ^2

Quantifica la DISTANZA DALL'INDIPENDENZA tra due variabili categoriali

- X con h categorie x_k , con $k = 1, \dots, h$,
- Y con m categorie y_j , con $j = 1, \dots, m$

Richiede il confronto tra **frequenze osservate** (n_{kj}) e **frequenze attese** o **frequenze teoriche** (n_{kj}^*)

n_{kj}	$n_{k.}$
$n_{.j}$	

Frequenze osservate

VS.

n_{kj}^*	$n_{k.}$
$n_{.j}$	

Frequenze teoriche

$$n_{kj}^* = \frac{n_{k.} \times n_{.j}}{n},$$

$$n = \sum_{k=1}^h \sum_{j=1}^m n_{kj} = \sum_{k=1}^h \sum_{j=1}^m n_{kj}^*$$

n_{kj}^* : Significato

Data l'ampiezza campionaria n , quali sono le frequenze che avremmo dovuto osservare se le due variabili fossero state indipendenti, ovvero se non avessero alcuna relazione?

$$n_{kj}^* = \frac{n_{k.} \cdot n_{.j}}{n}$$

χ^2

Table 4: Frequenze osservate

	Basso	Medio	Alto	Totale
Casalinghe	40	25	20	85
Lavoratrici	10	15	30	55
Totale	50	40	50	140

Table 5: Frequenze teoriche

	Basso	Medio	Alto	Totale
Casalinghe	$\frac{85 \times 50}{140} = 30.36$	$\frac{85 \times 40}{140} = 24.29$	$\frac{85 \times 50}{140} = 30.36$	85
Lavoratrici	$\frac{55 \times 50}{140} = 19.64$	$\frac{55 \times 40}{140} = 15.71$	$\frac{55 \times 50}{140} = 19.64$	55
Totale	50	40	50	140

χ^2

$$\chi^2 = \sum_{k=1}^h \sum_{j=1}^m \frac{(n_{kj} - n_{kj}^*)^2}{n_{kj}^*}$$

$\chi^2 = 0$: $n_{kj} = n_{kj}^*$ Indipendenza stocastica

$\chi^2 = \chi_{\max}^2$: Relazione di perfetta dipendenza (dove
 $\chi_{\max}^2 = n \times \min[(h-1); (m-1)]$)

$$\tilde{\chi}^2 = \frac{\chi^2}{\chi_{\max}^2}$$

$\tilde{\chi}^2$ è il χ^2 normalizzato, permette di esprimere il grado di associazione tra due variabili categoriali secondo una scala di tipo $[0, 1]$

- 1 Variabile statistica doppia
- 2 Tabella a doppia entrata – Tavola di contingenza
- 3 Connessione (Variabili qualitative)
 - χ^2
 - `chisq.test()`
- 4 Indipendenza stocastica e massima dipendenza

```
chisq.test()
```

`chisq.test(table)$statistic`: Calcola il χ^2 osservato a partire da una tavola di contingenza `table`

```
mytab
```

```
      var2  
var1 b1 b2  
a1   3  1  
a2   1  2
```

```
chisq.test(mytab)$statistic
```

```
X-squared  
0.109375
```

```
chisq.test()
```

Calcolo χ^2_{max}

```
chiMax = sum(mytab) * min(c(nrow(mytab) - 1, ncol(mytab) - 1))  
chiMax
```

```
[1] 7
```

```
chisq.test(mytab)$statistic/chiMax
```


X-squared

0.015625


- 1 Variabile statistica doppia
- 2 Tabella a doppia entrata – Tavola di contingenza
- 3 Connessione (Variabili qualitative)
- 4 Indipendenza stocastica e massima dipendenza**

	adolescenti	giovani	adulti	anziani
mare	18	24	30	12
monti	12	16	20	8
città d'arte	6	8	10	4


Frequenze assolute



Percentuali di colonna



Percentuali di riga



Frequenze osservate

```
obs_n = matrix(  
  c(18, 24, 30, 12,    # mare  
    12, 16, 20, 8,     # monti  
    6, 8, 10, 4),      # città d'arte  
  nrow = 3, byrow = TRUE) ; obs_n
```

	[,1]	[,2]	[,3]	[,4]
[1,]	18	24	30	12
[2,]	12	16	20	8
[3,]	6	8	10	4

Frequenze teoriche

```
chisq.test(obs_n)$expected
```

	[,1]	[,2]	[,3]	[,4]
[1,]	18	24	30	12
[2,]	12	16	20	8
[3,]	6	8	10	4

Calcolo χ^2


```
chisq.test(obs_n)$statistic
```

```
X-squared  
0
```

```
sum(obs_n) * min(c(nrow(obs_n) - 1,  
                    ncol(obs_n) - 1))
```

```
[1] 336
```

	adolescenti	giovani	adulti	Sum
mare	84	0	0	84
monti	0	64	0	64
città d'arte	0	0	20	20
Sum	84	64	20	168



Frequenze osservate

```
obs_n <- matrix(  
  c(84, 0, 0,      # mare → solo adolescenti  
    0, 64, 0,      # monti → solo giovani  
    0, 0, 20),     # città d'arte → solo adulti  
  nrow = 3, byrow = TRUE) ; obs_n
```

	[,1]	[,2]	[,3]
[1,]	84	0	0
[2,]	0	64	0
[3,]	0	0	20

Frequenze teoriche

```
chisq.test(obs_n)$expected
```

	[,1]	[,2]	[,3]
[1,]	42	32.000000	10.000000
[2,]	32	24.380952	7.619048
[3,]	10	7.619048	2.380952

Table 8: Frequenze osservate

84	0	0
0	64	0
0	0	20

Table 9: Frequenze Teoriche

42	32.000000	10.000000
32	24.380952	7.619048
10	7.619048	2.380952

```
chisq.test(obs_n)$statistic
```

```
X-squared  
336
```

```
sum(obs_n) * min(c(nrow(obs_n) - 1,  
                    ncol(obs_n) - 1))
```

```
[1] 336
```