

Modulo Didattico 3: Statistiche descrittive per la misura di associazione tra due variabili - Prima Parte

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
`ottavia.epifania@unitn.it`

A.A. 2025/2026

1 Tabelle di frequenza (contingenza)

2 Associazione (Variabili qualitative)

3 Riflessioni

1 Tabelle di frequenza (contingenza)

- `table()`
- `margin.table()`
- `prop.table()`

2 Associazione (Variabili qualitative)

3 Riflessioni

table(var1, var2): Produce la tabella di frequenza tra due variabili categoriali var1 e var2

```
var1 <- as.factor(c("a1", "a2", "a1", "a2", "a1", "a2", "a1"))
var2 <- as.factor(c("b1", "b1", "b1", "b2", "b1", "b2", "b2"))
table(var1, var2)
```

	var2	
var1	b1	b2
a1	3	1
a2	1	2

1 Tabelle di frequenza (contingenza)

- `table()`
- `margin.table()`
- `prop.table()`

2 Associazione (Variabili qualitative)

3 Riflessioni

```
margin.table()
```

`margin.table(table, margin)`: Frequenze marginali per la tabella a doppia entrata

*margin = 1: Frequenze marginali calcolate **attraverso le colonne***
*margin = 2: Frequenze marginali calcolate **attraverso le righe***

```
mytab <- table(var1,var2)
```

```
margin.table(mytab,2)
```

```
var2
```

```
b1 b2
```

```
4 3
```

1 Tabelle di frequenza (contingenza)

- `table()`
- `margin.table()`
- `prop.table()`

2 Associazione (Variabili qualitative)

3 Riflessioni

`prop.table()`

`prop.table(T, margin = NULL)`: Probabilità condizionate:

- riga (`margin = 1`, attraverso le colonne) o colonna (`margin = 2`, attraverso le righe).
- `margin = NULL` frequenze relative

```
prop.table(mytab)
```

```
      var2
var1      b1      b2
a1 0.4285714 0.1428571
a2 0.1428571 0.2857143
```

```
prop.table(mytab,2) # P(A|B)
```

```
      var2
var1      b1      b2
a1 0.7500000 0.3333333
a2 0.2500000 0.6666667
```

```
prop.table(mytab,1) # P(B|A)
```

```
      var2
var1      b1      b2
a1 0.7500000 0.2500000
a2 0.3333333 0.6666667
```


- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Riflessioni

1 Tabelle di frequenza (contingenza)

2 Associazione (Variabili qualitative)

- χ^2

- `chisq.test()`

3 Riflessioni

Quantifica il grado di associazione tra due variabili nominali:

- A con I categorie,
- B con J categorie Richiede il confronto tra **frequenze osservate** (n_{ij}) e **frequenze attese** o **frequenze teoriche** (n_{ij}^*)

n_{ij}	$n_{i.}$
$n_{.j}$	

Frequenze osservate

VS.

n_{ij}^*	$n_{i.}$
$n_{.j}$	

Frequenze teoriche

$$n_{ij}^* = \frac{n_{i.} \times n_{.j}}{N}$$

$$N = \sum_{i=1}^I \sum_{j=1}^J n_{ij}$$

Le frequenze teoriche n_{ij}^* sono calcolate assumendo l'indipendenza tra le variabili.

n_{ij}^* : Significato

Data l'ampiezza campionaria N , quali sono le frequenze che avremmo dovuto osservare se le due variabili fossero state indipendenti, ovvero se non avessero alcuna relazione?

$$\chi^2 = \sum_i \sum_j \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*}$$

χ^2

$\chi^2 = 0$: $n_{ij} = n_{ij}^*$ Indipendenza stocastica

$\chi^2 = \chi_{\max}^2$: Relazione di perfetta dipendenza (dove
 $\chi_{\max}^2 = N \times \min[(I - 1); (J - 1)]$)

χ^2

$\chi^2 = 0$: $n_{ij} = n_{ij}^*$ Indipendenza stocastica

$\chi^2 = \chi_{\max}^2$: Relazione di perfetta dipendenza (dove
 $\chi_{\max}^2 = N \times \min[(I - 1); (J - 1)]$)

$$\tilde{\chi}^2 = \frac{\chi^2}{\chi_{\max}^2}$$

$\tilde{\chi}^2$ è il χ^2 normalizzato, permette di esprimere il grado di associazione tra due variabili categoriali secondo una scala di tipo $[0, 1]$

1 Tabelle di frequenza (contingenza)

2 Associazione (Variabili qualitative)

- χ^2

- `chisq.test()`

3 Riflessioni

`chisq.test()`

`chisq.test(table)$statistic`: Calcola il χ^2 osservato a partire da una tavola di contingenza `table`

`chisq.test(mytab)$statistic`

X-squared
0.109375

Per calcolare il $\tilde{\chi}^2$:


`chisq.test(mytab)$statistic/sum(mytab)`

X-squared
0.015625

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Riflessioni

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Riflessioni
 - Frequenze percentuali
 - $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
 - $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)
 - Osservato vs. Teorico
 - Massima dipendenza


	Basso	Medio	Alto	Totale
Casalinghe	40	25	20	85
Lavoratrici	10	15	30	55
Totale	50	40	50	140



- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Riflessioni
 - Frequenze percentuali
 - $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
 - $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)
 - Osservato vs. Teorico
 - Massima dipendenza

$P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)

	Basso	Medio	Alto	Sum
Casalinghe	47	29	24	100
Lavoratrici	18	27	55	100




X% delle donne lavoratrici/casalinghe hanno un titolo di studio basso/medio/alto

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Riflessioni
 - Frequenze percentuali
 - $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
 - $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)
 - Osservato vs. Teorico
 - Massima dipendenza

$$P(\text{Occupazione}|\text{Titolo}) \text{ (Frequenze percentuali di colonna)}$$


	Basso	Medio	Alto
Casalinghe	80	62	40
Lavoratrici	20	38	60
Sum	100	100	100




X% delle donne con titolo di studio basso/medio/alto che sono lavoratrici/casalinghe

	adolescenti	giovani	adulti	anziani
mare	18	24	30	12
monti	12	16	20	8
città d'arte	6	8	10	4


Frequenze assolute



Percentuali di colonna



Percentuali di riga



- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Riflessioni
 - Frequenze percentuali
 - $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
 - $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)
 - Osservato vs. Teorico
 - Massima dipendenza

Tabella 5: Frequenze osservate

	adolescenti	giovani	adulti	anziani
mare	18	24	30	12
monti	12	16	20	8
città d'arte	6	8	10	4

Tabella 6: Frequenze Teoriche

	adolescenti	giovani	adulti	anziani
mare	18	24	30	12
monti	12	16	20	8
città d'arte	6	8	10	4

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Riflessioni
 - Frequenze percentuali
 - $P(\text{Titolo}|\text{Occupazione})$ (Frequenze percentuali di **riga**)
 - $P(\text{Occupazione}|\text{Titolo})$ (Frequenze percentuali di **colonna**)
 - Osservato vs. Teorico
 - Massima dipendenza

	adolescenti	giovani	adulti	Sum
mare	84	0	0	84
monti	0	64	0	64
città d'arte	0	0	20	20
Sum	84	64	20	168




Tabella 8: Frequenze osservate

	adolescenti	giovani	adulti
mare	84	0	0
monti	0	64	0
città d'arte	0	0	20

Tabella 9: Frequenze Teoriche

	adolescenti	giovani	adulti
mare	42	32.000000	10.000000
monti	32	24.380952	7.619048
città d'arte	10	7.619048	2.380952

$$\chi^2 = 336$$

$$\chi^2_{Max} =$$

$$N * \min[(i - i); (c - 1)] = 168 * \min[(3 - 1); (3 - 1)] = 336$$