

Modulo Didattico 3: Statistiche descrittive per la misura di associazione tra due variabili - Seconda Parte

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

A.A. 2025/2026


1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

1 Associazione (variabili quantitative)

- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`

2 Previsione variabili quantitative



	X	Y
1	10	8.04
2	8	6.95
3	13	7.58
4	9	8.81
5	11	8.33
6	14	9.96
7	6	7.24
8	4	4.26
9	12	10.84
10	7	4.82
11	5	5.68

Figura 1: Grafico a dispersione delle variabili X e Y

1 Associazione (variabili quantitative)

- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`

2 Previsione variabili quantitative


`plot()`

`plot(x, y)`: Grafico di dispersione di due variabili quantitative appaiate
(x,y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```

```
plot(X,Y,main="Grafico di dispersione", xlim=c(0,20),ylim=c(0,15))
```



1 Associazione (variabili quantitative)

- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`

2 Previsione variabili quantitative

Misura il grado di *dispersione* e *covariazione* di due variabili quantitative appaiate (X, Y) attorno ai loro baricentri (medie) $\bar{X}$ e $\bar{Y}$


$$x = (x_1, x_2, \dots, x_n)$$

$$y = (y_1, y_2, \dots, y_n)$$


$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

$$\text{Cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$


Covarianza campionaria




(a) $Cov = 0$



(a) $Cov = 0$



(a) $Cov > 0$



(a) $Cov < 0$

Covarianza

1 Associazione (variabili quantitative)

- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`

2 Previsione variabili quantitative

`cov()`: Restituisce la covarianza campionaria tra due variabili quantitative appaiate (X, Y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```

```
Z <- -Y
```

```
cov(X,Y)
```

```
[1] 6.309091
```

```
cov(X,Z)
```

```
[1] -6.309091
```

1 Associazione (variabili quantitative)

- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`

2 Previsione variabili quantitative

$$-sd(x)sd(y) \leq \text{Cov}(X, Y) \leq +sd(x)sd(y)$$

$$-sd(x)sd(y) \leq \text{Cov}(X, Y) \leq +sd(x)sd(y)$$

$$r = \frac{\text{Cov}(X, Y)}{sd(x)sd(y)}$$

$$-1 \leq r \leq 1$$

1 Associazione (variabili quantitative)

- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`

2 Previsione variabili quantitative

`cor()`: Restituisce la correlazione (lineare) campionaria tra due variabili quantitative appaiate (X, Y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```




```
Z <- -Y
```

```
cor(X,Y)
```

```
[1] 0.7921487
```

```
cor(X,Z)
```

```
[1] -0.7921487
```

`cor()`**cov = 12.24 , r = 0.72****cov = -13.09 , r = -0.71****cov = -3.84 , r = -0.21**

**Siberian Fox**

@SilverVVulpes

I'm just sayin', everyone that confuses correlation with causation eventually ends up dead.

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- I residui


Quanto varia y in funzione di x ?

La correlazione permette di stabilire quanto covariano due variabili, x e y :
modello simmetrico per determinare *l'intensità della relazione*

Con un modello di regressione si vuole andare più a fondo per capire
quanto varia y in funzione di ogni cambiamento in x : stabilire non solo se
le variabili sono associate o meno ma la portata della variazione

La relazione è *asimetrica*: si vuole spiegare y in funzione di x (questo non
vuol dire in alcun modo che la relazione sia causale)


Regressione lineare




	X	Y
1	10	8.04
2	8	6.95
3	13	7.58
4	9	8.81
5	11	8.33
6	14	9.96
7	6	7.24
8	4	4.26
9	12	10.84
10	7	4.82
11	5	5.68

$$r = 0.79$$

Regressione lineare



Regressione lineare



La regressione lineare tra una *variabile indipendente* X (predittore) ed una *variabile dipendente* Y (criterio) calcola la migliore approssimazione lineare che identifica il legame tra le due variabili utilizzando la struttura di dati bivariata (x, y) osservata su un campione di n osservazioni.

$$x = (x_1, x_2, \dots, x_n)$$

$$y = (y_1, x_2, \dots, y_n)$$

$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

$$Y = \beta_0 + \beta X$$

$$y_i = \beta_0 + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n)$$

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- I residui

$$SQE = \sum_{i=1}^n (y_i - y_i^*)^2 = SQE = \sum_{i=1}^n (y_i - (\beta_0 + \beta x_i))^2 = \sum_{i=1}^n e_i^2$$

dove $y_i^* = \beta_0 + \beta x_i$, e $e_i = y_i - y_i^*$.


Per il principio dei minimi quadrati si può dimostrare che lo stimatore ottimale per β è

$$\hat{\beta} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

mentre per β_0 è

$$\hat{\beta}_0 = \bar{y} - \hat{\beta} \bar{x}$$

Principio dei minimi quadrati



1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- I residui

$$R^2 = 1 - \frac{SQE/n - 1}{Var(Y)} = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$


$\varepsilon = \frac{SQE}{n-1}$: Stimatore campionario della varianza della componente di errore


$0 \leq R^2 \leq 1$: Più R^2 è vicino ad 1, migliore è il modello. Di fatto, $R^2 = r^2$

1 Associazione (variabili quantitative)


2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- I residui




Relazione R^2 e r 


$$R^2 = 0.34, r = 0.59$$

Relazione R^2 e r 

$$R^2 = 0.81, r = -0.9$$

Relazione R^2 e r 

$$R^2 = 0.96, r = 0.98$$

Relazione R^2 e r 

$$R^2 = 0, r = -0.14$$

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- I residui

lm()

`lm(Y ~ X)`: Retituisce la stima dei parametri del modello di regressione lineare dove si predicono i valori di Y a seconda dei valori di X

`~`: (Per i PC con tastierino numerico): ALT + 126, Per i MAC: ALT + 5 (fonte non verificata)

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
lm(Y~X)
```

Call:

```
lm(formula = Y ~ X)
```

Coefficients:

(Intercept)	X
2.4554	0.5624

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- I residui


Indipendenza dei predittori dall'errore

I predittori sono misurati senza errore, ovvero i predittori e gli errori di misura non sono correlati nella popolazione (per questo è importante il campionamento casuale)


Analisi dei residui

I residui e il predittore **non devono essere correlati tra di loro**

I residui




I residui




$$r = -0.05$$

I residui



I residui



$$r = 0.64$$