

Modulo Didattico 3: Statistiche descrittive per la misura di associazione tra due variabili - Variabili quantitative

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
`ottavia.epifania@unitn.it`

A.A. 2026/2027

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- `lm()`
- Assunti del modello

3 Materiale supplementare


1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare

Per relazione lineare si intende quanto le coppie di punti (x_i, y_i) tendono a disporsi lungo una retta




Due indici: la **covarianza** (direzione della relazione) e il **coefficiente di correlazione lineare di Bravais-Pearson** (direzione e intensità)

1 Associazione (variabili quantitative)

- Relazione lineare
- **Indice di covarianza campionaria**
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare



	X	Y
1	10	8.04
2	8	6.95
3	13	7.58
4	9	8.81
5	11	8.33
6	14	9.96
7	6	7.24
8	4	4.26
9	12	10.84
10	7	4.82
11	5	5.68

Figure 1: Grafico a dispersione delle variabili X e Y

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
plot(X,Y,main="Grafico di dispersione", xlim=c(0,20),ylim=c(0,15))
```





$$y = (y_1, y_2, \dots, y_n)$$

$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

$$\text{Cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

1000



Il prodotto $(x_i - \bar{x})(y_i - \bar{y})$ è più spesso positivo se $\text{Cov} > 0$, più spesso negativo se $\text{Cov} < 0$

- Il valore della covarianza dipende dall'unità di misura delle variabili $\rightarrow$ ci dice la **direzione** della relazione ma non la sua **intensità**



Covarianza

Età (in mesi) e peso (in kg) di un bambino rilevati in 6 momenti

	eta	peso
1	3	6
2	6	8
3	9	9
4	12	10
5	24	13
6	36	20




Figure 6: Grafico a dispersione

	x	y	x - media(x)	y - media(y)	prodotto
1	3	6	-12	-5	60
2	6	8	-9	-3	27
3	9	9	-6	-2	12
4	12	10	-3	-1	3
5	24	13	9	2	18
6	36	20	21	9	189

$$\bar{x} = 15, \bar{y} = 11, \sum_i (x_i - \bar{x})(y_i - \bar{y}) = 309$$

$$\text{Cov}(x, y) = \frac{309}{6 - 1} = 61.8$$

E quindi? Sappiamo che la relazione è **positiva**, ma è forte o debole?

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare

$\text{cov}(X, Y)$

[1] 6.309091

 $\text{cov}(X, Z)$

```
[1] -6.309091
```

```
cov(bimbo$eta, bimbo$peso)
```

[1] 61.8

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `cov()`
- **Correlazione campionaria**
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare

Per stabilire l'**intensità** della relazione la covarianza va *normalizzata*, ovvero divisa per il suo valore massimo

$$-sd(x)sd(y) \leq \text{Cov}(X, Y) \leq +sd(x)sd(y)$$

$$r = \frac{\text{Cov}(X, Y)}{sd(x)sd(y)}$$


$$-1 \leq r \leq 1$$

$r = +1$: legame **perfettamente lineare e diretto**;

$r = -1$: legame **perfettamente lineare e inverso**

$r = 0$: **incorrelazione**: non esiste un legame *lineare*... ma questo non implica che le variabili non siano in relazione tra loro

<https://app.wooclap.com/IROOIDS?from=instruction-slide>

$$\mathbf{r} = \mathbf{0}$$


1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `cov()`
- Correlazione campionaria
- **`cor()`**
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare

`cor()`

`cor()`: Restituisce la correlazione (lineare) campionaria tra due variabili quantitative appaiate (X, Y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```

```
Z <- -Y
```

```
cor(X,Y)
```

```
[1] 0.7921487
```

```
cor(X,Z)
```

```
[1] -0.7921487
```


Il bambino di prima

```
[1] 0.9860185
```


```
[1] 0.9860185
```

$$r = \frac{61.8}{12.59 \cdot 4.98} = 0.986$$


Le variabili presentano una **fortissima correlazione positiva**: i punti tendono a disporsi lungo una retta crescente

$$\text{COV} = 12.24, r = 0.72$$


cov = -13.09 , r = -0.71



COV = -3.84 , r = -0.21



cor()



Siberian Fox
@SilverVVulpes

I'm just sayin', everyone that confuses correlation with causation eventually ends up dead.

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative


3 Materiale supplementare

- Attendibilità test-retest
- Forme parallele di un test (coefficiente di equivalenza)
- Accordo tra le valutazioni di due giudici
- Consistenza interna di un questionario
- ...

Relazione diretta




Ma ne siamo proprio sicuri?



La relazione tra X e Y passa attraverso altre variabili (mediatori)

Relazione spuria



X e Y sono correlate solo perché entrambe dipendono da una terza variabile

LA STATISTICA SOSTIENE, NON ILLUMINA!

1 Relazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- `lm()`
- Assunti del modello


3 Materiale supplementare

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- `lm()`
- Assunti del modello

3 Materiale supplementare



	X	Y
1	10	8.04
2	8	6.95
3	13	7.58
4	9	8.81
5	11	8.33
6	14	9.96
7	6	7.24
8	4	4.26
9	12	10.84
10	7	4.82
11	5	5.68

$$r = 0.79$$

Regressione lineare




Figure 7: Una retta che passi attraverso le coppie di osservazioni




Figure 8: Ma quale retta?

Caso estremamente semplice dove varia solo l'intercetta – le rette sono parallele

◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- `lm()`
- Assunti del modello

3 Materiale supplementare

Principio dei minimi quadrati

$$SQE = \sum_{i=1}^n (y_i - y_i^*)^2 = \sum_{i=1}^n (y_i - (\beta_0 + \beta x_i))^2 = \sum_{i=1}^n e_i^2$$

dove $y_i^* = \beta_0 + \beta x_i$, e $e_i = y_i - y_i^*$.


Per il principio dei minimi quadrati si può dimostrare che lo stimatore ottimale per β è

$$\hat{\beta} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

mentre per β_0 è

$$\hat{\beta}_0 = \bar{y} - \hat{\beta} \bar{x}$$

Principio dei minimi quadrati



1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- `lm()`
- Assunti del modello

3 Materiale supplementare

Coefficiente angolare e correlazione

$$\hat{\beta} = \frac{\text{Cov}(X, Y)}{sd(x)^2}$$

$$r = \frac{\text{Cov}(X, Y)}{sd(x)sd(y)}$$

Moltiplicando e dividendo $\hat{\beta}$ per $sd(y)$:

$$\hat{\beta} = r \frac{sd(y)}{sd(x)}$$

- ① Il **segno** del coefficiente angolare è lo stesso di r : $r > 0 \Rightarrow$ retta crescente, $r < 0 \Rightarrow$ retta decrescente, $r = 0 \Rightarrow$ retta orizzontale
- ② La retta passa sempre per il **punto delle medie** $(\bar{x}, \bar{y})$ (basta sostituire $x = \bar{x}$ in $\hat{y} = \hat{\beta}_0 + \hat{\beta}x$)

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative


- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- `lm()`
- Assunti del modello

3 Materiale supplementare


$$R^2 = 1 - \frac{SQE/n - 1}{Var(Y)} = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$\varepsilon = \frac{SQE}{n - 1}$: Stimatore campionario della varianza della componente di errore


$0 \leq R^2 \leq 1$: Più R^2 è vicino ad 1, migliore è il modello. Di fatto, $R^2 = r^2$

Indice di adattamento R^2 


Indice di adattamento R^2




$$R^2 = 0.34, r = 0.59$$

Indice di adattamento R^2 

$$R^2 = 0.81, r = -0.9$$

Indice di adattamento R^2 

$$R^2 = 0.96, r = 0.98$$

Indice di adattamento R^2 

$$R^2 = 0, r = -0.14$$

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- `lm()`
- Assunti del modello

3 Materiale supplementare

~: (Per i PC con tastierino numerico): ALT + 126, Per i MAC: ALT + 5 (fonte non verificata)

```
Call:
lm(formula = Y ~ X)
```

```
Coefficients:
(Intercept)          X
      2.4554      0.5624
```


1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- `lm()`
- Assunti del modello

3 Materiale supplementare

Assunti del modello




La linea intera rossa rappresenta quello che dovremmo osservare, ossia la totale assenza di relazione tra la x e i residui del modello

Le linea tratteggiata blu indica la relazione effettiva tra i residui e il predittore x .


Questa linea deve essere il più vicina possibile alla linea rossa

Assunti del modello




$$r = -0.05$$

Assunti del modello



Assunti del modello



$$r = 0.64$$

```
head(studio)
```

```
      ore voto  
1 18.3 26.4  
2 18.7 25.5  
3  5.7 19.9  
4 16.6 23.5  
5 12.8 19.9  
6 10.4 22.1
```

```
modello <- lm(voto ~ ore, data = studio)  
modello
```

Call:

```
lm(formula = voto ~ ore, data = studio)
```

Coefficients:

(Intercept)	ore
14.8678	0.6243

I valori attesi e i residui

```
studio$attesi <- fitted(modello)      # y cappello
studio$residui <- residuals(modello)  # y - y cappello
head(studio)
```

	ore voto	voto	attesi	residui
1	18.3	26.4	26.29279	0.1072084
2	18.7	25.5	26.54252	-1.0425177
3	5.7	19.9	18.42642	1.4735784
4	16.6	23.5	25.23146	-1.7314560
5	12.8	19.9	22.85906	-2.9590587
6	10.4	22.1	21.36070	0.7392975

```
# i residui sono semplicemente osservati - attesi
head(studio$voto - studio$attesi)
```

```
[1] 0.1072084 -1.0425177 1.4735784 -1.7314560 -2.9590587 0.7392975
```

```
mean(studio$residui)
```

[1] -2.791617e-17

I residui dovrebbero distribuirsi in modo simmetrico attorno allo 0: la mediana deve essere il più vicina possibile a 0, il minimo e il massimo (così come il primo e il terzo quartile) dovrebbero essere simili in valore assoluto


```
summary(studio$residui)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-6.0988	-1.0629	0.2153	0.0000	1.2028	5.3498

```
plot(studio$ore, studio$residui, pch = 19,
     xlab = "ore", ylab = "residui")
abline(h = 0, col = "firebrick", lwd = 2)
```




Residui



Istogramma dei residui

```
hist(studio$residui, freq = FALSE, xlab = "residui", col = "gray90")
curve(dnorm(x, mean = 0, sd = sd(studio$residui)),
      add = TRUE, col = "firebrick", lwd = 2)
```




La linea rossa è la distribuzione normale con media 0 e sd pari a quella dei residui

Q-Q plot dei residui

Confronta i quantili dei residui con quelli di una distribuzione normale: se i residui sono normali, i punti stanno **sulla retta**

```
qqnorm(studio$residui, pch = 19)  
qqline(studio$residui, col = "firebrick", lwd = 2)
```






A histogram showing the distribution of residuals. The x-axis is labeled 'residui' and ranges from -5 to 25. The y-axis is labeled 'Density' and ranges from 0.00 to 0.12. The histogram bars are light gray. A red curve representing a normal distribution is overlaid on the histogram, peaking at a density of approximately 0.085 near x=0.

Omoschedasticità

La variabilità dei residui deve essere **costante** per tutti i valori attesi: la “nuvola” deve avere la stessa ampiezza da sinistra a destra

```
plot(studio$attesi, studio$residui, pch = 19,
      xlab = "valori attesi", ylab = "residui")
abline(h = 0, col = "firebrick", lwd = 2)
```





Forma “a imbuto”: i residui sono sempre più dispersi al crescere dei valori attesi → eteroschedasticità


Indipendenza delle osservazioni

Dipende soprattutto da **come sono stati raccolti i dati**: ogni osservazione deve essere indipendente dalle altre

Esempi di violazione: misure ripetute sulla stessa persona, studenti della stessa classe, dati raccolti nel tempo

Se i dati hanno un ordine (es. ordine di raccolta), si possono guardare i residui in quell'ordine: non deve esserci nessun andamento

```
plot(studio$residui, type = "b", pch = 19,  
      xlab = "ordine di raccolta", ylab = "residui")  
abline(h = 0, col = "firebrick", lwd = 2)
```



Cosa guardare nei residui

Assunto	Grafico	Cosa si deve vedere
Linearità	<code>plot(x, residui)</code>	Nuvola casuale attorno a 0
Normalità	<code>hist(residui), qqnorm(residui)</code>	Forma a campana, punti sulla retta
Omoschedasticità	<code>plot(attesi, residui)</code>	Ampiezza costante (niente imbuto)
Indipendenza	<code>plot(residui, type = "b")</code>	Nessun andamento nell'ordine

Tutto parte da due funzioni:

```
attesi <- fitted(modello)
residui <- residuals(modello)
```

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- `lm()`
- Assunti del modello

3 Materiale supplementare

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

3 Materiale supplementare

- Outliers e casi influenti
- Leverage e distanza di Cook


Outlier: Il valore di un'osservazione nella variabile dipendente è anomalo dato il valore del predittore (ha un residuo molto grande)

Leverage (leva): Quanto il valore di un'osservazione nel predittore è lontano dalla media del predittore $\rightarrow$ quanto *potenzialmente* può spostare la retta


Influential case: Una singola osservazione che riesce a spostare l'intera retta di regressione

Un'osservazione può essere:

- Un outlier (ma non un influential case)
- Un punto ad alta leva in linea con gli altri (ma non un influential case)
- Un outlier influente (anomalo e ad alta leva)




Il triangolo rosa è un outlier: è anomalo rispetto alla nuvola di punti, ma essendo vicino alla media dell'età sposta la retta di poco (soprattutto in alto, l'intercetta)



Il triangolo rosa è lontano dagli altri sull'asse delle x (alta leva), ma è in linea con l'andamento dei dati: la retta non cambia

Un outlier influential case living the life



Il triangolo rosa è anomalo e lontano dagli altri sull'asse delle x : ne sposta drasticamente la pendenza

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

3 **Materiale supplementare**

- Outliers e casi influenti
- Leverage e distanza di Cook

Tirare fuori leverage e distanza di Cook

Come per i residui, anche gli indici di influenza si estraggono dal modello e si guardano

`hatvalues()`: leverage di ogni osservazione

`cooks.distance()`: distanza di Cook → quanto cambiano *tutti* i valori attesi se l'osservazione viene tolta (combina residuo e leverage)

```
influyente <- rbind(dat, c(soggetto = 11, eta = 18, statura = 120))  
mod_inf <- lm(statura ~ eta, data = influyente)  
influyente$leva <- hatvalues(mod_inf)  
influyente$cook <- cooks.distance(mod_inf)
```

Leverage e distanza di Cook


```
round(influente, 2)
```

	soggetto	eta	statura	leva	cook
1	1	6	110	0.20	0.29
2	2	6	119	0.20	0.06
3	3	7	125	0.15	0.00
4	4	8	123	0.11	0.01
5	5	8	133	0.11	0.01
6	6	9	129	0.09	0.00
7	7	10	140	0.09	0.04
8	8	10	142	0.09	0.05
9	9	11	138	0.11	0.02
10	10	12	150	0.14	0.21
11	11	18	120	0.70	9.25

Il grafico della distanza di Cook

Una soglia spesso usata: $D_i > 4/n$

```
plot(influente$cook, type = "h", lwd = 3,
     xlab = "osservazione", ylab = "distanza di Cook")
abline(h = 4 / nrow(influente), col = "firebrick", lty = 2, lwd = 2)
```



```
which(influente$cook > 4 / nrow(influente))
```