Modulo Didattico 3: Statistiche descrittive per la misura di associazione tra due variabili - Variabili quantitative

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

A.A. 2026/2027

1 Associazione (variabili quantitative)

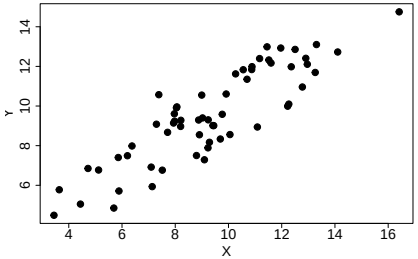
2 Previsione variabili quantitative

3 Materiale supplementare

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova r
2. Previsione variabili quantitative
3. Materiale supplementare

Si vuole studiare la **relazione lineare** tra due variabili quantitative X e Y misurate sulle stesse unità statistiche

Per relazione lineare si intende quanto le coppie di punti (x_i, y_i) tendono a disporsi lungo una retta



Due indici: la **covarianza** (direzione della relazione) e il **coefficiente di correlazione lineare di Bravais-Pearson** (direzione e intensità)

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova r
2. Previsione variabili quantitative
3. Materiale supplementare

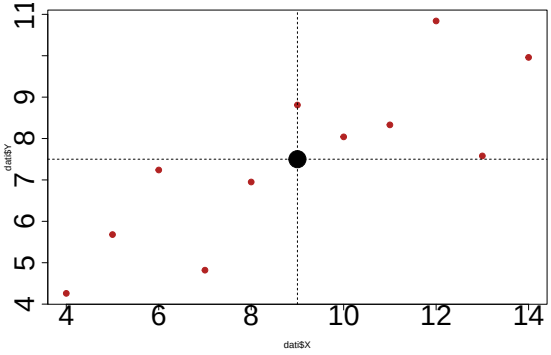
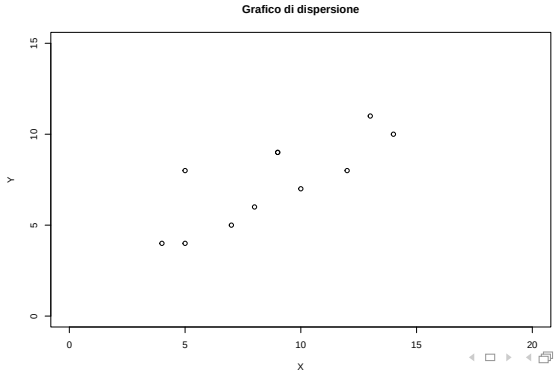


Figure 1: Grafico a dispersione delle variabili X e Y

	X	Y
1	10	8.04
2	8	6.95
3	13	7.58
4	9	8.81
5	11	8.33
6	14	9.96
7	6	7.24
8	4	4.26
9	12	10.84
10	7	4.82
11	5	5.68

`plot(x, y)`: Grafico di dispersione di due variabili quantitative appaiate `(x,y)` aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
plot(X,Y,main="Grafico di dispersione", xlim=c(0,20),ylim=c(0,15))
```



La **Covarianza** misura il grado di *dispersione* e *covariazione* di due variabili quantitative appaiate (X, Y) attorno ai loro baricentri (medie) $\bar{x}$ e $\bar{y}$

$x = (x_1, x_2, \dots, x_n)$
$y = (y_1, y_2, \dots, y_n)$

$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

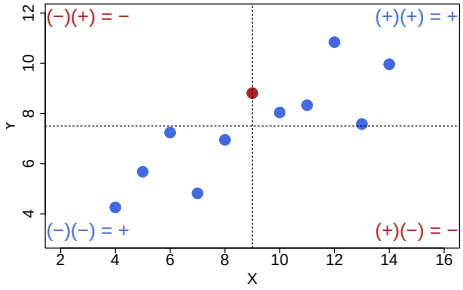
$$\mathrm{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

È (quasi) la **media dei prodotti degli scarti** di ogni variabile dalla propria media

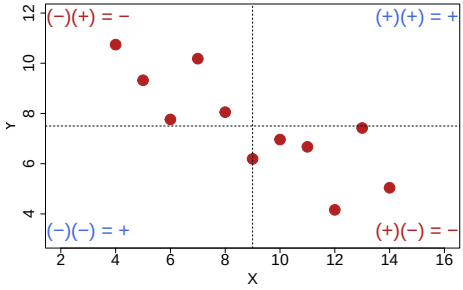
Note

Nota: alcuni testi dividono per n invece che per $n-1$ (covarianza "descrittiva"). La funzione `cov()` di `R` divide per $n-1$, quindi useremo sempre questa versione. Anche `sd()` divide per $n-1$: in questo modulo $sd(X)$ indica questa deviazione standard (a differenza di σ del Modulo 2, che divide per n)

$\mathrm{Cov}(X, Y) > 0$



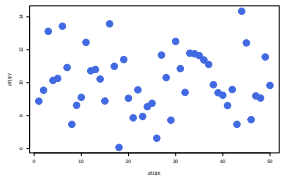
$\mathrm{Cov}(X, Y) < 0$



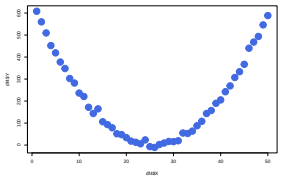
Il prodotto $(x_i - \bar{x})(y_i - \bar{y})$ è più spesso positivo se $\mathrm{Cov}(X, Y) > 0$, più spesso negativo se $\mathrm{Cov}(X, Y) < 0$

- La covarianza può assumere **tutti i valori reali**
- $\mathrm{Cov}(X, Y) > 0$: tendenza alla linearità positiva (**crescente**)
- $\mathrm{Cov}(X, Y) < 0$: tendenza alla linearità negativa (**decrescente**)
- $\mathrm{Cov}(X, Y) \approx 0$: nessuna tendenza lineare

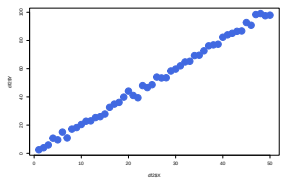
Il valore della covarianza dipende dall'unità di misura delle variabili $\rightarrow$ ci dice la **direzione** della relazione ma non la sua **intensità**.



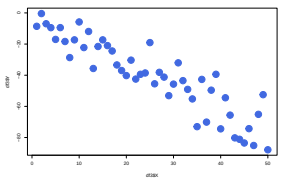
(a) Cov $= 0$



(b) Cov $= 0$



(c) Cov > 0



(d) Cov < 0

Figure 2: Covarianza

Età (in mesi) e peso (in kg) di un bambino rilevati in 6 momenti

	eta	peso
1	3	6
2	6	8
3	9	9
4	12	10
5	24	13
6	36	20

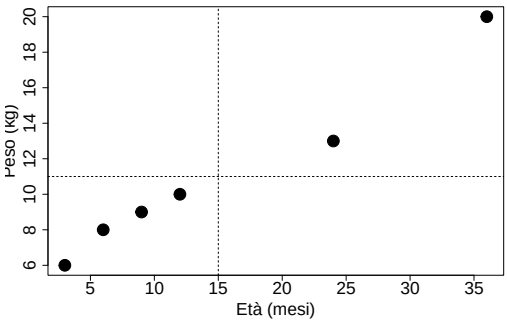


Figure 3: Grafico a dispersione

Calcolo della covarianza

	x	y	x - media(x)	y - media(y)	prodotto
1	3	6	-12	-5	60
2	6	8	-9	-3	27
3	9	9	-6	-2	12
4	12	10	-3	-1	3
5	24	13	9	2	18
6	36	20	21	9	189

$\bar{x} = 15$, $\bar{y} = 11$, $\sum_i (x_i - \bar{x})(y_i - \bar{y}) = 309$

$$\mathrm{Cov}(X, Y) = \frac{309}{6 - 1} = 61.8$$

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova r
2. Previsione variabili quantitative
3. Materiale supplementare

cov(): Restituisce la covarianza campionaria tra due variabili quantitative appaiate (X, Y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
Z <- -Y
cov(X,Y)
```

```
[1] 6.309091
```

```
cov(X,Z)
```

```
[1] -6.309091
```

```
cov(bimbo$eta, bimbo$peso)
```

```
[1] 61.8
```

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova r
2. Previsione variabili quantitative
3. Materiale supplementare

Per stabilire l'**intensità** della relazione la covarianza va *normalizzata*, ovvero divisa per il suo valore massimo:

$$-sd(X)\,sd(Y) \leq \mathrm{Cov}(X,Y) \leq +sd(X)\,sd(Y)$$

$$r = \frac{\mathrm{Cov}(X,Y)}{sd(X)\,sd(Y)}$$

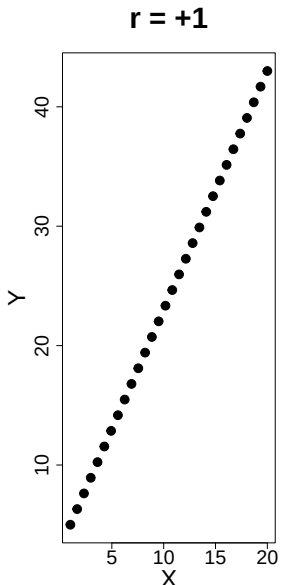
$$-1 \leq r \leq 1$$

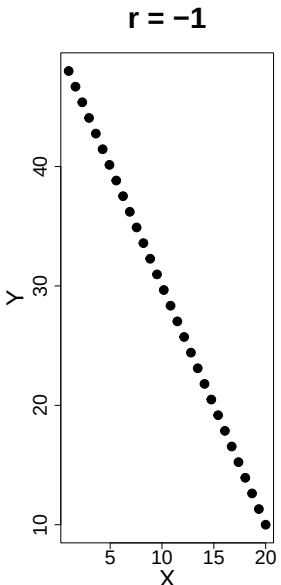
$r = +1$: legame **perfettamente lineare e diretto**;

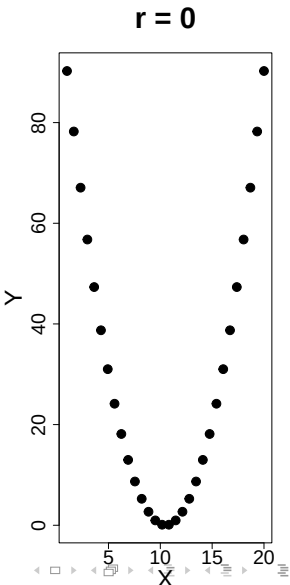
$r = -1$: legame **perfettamente lineare e inverso**

$r = 0$: **incorrelazione**: non esiste un legame *lineare*... ma questo non implica che le variabili non siano in relazione tra loro

https://app.wooclap.com/IROOIDS?from=instruction-slide


r = +1
Y
X
10
20
30
40
5
10
15
20


r = −1
Y
X
10
20
30
40
5
10
15
20


r = 0
Y
X
0
20
40
60
80
5
10
15
20

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova r
2. Previsione variabili quantitative
3. Materiale supplementare

`cor()`: Restituisce la correlazione (lineare) campionaria tra due variabili quantitative appaiate (X, Y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
Z <- -Y
cor(X,Y)
```

```
[1] 0.7921487
```

```
cor(X,Z)
```

```
[1] -0.7921487
```

Il bambino di prima

```
cov(bimbo$eta, bimbo$peso) / (sd(bimbo$eta) * sd(bimbo$peso))
```

```
[1] 0.9860185
```

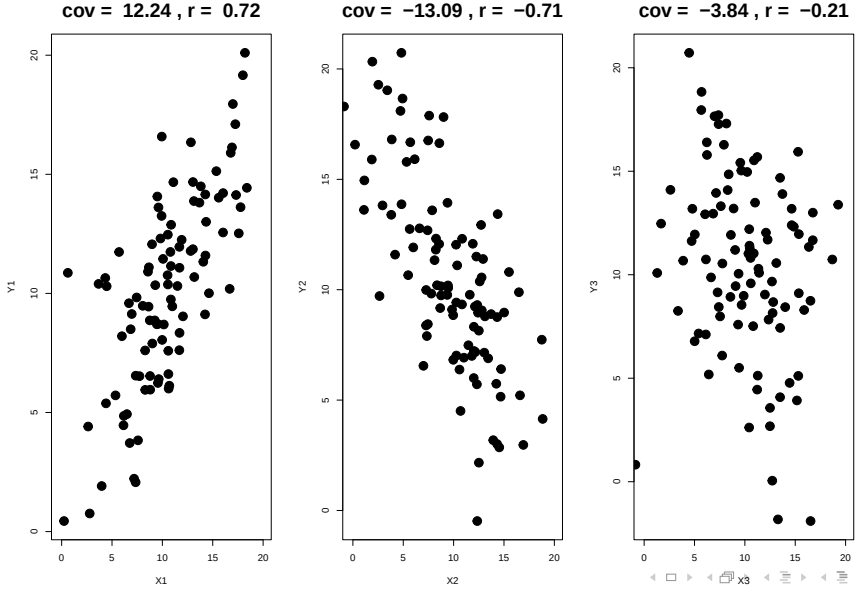
```
cor(bimbo$eta, bimbo$peso)
```

```
[1] 0.9860185
```

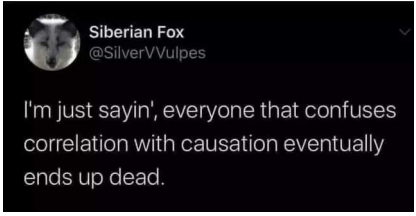
$$r = \frac{61.8}{12.59 \cdot 4.98} = 0.986$$

Le variabili presentano una **fortissima correlazione positiva**: i punti tendono a disporsi lungo una retta crescente

cor()


cov = 12.24 , r = 0.72
cov = −13.09 , r = −0.71
cov = −3.84 , r = −0.21
Y1
X1
Y2
X2
Y3
X3
0
5
10
15
20

`cor()`


Siberian Fox
@SilverVVulpes
I'm just sayin', everyone that confuses correlation with causation eventually ends up dead.

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova r
2. Previsione variabili quantitative
3. Materiale supplementare

- Attendibilità test-retest
- Forme parallele di un test (coefficiente di equivalenza)
- Accordo tra le valutazioni di due giudici
- Consistenza interna di un questionario
- ...

Statistics doesn't lie, but liars use statistics

Due variabili possono essere fortemente correlate senza che esista alcun legame tra di loro

https://www.tylervigen.com/spurious-correlations

Correlazione $\neq$ causalità

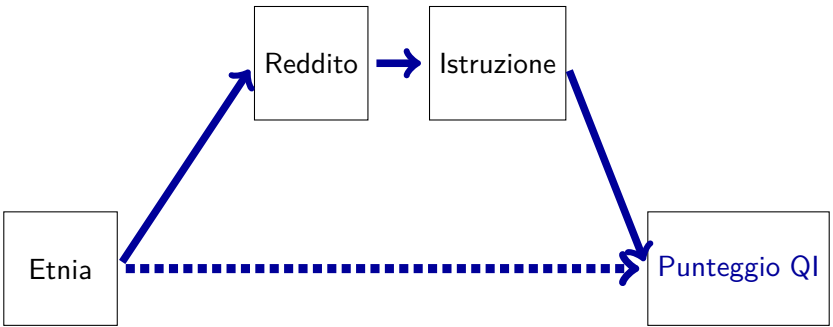
L'ignoranza afferma o nega rotondamente; la scienza dubita (Voltaire)

Relazione diretta



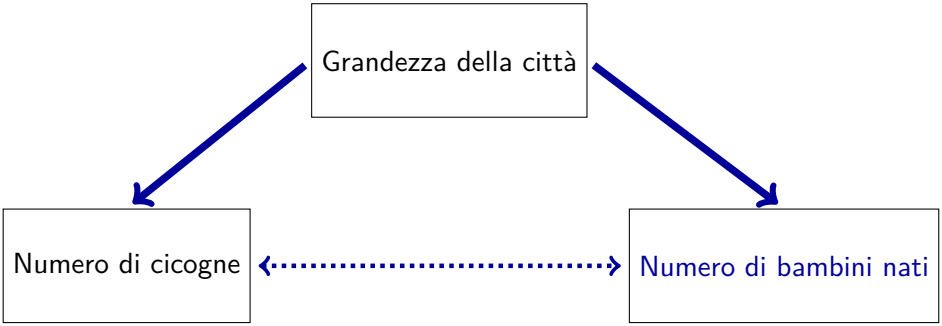
X influenza Y senza che intervengano altre variabili.

Relazione indiretta



La relazione tra X e Y passa attraverso altre variabili (mediatori).

Relazione spuria



X e Y sono correlate solo perché entrambe dipendono da una terza variabile.

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

3 Materiale supplementare

1. Associazione (variabili quantitative)

2. Previsione variabili quantitative
   - Regressione lineare
   - Principio dei minimi quadrati
   - Proprietà della retta di regressione
   - Indice di adattamento R^2
   - `lm()`
   - Assunti del modello

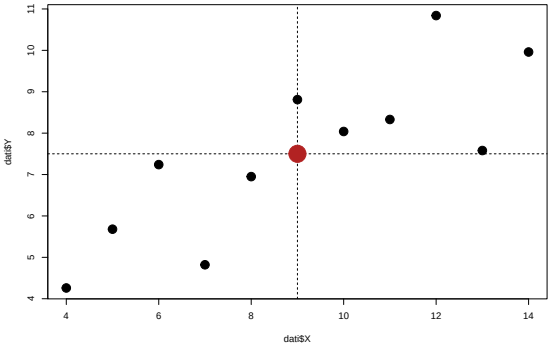
3. Materiale supplementare

Quanto varia y in funzione di x?

La correlazione permette di stabilire quanto covariano due variabili, x e y: **modello simmetrico** per determinare *l'intensità della relazione*.

Con un modello di regressione si vuole andare più a fondo per capire **quanto** varia y in funzione di ogni cambiamento in x: stabilire non solo se le variabili sono associate o meno ma la portata della variazione.

La relazione è *asimmetrica*: si vuole spiegare y in funzione di x (questo non vuol dire in alcun modo che la relazione sia causale).



	X	Y
1	10	8.04
2	8	6.95
3	13	7.58
4	9	8.81
5	11	8.33
6	14	9.96
7	6	7.24
8	4	4.26
9	12	10.84
10	7	4.82
11	5	5.68

$$r = 0.82$$

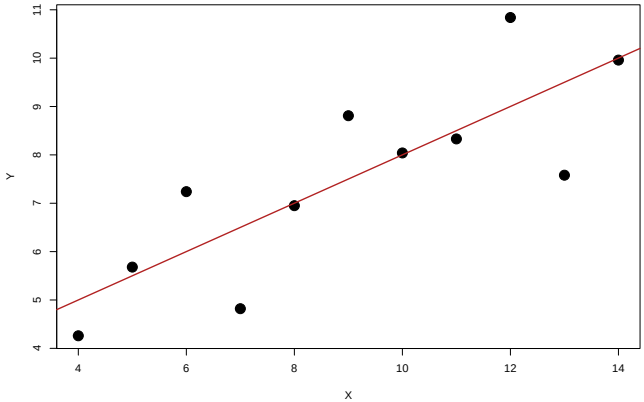


Figure 4: Una retta che passi attraverso le coppie di osservazioni

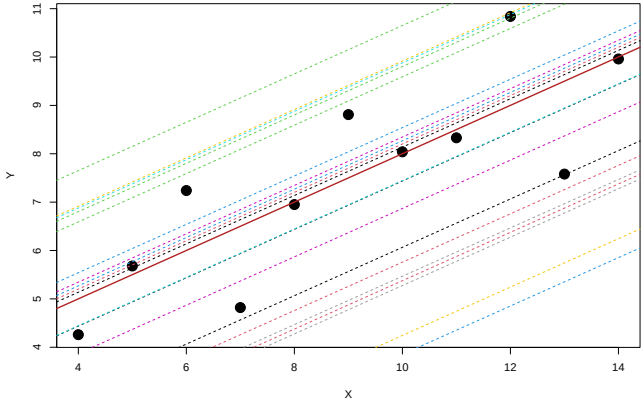


Figure 5: Ma quale retta?

Caso estremamente semplice dove varia solo l'intercetta – le rette sono parallele

La regressione lineare tra una *variabile indipendente* X (predittore) ed una *variabile dipendente* Y (criterio) calcola la migliore approssimazione lineare che identifica il legame tra le due variabili utilizzando la struttura di dati bivariata (x_i, y_i) osservata su un campione di n osservazioni.

$x = (x_1, x_2, \dots, x_n)$
$y = (y_1, y_2, \dots, y_n)$

$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

$$Y = \beta_0 + \beta X$$
$$y_i = \beta_0 + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n)$$

y_i: Valore di y osservato per l'i-esima osservazione

$y_i^* = \hat{\beta}_0 + \hat{\beta} x_i$: Valore di y atteso per l'i-esima osservazione

β_0: Valore dell'intercetta, ovvero *valore atteso in y quando $x_i = 0$*

β: Coefficiente angolare ovvero la pendenza della retta. Definisce *il cambiamento medio atteso in y per ogni cambiamento unitario in x*

ε_i: Componente d'errore, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$

1. Associazione (variabili quantitative)

2. Previsione variabili quantitative
   - Regressione lineare
   - Principio dei minimi quadrati
   - Proprietà della retta di regressione
   - Indice di adattamento R^2
   - `lm()`
   - Assunti del modello

3. Materiale supplementare

$$SQE(\beta_0, \beta) = \sum_{i=1}^{n} \big(y_i - (\beta_0 + \beta x_i)\big)^2$$

Si cercano i valori di β_0 e β che minimizzano l'SQE. Con le stime $\hat{\beta}_0$ e $\hat{\beta}$: $y_i^* = \hat{\beta}_0 + \hat{\beta} x_i$, $e_i = y_i - y_i^*$ e $\min SQE = \sum_{i=1}^{n} e_i^2$.

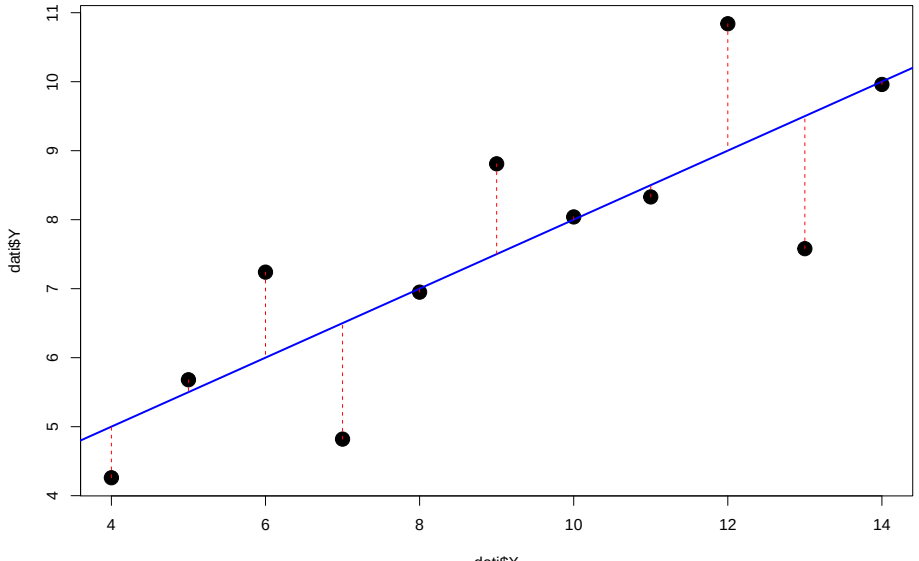
Per il principio dei minimi quadrati si può dimostrare che lo stimatore ottimale per β è

$$\hat{\beta} = \frac{\mathrm{Cov}(X, Y)}{sd(X)^2} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

mentre per β_0 è

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}\,\bar{x}$$

Principio dei minimi quadrati



1. Associazione (variabili quantitative)

2. Previsione variabili quantitative
   - Regressione lineare
   - Principio dei minimi quadrati
   - Proprietà della retta di regressione
   - Indice di adattamento R^2
   - `lm()`
   - Assunti del modello

3. Materiale supplementare

Coefficiente angolare e correlazione

$$\hat{\beta} = \frac{\mathrm{Cov}(X,Y)}{sd(X)^2} \qquad r = \frac{\mathrm{Cov}(X,Y)}{sd(X)\,sd(Y)}$$

Moltiplicando e dividendo $\hat{\beta}$ per $sd(Y)$:

$$\hat{\beta} = \frac{\mathrm{Cov}(X,Y)}{sd(X)\,sd(X)} \cdot \frac{sd(Y)}{sd(Y)} = \underbrace{\frac{\mathrm{Cov}(X,Y)}{sd(X)\,sd(Y)}}_{r} \cdot \frac{sd(Y)}{sd(X)} = r\,\frac{sd(Y)}{sd(X)}$$

1. Il **segno** del coefficiente angolare è lo stesso di r: $r > 0 \Rightarrow$ retta crescente, $r < 0 \Rightarrow$ retta decrescente, $r = 0 \Rightarrow$ retta orizzontale.
2. La retta passa sempre per il **punto delle medie** $(\bar{x}, \bar{y})$ (basta sostituire $x = \bar{x}$ in $y^* = \hat{\beta}_0 + \hat{\beta}x$).

```
b <- cov(bimbo$eta, bimbo$peso) / var(bimbo$eta)
b0 <- mean(bimbo$peso) - b * mean(bimbo$eta)
c(b0, b)
```

```
[1] 5.1477273 0.3901515
```

Retta di regressione: $y^* = 5.15 + 0.39x$

Quale sarebbe il peso previsto a 48 mesi? $y^*_{48} = 5.15 + 0.39 \cdot 48 = 23.88$ kg

1. Associazione (variabili quantitative)

2. Previsione variabili quantitative
   - Regressione lineare
   - Principio dei minimi quadrati
   - Proprietà della retta di regressione
   - Indice di adattamento R^2
   - `lm()`
   - Assunti del modello

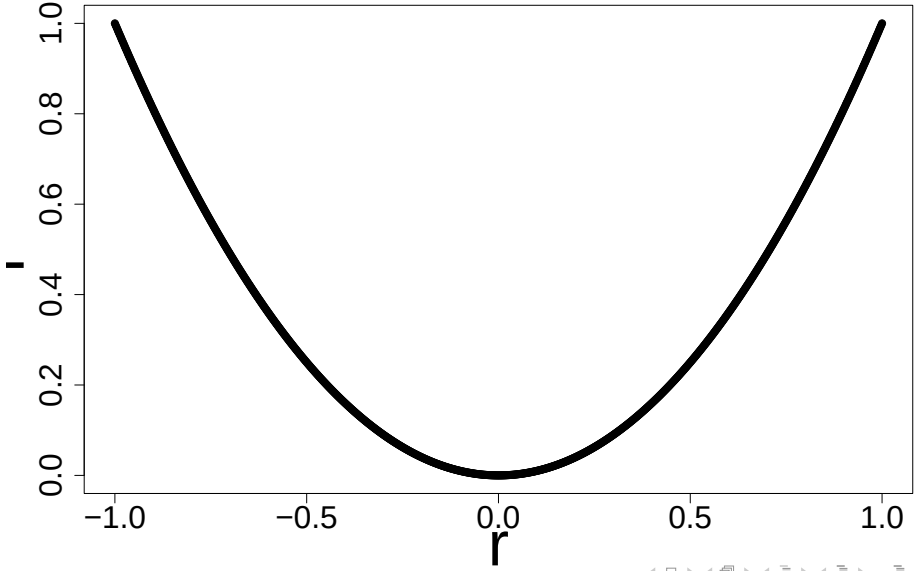
3. Materiale supplementare

$$R^2 = 1 - \frac{\frac{SQE}{n-1}}{\mathrm{Var}(Y)} = 1 - \frac{\frac{\sum_{i=1}^n e_i^2}{n-1}}{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}} = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

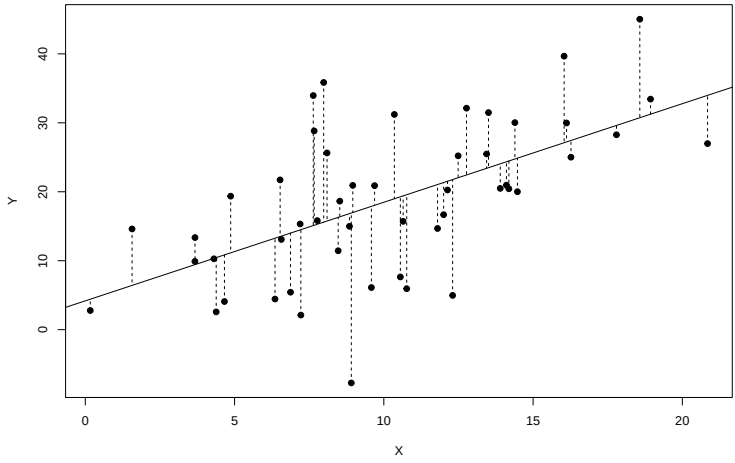
$\frac{SQE}{n-1}$: varianza dei residui. Come stima di σ^2 si usa $\hat{\sigma}^2_\varepsilon = \frac{SQE}{n-2}$ (si stimano due parametri, β_0 e β)

$0 \leq R^2 \leq 1$: Più R^2 è vicino ad 1, migliore è il modello. Di fatto, $R^2 = r^2$

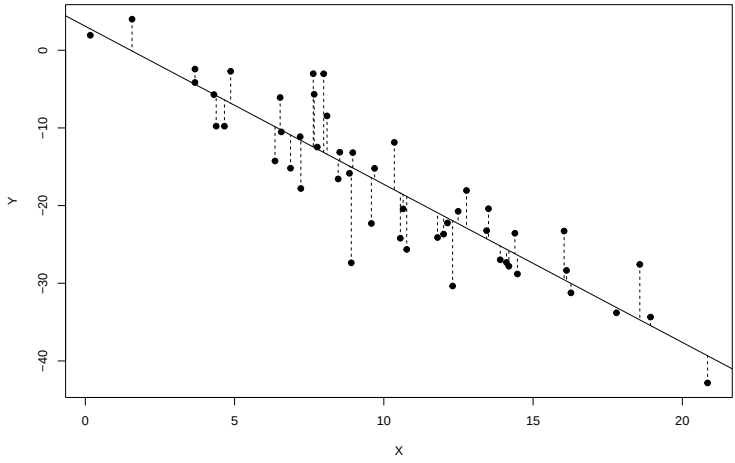
Indice di adattamento R^2



Indice di adattamento R^2

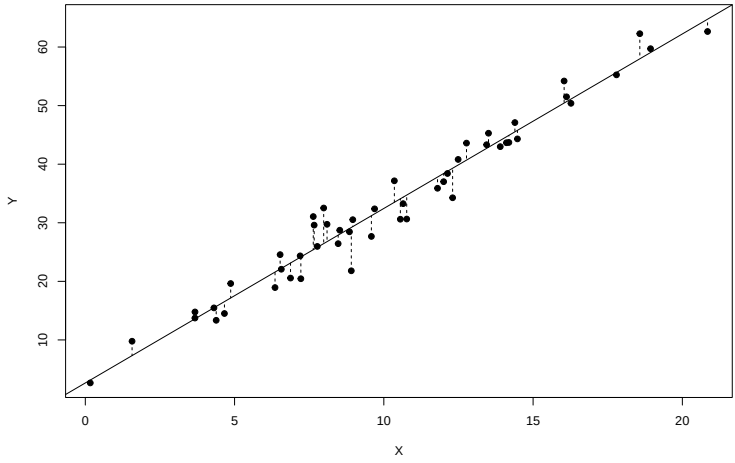


$R^2 = 0.35$, $r = 0.59$

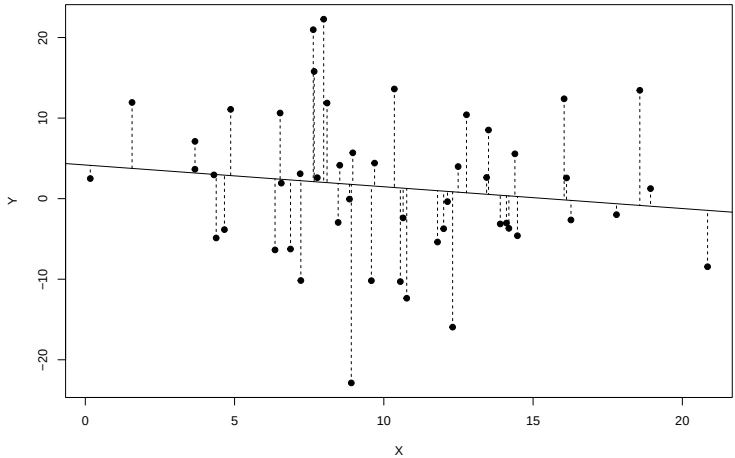


$R^2 = 0.81$, $r = -0.9$

Indice di adattamento R^2



$R^2 = 0.96$, $r = 0.98$



$R^2 = 0.02$, $r = -0.14$

1. Associazione (variabili quantitative)

2. Previsione variabili quantitative
   - Regressione lineare
   - Principio dei minimi quadrati
   - Proprietà della retta di regressione
   - Indice di adattamento R^2
   - `lm()`
   - Assunti del modello

3. Materiale supplementare

`lm(Y ~ X)`: Restituisce la stima dei parametri del modello di regressione lineare dove si predicono i valori di Y a seconda dei valori di X

~: (Per i PC con tastierino numerico): `ALT + 126`, Per i MAC: `ALT + 5`

```
lm(bimbo$peso~bimbo$eta)
```

```
Call:
lm(formula = bimbo$peso ~ bimbo$eta)

Coefficients:
(Intercept)    bimbo$eta
     5.1477       0.3902
```

1. Associazione (variabili quantitative)

2. Previsione variabili quantitative
   - Regressione lineare
   - Principio dei minimi quadrati
   - Proprietà della retta di regressione
   - Indice di adattamento R^2
   - `lm()`
   - Assunti del modello

3. Materiale supplementare

Assunzioni

- **Indipendenza dei predittori dall'errore**

  I predittori sono misurati senza errore, ovvero i predittori e gli errori di misura non sono correlati nella popolazione (per questo è importante il campionamento casuale)

- **Indipendenza delle osservazioni**

  $\forall i \neq j, \varepsilon_i \perp\!\!\!\perp \varepsilon_j$ *(le osservazioni sono state campionate indipendentemente l'una dall'altra)*

- **Linearità**

  Il valore atteso dell'errore per un dato valore di x *è 0*

Assunzioni

- **Normalità**

  $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$: *per ogni valore fissato di* x_i*, anche* y_i *è distribuita normalmente, con media* $\beta_0 + \beta x_i$ *e varianza* σ^2

$$y_i \mid x_i \sim \mathcal{N}(\beta_0 + \beta x_i, \sigma^2)$$

- **Varianza costante** (omoschedasticità)

  La varianza degli errori è costante per qualunque valore di X

Gli errori ε_i della popolazione non si osservano $\rightarrow$ si guardano i loro "rappresentanti" nel campione: i **residui** $e_i = y_i - y_i^*$

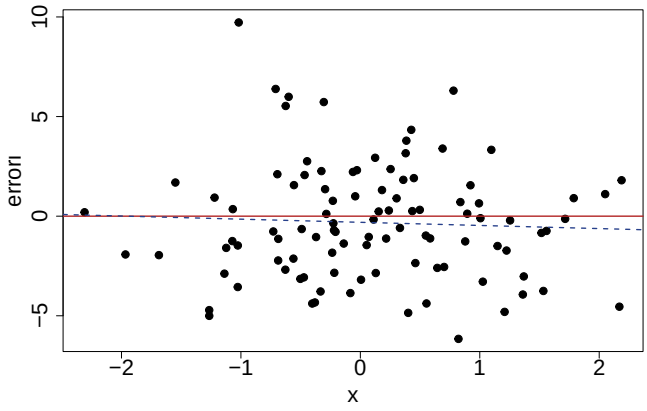
Indipendenza dei predittori dall'errore

> *I predittori sono misurati senza errore, ovvero i predittori e gli errori di misura non sono correlati nella popolazione (per questo è importante il campionamento casuale)*

Questa assunzione **non si può verificare con i residui**: per come è costruita la retta dei minimi quadrati, i residui sono sempre non correlati con il predittore, anche quando l'assunzione è violata

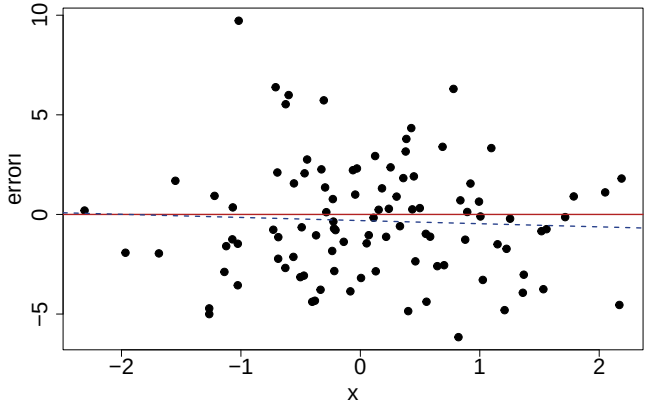
$\rightarrow$ Va garantita a monte, con il disegno dello studio (campionamento casuale, misure affidabili del predittore)

Nelle prossime slide: una simulazione, in cui gli errori veri sono noti, per capire che cosa significa l'assunzione

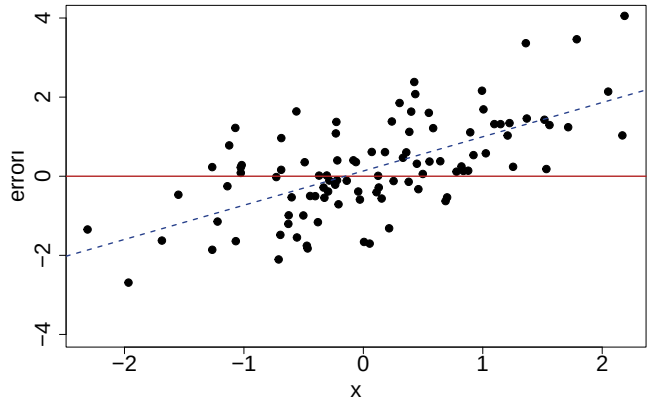


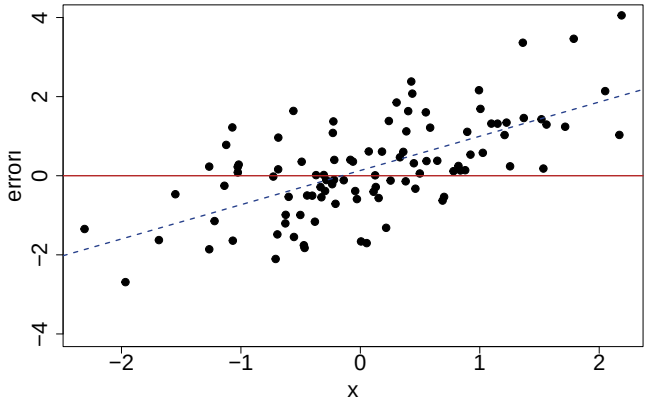
La linea intera rossa rappresenta quello che dovremmo osservare se l'assunzione è rispettata, ossia la totale assenza di relazione tra x e gli errori

La linea tratteggiata blu indica la relazione effettiva tra gli errori e il predittore x: se l'assunzione è rispettata, è molto vicina alla linea rossa



$$r = -0.05$$


errori
x
4
2
0
−2
−4
−2
−1
0
1
2



$r = 0.64$

```r
head(studio)
```

```
   ore voto
1 18.3 26.4
2 18.7 25.5
3  5.7 19.9
4 16.6 23.5
5 12.8 19.9
6 10.4 22.1
```

```r
modello <- lm(voto ~ ore, data = studio)
modello
```

```

Call:
lm(formula = voto ~ ore, data = studio)

Coefficients:
(Intercept)          ore
    14.8678       0.6243
```

I valori attesi e i residui

```
studio$attesi <- fitted(modello)      # valori attesi y*
studio$residui <- residuals(modello)  # residui y - y*
head(studio)
```

```
   ore voto   attesi    residui
1 18.3 26.4 26.29279  0.1072084
2 18.7 25.5 26.54252 -1.0425177
3  5.7 19.9 18.42642  1.4735784
4 16.6 23.5 25.23146 -1.7314560
5 12.8 19.9 22.85906 -2.9590587
6 10.4 22.1 21.36070  0.7392975
```

```
# i residui sono semplicemente osservati - attesi
head(studio$voto - studio$attesi)
```

```
[1]  0.1072084 -1.0425177  1.4735784 -1.7314560 -2.9590587  0.7392975
```

Normalità degli errori

La media dei residui è (sempre) 0:

```
mean(studio$residui)
```

```
[1] -2.791617e-17
```

I residui dovrebbero distribuirsi in modo simmetrico attorno allo 0: la mediana deve essere il più vicina possibile a 0, il minimo e il massimo (così come il primo e il terzo quartile) dovrebbero essere simili in valore assoluto

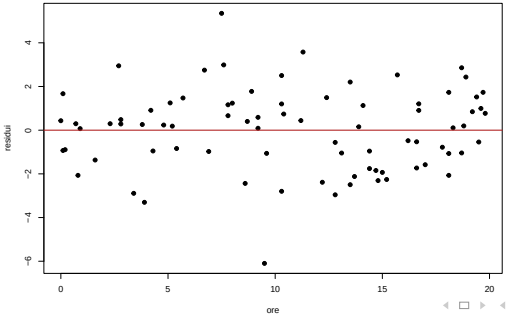
```
summary(studio$residui)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-6.0988 -1.0629  0.2153  0.0000  1.2028  5.3498
```

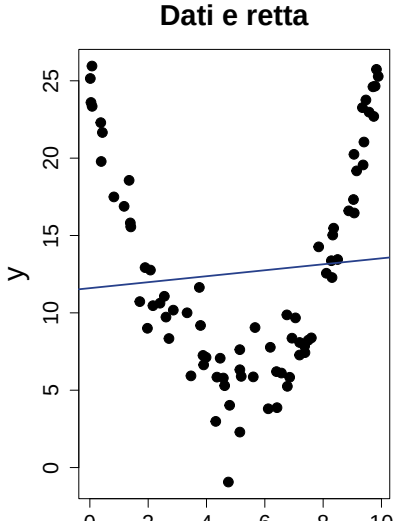
Residui vs predittore

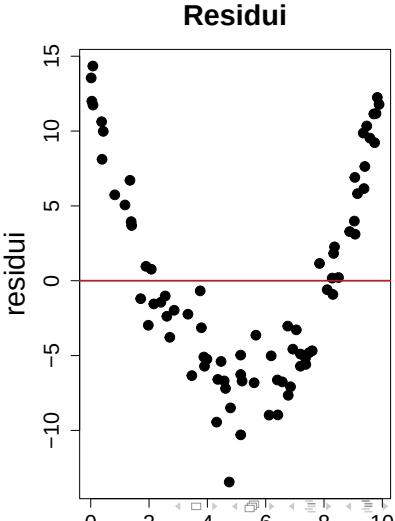
Se la relazione è lineare, i residui si distribuiscono **casualmente** attorno allo 0, senza alcun andamento

```
plot(studio$ore, studio$residui, pch = 19,
     xlab = "ore", ylab = "residui")
abline(h = 0, col = "firebrick", lwd = 2)
```



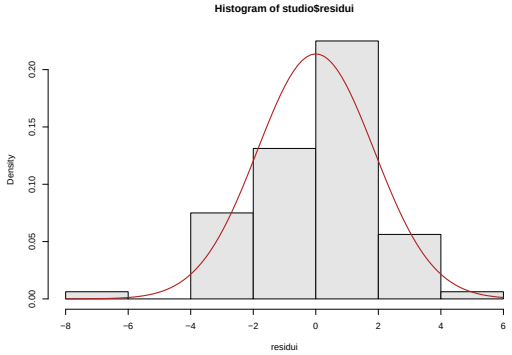
Quando la relazione non è lineare





Istogramma dei residui

```
hist(studio$residui, freq = FALSE, xlab = "residui", col = "gray90")
curve(dnorm(x, mean = 0, sd = sd(studio$residui)),
      add = TRUE, col = "firebrick", lwd = 2)
```

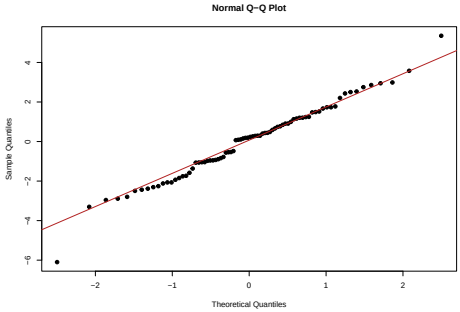


La linea rossa è la distribuzione normale con media 0 e sd pari a quella dei residui

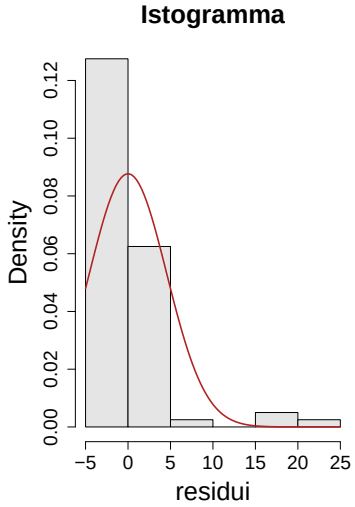
Q-Q plot dei residui

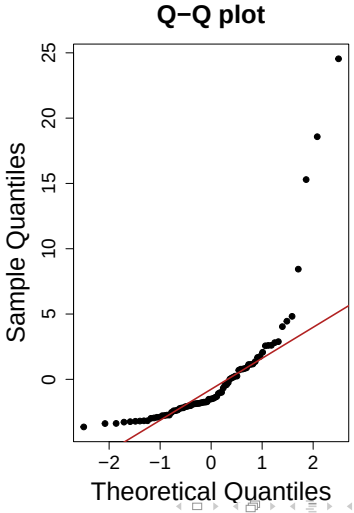
Confronta i quantili dei residui con quelli di una distribuzione normale: se i residui sono normali, i punti stanno **sulla retta**

```
qqnorm(studio$residui, pch = 19)
qqline(studio$residui, col = "firebrick", lwd = 2)
```



Quando i residui non sono normali

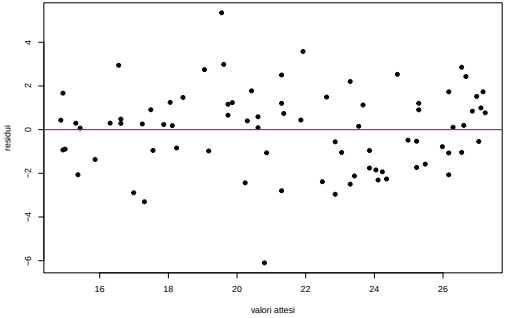


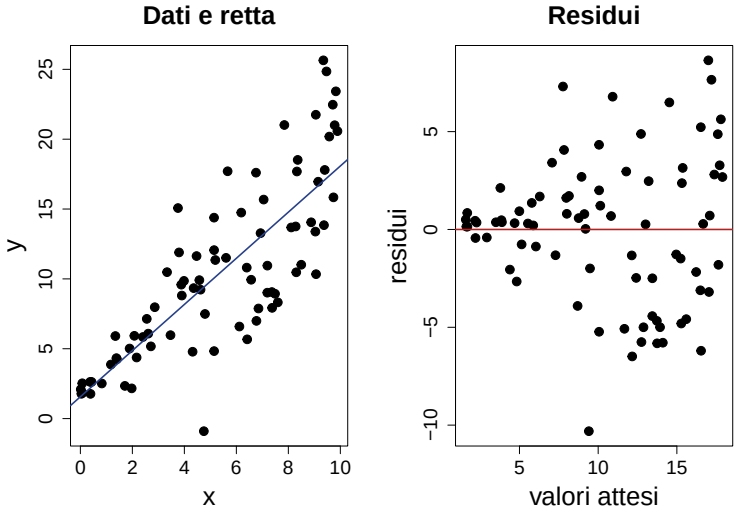


Omoschedasticità

La variabilità dei residui deve essere **costante** per tutti i valori attesi: la "nuvola" deve avere la stessa ampiezza da sinistra a destra

```
plot(studio$attesi, studio$residui, pch = 19,
     xlab = "valori attesi", ylab = "residui")
abline(h = 0, col = "firebrick", lwd = 2)
```





Forma "a imbuto": i residui sono sempre più dispersi al crescere dei valori attesi $\rightarrow$ eteroschedasticità

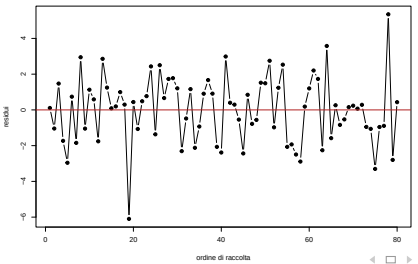
Indipendenza delle osservazioni

Dipende soprattutto da **come sono stati raccolti i dati**: ogni osservazione deve essere indipendente dalle altre

Esempi di violazione: misure ripetute sulla stessa persona, studenti della stessa classe, dati raccolti nel tempo

Se i dati hanno un ordine (es. ordine di raccolta), si possono guardare i residui in quell'ordine: non deve esserci nessun andamento

```
plot(studio$residui, type = "b", pch = 19,
     xlab = "ordine di raccolta", ylab = "residui")
abline(h = 0, col = "firebrick", lwd = 2)
```



Cosa guardare nei residui

Assunto	Grafico	Cosa si deve vedere
Linearità	`plot(x, residui)`	Nuvola casuale attorno a 0
Normalità	`hist(residui)`, `qqnorm(residui)`	Forma a campana, punti sulla retta
Omoschedasticità	`plot(attesi, residui)`	Ampiezza costante (niente imbuti)
Indipendenza	`plot(residui, type = "b")`	Nessun andamento nell'ordine

Tutto parte da due funzioni:

```
attesi <- fitted(modello)
residui <- residuals(modello)
```

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

3 Materiale supplementare

1. Associazione (variabili quantitative)

2. Previsione variabili quantitative

3. Materiale supplementare
   - Outliers e casi influenti
   - Leverage e distanza di Cook

Definizioni

Outlier: Il valore di un'osservazione nella variabile dipendente è anomalo dato il valore del predittore (ha un residuo molto grande)

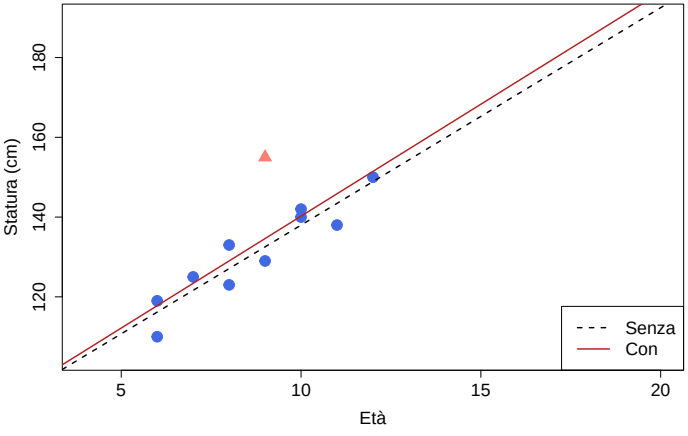
Leverage (leva): Quanto il valore di un'osservazione nel predittore è lontano dalla media del predittore $\rightarrow$ quanto *potenzialmente* può spostare la retta

Influential case: Una singola osservazione che riesce a spostare l'intera retta di regressione

Un'osservazione può essere:

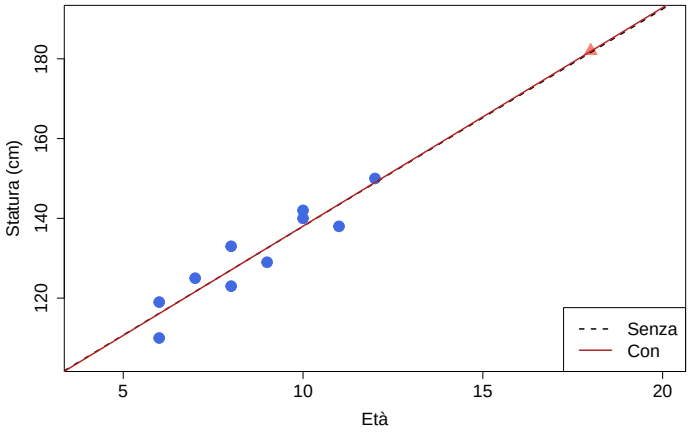
- Un outlier (ma non un influential case)
- Un punto ad alta leva in linea con gli altri (ma non un influential case)
- Un outlier influente (anomalo **e** ad alta leva)

Un outlier living the life



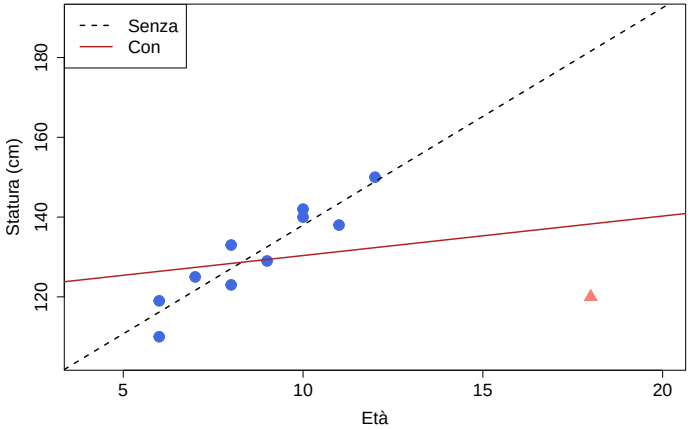
Il triangolo rosa è un outlier: è anomalo rispetto alla nuvola di punti, ma essendo vicino alla media dell'età sposta la retta di poco (soprattutto in alto, l'intercetta)

Un punto ad alta leva living the life



Il triangolo rosa è lontano dagli altri sull'asse delle x (alta leva), ma è in linea con l'andamento dei dati: la retta non cambia

Un outlier influential case living the life



Il triangolo rosa è anomalo **e** lontano dagli altri sull'asse delle x: ne sposta drasticamente la pendenza

1. Associazione (variabili quantitative)

2. Previsione variabili quantitative

3. Materiale supplementare
   - Outliers e casi influenti
   - Leverage e distanza di Cook

Tirare fuori leverage e distanza di Cook

Come per i residui, anche gli indici di influenza si estraggono dal modello e si guardano

`hatvalues()`: leverage di ogni osservazione

`cooks.distance()`: distanza di Cook → quanto cambiano *tutti* i valori attesi se l'osservazione viene tolta (combina residuo e leverage)

```
influente <- rbind(dat, c(soggetto = 11, eta = 18, statura = 120))
mod_inf <- lm(statura ~ eta, data = influente)
influente$leva <- hatvalues(mod_inf)
influente$cook <- cooks.distance(mod_inf)
```

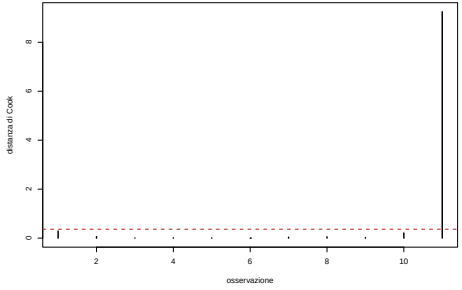
```
round(influente, 2)
```

```
   soggetto eta statura leva cook
1         1   6     110 0.20 0.29
2         2   6     119 0.20 0.06
3         3   7     125 0.15 0.00
4         4   8     123 0.11 0.01
5         5   8     133 0.11 0.01
6         6   9     129 0.09 0.00
7         7  10     140 0.09 0.04
8         8  10     142 0.09 0.05
9         9  11     138 0.11 0.02
10       10  12     150 0.14 0.21
11       11  18     120 0.70 9.25
```

Il grafico della distanza di Cook

Una soglia spesso usata: $D_i > 4/n$

```
plot(influente$cook, type = "h", lwd = 3,
     xlab = "osservazione", ylab = "distanza di Cook")
abline(h = 4 / nrow(influente), col = "firebrick", lty = 2, lwd = 2)
```




```
which(influente$cook > 4 / nrow(influente))
```