# Modulo Didattico 3: Statistiche descrittive per la misura di associazione tra due variabili - Variabili quantitative

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

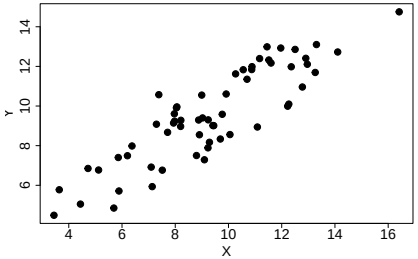
A.A. 2026/2027

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova $r$
2. Previsione variabili quantitative
3. Materiale supplementare

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova $r$
2. Previsione variabili quantitative
3. Materiale supplementare

Si vuole studiare la **relazione lineare** tra due variabili quantitative $X$ e $Y$ misurate sulle stesse unità statistiche

Per relazione lineare si intende quanto le coppie di punti $(x_i, y_i)$ tendono a disporsi lungo una retta




Due indici: la **covarianza** (direzione della relazione) e il **coefficiente di correlazione lineare di Bravais-Pearson** (direzione e intensità)

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova $r$
2. Previsione variabili quantitative
3. Materiale supplementare

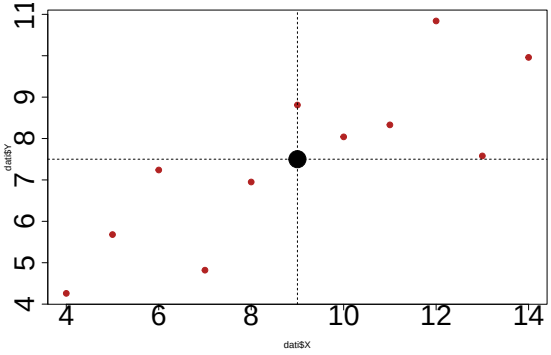
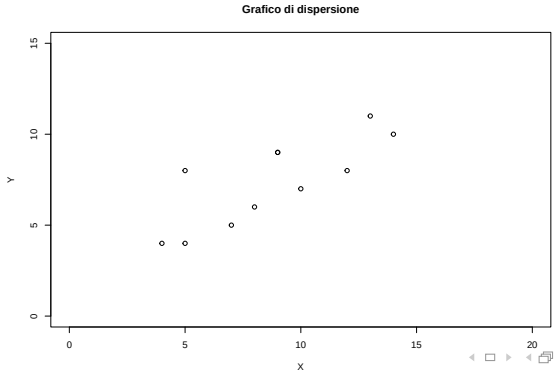



Figure 1: Grafico a dispersione delle variabili X e Y

| | X | Y |
|---|---|---|
| 1 | 10 | 8.04 |
| 2 | 8 | 6.95 |
| 3 | 13 | 7.58 |
| 4 | 9 | 8.81 |
| 5 | 11 | 8.33 |
| 6 | 14 | 9.96 |
| 7 | 6 | 7.24 |
| 8 | 4 | 4.26 |
| 9 | 12 | 10.84 |
| 10 | 7 | 4.82 |
| 11 | 5 | 5.68 |

`plot(x, y)`: Grafico di dispersione di due variabili quantitative appaiate `(x,y)` aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
plot(X,Y,main="Grafico di dispersione", xlim=c(0,20),ylim=c(0,15))
```



La **Covarianza** misura il grado di *dispersione* e *covariazione* di due variabili quantitative appaiate $(X, Y)$ attorno ai loro baricentri (medie) $\bar{X}$ e $\bar{Y}$

$x = (x_1, x_2, \dots, x_n)$
$y = (y_1, y_2, \dots, y_n)$

$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

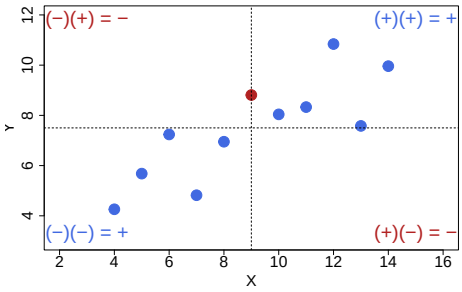
$$\mathrm{Cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

È (quasi) la **media dei prodotti degli scarti** di ogni variabile dalla propria media

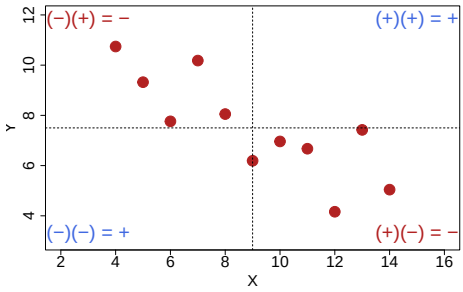
Note

Nota: alcuni testi dividono per $n$ invece che per $n-1$ (covarianza "descrittiva"). La funzione `cov()` di `R` divide per $n-1$, quindi useremo sempre questa versione

$\mathrm{Cov}(X, Y) > 0$



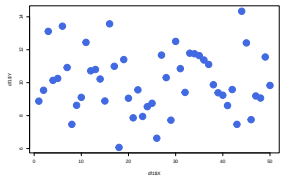

$\mathrm{Cov}(X, Y) < 0$



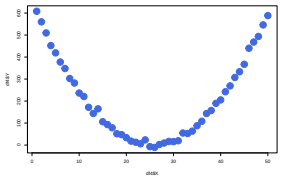

Il prodotto $(x_i - \bar{x})(y_i - \bar{y})$ è più spesso positivo se $\mathrm{Cov} > 0$, più spesso negativo se $\mathrm{Cov} < 0$

- La covarianza può assumere **tutti i valori reali**
- $\mathrm{Cov}(X, Y) > 0$: tendenza alla linearità positiva (**crescente**)
- $\mathrm{Cov}(X, Y) < 0$: tendenza alla linearità negativa (**decrescente**)
- $\mathrm{Cov}(X, Y) \approx 0$: nessuna tendenza lineare

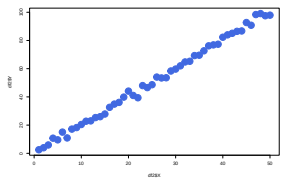
Il valore della covarianza dipende dall'unità di misura delle variabili $\rightarrow$ ci dice la **direzione** della relazione ma non la sua **intensità**.



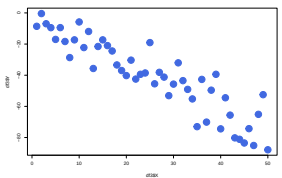
(a) Cov $= 0$



(b) Cov $= 0$



(c) Cov $> 0$



(d) Cov $< 0$

Figure 2: Covarianza

Età (in mesi) e peso (in kg) di un bambino rilevati in 6 momenti

| | eta | peso |
|---|---|---|
| 1 | 3 | 6 |
| 2 | 6 | 8 |
| 3 | 9 | 9 |
| 4 | 12 | 10 |
| 5 | 24 | 13 |
| 6 | 36 | 20 |

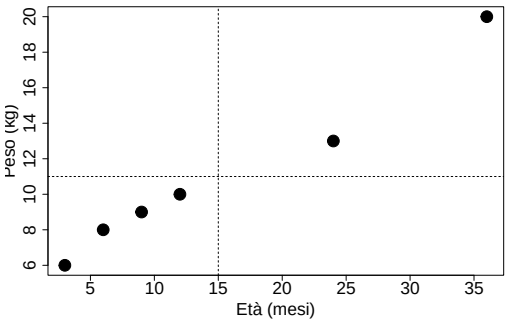



Figure 3: Grafico a dispersione

# Calcolo della covarianza

| | x | y | x - media(x) | y - media(y) | prodotto |
|---|---|---|---|---|---|
| 1 | 3 | 6 | -12 | -5 | 60 |
| 2 | 6 | 8 | -9 | -3 | 27 |
| 3 | 9 | 9 | -6 | -2 | 12 |
| 4 | 12 | 10 | -3 | -1 | 3 |
| 5 | 24 | 13 | 9 | 2 | 18 |
| 6 | 36 | 20 | 21 | 9 | 189 |

$\bar{x} = 15$, $\bar{y} = 11$, $\sum_i (x_i - \bar{x})(y_i - \bar{y}) = 309$

$$\mathrm{Cov}(x, y) = \frac{309}{6 - 1} = 61.8$$

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova $r$
2. Previsione variabili quantitative
3. Materiale supplementare

cov(): Restituisce la covarianza campionaria tra due variabili quantitative appaiate $(X, Y)$ aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
Z <- -Y
cov(X,Y)
```

```
[1] 6.309091
```

```
cov(X,Z)
```

```
[1] -6.309091
```

```
cov(bimbo$eta, bimbo$peso)
```

```
[1] 61.8
```

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova $r$
2. Previsione variabili quantitative
3. Materiale supplementare

Per stabilire l'**intensità** della relazione la covarianza va *normalizzata*, ovvero divisa per il suo valore massimo:

$$-sd(x)sd(y) \leq \mathrm{Cov}(X,Y) \leq +sd(x)sd(y)$$

$$r = \frac{\mathrm{Cov}(X,Y)}{sd(x)sd(y)}$$

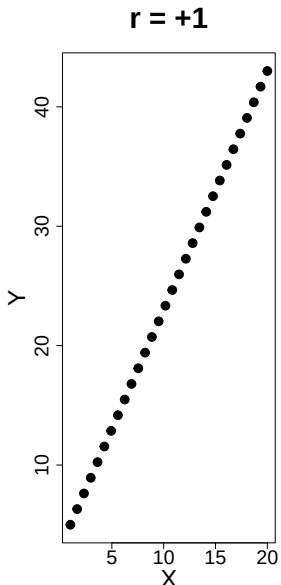
$$-1 \leq r \leq 1$$

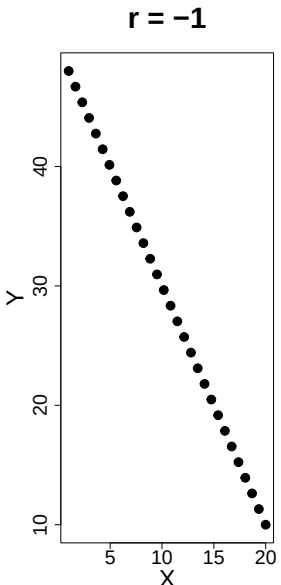
$r = +1$: legame **perfettamente lineare e diretto**;

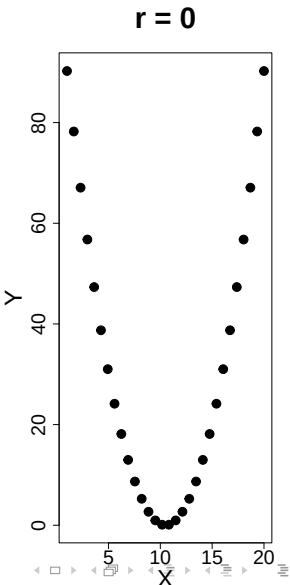
$r = -1$: legame **perfettamente lineare e inverso**

$r = 0$: **incorrelazione**: non esiste un legame *lineare*... ma questo non implica che le variabili non siano in relazione tra loro

https://app.wooclap.com/IROOIDS?from=instruction-slide


r = +1
Y
X
10
20
30
40
5
10
15
20


r = −1
Y
X
10
20
30
40
5
10
15
20


r = 0
Y
X
0
20
40
60
80
5
10
15
20

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova $r$
2. Previsione variabili quantitative
3. Materiale supplementare

`cor()`: Restituisce la correlazione (lineare) campionaria tra due variabili quantitative appaiate $(X, Y)$ aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
Z <- -Y
cor(X,Y)
```

```
[1] 0.7921487
```

```
cor(X,Z)
```

```
[1] -0.7921487
```

# Il bambino di prima

```
cov(bimbo$eta, bimbo$peso) / (sd(bimbo$eta) * sd(bimbo$peso))
```

```
[1] 0.9860185
```

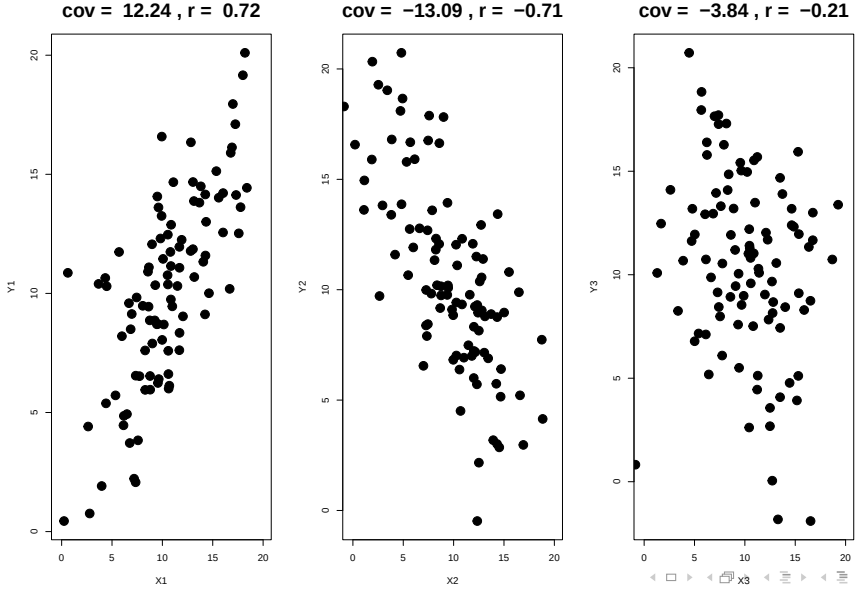
```
cor(bimbo$eta, bimbo$peso)
```

```
[1] 0.9860185
```

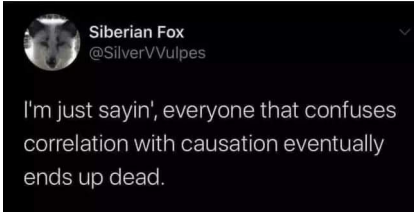
$$r = \frac{61.8}{12.59 \cdot 4.98} = 0.986$$

Le variabili presentano una **fortissima correlazione positiva**: i punti tendono a disporsi lungo una retta crescente

cor()


cov = 12.24 , r = 0.72
cov = −13.09 , r = −0.71
cov = −3.84 , r = −0.21
Y1
X1
Y2
X2
Y3
X3
0
5
10
15
20

`cor()`


Siberian Fox
@SilverVVulpes
I'm just sayin', everyone that confuses correlation with causation eventually ends up dead.

1. Associazione (variabili quantitative)
   - Relazione lineare
   - Indice di covarianza campionaria
   - `cov()`
   - Correlazione campionaria
   - `cor()`
   - Dove si trova $r$
2. Previsione variabili quantitative
3. Materiale supplementare

- Attendibilità test-retest
- Forme parallele di un test (coefficiente di equivalenza)
- Accordo tra le valutazioni di due giudici
- Consistenza interna di un questionario
- ...

# Statistics doesn't lie, but liars use statistics

Due variabili possono essere fortemente correlate senza che esista alcun legame tra di loro

https://www.tylervigen.com/spurious-correlations

**Correlazione $\neq$ causalità**

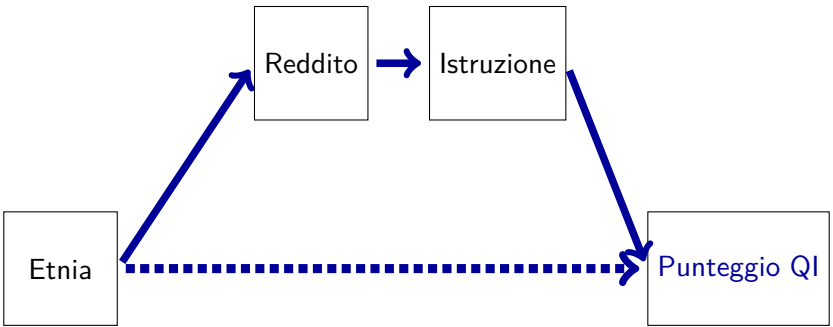
*L'ignoranza afferma o nega rotondamente; la scienza dubita* (Voltaire)

# Relazione diretta



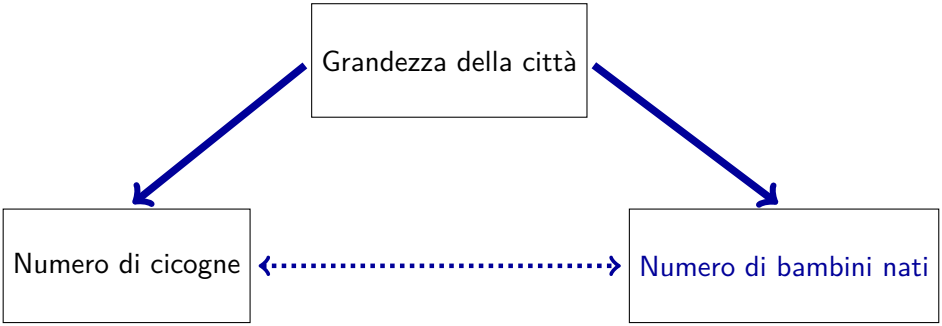

$X$ influenza $Y$ senza che intervengano altre variabili.

# Relazione indiretta




La relazione tra $X$ e $Y$ passa attraverso altre variabili (mediatori).

# Relazione spuria




$X$ e $Y$ sono correlate solo perché entrambe dipendono da una terza variabile.

1. Associazione (variabili quantitative)

2. Previsione variabili quantitative
   - Regressione lineare
   - Principio dei minimi quadrati
   - Proprietà della retta di regressione
   - Indice di adattamento $R^2$
   - `lm()`
   - Assunti del modello

3. Materiale supplementare

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative
- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento $R^2$
- `lm()`
- Assunti del modello

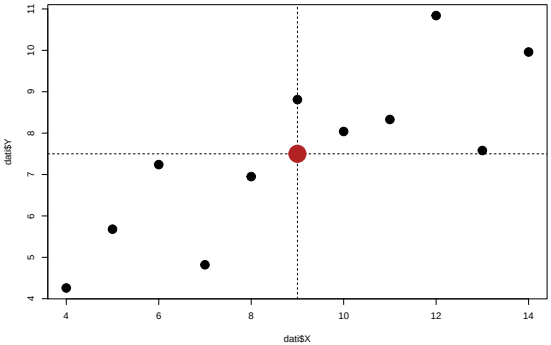
3 Materiale supplementare

# Quanto varia $y$ in funzione di $x$?

La correlazione permette di stabilire quanto covariano due variabili, $x$ e $y$: **modello simmetrico** per determinare *l'intensità della relazione*.

Con un modello di regressione si vuole andare più a fondo per capire **quanto** varia $y$ in funzione di ogni cambiamento in $x$: stabilire non solo se le variabili sono associate o meno ma la portata della variazione.

La relazione è *asimettrica*: si vuole spiegare $y$ in funzione di $x$ (questo non vuol dire in alcun modo che la relazione sia causale).




| | X | Y |
|---|---|---|
| 1 | 10 | 8.04 |
| 2 | 8 | 6.95 |
| 3 | 13 | 7.58 |
| 4 | 9 | 8.81 |
| 5 | 11 | 8.33 |
| 6 | 14 | 9.96 |
| 7 | 6 | 7.24 |
| 8 | 4 | 4.26 |
| 9 | 12 | 10.84 |
| 10 | 7 | 4.82 |
| 11 | 5 | 5.68 |

$$r = 0.79$$

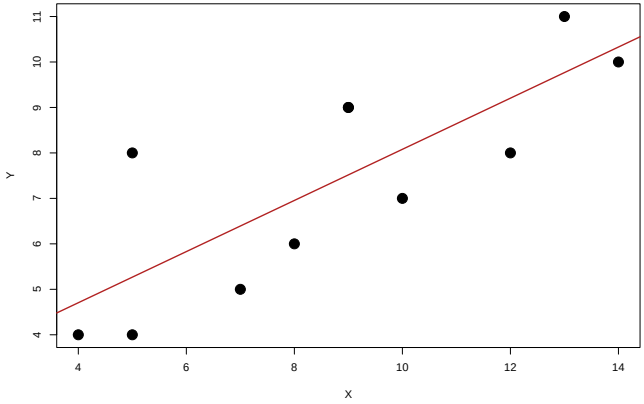



Figure 4: Una retta che passi attraverso le coppie di osservazioni

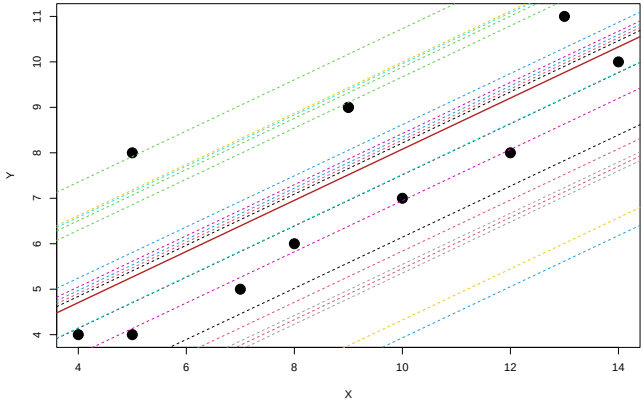



Figure 5: Ma quale retta?

Caso estremamente semplice dove varia solo l'intercetta – le rette sono parallele

La regressione lineare tra una *variabile indipendente* $X$ (predittore) ed una *variabile dipendente* $Y$ (criterio) calcola la migliore approssimazione lineare che identifica il legame tra le due variabili utilizzando la struttura di dati bivariata $(x_i, y_i)$ osservata su un campione di $n$ osservazioni.

$x = (x_1, x_2, \dots, x_n)$
$y = (y_1, y_2, \dots, y_n)$

$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

$$Y = \beta_0 + \beta X$$

$$y_i = \beta_0 + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n)$$

$y_i$: Valore di $y$ atteso per l'i-esima osservazione

$\beta_0$: Valore dell'intercetta, ovvero *valore atteso in y quando* $x_i = 0$

$\beta_1$: Coefficiente angolare ovvero la pendenza della retta. Definisce *il cambiamento medio atteso in y per ogni cambiamento unitario in* $x$

$\varepsilon_i$: Componente d'errore ($\mathcal{N}(0, \sigma^2)$)

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative
- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento $R^2$
- `lm()`
- Assunti del modello

3 Materiale supplementare

$$SQE = \sum_{i=1}^{n}(y_i - y_i^*)^2 = \sum_{i=1}^{n}\left(y_i - (\beta_0 + \beta x_i)\right)^2 = \sum_{i=1}^{n} e_i^2$$

dove $y_i^* = \beta_0 + \beta x_i$, e $e_i = y_i - y_i^*$.

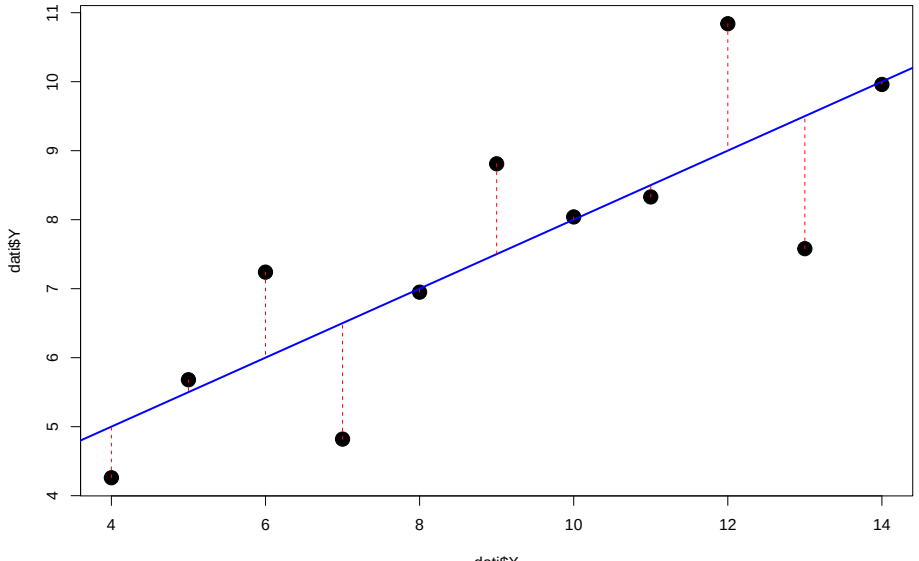
Per il principio dei minimi quadrati si può dimostrare che lo stimatore ottimale per $\beta$ è

$$\hat{\beta} = \frac{\mathrm{Cov}(X,Y)}{\mathrm{Var}(X)} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

mentre per $\beta_0$ è

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}\,\bar{x}$$

Principio dei minimi quadrati



1 Associazione (variabili quantitative)

2 Previsione variabili quantitative
- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento $R^2$
- `lm()`
- Assunti del modello

3 Materiale supplementare

# Coefficiente angolare e correlazione

$$\hat{\beta} = \frac{\text{Cov}(X,Y)}{sd(x)^2} \qquad r = \frac{\text{Cov}(X,Y)}{sd(x)sd(y)}$$

Moltiplicando e dividendo $\hat{\beta}$ per $sd(y)$:

$$\hat{\beta} = \frac{\text{Cov}(X,Y)}{sd(x)\,sd(x)} \cdot \frac{sd(y)}{sd(y)} = \underbrace{\frac{\text{Cov}(X,Y)}{sd(x)\,sd(y)}}_{r} \cdot \frac{sd(y)}{sd(x)} = r\,\frac{sd(y)}{sd(x)}$$

1. Il **segno** del coefficiente angolare è lo stesso di $r$: $r > 0 \Rightarrow$ retta crescente, $r < 0 \Rightarrow$ retta decrescente, $r = 0 \Rightarrow$ retta orizzontale.
2. La retta passa sempre per il **punto delle medie** $(\bar{x}, \bar{y})$ (basta sostituire $x = \bar{x}$ in $y^* = \hat{\beta}_0 + \hat{\beta}x$).

```
b <- cov(bimbo$eta, bimbo$peso) / var(bimbo$eta)
b0 <- mean(bimbo$peso) - b * mean(bimbo$eta)
c(b0, b)
```

```
[1] 5.1477273 0.3901515
```

Retta di regressione: $y^* = 5.15 + 0.39x$

Quale sarebbe il peso previsto a 48 mesi? $y^*_{48} = 5.15 + 0.39 \cdot 48 = 23.88$ kg

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative
- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento $R^2$
- `lm()`
- Assunti del modello

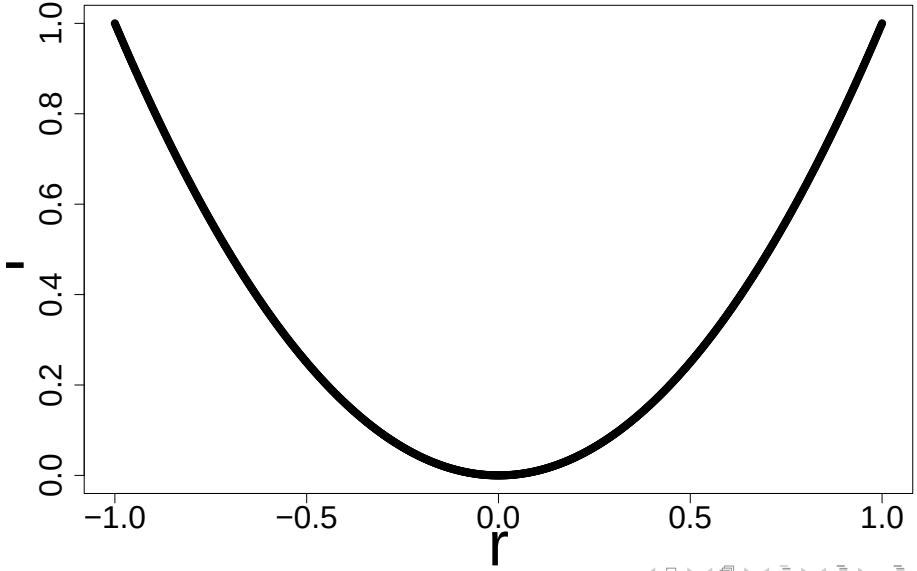
3 Materiale supplementare

$$R^2 = 1 - \frac{\frac{SQE}{n-1}}{Var(Y)} = 1 - \frac{\frac{\sum_{i=1}^{n} e_i^2}{n-1}}{\frac{\sum_{i=1}^{n}(y_i - \bar{y})^2}{n-1}} = 1 - \frac{\sum_{i=1}^{n} e_i^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

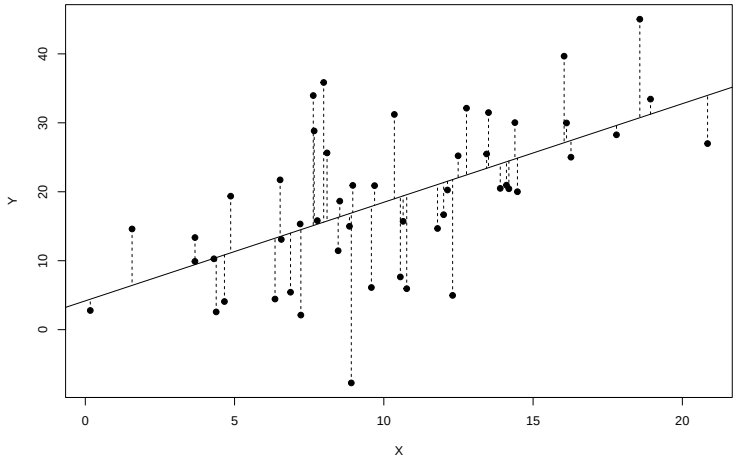
$\varepsilon = \frac{SQE}{n-1}$: Stimatore campionario della varianza della componente di errore

$0 \leq R^2 \leq 1$: Più $R^2$ è vicino ad 1, migliore è il modello. Di fatto, $R^2 = r^2$

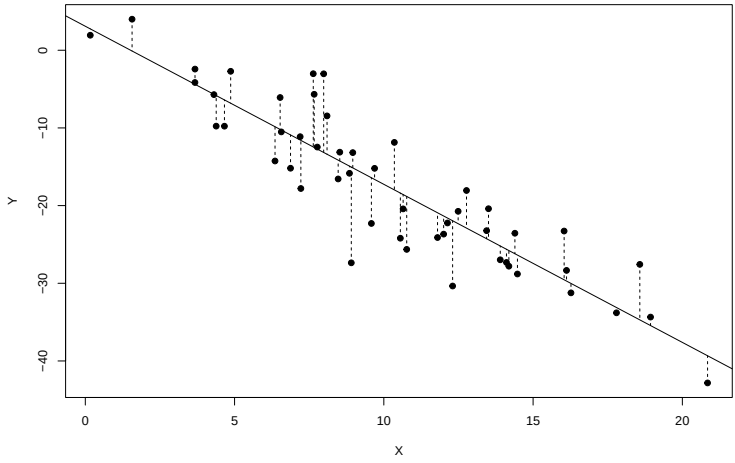
Indice di adattamento $R^2$



Indice di adattamento $R^2$

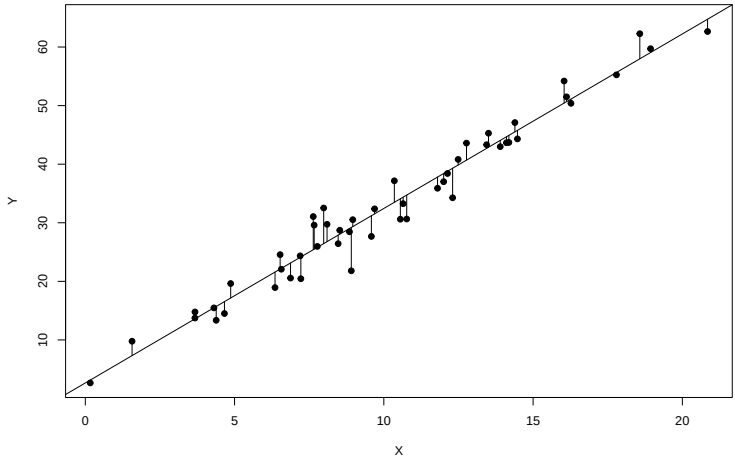



$R^2 = 0.34$, $r = 0.59$

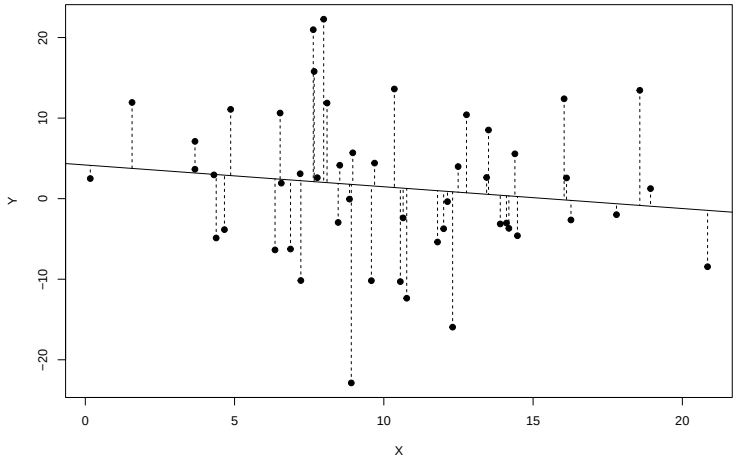



$R^2 = 0.81$, $r = -0.9$

Indice di adattamento $R^2$




$R^2 = 0.96$, $r = 0.98$




$R^2 = 0$, $r = -0.14$

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative
- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento $R^2$
- `lm()`
- Assunti del modello

3 Materiale supplementare

`lm(Y ~ X)`: Retituisce la stima dei parametri del modello di regressione lineare dove si predicono i valori di $Y$ a seconda dei valori di $X$

~: (Per i PC con tastierino numerico): `ALT + 126`, Per i MAC: `ALT + 5`

```
lm(bimbo$peso~bimbo$eta)
```

```
Call:
lm(formula = bimbo$peso ~ bimbo$eta)

Coefficients:
(Intercept)    bimbo$eta
     5.1477       0.3902
```

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative
- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento $R^2$
- `lm()`
- Assunti del modello

3 Materiale supplementare

# Assunzioni

- **Indipendenza dei predittori dall'errore**

  *I predittori sono misurati senza errore, ovvero i predittori e gli errori di misura non sono correlati nella popolazione (per questo è importante il campionamento casuale)*

- **Indipendenza delle osservazioni**

  $\forall i \neq j, \varepsilon_i \perp\!\!\!\perp \varepsilon_j$ *(le osservazioni sono state campionate indipendentemente l'una dall'altra)*

- **Linearità**

  *Il valore atteso dell'errore per un dato valore di* $x$ *è 0*

# Assunzioni

- **Normalità**

  $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$: *per ogni valore fissato di* $x_i$*, anche* $y_i$ *è distribuita normalmente, con media* $\beta_0 + \beta_1 x_i$ *e varianza* $\sigma^2$

$$y_i \mid x_i \sim \mathcal{N}(\beta_0 + \beta_1 x_i,\, \sigma^2)$$

- **Varianza costante** (omoschedasticità)

  *La varianza degli errori è costante per qualunque valore di* $X$

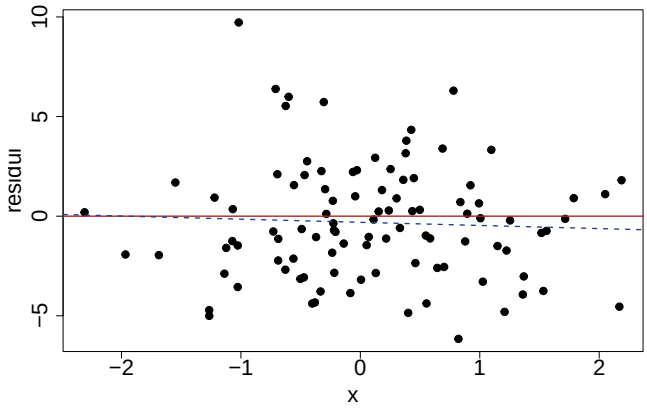
Gli errori $\varepsilon_i$ della popolazione non si osservano $\rightarrow$ si guardano i loro "rappresentanti" nel campione: i **residui** $e_i = y_i - y_i^*$

**Indipendenza dei predittori dall'errore**

*I predittori sono misurati senza errore, ovvero i predittori e gli errori di misura non sono correlati nella popolazione (per questo è importante il campionamento casuale)*

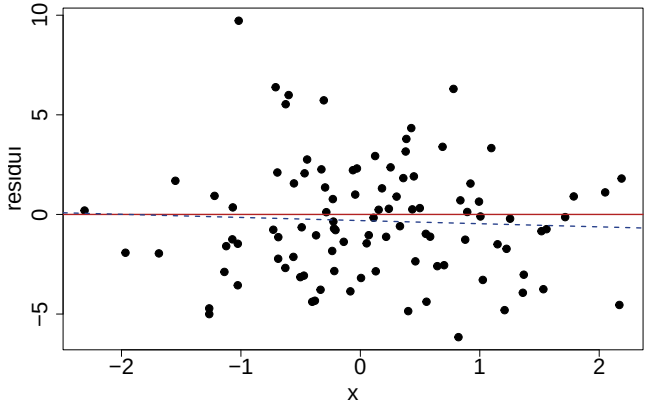
*Analisi dei residui*

I residui e il predittore **non devono essere correlati tra di loro**

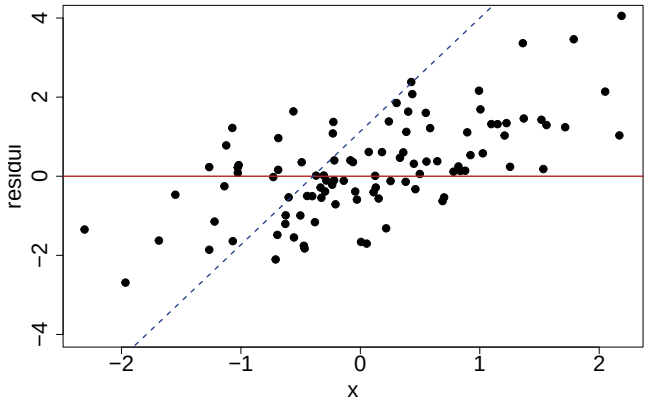


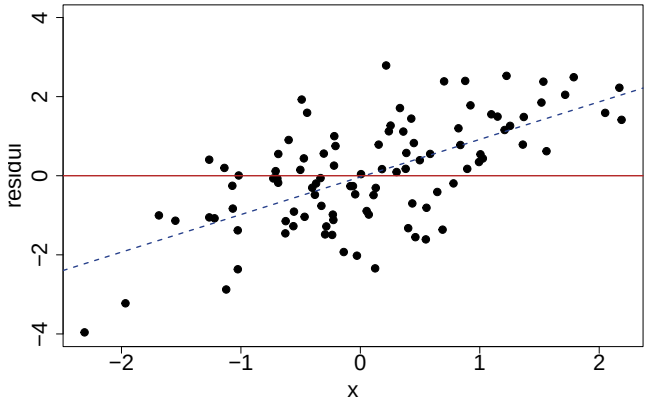

La linea intera rossa rappresenta quello che dovremmo osservare, ossia la totale assenza di relazione tra la $x$ e i residui del modello

Le linea tratteggiata blu indica la relazione effettiva tra i residui e il predittore $x$.
Questa linea deve essere il più vicina possibile alla linea rossa




$$r = -0.05$$


residui
x
4
2
0
−2
−4
−2
−1
0
1
2




$r = 0.64$

```r
head(studio)
```

```
   ore voto
1 18.3 26.4
2 18.7 25.5
3  5.7 19.9
4 16.6 23.5
5 12.8 19.9
6 10.4 22.1
```

```r
modello <- lm(voto ~ ore, data = studio)
modello
```

```

Call:
lm(formula = voto ~ ore, data = studio)

Coefficients:
(Intercept)          ore
    14.8678       0.6243
```

# I valori attesi e i residui

```
studio$attesi <- fitted(modello)      # y cappello
studio$residui <- residuals(modello)  # y - y cappello
head(studio)
```

```
   ore voto   attesi    residui
1 18.3 26.4 26.29279  0.1072084
2 18.7 25.5 26.54252 -1.0425177
3  5.7 19.9 18.42642  1.4735784
4 16.6 23.5 25.23146 -1.7314560
5 12.8 19.9 22.85906 -2.9590587
6 10.4 22.1 21.36070  0.7392975
```

```
# i residui sono semplicemente osservati - attesi
head(studio$voto - studio$attesi)
```

```
[1]  0.1072084 -1.0425177  1.4735784 -1.7314560 -2.9590587  0.7392975
```

# Normalità degli errori

La media dei residui è (sempre) 0:

```
mean(studio$residui)
```

```
[1] -2.791617e-17
```

I residui dovrebbero distribuirsi in modo simmetrico attorno allo 0: la mediana deve essere il più vicina possibile a 0, il minimo e il massimo (così come il primo e il terzo quartile) dovrebbero essere simili in valore assoluto

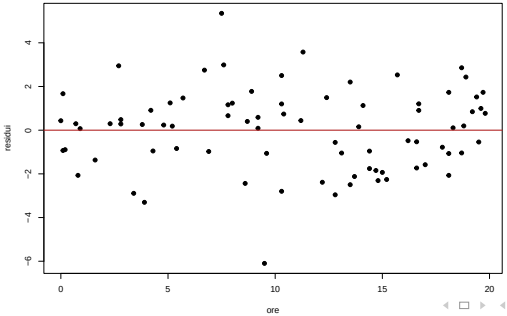
```
summary(studio$residui)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-6.0988 -1.0629  0.2153  0.0000  1.2028  5.3498
```

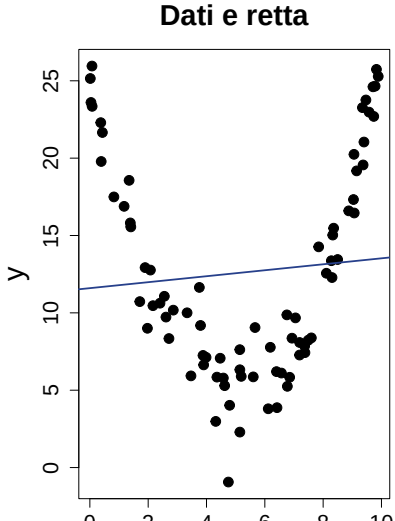
# Residui vs predittore

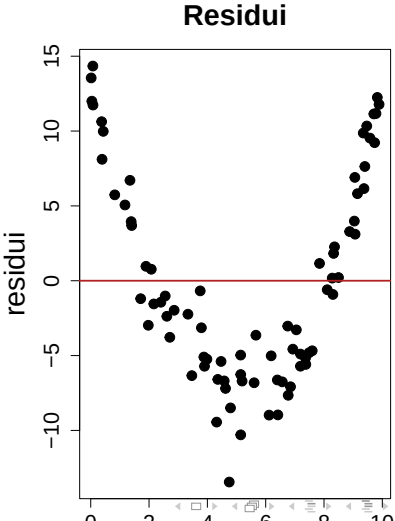
Se la relazione è lineare, i residui si distribuiscono **casualmente** attorno allo 0, senza alcun andamento

```
plot(studio$ore, studio$residui, pch = 19,
     xlab = "ore", ylab = "residui")
abline(h = 0, col = "firebrick", lwd = 2)
```



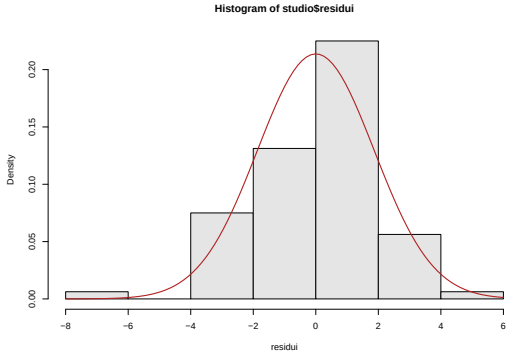
# Quando la relazione non è lineare



# Istogramma dei residui

```
hist(studio$residui, freq = FALSE, xlab = "residui", col = "gray90")
curve(dnorm(x, mean = 0, sd = sd(studio$residui)),
      add = TRUE, col = "firebrick", lwd = 2)
```

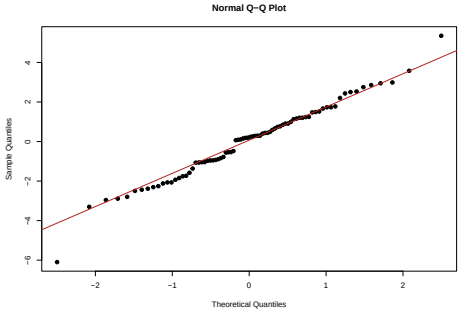



La linea rossa è la distribuzione normale con media 0 e sd pari a quella dei residui

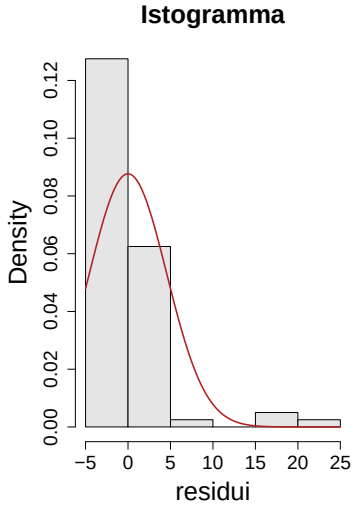
# Q-Q plot dei residui

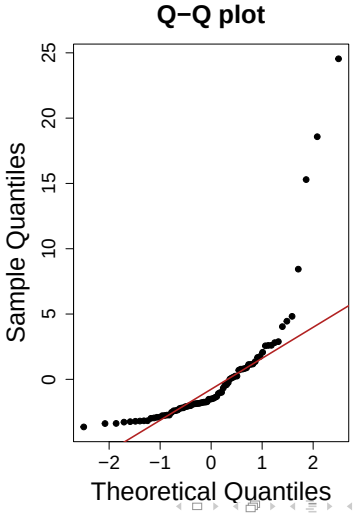
Confronta i quantili dei residui con quelli di una distribuzione normale: se i residui sono normali, i punti stanno **sulla retta**

```
qqnorm(studio$residui, pch = 19)
qqline(studio$residui, col = "firebrick", lwd = 2)
```



# Quando i residui non sono normali

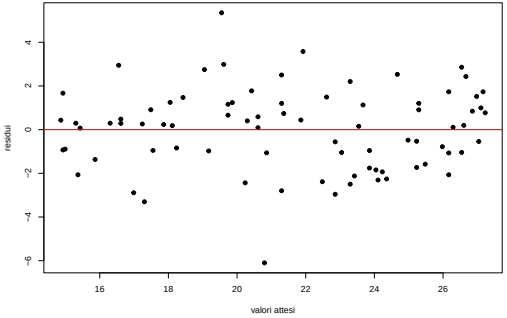


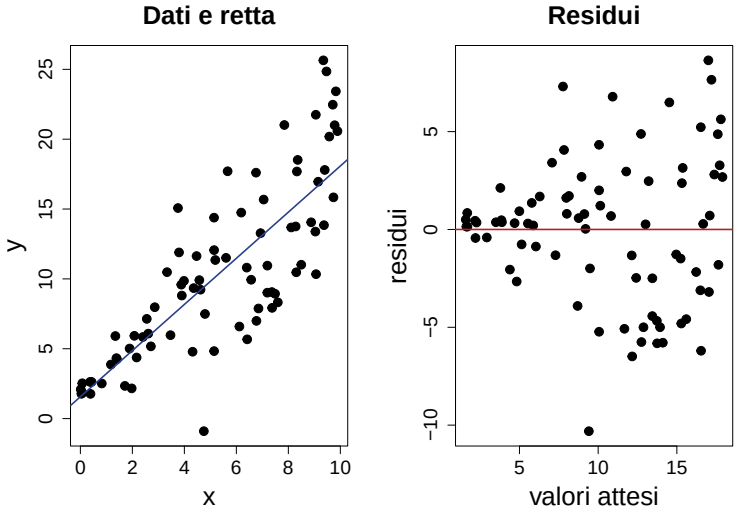



## Omoschedasticità

La variabilità dei residui deve essere **costante** per tutti i valori attesi: la "nuvola" deve avere la stessa ampiezza da sinistra a destra

```
plot(studio$attesi, studio$residui, pch = 19,
     xlab = "valori attesi", ylab = "residui")
abline(h = 0, col = "firebrick", lwd = 2)
```






Forma "a imbuto": i residui sono sempre più dispersi al crescere dei valori attesi $\rightarrow$ eteroschedasticità

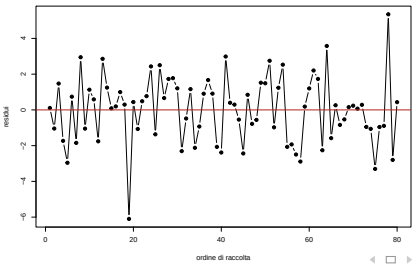
## Indipendenza delle osservazioni

Dipende soprattutto da **come sono stati raccolti i dati**: ogni osservazione deve essere indipendente dalle altre

Esempi di violazione: misure ripetute sulla stessa persona, studenti della stessa classe, dati raccolti nel tempo

Se i dati hanno un ordine (es. ordine di raccolta), si possono guardare i residui in quell'ordine: non deve esserci nessun andamento

```
plot(studio$residui, type = "b", pch = 19,
     xlab = "ordine di raccolta", ylab = "residui")
abline(h = 0, col = "firebrick", lwd = 2)
```



# Cosa guardare nei residui

| Assunto | Grafico | Cosa si deve vedere |
|---|---|---|
| Linearità | `plot(x, residui)` | Nuvola casuale attorno a 0 |
| Normalità | `hist(residui)`, `qqnorm(residui)` | Forma a campana, punti sulla retta |
| Omoschedasticità | `plot(attesi, residui)` | Ampiezza costante (niente imbuti) |
| Indipendenza | `plot(residui, type = "b")` | Nessun andamento nell'ordine |

Tutto parte da due funzioni:

```
attesi <- fitted(modello)
residui <- residuals(modello)
```

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

3 Materiale supplementare

- Outliers e casi influenti
- Leverage e distanza di Cook

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

3 Materiale supplementare
- Outliers e casi influenti
- Leverage e distanza di Cook

# Definizioni

**Outlier**: Il valore di un'osservazione nella variabile dipendente è anomalo dato il valore del predittore (ha un residuo molto grande)

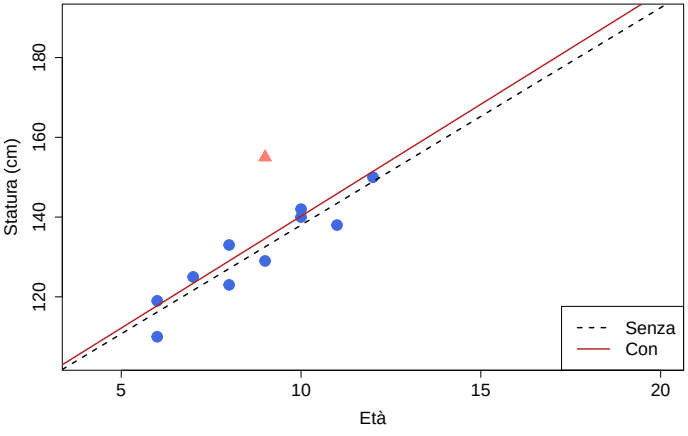
**Leverage** (leva): Quanto il valore di un'osservazione nel predittore è lontano dalla media del predittore $\rightarrow$ quanto *potenzialmente* può spostare la retta

**Influential case**: Una singola osservazione che riesce a spostare l'intera retta di regressione

Un'osservazione può essere:

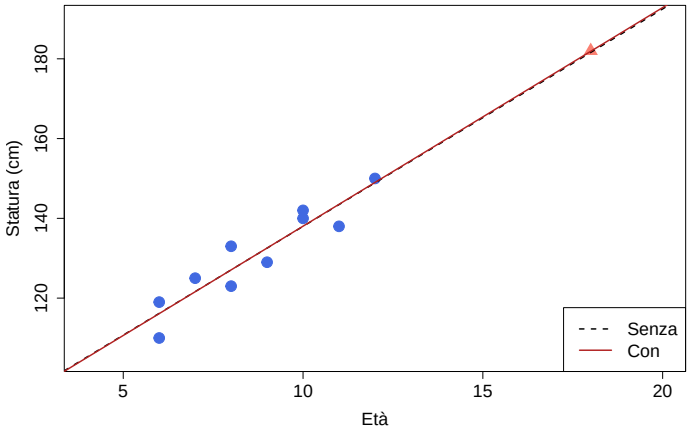
- Un outlier (ma non un influential case)
- Un punto ad alta leva in linea con gli altri (ma non un influential case)
- Un outlier influente (anomalo **e** ad alta leva)

# Un outlier living the life



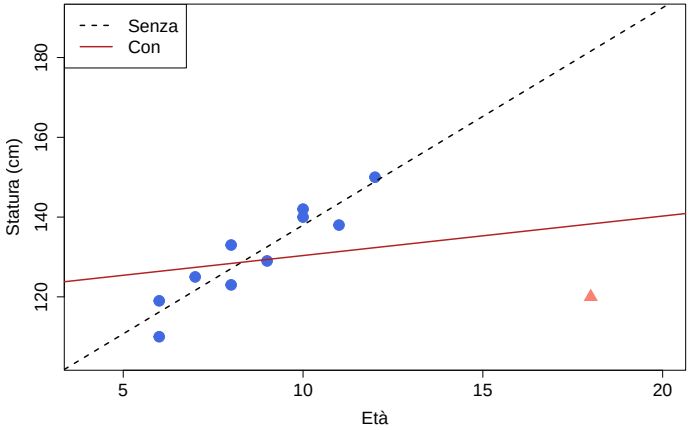

Il triangolo rosa è un outlier: è anomalo rispetto alla nuvola di punti, ma essendo vicino alla media dell'età sposta la retta di poco (soprattutto in alto, l'intercetta)

# Un punto ad alta leva living the life




Il triangolo rosa è lontano dagli altri sull'asse delle $x$ (alta leva), ma è in linea con l'andamento dei dati: la retta non cambia

# Un outlier influential case living the life




Il triangolo rosa è anomalo **e** lontano dagli altri sull'asse delle $x$: ne sposta drasticamente la pendenza

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

3 Materiale supplementare

- Outliers e casi influenti
- Leverage e distanza di Cook

# Tirare fuori leverage e distanza di Cook

Come per i residui, anche gli indici di influenza si estraggono dal modello e si guardano

`hatvalues()`: leverage di ogni osservazione

`cooks.distance()`: distanza di Cook → quanto cambiano *tutti* i valori attesi se l'osservazione viene tolta (combina residuo e leverage)

```
influente <- rbind(dat, c(soggetto = 11, eta = 18, statura = 120))
mod_inf <- lm(statura ~ eta, data = influente)
influente$leva <- hatvalues(mod_inf)
influente$cook <- cooks.distance(mod_inf)
```

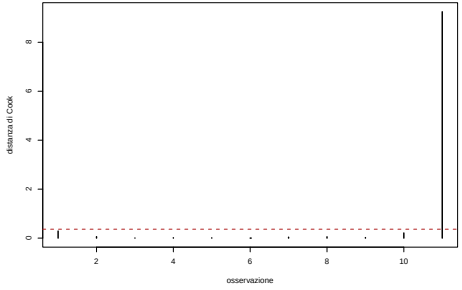
```
round(influente, 2)
```

```
   soggetto eta statura leva cook
1         1   6     110 0.20 0.29
2         2   6     119 0.20 0.06
3         3   7     125 0.15 0.00
4         4   8     123 0.11 0.01
5         5   8     133 0.11 0.01
6         6   9     129 0.09 0.00
7         7  10     140 0.09 0.04
8         8  10     142 0.09 0.05
9         9  11     138 0.11 0.02
10       10  12     150 0.14 0.21
11       11  18     120 0.70 9.25
```

# Il grafico della distanza di Cook

Una soglia spesso usata: $D_i > 4/n$

```
plot(influente$cook, type = "h", lwd = 3,
     xlab = "osservazione", ylab = "distanza di Cook")
abline(h = 4 / nrow(influente), col = "firebrick", lty = 2, lwd = 2)
```




```
which(influente$cook > 4 / nrow(influente))
```