

Modulo Didattico 3: Statistiche descrittive per la misura di associazione tra due variabili

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

A.A. 2025/2026

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
- 4 Previsione variabili quantitative

1 Tabelle di frequenza (contingenza)

- `table()`
- `margin.table()`
- `prop.table()`

2 Associazione (Variabili qualitative)

3 Associazione (variabili quantitative)

4 Previsione variabili quantitative

table()

table(var1, var2): Produce la tabella di frequenza tra due variabili categoriali var1 e var2

```
var1 <- as.factor(c("a1","a2","a1","a2","a1","a2","a1"))
var2 <- as.factor(c("b1","b1","b1","b2","b1","b2","b2"))
table(var1, var2)
```

```
      var2
var1 b1 b2
a1   3  1
a2   1  2
```

1 Tabelle di frequenza (contingenza)

- `table()`
- `margin.table()`
- `prop.table()`

2 Associazione (Variabili qualitative)

3 Associazione (variabili quantitative)

4 Previsione variabili quantitative

`margin.table()`

`margin.table(table, margin)`: Frequenze marginali per la tabella a doppia entrata

*margin = 1: Frequenze marginali calcolate **attraverso le colonne***
*margin = 2: Frequenze marginali calcolate **attraverso le righe***

```
mytab <- table(var1,var2)
```

```
margin.table(mytab,2)
```

```
var2
```

```
b1 b2
```

```
4 3
```

1 Tabelle di frequenza (contingenza)

- `table()`
- `margin.table()`
- `prop.table()`

2 Associazione (Variabili qualitative)

3 Associazione (variabili quantitative)

4 Previsione variabili quantitative

`prop.table()`

`prop.table(T, margin = NULL)`: Probabilità condizionate:

- riga (`margin = 1`, attraverso le colonne) o colonna (`margin = 2`, attraverso le righe).
- `margin = NULL` frequenze relative

```
prop.table(mytab)
```

```
      var2
var1      b1      b2
a1 0.4285714 0.1428571
a2 0.1428571 0.2857143
```

```
prop.table(mytab,2) # P(A|B)
```

```
      var2
var1      b1      b2
a1 0.7500000 0.3333333
a2 0.2500000 0.6666667
```

```
prop.table(mytab,1) # P(B|A)
```

```
      var2
var1      b1      b2
a1 0.7500000 0.2500000
a2 0.3333333 0.6666667
```

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)**
- 3 Associazione (variabili quantitative)
- 4 Previsione variabili quantitative

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
 - χ^2
 - `chisq.test()`
- 3 Associazione (variabili quantitative)
- 4 Previsione variabili quantitative

Quantifica il grado di associazione tra due variabili nominali:

- A con I categorie,
- B con J categorie Richiede il confronto tra **frequenze osservate** (n_{ij}) e **frequenze attese** o **frequenze teoriche** (n_{ij}^*)

n_{ij}	$n_{i.}$
$n_{.j}$	

Frequenze osservate

VS.

n_{ij}^*	$n_{i.}$
$n_{.j}$	

Frequenze teoriche

$$n_{ij}^* = \frac{n_{i.} \times n_{.j}}{N}$$

$$N = \sum_{i=1}^I \sum_{j=1}^J n_{ij}$$

Le frequenze teoriche n_{ij}^* sono calcolate assumendo l'indipendenza tra le variabili.

n_{ij}^* : Significato

Data l'ampiezza campionaria N , quali sono le frequenze che avremmo dovuto osservare se le due variabili fossero state indipendenti, ovvero se non avessero alcuna relazione?

$$\chi^2 = \sum_i \sum_j \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*}$$

$\chi^2 = 0$: $n_{ij} = n_{ij}^*$ Indipendenza stocastica

$\chi^2 = \chi_{\max}^2$: Relazione di perfetta dipendenza (dove
 $\chi_{\max}^2 = N \times \min[(I - 1); (J - 1)]$)

$\chi^2 = 0$: $n_{ij} = n_{ij}^*$ Indipendenza stocastica

$\chi^2 = \chi_{\max}^2$: Relazione di perfetta dipendenza (dove
 $\chi_{\max}^2 = N \times \min[(I - 1); (J - 1)]$)

$$\tilde{\chi}^2 = \frac{\chi^2}{\chi_{\max}^2}$$

$\tilde{\chi}^2$ è il χ^2 normalizzato, permette di esprimere il grado di associazione tra due variabili categoriali secondo una scala di tipo $[0, 1]$

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
 - χ^2
 - `chisq.test()`
- 3 Associazione (variabili quantitative)
- 4 Previsione variabili quantitative

```
chisq.test()
```

`chisq.test(table)$statistic`: Calcola il χ^2 osservato a partire da una tavola di contingenza `table`

```
chisq.test(mytab)$statistic
```

X-squared
0.109375


Per calcolare il $\tilde{\chi}^2$:

```
chisq.test(mytab)$statistic/sum(mytab)
```

X-squared
0.015625

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)**
- 4 Previsione variabili quantitative

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
 - Indice di covarianza campionaria
 - `plot()`
 - Covarianza campionaria
 - `cov()`
 - Correlazione campionaria
 - `cor()`
- 4 Previsione variabili quantitative



	X	Y
1	10	8.04
2	8	6.95
3	13	7.58
4	9	8.81
5	11	8.33
6	14	9.96
7	6	7.24
8	4	4.26
9	12	10.84
10	7	4.82
11	5	5.68

Figura 1: Grafico a dispersione delle variabili X e Y

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
 - Indice di covarianza campionaria
 - `plot()`
 - Covarianza campionaria
 - `cov()`
 - Correlazione campionaria
 - `cor()`
- 4 Previsione variabili quantitative


plot()

plot(x, y): Grafico di dispersione di due variabili quantitative appaiate
(x,y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```

```
plot(X,Y,main="Grafico di dispersione", xlim=c(0,20),ylim=c(0,15))
```



- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
 - Indice di covarianza campionaria
 - `plot()`
 - Covarianza campionaria
 - `cov()`
 - Correlazione campionaria
 - `cor()`
- 4 Previsione variabili quantitative

Misura il grado di *dispersione* e *covariazione* di due variabili quantitative appaiate (X, Y) attorno ai loro baricentri (medie) $\bar{X}$ e $\bar{Y}$





$$x = (x_1, x_2, \dots, x_n)$$

$$y = (y_1, y_2, \dots, y_n)$$

$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

$$\text{Cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Covarianza campionaria

(a) $\text{Cov} = 0$ (a) $\text{Cov} = 0$ (a) $\text{Cov} > 0$ (a) $\text{Cov} < 0$

Covarianza

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
 - Indice di covarianza campionaria
 - `plot()`
 - Covarianza campionaria
 - `cov()`
 - Correlazione campionaria
 - `cor()`
- 4 Previsione variabili quantitative

`cov()`: Restituisce la covarianza campionaria tra due variabili quantitative appaiate (X, Y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```

```
Z <- -Y
```

```
cov(X,Y)
```

```
[1] 6.309091
```

```
cov(X,Z)
```

```
[1] -6.309091
```

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
 - Indice di covarianza campionaria
 - `plot()`
 - Covarianza campionaria
 - `cov()`
 - Correlazione campionaria
 - `cor()`
- 4 Previsione variabili quantitative

$$-sd(x)s(y) \leq \text{Cov}(X, Y) \leq +sd(x)s(y)$$

$$-sd(x)s(y) \leq \text{Cov}(X, Y) \leq +sd(x)s(y)$$

$$r = \frac{\text{Cov}(X, Y)}{sd(x)s(y)}$$

$$-1 \leq r \leq 1$$

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
 - Indice di covarianza campionaria
 - `plot()`
 - Covarianza campionaria
 - `cov()`
 - Correlazione campionaria
 - `cor()`
- 4 Previsione variabili quantitative

cor(): Restituisce la correlazione (lineare) campionaria tra due variabili quantitative appaiate (X, Y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```




```
Z <- -Y
```

```
cor(X,Y)
```

```
[1] 0.7921487
```

```
cor(X,Z)
```


```
[1] -0.7921487
```

`cor()`

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
- 4 Previsione variabili quantitative**


- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
- 4 Previsione variabili quantitative
 - Regressione lineare
 - Principio dei minimi quadrati
 - Indice di adattamento R^2
 - Relazione R^2 e r
 - `lm()`

Regressione lineare



	X	Y
1	10	8.04
2	8	6.95
3	13	7.58
4	9	8.81
5	11	8.33
6	14	9.96
7	6	7.24
8	4	4.26
9	12	10.84
10	7	4.82
11	5	5.68

Regressione lineare



La regressione lineare tra una *variabile indipendente* X (predittore) ed una *variabile dipendente* Y (criterio) calcola la migliore approssimazione lineare che identifica il legame tra le due variabili utilizzando la struttura di dati bivariata (x, y) osservata su un campione di n osservazioni.

$$x = (x_1, x_2, \dots, x_n)$$

$$y = (y_1, y_2, \dots, y_n)$$

$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

$$Y = \beta_0 + \beta X$$

$$y_i = \beta_0 + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n)$$

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
- 4 Previsione variabili quantitative
 - Regressione lineare
 - Principio dei minimi quadrati
 - Indice di adattamento R^2
 - Relazione R^2 e r
 - `lm()`

$$SQE = \sum_{i=1}^n (y_i - y_i^*)^2 = SQE = \sum_{i=1}^n (y_i - (\beta_0 + \beta x_i))^2 = \sum_{i=1}^n e_i^2$$

dove $y_i^* = \beta_0 + \beta x_i$, e $e_i = y_i - y_i^*$.

Per il principio dei minimi quadrati si può dimostrare che lo stimatore ottimale per β è

$$\hat{\beta} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

mentre per β_0 è

$$\hat{\beta}_0 = \bar{y} - \hat{\beta} \bar{x}$$


- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
- 4 Previsione variabili quantitative
 - Regressione lineare
 - Principio dei minimi quadrati
 - Indice di adattamento R^2
 - Relazione R^2 e r
 - `lm()`

$$R^2 = 1 - \frac{SQE/n - 1}{Var(Y)} = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$\varepsilon = \frac{SQE}{n - 1}$: Stimatore campionario della varianza della componente di errore


$0 \leq R^2 \leq 1$: Più R^2 è vicino ad 1, migliore è il modello. Di fatto,
 $R^2 = r^2$

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
- 4 Previsione variabili quantitative
 - Regressione lineare
 - Principio dei minimi quadrati
 - Indice di adattamento R^2
 - Relazione R^2 e r
 - `lm()`

Relazione R^2 e r 


$$R^2 = 0.34, r = 0.59$$

Relazione R^2 e r




$$R^2 = 0.81, r = -0.9$$

Relazione R^2 e r



$$R^2 = 0.96, r = 0.98$$

Relazione R^2 e r



$$R^2 = 0, r = -0.14$$

- 1 Tabelle di frequenza (contingenza)
- 2 Associazione (Variabili qualitative)
- 3 Associazione (variabili quantitative)
- 4 Previsione variabili quantitative
 - Regressione lineare
 - Principio dei minimi quadrati
 - Indice di adattamento R^2
 - Relazione R^2 e r
 - `lm()`

`lm()`

`lm(Y ~ X)`: Restituisce la stima dei parametri del modello di regressione lineare dove si predicono i valori di Y a seconda dei valori di X

`~`: (Per i PC con tastierino numerico): ALT + 126, Per i MAC: ALT + 5 (fonte non verificata)

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
lm(Y~X)
```

Call:

```
lm(formula = Y ~ X)
```

Coefficients:

(Intercept)	X
2.4554	0.5624