

Modulo Didattico 3: Statistiche descrittive per la misura di associazione tra due variabili categoriali

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
`ottavia.epifania@unitn.it`

A.A. 2025/2026

1 Tabelle di frequenza (contingenza)

2 Misura di associazione

1 Tabelle di frequenza (contingenza)

- `table()`
- `margin.table()`
- `prop.table()`

2 Misura di associazione

table()

table(var1, var2): Produce la tabella di frequenza tra due variabili categoriali var1 e var2

```
var1 <- as.factor(c("a1", "a2", "a1", "a2", "a1", "a2", "a1"))
var2 <- as.factor(c("b1", "b1", "b1", "b2", "b1", "b2", "b2"))
table(var1, var2)
```

	var2	
var1	b1	b2
a1	3	1
a2	1	2

```
table()
```

1 Tabelle di frequenza (contingenza)

- `table()`
- `margin.table()`
- `prop.table()`

2 Misura di associazione

```
margin.table()
```

`margin.table(table, margin)`: Frequenze marginali per la tabella a doppia entrata
`> margin = 1`: Frequenze marginali calcolate **attraverso le colonne**
`> margin = 2`: Frequenze marginali calcolate **attraverso le righe**

Esempio:

```
mytab <- table(var1,var2)  
margin.table(mytab,2)
```

```
var2  
b1 b2  
4  3
```

1 Tabelle di frequenza (contingenza)

- `table()`
- `margin.table()`
- `prop.table()`

2 Misura di associazione

prop.table()

prop.table(T, margin = NULL): Probabilità condizionate: >riga (margin = 1, attraverso le colonne) o colonna (margin = 2, attraverso le righe). > margin = NULL frequenze relative

Esempio:

```
prop.table(mytab)      # frequenze relative
```

```
      var2
var1      b1      b2
a1 0.4285714 0.1428571
a2 0.1428571 0.2857143
```

```
prop.table(mytab,1)    # P(B|A)
```

```
      var2
var1      b1      b2
a1 0.7500000 0.2500000
a2 0.3333333 0.6666667
```

1 Tabelle di frequenza (contingenza)

2 Misura di associazione

1 Tabelle di frequenza (contingenza)

2 Misura di associazione

- χ^2

- Quantifica il grado di associazione tra due variabili nominali
- Richiede il confronto tra **frequenze osservate** (f_0) e **frequenze attese** o **frequenze teoriche** (f_t)

Le frequenze teoriche sono calcolate assumendo l'indipendenza tra le variabili.

f_t : Significato

Data l'ampiezza campionaria (n totale di osservazioni), quali sono le frequenze che avremmo dovuto osservare se le due variabili fossero state indipendenti, ovvero se non avessero alcuna relazione?

χ^2

f_{ij}	$f_{i.}$
$f_{.j}$	

Frequenze osservate

VS.

$\hat{f}_{ij}$	$f_{i.}$
$f_{.j}$	

Frequenze teoriche

$$\chi^2 = \sum_i \sum_j \frac{(f_{ij} - \hat{f}_{ij})^2}{\hat{f}_{ij}}$$