

Modulo Didattico 3: Statistiche descrittive per la misura di associazione tra due variabili - Variabili quantitative

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
`ottavia.epifania@unitn.it`

A.A. 2026/2027

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione


• Indice di adattamento: R^2

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative


3 Materiale supplementare



Studio della relazione lineare tra due variabili quantitative

Si vuole studiare la **relazione lineare** tra due variabili quantitative X e Y misurate sulle stesse unità statistiche

Per relazione lineare si intende quanto le coppie di punti (x_i, y_i) tendono a disporsi lungo una retta



Due indici: la **covarianza** (direzione della relazione) e il **coefficiente di**

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare

Indice di covarianza campionaria




Figure 1: Grafico a dispersione delle variabili X e Y

	X	Y
1	10	8.04
2	8	6.95
3	13	7.58
4	9	8.81
5	11	8.33
6	14	9.96
7	6	7.24
8	4	4.26
9	12	10.84
10	7	4.82
11	5	5.68

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare


```
plot()
```

`plot(x, y)`: Grafico di dispersione di due variabili quantitative appaiate
(x,y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```

```
plot(X,Y,main="Grafico di dispersione", xlim=c(0,20),ylim=c(0,15))
```



1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- **Covarianza campionaria**
- Esempio: età e peso di un bambino
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare

Misura il grado di *dispersione* e *covariazione* di due variabili quantitative appaiate (X, Y) attorno ai loro baricentri (medie) $\bar{X}$ e $\bar{Y}$

$$x = (x_1, x_2, \dots, x_n)$$


$$y = (y_1, y_2, \dots, y_n)$$

$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

$$\text{Cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

È (quasi) la **media dei prodotti degli scarti** di ogni variabile dalla propria media

Il segno dei prodotti degli scarti



Il prodotto $(x_i - \bar{x})(y_i - \bar{y})$ è più spesso positivo se $\text{Cov} > 0$, più spesso negativo se $\text{Cov} < 0$


- La covarianza può assumere **tutti i valori reali**
- $\text{Cov}(X, Y) > 0$: tendenza alla linearità positiva (**crescente**)
- $\text{Cov}(X, Y) < 0$: tendenza alla linearità negativa (**decrescente**)
- $\text{Cov}(X, Y) \approx 0$: nessuna tendenza lineare

Quali valori può assumere?


- La covarianza può assumere **tutti i valori reali**
- $\text{Cov}(X, Y) > 0$: tendenza alla linearità positiva (**crescente**)
- $\text{Cov}(X, Y) < 0$: tendenza alla linearità negativa (**decrecente**)
- $\text{Cov}(X, Y) \approx 0$: nessuna tendenza lineare

Il valore della covarianza dipende dall'unità di misura delle variabili → ci dice la **direzio**ne della relazione ma non la sua **intensità**


Covarianza campionaria




(a) $\text{Cov} = 0$



(a) $\text{Cov} = 0$



(a) $\text{Cov} > 0$



(a) $\text{Cov} < 0$

Covarianza

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare

eta peso

1	3	6
2	6	8
3	9	9
4	12	10
5	24	13
6	36	20




Figure 6: Grafico a dispersione

Esempio: età e peso di un bambino

Calcolo della covarianza

	x	y	x - media(x)	y - media(y)	prodotto
1	3	6	-12	-5	60
2	6	8	-9	-3	27
3	9	9	-6	-2	12
4	12	10	-3	-1	3
5	24	13	9	2	18
6	36	20	21	9	189

$$\bar{x} = 15, \bar{y} = 11, \sum_i (x_i - \bar{x})(y_i - \bar{y}) = 309$$

$$\text{Cov}(x, y) = \frac{309}{6 - 1} = 61.8$$

Esempio: età e peso di un bambino

Calcolo della covarianza

	x	y	x - media(x)	y - media(y)	prodotto
1	3	6	-12	-5	60
2	6	8	-9	-3	27
3	9	9	-6	-2	12
4	12	10	-3	-1	3
5	24	13	9	2	18
6	36	20	21	9	189

$$\bar{x} = 15, \bar{y} = 11, \sum_i (x_i - \bar{x})(y_i - \bar{y}) = 309$$

$$\text{Cov}(x, y) = \frac{309}{6 - 1} = 61.8$$

E quindi? Sappiamo che la relazione è **positiva**, ma è forte o debole?

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- **`cov()`**
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare

`cov()`: Restituisce la covarianza campionaria tra due variabili quantitative appaiate (X, Y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```

```
Z <- -Y
```

```
cov(X,Y)
```

```
[1] 6.309091
```

```
cov(X,Z)
```

```
[1] -6.309091
```

```
cov(bimbo$eta, bimbo$peso)
```

```
[1] 61.8
```

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- `cov()`
- **Correlazione campionaria**
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative




3 Materiale supplementare

$$-sd(x)sd(y) \leq \text{Cov}(X, Y) \leq +sd(x)sd(y)$$

◀ ◻ ▶ ◀ ◻ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ≡ ▶ ≡ ↺ 🔍 ↻

$$r = +1, r = -1, r = 0$$

$r = +1$


$$r = -1$$

$$r = 0$$


1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- `cov()`
- Correlazione campionaria
- **`cor()`**
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare

```
cor()
```

`cor()`: Restituisce la correlazione (lineare) campionaria tra due variabili quantitative appaiate (X, Y) aventi lo stesso numero di osservazioni

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```

```
Z <- -Y
```

```
cor(X,Y)
```

```
[1] 0.7921487
```

```
cor(X,Z)
```

```
[1] -0.7921487
```

cor()

Il bambino di prima

```
cov(bimbo$eta, bimbo$peso) / (sd(bimbo$eta) * sd(bimbo$peso))
```




```
[1] 0.9860185
```

```
cor(bimbo$eta, bimbo$peso)
```

```
[1] 0.9860185
```

$$r = \frac{61.8}{12.59 \cdot 4.98} = 0.986$$

Le variabili presentano una **fortissima correlazione positiva**: i punti tendono a disporsi lungo una retta crescente





◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

3 Materiale supplementare

Usi di r in psicologia

- Attendibilità test-retest
- Forme parallele di un test (coefficiente di equivalenza)
- Accordo tra le valutazioni di due giudici
- Consistenza interna di un questionario
- ...

Statistics doesn't lie, but liars use statistics

Due variabili possono essere fortemente correlate senza che esista alcun legame tra di loro


<https://www.tylervigen.com/spurious-correlations>

Due variabili possono essere fortemente correlate senza che esista alcun legame tra di loro

Relazione diretta




Ma ne siamo proprio sicuri?



La relazione tra X e Y passa attraverso altre variabili (mediatori)

Relazione spuria



X e Y sono correlate solo perché entrambe dipendono da una terza variabile

LA STATISTICA SOSTIENE, NON ILLUMINA!

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento: R^2

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
 - Principio dei minimi quadrati
 - Proprietà della retta di regressione
 - Indice di adattamento R^2
 - Relazione R^2 e r
 - `lm()`
 - Assunti del modello
 - I residui
 - Tirare fuori i residui
 - Linearità
 - Normalità


Quanto varia y in funzione di x ?

La correlazione permette di stabilire quanto covariano due variabili, x e y :
modello simmetrico per determinare *l'intensità della relazione*

Con un modello di regressione si vuole andare più a fondo per capire
quanto varia y in funzione di ogni cambiamento in x : stabilire non solo se
le variabili sono associate o meno ma la portata della variazione

La relazione è *asimetrica*: si vuole spiegare y in funzione di x (questo non
vuol dire in alcun modo che la relazione sia causale)


Regressione lineare




	X	Y
1	10	8.04
2	8	6.95
3	13	7.58
4	9	8.81
5	11	8.33
6	14	9.96
7	6	7.24
8	4	4.26
9	12	10.84
10	7	4.82
11	5	5.68

$$r = 0.79$$

Regressione lineare



Regressione lineare



La regressione lineare tra una *variabile indipendente* X (predittore) ed una *variabile dipendente* Y (criterio) calcola la migliore approssimazione lineare che identifica il legame tra le due variabili utilizzando la struttura di dati bivariata (x, y) osservata su un campione di n osservazioni.

$$x = (x_1, x_2, \dots, x_n)$$

$$y = (y_1, y_2, \dots, y_n)$$

$$d = ((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

$$Y = \beta_0 + \beta X$$

$$y_i = \beta_0 + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n)$$

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità

$$SQE = \sum_{i=1}^n (y_i - y_i^*)^2 = \sum_{i=1}^n (y_i - (\beta_0 + \beta x_i))^2 = \sum_{i=1}^n e_i^2$$

dove $y_i^* = \beta_0 + \beta x_i$, e $e_i = y_i - y_i^*$.


Per il principio dei minimi quadrati si può dimostrare che lo stimatore ottimale per β è

$$\hat{\beta} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

mentre per β_0 è

$$\hat{\beta}_0 = \bar{y} - \hat{\beta} \bar{x}$$

Principio dei minimi quadrati



1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità

Coefficiente angolare e correlazione

$$\hat{\beta} = \frac{\text{Cov}(X, Y)}{sd(x)^2}$$

$$r = \frac{\text{Cov}(X, Y)}{sd(x)sd(y)}$$

Moltiplicando e dividendo $\hat{\beta}$ per $sd(y)$:

$$\hat{\beta} = r \frac{sd(y)}{sd(x)}$$

Coefficiente angolare e correlazione

$$\hat{\beta} = \frac{\text{Cov}(X, Y)}{sd(x)^2}$$

$$r = \frac{\text{Cov}(X, Y)}{sd(x)sd(y)}$$

Moltiplicando e dividendo $\hat{\beta}$ per $sd(y)$:

$$\hat{\beta} = r \frac{sd(y)}{sd(x)}$$

- ① Il **segno** del coefficiente angolare è lo stesso di r : $r > 0 \Rightarrow$ retta crescente, $r < 0 \Rightarrow$ retta decrescente, $r = 0 \Rightarrow$ retta orizzontale
- ② La retta passa sempre per il **punto delle medie** $(\bar{x}, \bar{y})$ (basta sostituire $x = \bar{x}$ in $\hat{y} = \hat{\beta}_0 + \hat{\beta}x$)

Il bambino di prima

```
b <- cov(bimbo$eta, bimbo$peso) / var(bimbo$eta)
b0 <- mean(bimbo$peso) - b * mean(bimbo$eta)
c(b0, b)
```

```
[1] 5.1477273 0.3901515
```

```
cor(bimbo$eta, bimbo$peso) * sd(bimbo$peso) / sd(bimbo$eta)
```

```
[1] 0.3901515
```

Retta di regressione: $\hat{y} = 5.15 + 0.39x$

Il bambino di prima

```
b <- cov(bimbo$eta, bimbo$peso) / var(bimbo$eta)
b0 <- mean(bimbo$peso) - b * mean(bimbo$eta)
c(b0, b)
```

```
[1] 5.1477273 0.3901515
```

```
cor(bimbo$eta, bimbo$peso) * sd(bimbo$peso) / sd(bimbo$eta)
```

```
[1] 0.3901515
```

Retta di regressione: $\hat{y} = 5.15 + 0.39x$

Quale sarebbe il peso previsto a 48 mesi? $\hat{y}_{48} = 5.15 + 0.39 \cdot 48 = 23.88$
kg

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- **Indice di adattamento R^2**
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità

$$R^2 = 1 - \frac{SQE/n - 1}{Var(Y)} = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$


$\varepsilon = \frac{SQE}{n-1}$: Stimatore campionario della varianza della componente di errore

$0 \leq R^2 \leq 1$: Più R^2 è vicino ad 1, migliore è il modello. Di fatto, $R^2 = r^2$


1 Associazione (variabili quantitative)

2 Previsione variabili quantitative


- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità

Relazione R^2 e r 


Relazione R^2 e r




$$R^2 = 0.34, r = 0.59$$

Relazione R^2 e r 

$$R^2 = 0.81, r = -0.9$$

Relazione R^2 e r 

$$R^2 = 0.96, r = 0.98$$

Relazione R^2 e r 

$$R^2 = 0, r = -0.14$$

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità

lm()

`lm(Y ~ X)`: Restituisce la stima dei parametri del modello di regressione lineare dove si predicono i valori di Y a seconda dei valori di X

`~`: (Per i PC con tastierino numerico): ALT + 126, Per i MAC: ALT + 5 (fonte non verificata)

```
X <- c(9,8,12,9,10,14,5,4,13,7,5)
```

```
Y <- c(9,6,8,9,7,10,8,4,11,5,4)
```

```
lm(Y~X)
```

Call:

```
lm(formula = Y ~ X)
```

Coefficients:

(Intercept)	X
2.4554	0.5624

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- **Assunti del modello**
- I residui
- Tirare fuori i residui
- Linearità
- Normalità

Assunzioni

- **Indipendenza dei predittori dall'errore**

I predittori sono misurati senza errore, ovvero i predittori e gli errori di misura non sono correlati nella popolazione (per questo è importante il campionamento casuale)

- **Indipendenza delle osservazioni**

$\forall i \neq j, \varepsilon_i \perp \varepsilon_j$ (le osservazioni sono state campionate indipendentemente l'una dall'altra)

- **Linearità**

Il valore atteso dell'errore per un dato valore di x è 0

Assunzioni

- **Normalità**

$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$: Anche y_i è distribuita normalmente con media $\beta_0 + \beta_1 x_i$

- **Varianza costante** (omoschedasticità)

La varianza degli errori è costante per qualunque valore di X

Assunzioni

- **Normalità**

$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$: Anche y_i è distribuita normalmente con media $\beta_0 + \beta_1 x_i$

- **Varianza costante** (omoschedasticità)

La varianza degli errori è costante per qualunque valore di X

Gli errori ε_i della popolazione non si osservano $\rightarrow$ si guardano i loro “rappresentanti” nel campione: i **residui** $e_i = y_i - \hat{y}_i$

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità


Indipendenza dei predittori dall'errore

I predittori sono misurati senza errore, ovvero i predittori e gli errori di misura non sono correlati nella popolazione (per questo è importante il campionamento casuale)


Analisi dei residui

I residui e il predittore **non devono essere correlati tra di loro**

I residui




I residui




$$r = -0.05$$

I residui



I residui



$$r = 0.64$$

Attenzione!

Nei grafici precedenti abbiamo guardato gli **errori veri** ε_i (che conosciamo solo perché i dati sono simulati)

I **residui** stimati con `lm()` sono invece *per costruzione* incorrelati con il predittore: il metodo dei minimi quadrati fa sì che $r(e, x) = 0$ sempre

```
round(cor(residuals(fitcorr), x), 10)
```

```
[1] 0
```

Attenzione!

Nei grafici precedenti abbiamo guardato gli **errori veri** ε_i (che conosciamo solo perché i dati sono simulati)

I **residui** stimati con `lm()` sono invece *per costruzione* incorrelati con il predittore: il metodo dei minimi quadrati fa sì che $r(e, x) = 0$ sempre

```
round(cor(residuals(fitcorr), x), 10)
```

```
[1] 0
```

L'indipendenza tra predittore ed errore si garantisce soprattutto con il **disegno di ricerca** (campionamento casuale, misure affidabili)

Nei residui cerchiamo invece degli **andamenti sistematici** (curve, imbuti, asimmetrie) che segnalano la violazione degli altri assunti

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità

Un esempio: ore di studio e voto

```
head(studio)
```

```
      ore voto
1 18.3 26.4
2 18.7 25.5
3  5.7 19.9
4 16.6 23.5
5 12.8 19.9
6 10.4 22.1
```

```
modello <- lm(voto ~ ore, data = studio)
modello
```

Call:

```
lm(formula = voto ~ ore, data = studio)
```

I valori attesi e i residui

```
studio$attesi <- fitted(modello)      # y cappello
studio$residui <- residuals(modello)  # y - y cappello
head(studio)
```

	ore	voto	attesi	residui
1	18.3	26.4	26.29279	0.1072084
2	18.7	25.5	26.54252	-1.0425177
3	5.7	19.9	18.42642	1.4735784
4	16.6	23.5	25.23146	-1.7314560
5	12.8	19.9	22.85906	-2.9590587
6	10.4	22.1	21.36070	0.7392975

I valori attesi e i residui

```
studio$attesi <- fitted(modello)      # y cappello
studio$residui <- residuals(modello)  # y - y cappello
head(studio)
```

	ore	voto	attesi	residui
1	18.3	26.4	26.29279	0.1072084
2	18.7	25.5	26.54252	-1.0425177
3	5.7	19.9	18.42642	1.4735784
4	16.6	23.5	25.23146	-1.7314560
5	12.8	19.9	22.85906	-2.9590587
6	10.4	22.1	21.36070	0.7392975

```
# i residui sono semplicemente osservati - attesi
head(studio$voto - studio$attesi)
```

```
[1] 0.1072084 -1.0425177 1.4735784 -1.7314560 -2.9590587 0.7392975
```

Media e distribuzione dei residui

La media dei residui è (sempre) 0:

```
mean(studio$residui)
```

```
[1] -2.791617e-17
```

Media e distribuzione dei residui

La media dei residui è (sempre) 0:

```
mean(studio$residui)
```

```
[1] -2.791617e-17
```

I residui dovrebbero distribuirsi in modo simmetrico attorno allo 0: la mediana deve essere il più vicina possibile a 0, il minimo e il massimo (così come il primo e il terzo quartile) dovrebbero essere simili in valore assoluto

```
summary(studio$residui)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-6.0988	-1.0629	0.2153	0.0000	1.2028	5.3498

1 Associazione (variabili quantitative)


2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- **Linearità**
- **Normalità**

Residui vs predittore


Se la relazione è lineare, i residui si distribuiscono **casualmente** attorno allo 0, senza alcun andamento

```
plot(studio$ore, studio$residui, pch = 19,  
     xlab = "ore", ylab = "residui")  
abline(h = 0, col = "firebrick", lwd = 2)
```




Quando la relazione non è lineare

Dati e retta



Residui




1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità

Istogramma dei residui

```
hist(studio$residui, freq = FALSE, main = "",  
      xlab = "residui", col = "gray90")  
curve(dnorm(x, mean = 0, sd = sd(studio$residui)),  
      add = TRUE, col = "firebrick", lwd = 2)
```




La linea rossa è la distribuzione normale con media 0 e deviazione standard pari a quella

Q-Q plot dei residui


Confronta i quantili dei residui con quelli di una distribuzione normale: se i residui sono normali, i punti stanno **sulla retta**

```
qqnorm(studio$residui, pch = 19)  
qqline(studio$residui, col = "firebrick", lwd = 2)
```




Quando i residui non sono normali

Istogramma



Q-Q plot



1 Associazione (variabili quantitative)


2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità

Residui vs valori attesi


La variabilità dei residui deve essere **costante** per tutti i valori attesi: la “nuvola” deve avere la stessa ampiezza da sinistra a destra

```
plot(studio$attesi, studio$residui, pch = 19,
     xlab = "valori attesi", ylab = "residui")
abline(h = 0, col = "firebrick", lwd = 2)
```




Quando la varianza non è costante

Dati e retta



Residui



1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità


Esempi di violazione: misure ripetute sulla stessa persona, studenti della stessa classe, dati raccolti nel tempo

Dipende soprattutto da **come sono stati raccolti i dati**: ogni osservazione deve essere indipendente dalle altre

Esempi di violazione: misure ripetute sulla stessa persona, studenti della stessa classe, dati raccolti nel tempo

Se i dati hanno un ordine (es. ordine di raccolta), si possono guardare i residui in quell'ordine: non deve esserci nessun andamento

```
plot(studio$residui, type = "b", pch = 19,  
      xlab = "ordine di raccolta", ylab = "residui")  
abline(h = 0, col = "firebrick", lwd = 2)
```



1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento R^2
- Relazione R^2 e r
- `lm()`
- Assunti del modello
- I residui
- Tirare fuori i residui
- Linearità
- Normalità

Cosa guardare nei residui

Assunto	Grafico	Cosa si deve vedere
Linearità	<code>plot(x, residui)</code>	Nuvola casuale attorno a 0
Normalità	<code>hist(residui)</code> , <code>qqnorm(residui)</code>	Forma a campana, punti sulla retta
Omoschedasticità	<code>plot(attesi, residui)</code>	Ampiezza costante (niente imbuto)
Indipendenza	<code>plot(residui, type = "b")</code>	Nessun andamento nell'ordine

Tutto parte da due funzioni:

```
attesi <- fitted(modello)
residui <- residuals(modello)
```

1 Associazione (variabili quantitative)

- Relazione lineare
- Indice di covarianza campionaria
- `plot()`
- Covarianza campionaria
- Esempio: età e peso di un bambino
- `cov()`
- Correlazione campionaria
- `cor()`
- Usi e abusi di r

2 Previsione variabili quantitative

- Regressione lineare
- Principio dei minimi quadrati
- Proprietà della retta di regressione
- Indice di adattamento: R^2

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

3 **Materiale supplementare**

- **Outliers e casi influenti**
- Leverage e distanza di Cook

Definizioni

Outlier: Il valore di un'osservazione nella variabile dipendente è anomalo dato il valore del predittore (ha un residuo molto grande)


Leverage (leva): Quanto il valore di un'osservazione nel predittore è lontano dalla media del predittore → quanto *potenzialmente* può spostare la retta

Influential case: Una singola osservazione che riesce a spostare l'intera retta di regressione

Un'osservazione può essere:


- Un outlier (ma non un influential case)
- Un punto ad alta leva in linea con gli altri (ma non un influential case)
- Un outlier influente (anomalo e ad alta leva)

Un outlier living the life




Il triangolo rosa è un outlier: è anomalo rispetto alla nuvola di punti, ma essendo vicino alla media dell'età sposta la retta di poco (soprattutto in alto, l'intercetta)

Un punto ad alta leva living the life



Il triangolo rosa è lontano dagli altri sull'asse delle x (alta leva), ma è in linea con l'andamento dei dati: la retta non cambia

Un outlier influential case living the life



Il triangolo rosa è anomalo e lontano dagli altri sull'asse delle x : ne sposta drasticamente la pendenza

1 Associazione (variabili quantitative)

2 Previsione variabili quantitative

3 Materiale supplementare

- Outliers e casi influenti
- Leverage e distanza di Cook

Tirare fuori leverage e distanza di Cook

Come per i residui, anche gli indici di influenza si estraggono dal modello e si guardano

`hatvalues()`: leverage di ogni osservazione

`cooks.distance()`: distanza di Cook → quanto cambiano *tutti* i valori attesi se l'osservazione viene tolta (combina residuo e leverage)

```
influyente <- rbind(dat, c(soggetto = 11, eta = 18, statura = 120))  
mod_inf <- lm(statura ~ eta, data = influyente)  
influyente$leva <- hatvalues(mod_inf)  
influyente$cook <- cooks.distance(mod_inf)
```

Leverage e distanza di Cook


```
round(influente, 2)
```

	soggetto	eta	statura	leva	cook
1	1	6	110	0.20	0.29
2	2	6	119	0.20	0.06
3	3	7	125	0.15	0.00
4	4	8	123	0.11	0.01
5	5	8	133	0.11	0.01
6	6	9	129	0.09	0.00
7	7	10	140	0.09	0.04
8	8	10	142	0.09	0.05
9	9	11	138	0.11	0.02
10	10	12	150	0.14	0.21
11	11	18	120	0.70	9.25

Il grafico della distanza di Cook

Una soglia spesso usata: $D_i > 4/n$

```
plot(influente$cook, type = "h", lwd = 3,
     xlab = "osservazione", ylab = "distanza di Cook")
abline(h = 4 / nrow(influente), col = "firebrick", lty = 2, lwd = 2)
```



```
which(influente$cook > 4 / nrow(influente))
```