Modulo Didattico 5: Principi base di inferenza statistica

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
Univeristà di Trento
ottavia.epifania@unitn.it

A.A. 2026/2027

L'**inferenza statistica** è definita come un insieme di metodi, basati sulla teoria della probabilità, tali per cui si possano trarre conclusioni plausibili sulla variabile casuale associata ad una particolare caratteristica di una *popolazione* a partire dall'osservazione di un **campione** di elementi della popolazione stessa.

Secondo l'impostazione classica, la teoria dell'inferenza statistica si sviluppa lungo due direttrici:

- Teoria della **stima di parametri**
- Teoria della **verifica di ipotesi**

La maggior parte degli studi viene condotta su “gruppi” più o meno ampi di elementi che appartengono ad un insieme più ampio definito POPOLAZIONE

Popolazione

Rappresenta tutto l’universo di individui a cui si rivolge l’attenzione del ricercatore (ad es. la popolazione degli studenti della scuola elementare)

Campione

Sottoinsieme della popolazione, possibilmente composto da unità estratte **casualmente** dalla popolazione.

POPOLAZIONE

Finita (N)

È possibile avere informazioni rispetto al numero di unità di analisi che la compongono
Molto piccola (e.g., persone con sindrome rara) o molto grande (e.g., tutti gli studenti di psicologia)

Infinita

Non è possibile conoscere con precisione il numero di unità di analisi che la compongono (anche se hanno un numero finito)
Non è possibile determinare il numero di unità di analisi che la compongono (e.g., lanci di un dado)



CAMPIONAMENTO

con o senza reinserimento



Campione

finito (n)

Lo studio *dell'intera popolazione* porta alla **certezza delle conclusioni**

Esempio

Si vuole verificare se il reddito familiare medio degli studenti di psicologia in Italia (popolazione A) sia superiore a quello dei loro colleghi in Francia (popolazione B). Se si calcolasse il reddito medio di tutte le famiglie italiane e francesi il risultato (indipendentemente da quale) sarebbe certo

Lo studio *dell'intera popolazione* porta alla **certezza delle conclusioni**

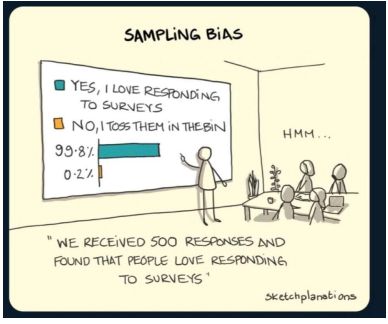
Esempio

Si vuole verificare se il reddito familiare medio degli studenti di psicologia in Italia (popolazione A) sia superiore a quello dei loro colleghi in Francia (popolazione B). Se si calcolasse il reddito medio di tutte le famiglie italiane e francesi il risultato (indipendentemente da quale) sarebbe certo

Studiare l'intera popolazione è irrealistico (a livello di risorse umane, economiche, temporali ecc.) $\rightarrow$ è necessario l'utilizzo dei campioni e della statistica inferenziale.

Un'*indagine campionaria* **non offre la certezza delle conclusioni**: quello che si osserva su due campioni A e B potrebbe non riflettere la realtà delle popolazioni

Il modo in cui viene selezionato il campione è di fondamentale importanza!!



Gli strumenti statistici consentono di valutare **probabilisticamente** gli errori che si possono commettere traendo conclusioni sulle popolazioni a partire dalle caratteristiche di uno o più campioni

Gli errori di un'indagine campionaria possono essere ridotti se il campione è **rappresentativo** della popolazione; dovrebbe cioè *possedere le caratteristiche della popolazione dalla quale proviene*

Campionamento casuale

Se il campione è estratto *casualmente* dalla popolazione si può affermare che eventuali differenze sono dovute "al caso", dovute cioè *a variazioni accidentali e non sistematiche*

Non solo come... ma anche quanto! L'importanza dell'ampiezza campionaria per studi che permettano inferenze "valide"



Un **indicatore o statistica** o più comunemente **STIMATORE** è una funzione dei valori osservati sul campione $(X_1, X_2, ..., X_n)$, utilizzato per la stima di un **parametro** (generalmente incognito) di una **popolazione** e che (possibilmente) rispetta una serie di caratteristiche.

Stima:

- *Stima puntuale*: il metodo di stima conduce ad un unico valore per il parametro in oggetto
- *Stima intervallare*: il metodo di stima conduce ad un intervallo di valori, all'interno dei quali si suppone che si trovi con una certa probabilità il valore vero del parametro