Modulo Didattico 5: Principi base di inferenza statistica

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
Univeristà di Trento
ottavia.epifania@unitn.it

A.A. 2026/2027

1 Inferenza statistica

2 Test di ipotesi

3 Distribuzioni campionarie

4 Valore critico

L'**inferenza statistica** è definita come un insieme di metodi, basati sulla teoria della probabilità, tali per cui si possano trarre conclusioni plausibili sulla variabile casuale associata ad una particolare caratteristica di una *popolazione* a partire dall'osservazione di un **campione** di elementi della popolazione stessa.

Secondo l'impostazione classica, la teoria dell'inferenza statistica si sviluppa lungo due direttrici:

- Teoria della **stima di parametri**
- Teoria della **verifica di ipotesi**

La maggior parte degli studi viene condotta su "gruppi" più o meno ampi di elementi che appartengono ad un insieme più ampio definito POPOLAZIONE

Popolazione

Rappresenta tutto l'universo di individui a cui si rivolge l'attenzione del ricercatore (ad es. la popolazione degli studenti della scuola elementare)

Campione

Sottoinsieme della popolazione, possibilmente composto da unità estratte **casualmente** dalla popolazione.

POPOLAZIONE

Finita (N)

È possibile avere informazioni rispetto al numero di unità di analisi che la compongono
Molto piccola (e.g., persone con sindrome rara) o molto grande (e.g., tutti gli studenti di psicologia)

Infinita

Non è possibile conoscere con precisione il numero di unità di analisi che la compongono (anche se hanno un numero finito)
Non è possibile determinare il numero di unità di analisi che la compongono (e.g., lanci di un dado)



CAMPIONAMENTO

con o senza reinserimento



Campione

finito (n)

Lo studio *dell'intera popolazione* porta alla **certezza delle conclusioni**

Esempio

Si vuole verificare se il reddito familiare medio degli studenti di psicologia in Italia (popolazione A) sia superiore a quello dei loro colleghi in Francia (popolazione B). Se si calcolasse il reddito medio di tutte le famiglie italiane e francesi il risultato (indipendentemente da quale) sarebbe certo

Lo studio *dell'intera popolazione* porta alla **certezza delle conclusioni**

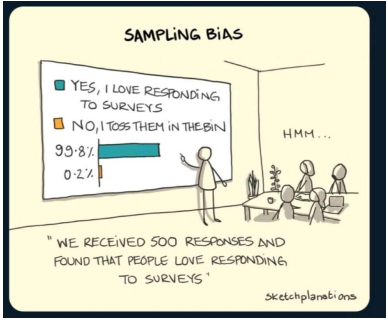
Esempio

Si vuole verificare se il reddito familiare medio degli studenti di psicologia in Italia (popolazione A) sia superiore a quello dei loro colleghi in Francia (popolazione B). Se si calcolasse il reddito medio di tutte le famiglie italiane e francesi il risultato (indipendentemente da quale) sarebbe certo

Studiare l'intera popolazione è irrealistico (a livello di risorse umane, economiche, temporali ecc.) $\rightarrow$ è necessario l'utilizzo dei campioni e della statistica inferenziale.

Un'*indagine campionaria* **non offre la certezza delle conclusioni**: quello che si osserva su due campioni A e B potrebbe non riflettere la realtà delle popolazioni

Il modo in cui viene selezionato il campione è di fondamentale importanza!!



Gli strumenti statistici consentono di valutare **probabilisticamente** gli errori che si possono commettere traendo conclusioni sulle popolazioni a partire dalle caratteristiche di uno o più campioni

Gli errori di un'indagine campionaria possono essere ridotti se il campione è **rappresentativo** della popolazione; dovrebbe cioè *possedere le caratteristiche della popolazione dalla quale proviene*

Campionamento casuale

Se il campione è estratto *casualmente* dalla popolazione si può affermare che eventuali differenze sono dovute "al caso", dovute cioè *a variazioni accidentali e non sistematiche*

Non solo come... ma anche quanto! L'importanza dell'ampiezza campionaria per studi che permettano inferenze "valide"



1 Inferenza statistica

2 Test di ipotesi

3 Distribuzioni campionarie

4 Valore critico

Obiettivi dell'inferenza statistica:

- Stima dei parametri
- **Verifica di ipotesi**



Procedura che si svolge per passi logici successivi:

- (Porsi una domanda di ricerca) (dotata di senso) (basata sulla letteratura)
- Formulazione ipotesi riguardanti i parametri della popolazione
- Definizione dei criteri e dei vincoli di accettazione dell'ipotesi
- Raccolta dati campionari
- Valutazione delle ipotesi formulate

Le ipotesi di ricerca sono ipotesi statistiche:

- consistono in affermazioni di tipo logico-matematico che definiscono i rapporti fra i parametri di una o più popolazioni
- la verifica delle ipotesi consiste in un **processo di decisione che termina nell'accettazione –o non rifiuto– delle affermazioni contenute nelle ipotesi stesse**
- Un'ipotesi statistica è un'asserzione o supposizione sulla distribuzione di una o più variabili casuali, o su uno o più parametri della stessa, e si indica con la lettera ***H***.

Esempio

Sia $X_1, X_2, ..., X_n$ un campione casuale estratto da una popolazione normale con media incognita. Si può formulare l'ipotesi che la media di tale popolazione sia 12. Formalmente si esprime con:

$$\mathrm{H}: \ \mu = 12$$

1. Inferenza statistica
2. Test di ipotesi
   - Null Hypothesis Significance Testing (NHST)
3. Distribuzioni campionarie
4. Valore critico

Due approcci... e un ibrido

Fisher (1925)

- Solo H_0, nessuna ipotesi alternativa formale
- Il p-value indica quanto i dati sono poco compatibili con H_0 (misura graduata dell'evidenza **contro** H_0)

Neyman e Pearson (1933)

- H_0 contro H_1
- α e β fissati prima di raccogliere i dati $\rightarrow$ decisione: si rifiuta o non si rifiuta H_0

NHST

È una *forzatura* dei due approcci: prende H_0 e il p-value da Fisher, H_1, α e β da Neyman e Pearson, e li mette insieme (anche se i due approcci hanno logiche diverse)

Ipotesi nulla e ipotesi alternativa

Le distribuzioni di probabilità a livello delle popolazioni che identificano lo schema logico del confronto sono classificate in due gruppi distinti:

- $\mathbf{H}_0$: definita come **l'ipotesi nulla**
- $\mathbf{H}_A$: definita come **l'ipotesi alternativa**

L'ipotesi alternativa viene indicata con altri simboli equivalenti come $\mathbf{H}_1$ oppure $\mathbf{K}$, che sono di fatto sinonimi del più diffuso H_A.

Nota

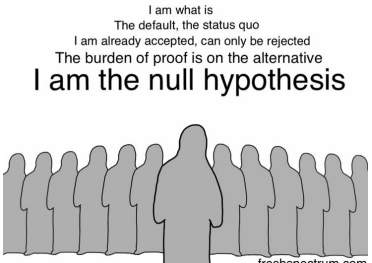
H_0 è definita come la **negazione logica** di H_A e viceversa.
Ad esempio, supponiamo che H_0 affermi che $\mu \leq \mu_0$, allora H_A indica la relazione complementare $\mu > \mu_0$.

$$\Theta_0 = (\Theta_A)^c$$

1. **Ipotesi** H_0: è l'ipotesi che costituisce l'oggetto del test; specifica i valori dei parametri della popolazione da cui si suppone provenga il campione (o i campioni) in esame. Stabilisce che i diversi valori ottenuti nel campione sono puramente **casuali**. Formalmente si esprime con:

$$H_0 : \theta = \theta_0$$

dove θ indica il parametro della popolazione e θ_0 il valore che ci si attende



2. **Ipotesi** H_1: è l'ipotesi alternativa, solitamente l'ipotesi di ricerca secondo la quale i risultati ottenuti **non sono casuali** ma sono spiegabili secondo una qualche regola o teoria. L'ipotesi alternativa può essere:

Bidirezionale

$$\theta \neq \theta_0$$

Monodirezionale

Sinistra

$$\theta < \theta_0$$

Destra

$$\theta > \theta_0$$

Esempio

Si vuole stabilire, attraverso un esperimento, se una moneta sia truccata o meno. Si indicherà con π la probabilità di ottenere testa in un lancio. Prima di eseguire l'esperimento si devono formulare le due ipotesi relativamente al parametro π:

- H_0 : $\pi = .50$ la moneta non è truccata
- H_1 : $\pi \neq .50$ la moneta è truccata

Il problema è stabilire se i risultati dell'esperimento (ad es. lanciare una moneta 30 volte) falsificano o meno l'ipotesi;

I valori empirici possono considerarsi dovuti a fluttuazioni casuali intorno al valore atteso e di conseguenza non confutare H_0?

Oppure il risultato non lo consente, le fluttuazioni non sono casuali ma sistematiche e di conseguenza H_0 è confutata?

La decisione si basa sul calcolo di un test statistico e sulla probabilità associata al valore di tale test:

Test statistico

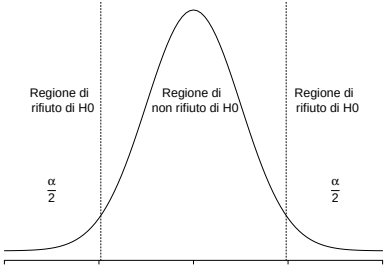
Valore di una variabile casuale che può assumere i valori di una distribuzione campionaria caratterizzata da una determinata distribuzione di probabilità

Ogni test statistico divide lo spazio campionario:

1. Regione di non rifiuto di H_0
2. Regione di rifiuto di H_0

In base alla regione in cui andrà a cadere il valore campionario, si prenderà una decisione sull'ipotesi H_0

Le regioni di rifiuto e di accettazione corrispondono ad aree di probabilità sottese alla curva



Regione di non rifiuto: valori delle statistiche campionarie con probabilità maggiori di verificarsi

Regione di rifiuto: valori delle statistiche campionarie con probabilità molto basse di verificarsi

1 Inferenza statistica

2 Test di ipotesi

3 Distribuzioni campionarie

4 Valore critico

Distribuzione campionaria

> *La **distribuzione campionaria** è la distribuzione di probabilità relativa a una specifica statistica calcolata su tutti i k campioni estraibili da una popolazione*

Per determinare una distribuzione campionaria:

1. Estrarre tutti i possibili k campioni dalla popolazione di interesse con campionamento *casuale e indipendente* $\rightarrow$ ogni unità di analisi deve avere la stessa probabilità di essere estratta e l'estrazione di una unità non deve modificare la probabilità delle altre unità
2. Calcolare su ognuno dei k campioni la statistica di interesse
3. Determinare (i.e., contare) la frequenza per ognuno dei valori della statistica $\rightarrow$ quanti *campioni* presentano quel valore

1 Inferenza statistica

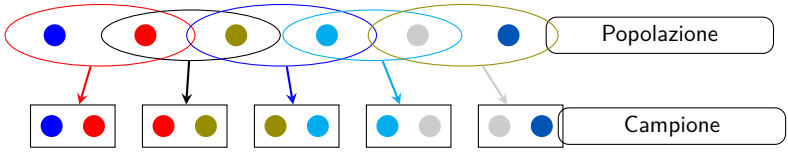
2 Test di ipotesi

3 Distribuzioni campionarie
- Distribuzione campionaria della media

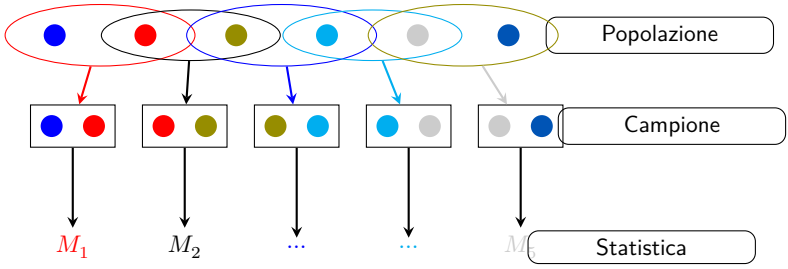
4 Valore critico

Distribuzione campionaria della media

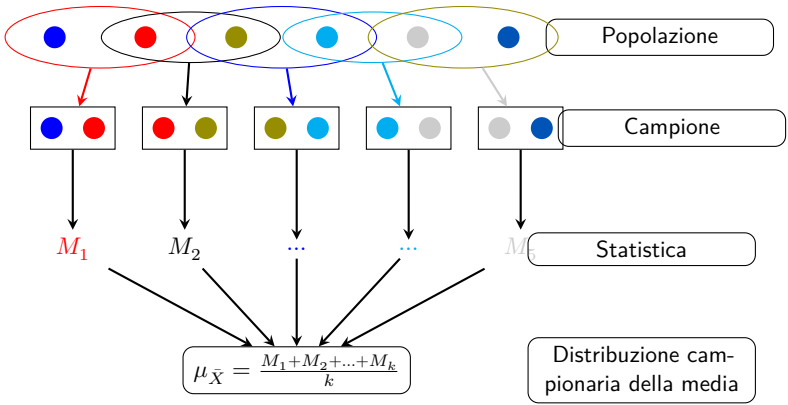




N.B.: Sono illustrati solo alcuni dei possibili k campioni



N.B.: Sono illustrati solo alcuni dei possibili k campioni



N.B.: Sono illustrati solo alcuni dei possibili k campioni

Esempio

Popolazione: $N = 5$

Campione: $n = 2$, somministrato un test con punteggio 0–10

Popolazione $N = 5$

Soggetto	Punteggio
Giorgio	6
Alessandra	8
Francesco	10
Livio	3
Jessica	8

$$\mu = \frac{6 + 8 + 10 + 3 + 8}{5} = 7$$

Esempio

Popolazione: $N = 5$

Campione: $n = 2$, somministrato un test con punteggio 0–10

Popolazione $N = 5$

Soggetto	Punteggio
Giorgio	6
Alessandra	8
Francesco	10
Livio	3
Jessica	8

Campione $n = 2$

Soggetto	Punteggio
Giorgio	6
Alessandra	8

$$\bar{X} = \frac{6+8}{2} = 7$$

$$\mu = \frac{6+8+10+3+8}{5} = 7$$

Esempio

Popolazione: $N = 5$

Campione: $n = 2$, somministrato un test con punteggio 0–10

Popolazione $N = 5$

Soggetto	Punteggio
Giorgio	6
Alessandra	8
Francesco	10
Livio	3
Jessica	8

$$\mu = \frac{6 + 8 + 10 + 3 + 8}{5} = 7$$

Campione $n = 2$

Soggetto	Punteggio
Giorgio	6
Alessandra	8

$$\bar{X} = \frac{6 + 8}{2} = 7$$

E un altro campione?

Soggetto	Punteggio
Alessandra	8
Francesco	10

$$\bar{X} = \frac{8 + 10}{2} = 9$$

Tutti i campioni possibili

Campione	Elemento 1	Elemento 2	Valore 1	Valore 2	**Media**	Campione	Elemento 1	Elemento 2	Valore 1	Valore 2	**Media**
1	G	G	6	6	6	16	L	G	3	6	4.5
2	G	A	6	8	7	17	L	A	3	8	5.5
3	G	F	6	10	8	18	L	F	3	10	6.5
4	G	L	6	3	4.5	19	L	L	3	3	3
5	G	J	6	8	7	20	L	J	3	8	5.5
6	A	G	8	6	7	21	J	G	8	6	7
7	A	A	8	8	8	22	J	A	8	8	8
8	A	F	8	10	9	23	J	F	8	10	9
9	A	L	8	3	5.5	24	J	L	8	3	5.5
10	A	J	8	8	8	25	J	J	8	8	8
11	F	G	10	6	8						
12	F	A	10	8	9						
13	F	F	10	10	10						
14	F	L	10	3	6.5						
15	F	J	10	8	9						

$$\mu_{\bar{x}} = \frac{6 \cdot 1 + 7 \cdot 4 + 8 \cdot 6 + 4.5 \cdot 2 + 9 \cdot 4 + 5.5 \cdot 4 + 10 \cdot 1 + 6.5 \cdot 2 + 3 \cdot 1}{25} = 7$$

Tutti i campioni possibili

Campione	Elemento 1	Elemento 2	Valore 1	Valore 2	**Media**	Campione	Elemento 1	Elemento 2	Valore 1	Valore 2	**Media**
1	G	G	6	6	6	16	L	G	3	6	4.5
2	G	A	6	8	7	17	L	A	3	8	5.5
3	G	F	6	10	8	18	L	F	3	10	6.5
4	G	L	6	3	4.5	19	L	L	3	3	3
5	G	J	6	8	7	20	L	J	3	8	5.5
6	A	G	8	6	7	21	J	G	8	6	7
7	A	A	8	8	8	22	J	A	8	8	8
8	A	F	8	10	9	23	J	F	8	10	9
9	A	L	8	3	5.5	24	J	L	8	3	5.5
10	A	J	8	8	8	25	J	J	8	8	8
11	F	G	10	6	8						
12	F	A	10	8	9						
13	F	F	10	10	10						
14	F	L	10	3	6.5						
15	F	J	10	8	9						

$$\mu_{\bar{x}} = \frac{6 \cdot 1 + 7 \cdot 4 + 8 \cdot 6 + 4.5 \cdot 2 + 9 \cdot 4 + 5.5 \cdot 4 + 10 \cdot 1 + 6.5 \cdot 2 + 3 \cdot 1}{25} = 7$$

$$\mu = \mu_{\bar{x}} = 7$$

1 Inferenza statistica

2 Test di ipotesi

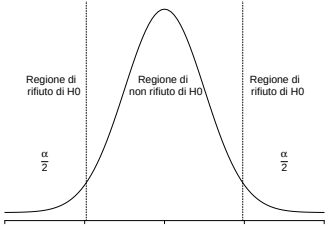
3 Distribuzioni campionarie

4 Valore critico

È il valore che separa le due regioni

Per stabilire se il valore di un test è coerente o meno con l'ipotesi nulla è necessario verificare che il suo valore sia compreso all'interno della **regione di non rifiuto**.

Se il valore campionario cade nella **regione di rifiuto** c'è da ritenere che le osservazioni campionarie si discostino dai valori più probabili della distribuzione; in tal caso si può decidere di rifiutare H_0.



I valori delle statistiche campionarie che cadono nella **zona di rifiuto** sono comunque in grado di verificare l'ipotesi nulla ma la loro probabilità è così bassa ($\leq \alpha$) che si accetta il rischio di rifiutare H_0



Figure 1: Stai barando vero? Come è possibile che tu vinca a ogni mano?? Le probabilità sono 50-50, vuol dire che stai barando!!!!!

Una decisione di questo tipo comporta quindi degli errori

Decisione	Ipotesi: H_0 vera	Ipotesi: H_0 falsa
Non si rifiuta H_0	Corretta	Errata
Si rifiuta H_0	Errata	Corretta

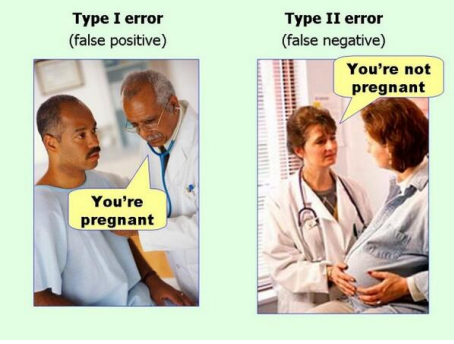
1 Inferenza statistica

2 Test di ipotesi

3 Distribuzioni campionarie

4 Valore critico
- Errori di I e II tipo
- Regola decisionale
- Cos'è il p-value?

decisione	*ipotesi* H_0 *vera*	H_0 *falsa*
si accetta H_0	corretta	errore II tipo
si rifiuta H_0	errore I tipo	corretta



Non è mai possibile sapere con certezza se è vera H_0, l'unica cosa che si può fare è **minimizzare** la probabilità di prendere una decisione sbagliata

Si è definita la probabilità di non rifiutare H_0 quando è vera come $1 - \alpha$

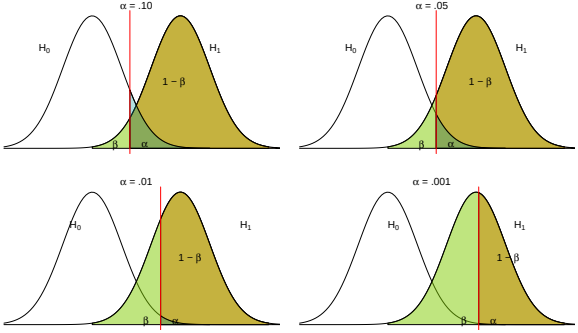
Facendo un ragionamento analogo su H_1 e definendo β la probabilità di non rifiutare H_0 quando è falsa si avrà una regione $1 - \beta$ che corrisponde alla probabilità di rifiutare H_0 quando è falsa

		Ipotesi	
		H_0 vera	H_0 falsa
Decisione	Non si rifiuta H_0	Corretta $(1 - \alpha)$	Errore di II tipo (β)
	Si rifiuta H_0	Errore di I tipo (α)	Corretta $(1 - \beta)$

Quello che si controlla: α (la probabilità di commettere un errore di I tipo)

Quello che viene ignorato: β (la probabilità di commettere un errore di II tipo)

Relazione tra α e β



α	β	$1-\beta$
.10	.04	.96
.05	.09	.91
.01	.25	.75
.001	.54	.46

$\mu_0 = 0$, $\mu_1 = 3$

1 Inferenza statistica

2 Test di ipotesi

3 Distribuzioni campionarie

4 Valore critico
- Errori di I e II tipo
- Regola decisionale
- Cos'è il p-value?

Valore critico e p-value

In generale, se indichiamo con ψ_c e ψ_o rispettivamente il **valore critico** e il **valore osservato** di una statistica ψ, allora sussiste il seguente rapporto relazionale tra $(p\text{-value}, \alpha)$ e (ψ_c, ψ_o):

$$\begin{array}{c} p\text{-value} < \alpha \Rightarrow H_A \\ p\text{-value} \geq \alpha \Rightarrow \neg H_A \end{array} \quad \Leftrightarrow \quad \begin{array}{c} \psi_c < \psi_o \Rightarrow H_A \\ \psi_c \geq \psi_o \Rightarrow \neg H_A \end{array}$$

Significatività statistica

Un risultato si dice statisticamente significativo (rigetto ipotesi nulla H_0) nel caso in cui il valore della statistica critica ψ_c (calcolato sulla base di α) sia strettamente minore del valore della statistica osservata ψ_o.
Un risultato si dice statisticamente non significativo (non rigetto ipotesi nulla H_0) nel caso in cui il valore della statistica critica ψ_c (calcolato sulla base di α) sia maggiore o uguale al valore della statistica osservata ψ_o.

1 Inferenza statistica

2 Test di ipotesi

3 Distribuzioni campionarie

4 Valore critico
- Errori di I e II tipo
- Regola decisionale
- Cos'è il p-value?

Il p-value indica la probabilità di osservare un valore uguale o più estremo rispetto a quello osservato, ***posto che sia vera*** H_0

$$P(x \geq T_0 | H_0) = p\text{-value}$$

Un esempio

$T_0 = 2.70$, p-value $= .0073$ $(p < .01)$
Replicando per molte molte volte l'esperimento, quante volte ci si aspetta di rifiutare H_0?

Il p-value indica la probabilità di osservare un valore uguale o più estremo rispetto a quello osservato, ***posto che sia vera*** H_0

$$P(x \geq T_0 | H_0) = p\text{-value}$$

Un esempio

$T_0 = 2.70$, p-value $= .0073$ $(p < .01)$
Replicando per molte molte volte l'esperimento, quante volte ci si aspetta di rifiutare H_0?
$P(T_0 \geq 2.70 | H_0) = .0073$: Se fosse vera H_0, il risultato osservato sarebbe un risultato estremamente poco probabile, per cui questo risultato si osserverebbe meno dell'1% delle volte

Dettagli sul p-value

- Il p-value è la probabilità di ottenere un valore uguale o più estremo rispetto a T_0 *se* H_0 *fosse vera*. NON è la probabilità che H_0 sia vera $\rightarrow$ non può essere usato come indicatore della verità o falsità di H_0
- Il p-value è sensibile all'ampiezza campionaria: all'aumentare dell'ampiezza campionaria, diminuisce il p-value, aumenta la probabilità di rigettare H_0
- Il p-value permette solo di prendere una decisione qualitativa nei termini di "Non rigetto H_0" vs. "Rigetto H_0" $\rightarrow$ **Non è una misura dell'evidenza statistica**