

Modulo Didattico 5: Statistica inferenziale - Indici di centralità attraverso il t -test

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania

1 Un campione

2 Due campioni indipendenti

3 Due campioni appaiati

Test a due code (two-sided)

$$H_0 : \mu = \mu_0 \quad H_A : \mu \neq \mu_0$$

Una coda-destra (one-sided right)

$$H_0 : \mu \leq \mu_0 \quad H_A : \mu > \mu_0$$

Una coda sinistra (one-sided left)

$$H_0 : \mu \geq \mu_0 \quad H_A : \mu < \mu_0$$

1 Un campione

- In R
- Esempi

2 Due campioni indipendenti

3 Due campioni appaiati

1 Un campione

- In R
- Esempi

2 Due campioni indipendenti

3 Due campioni appaiati

```
set.seed(999)
x = rnorm(11, mean = 12, sd = 7.5)
mu0 = 10
t.test(x, mu = mu0) # test a due code
t.test(x, mu = mu0,
       alternative = "greater") # test a una coda destra
t.test(x, mu = mu0,
       alternative = "less") # test a una coda sinistra
t.test(x) # test a due code assumedno mu0 = 0
```

```
t.test(x, mu = mu0) # test a due code
```

One Sample t-test

```
data: x
t = -0.72806, df = 10, p-value = 0.4833
alternative hypothesis: true mean is not equal to 10
95 percent confidence interval:
 3.50030 13.29817
sample estimates:
mean of x
 8.399236
```

```
t.test(x, mu = mu0) # test a due code
```

Tipo di test

One Sample t-test

$$Df = N - 1$$

Statistica
test

```
data:  x
```

$t = -0.72806$, $df = 10$, $p\text{-value} = 0.4833$ **P-value**

alternative hypothesis: true mean is not equal to 10

95 percent confidence interval:

3.50030 13.29817

sample estimates:

mean of x

8.399236

```
t.test(x, mu = mu0) # test a due code
```

One Sample t-test

```
data: x
```

```
t = -0.72806, df = 10, p-value = 0.4833
```

Ipotesi inferenziale

```
alternative hypothesis: true mean is not equal to 10
```

```
95 percent confidence interval:
```

```
3.50030 13.29817
```

IC al 95%


```
sample estimates:
```

```
mean of x
```

```
8.399236
```

Esempi

$$\begin{aligned} p\text{-value} &= \int_{-\infty}^{-|t_o|} f_T(t | \theta) dt + \int_{|t_o|}^{\infty} f_T(t | \theta) dt \\ &= 2 \int_{|t_o|}^{\infty} f_T(t | \theta) dt \end{aligned}$$



t_0 : Statistica test osservata -0.7281

$f_T(t|\theta)$: Distribuzione t di Student con parametro θ (ovvero i gdl)

calcolo p-value

```
2*(1-pt(abs(-0.72806),10))
```


```
[1] 0.4832762
```

```
t.test(x, mu = mu0,  
       alternative = "greater") # test a una coda destra
```

One Sample t-test

```
data: x  
t = -0.72806, df = 10, p-value = 0.7584  
alternative hypothesis: true mean is greater than 10  
95 percent confidence interval:  
 4.414237      Inf  
sample estimates:  
mean of x  
 8.399236
```

$$p\text{-value} = \int_{t_o}^{\infty} f_T(t | \theta) dt$$



t_0 : Statistica test osservata -0.7281

$f_T(t|\theta)$: Distribuzione t di Student
con parametro θ (ovvero i gdl)

calcolo p-value

```
1-pt(-0.72806, 10)
```


```
[1] 0.7583619
```

```
t.test(x, mu = mu0,  
       alternative = "less") # test a una coda sinistra
```

One Sample t-test

```
data: x  
t = -0.72806, df = 10, p-value = 0.2416  
alternative hypothesis: true mean is less than 10  
95 percent confidence interval:  
  -Inf 12.38424  
sample estimates:  
mean of x  
  8.399236
```

$$p\text{-value} = \int_{-\infty}^{t_o} f_T(t | \theta) dt$$



t_0 : Statistica test osservata -0.7281

$f_T(t|\theta)$: Distribuzione t di Student
con parametro θ (ovvero i gdl)

calcolo p-value

`pt(-0.72806, 10)`

`[1] 0.2416381`

- 1 Un campione
- 2 Due campioni indipendenti
- 3 Due campioni appaiati

Scopo

Permette di valutare se la media μ_X della popolazione di un campione di dati x sia significativamente differente (risp. maggiore/minore) rispetto alla media μ_Y della popolazione di un campione di dati y .

Sia $\mathbf{x} = (x_1, x_2, \dots, x_N)$ un campione empirico di N osservazioni quantitative indipendenti tali che $x_i \sim N(\mu_X, \sigma^2)$ e sia $\mathbf{y} = (y_1, y_2, \dots, y_M)$ un campione empirico di M osservazioni quantitative indipendenti tali che $y_j \sim N(\mu_Y, \sigma^2)$, dove σ^2 è la varianza comune ad entrambe le popolazioni.

$$t = \frac{(\bar{x} - \bar{y}) - (\mu_x - \mu_y)}{s \sqrt{\frac{1}{N} + \frac{1}{M}}}$$

$$s = \sqrt{\frac{(N-1)\text{var}(\mathbf{x}) + (M-1)\text{var}(\mathbf{y})}{N+M-2}}$$

Test a due code (two-sided)

$$\begin{array}{ll} H_0 : \mu_X = \mu_Y & H_A : \mu_X \neq \mu_Y \\ H_0 : \mu_X - \mu_Y = 0 & H_A : \mu_X - \mu_Y \neq 0 \end{array}$$

Una coda-destra (one-sided right)

$$\begin{array}{ll} H_0 : \mu_X \leq \mu_Y & H_A : \mu_X > \mu_Y \\ H_0 : \mu_X - \mu_Y \leq 0 & H_A : \mu_X - \mu_Y > 0 \end{array}$$

Una coda sinistra (one-sided left)

$$\begin{array}{ll} H_0 : \mu_X \geq \mu_Y & H_A : \mu_X < \mu_Y \\ H_0 : \mu_X - \mu_Y \geq 0 & H_A : \mu_X - \mu_Y < 0 \end{array}$$

1 Un campione

2 Due campioni indipendenti

- In R
- Esempi

3 Due campioni appaiati

1 Un campione

2 Due campioni indipendenti

- In R
- Esempi

3 Due campioni appaiati

Esempi

```
x <- c(12.2,23.2,14,20.3,9.2,3.7,8,16.8,3.7,1.9,20.5)
y <- c(8.5,3.2,4,10.5,7.7,3.1,2,3.9)
t.test(x,y,var.equal=TRUE)
t.test(x,y,var.equal=TRUE,alternative="greater")
t.test(x,y,var.equal=TRUE,alternative="less")
t.test(x,y)
```

Test a due code `var.equal=TRUE`

```
t.test(x,y,var.equal=TRUE)
```

Two Sample t-test

data: x and y

t = 2.4064, df = 17, p-value = 0.02776

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

0.8349434 12.7127839

sample estimates:

mean of x mean of y

12.13636 5.36250

```
var.equal=FALSE
```

```
t.test(x,y)
```

Welch Two Sample t-test

```
data:  x and y
```

```
t = 2.708, df = 14.144, p-value = 0.01687
```

```
alternative hypothesis: true difference in means is not equal to 0
```

```
95 percent confidence interval:
```

```
 1.413924 12.133803
```

```
sample estimates:
```

```
mean of x mean of y
```

```
12.13636    5.36250
```

- 1 Un campione
- 2 Due campioni indipendenti
- 3 Due campioni appaiati**

Scopo

Permette di valutare se le medie μ_x e μ_y delle popolazioni di due campioni di dati appaiati (x, y) siano significativamente differenti (risp. maggiore/minore).

Sia $(\mathbf{x}, \mathbf{y}) = ((x_1, y_1), (x_2, y_2), \dots, (x_N, y_N))$ un campione bivariato di N osservazioni (x_i, y_i) indipendenti. Inoltre sia $d_i \sim N(d \mid \mu_D, \sigma^2)$ l'osservazione differenziale $d_i = x_i - y_i$ derivata da $(\mathbf{x}, \mathbf{y})$. I parametri μ_D e σ^2 sono i termini ignoti della variabile differenziale D .

$$t = \frac{\bar{d}}{\sqrt{\text{var}(\mathbf{d})/N}}$$

Test a due code (two-sided)

$$H_0 : \mu_D = 0 \quad H_A : \mu_D \neq 0$$

Una coda-destra (one-sided right)

$$H_0 : \mu_D \leq 0 \quad H_A : \mu_D > 0$$

Una coda sinistra (one-sided left)

$$H_0 : \mu_D \geq 0 \quad H_A : \mu_D < 0$$

- 1 Un campione
- 2 Due campioni indipendenti
- 3 Due campioni appaiati**
 - In R
 - Esempi

◀ ◻ ▶ ◀ ◼ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡

- 1 Un campione
- 2 Due campioni indipendenti
- 3 Due campioni appaiati**
 - In R
 - Esempi

Esempi

```
x = c(5.2,3.5,3.4,7.1,6.2,3.0,1,4)
y = c(8.5,3.2,4,10.5,7.7,3.1,2,3.9)
```

```
t.test(x,y,paired=TRUE)
t.test(x,y,paired=TRUE,alternative="less")
t.test(x,y,paired=TRUE,alternative="greater")
```

```
t.test(x,y,paired=TRUE,alternative="less")
```

Paired t-test

data: x and y

t = -2.303, df = 7, p-value = 0.02737

alternative hypothesis: true mean difference is less than 0

95 percent confidence interval:

-Inf -0.2106053

sample estimates:

mean difference

-1.1875