Modulo Didattico 5: Principi base di inferenza statistica

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
Univeristà di Trento
ottavia.epifania@unitn.it

A.A. 2026/2027

```
> t.test(mpg ~ am, data = mtcars)

        Welch Two Sample t-test

data:  mpg by am
t = -3.7671, df = 18.332, p-value = 0.001374
alternative hypothesis: true difference in means between group 0 and
  group 1 is not equal to 0
95 percent confidence interval:
 -11.280194  -3.209684
sample estimates:
mean in group 0 mean in group 1
       17.14737        24.39231
```

1. Tipo di test (Welch: varianze non assunte uguali)
2. Statistica test t
3. Gradi di libertà
4. p-value
5. H_1: bidirezionale
6. Intervallo di confidenza al 95%
7. Medie dei due gruppi

1 Inferenza statistica

2 Stimatore

3 Distribuzioni campionarie

4 Test di ipotesi

5 Valore critico

6 Cos'è il p-value?

L'**inferenza statistica** è definita come un insieme di metodi, basati sulla teoria della probabilità, tali per cui si possano trarre conclusioni plausibili sulla variabile casuale associata ad una particolare caratteristica di una *popolazione* a partire dall'osservazione di un **campione** di elementi della popolazione stessa.

Secondo l'impostazione classica, la teoria dell'inferenza statistica si sviluppa lungo due direttrici:

- Teoria della **stima di parametri**
- Teoria della **verifica di ipotesi**

La maggior parte degli studi viene condotta su "gruppi" più o meno ampi di elementi che appartengono ad un insieme più ampio definito POPOLAZIONE

Popolazione

Rappresenta tutto l'universo di individui a cui si rivolge l'attenzione del ricercatore (ad es. la popolazione degli studenti della scuola elementare)

Campione

Sottoinsieme della popolazione, possibilmente composto da unità estratte **casualmente** dalla popolazione.

POPOLAZIONE

Finita (N)

È possibile avere informazioni rispetto al numero di unità di analisi che la compongono
Molto piccola (e.g., persone con sindrome rara) o molto grande (e.g., tutti gli studenti di psicologia)

Infinita

Non è possibile conoscere con precisione il numero di unità di analisi che la compongono (anche se hanno un numero finito)
Non è possibile determinare il numero di unità di analisi che la compongono (e.g., lanci di un dado)



CAMPIONAMENTO

con o senza reinserimento



Campione

finito (n)

Lo studio *dell'intera popolazione* porta alla **certezza delle conclusioni**

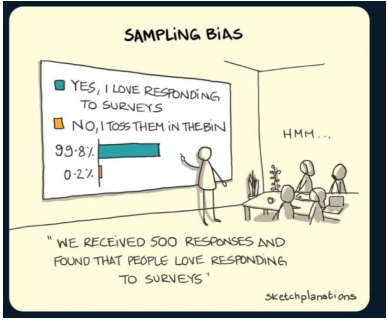
Esempio

Si vuole verificare se il reddito familiare medio degli studenti di psicologia in Italia (popolazione A) sia superiore a quello dei loro colleghi in Francia (popolazione B). Se si calcolasse il reddito medio di tutte le famiglie italiane e francesi il risultato (indipendentemente da quale) sarebbe certo

Studiare l'intera popolazione è irrealistico (a livello di risorse umane, economiche, temporali ecc.) $\rightarrow$ è necessario l'utilizzo dei campioni e della statistica inferenziale.

Un'*indagine campionaria* **non offre la certezza delle conclusioni**: quello che si osserva su due campioni A e B potrebbe non riflettere la realtà delle popolazioni

Il modo in cui viene selezionato il campione è di fondamentale importanza!!



Gli strumenti statistici consentono di valutare **probabilisticamente** gli errori che si possono commettere traendo conclusioni sulle popolazioni a partire dalle caratteristiche di uno o più campioni

Gli errori di un'indagine campionaria possono essere ridotti se il campione è **rappresentativo** della popolazione; dovrebbe cioè *possedere le caratteristiche della popolazione dalla quale proviene*

Campionamento casuale

Se il campione è estratto *casualmente* dalla popolazione si può affermare che eventuali differenze sono dovute "al caso", dovute cioè *a variazioni accidentali e non sistematiche*

Non solo come... ma anche quanto! L'importanza dell'ampiezza campionaria per studi che permettano inferenze "valide"



1 Inferenza statistica

2 Stimatore

3 Distribuzioni campionarie

4 Test di ipotesi

5 Valore critico

6 Cos'è il p-value?

Un **indicatore o statistica** o più comunemente **STIMATORE** è una funzione dei valori osservati sul campione $(X_1, X_2, ..., X_n)$, utilizzato per la stima di un **parametro** (generalmente incognito) di una **popolazione** e che (possibilmente) rispetta una serie di caratteristiche.

Stima:

- *Stima puntuale*: il metodo di stima conduce ad un unico valore per il parametro in oggetto
- *Stima intervallare*: il metodo di stima conduce ad un intervallo di valori, all'interno dei quali si suppone che si trovi con una certa probabilità il valore vero del parametro

Proprietà di uno stimatore

Uno stimatore è tanto migliore quanto più rispetta queste proprietà:

- **Correttezza** (o non distorsione): in media, su tutti i campioni possibili, lo stimatore restituisce il valore del parametro $\rightarrow$ ad es., $\mu_{\bar{x}} = \mu$
- **Efficienza**: tra due stimatori corretti, è più efficiente quello con varianza minore $\rightarrow$ le stime cambiano meno da un campione all'altro
- **Consistenza**: all'aumentare dell'ampiezza campionaria n, le stime si avvicinano sempre di più al valore del parametro

La media campionaria $\bar{x}$ è uno stimatore corretto e consistente della media della popolazione μ (lo si vede nell'esempio sulle distribuzioni campionarie)

La **statistica inferenziale** ha pertanto l'obiettivo di stimare incogniti parametri attraverso certe funzioni dei dati campionari (*indicatori* o *stimatori*).

Si calcolano, quindi, le **STATISTICHE** (ad es., $\bar{x}$) del campione per conoscere i **PARAMETRI** (ad es., μ) della popolazione.

Questo passaggio dalle STATISTICHE ai PARAMETRI si basa sulla conoscenza delle proprietà delle **DISTRIBUZIONI CAMPIONARIE** delle statistiche (ad es., $\bar{x}$)

1 Inferenza statistica

2 Stimatore

3 Distribuzioni campionarie

4 Test di ipotesi

5 Valore critico

6 Cos'è il p-value?

*La **distribuzione campionaria** è la distribuzione di probabilità relativa a una specifica statistica calcolata su tutti i k campioni estraibili da una popolazione*

Per determinare una distribuzione campionaria:

1. Estrarre tutti i possibili k campioni dalla popolazione di interesse con campionamento *casuale e indipendente* $\rightarrow$ ogni unità di analisi deve avere la stessa probabilità di essere estratta e l'estrazione di una unità non deve modificare la probabilità delle altre unità
2. Calcolare su ognuno dei k campioni la statistica/stimatore di interesse (ad esempio, la media $\bar{x}$)
3. Determinare (i.e., contare) la frequenza per ognuno dei valori della statistica $\rightarrow$ quanti *campioni* presentano quel valore

1 Inferenza statistica

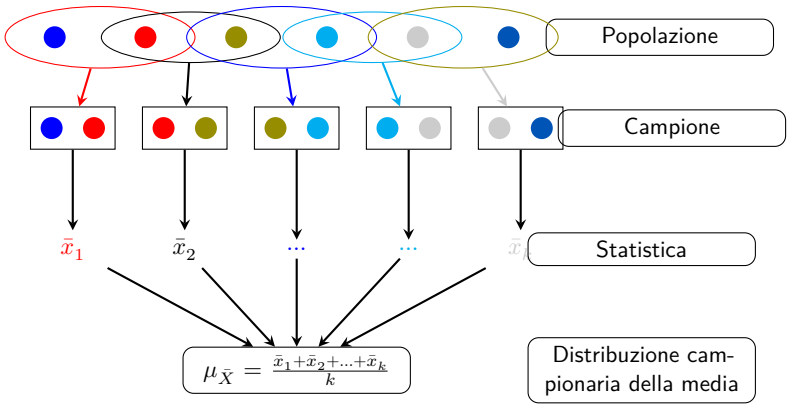
2 Stimatore

3 Distribuzioni campionarie
- Distribuzione campionaria della media
- Determinare la distribuzione campionaria

4 Test di ipotesi

5 Valore critico

6 Cos'è il p-value?



N.B.: Sono illustrati solo alcuni dei possibili k campioni

1 Inferenza statistica

2 Stimatore

3 Distribuzioni campionarie

- Distribuzione campionaria della media
- Determinare la distribuzione campionaria

4 Test di ipotesi

5 Valore critico

6 Cos'è il p-value?

Popolazione: $N = 5$
Campione: $n = 2$, somministrato un test con punteggio 0–10

Popolazione $N = 5$

Soggetto	Punteggio
Giorgio	6
Alessandra	8
Francesco	10
Luca	3
Jessica	8

$$\mu = \frac{6 + 8 + 10 + 3 + 8}{5} = 7$$

Campione $n = 2$

Soggetto	Punteggio
Giorgio	6
Alessandra	8

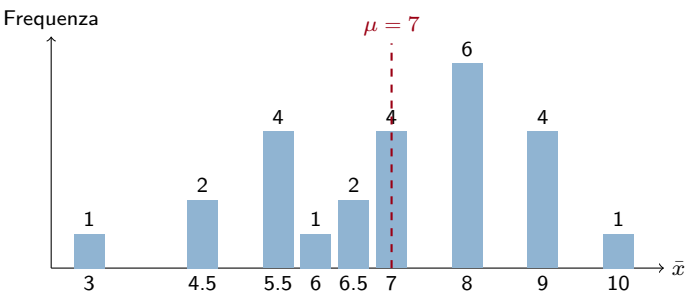
$$\bar{x} = \frac{6 + 8}{2} = 7$$

E un altro campione?

Soggetto	Punteggio
Alessandra	8
Francesco	10

$$\bar{x} = \frac{8 + 10}{2} = 9$$

Campione	Elemento 1	Elemento 2	Valore 1	Valore 2	**Media**	Campione	Elemento 1	Elemento 2	Valore 1	Valore 2	**Media**
1	G	G	6	6	6	16	L	G	3	6	4.5
2	G	A	6	8	7	17	L	A	3	8	5.5
3	G	F	6	10	8	18	L	F	3	10	6.5
4	G	L	6	3	4.5	19	L	L	3	3	3
5	G	J	6	8	7	20	L	J	3	8	5.5
6	A	G	8	6	7	21	J	G	8	6	7
7	A	A	8	8	8	22	J	A	8	8	8
8	A	F	8	10	9	23	J	F	8	10	9
9	A	L	8	3	5.5	24	J	L	8	3	5.5
10	A	J	8	8	8	25	J	J	8	8	8
11	F	G	10	6	8						
12	F	A	10	8	9						
13	F	F	10	10	10						
14	F	L	10	3	6.5						
15	F	J	10	8	9						



$$\mu_{\bar{x}} = \frac{6 \cdot 1 + 7 \cdot 4 + 8 \cdot 6 + 4.5 \cdot 2 + 9 \cdot 4 + 5.5 \cdot 4 + 10 \cdot 1 + 6.5 \cdot 2 + 3 \cdot 1}{25} = 7$$

$$\mu = \mu_{\bar{x}} = 7$$

Le medie campionarie si distribuiscono **attorno a** $\mu = 7$: alcuni campioni sovrastimano μ, altri lo sottostimano, ma **in media** lo stimatore restituisce il valore del parametro (correttezza)

Errore standard

Oltre al centro della distribuzione campionaria serve sapere **quanto variano** le medie da un campione all'altro

Errore standard della media

È la deviazione standard della distribuzione campionaria della media:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

dove σ è la deviazione standard della popolazione e n l'ampiezza dei campioni

Nell'esempio: $\sigma^2 = 5.6$ (varianza della popolazione), mentre la varianza delle 25 medie è $2.8 = \frac{5.6}{2}$, quindi $\sigma_{\bar{x}} = \frac{\sqrt{5.6}}{\sqrt{2}} = 1.67$

All'aumentare di n l'errore standard diminuisce $\rightarrow$ con campioni più grandi la media campionaria è una stima più precisa di μ (consistenza)

Forma della distribuzione campionaria

Teorema del limite centrale

Se l'ampiezza campionaria n è sufficientemente grande (regola pratica: $n \geq 30$), la distribuzione campionaria della media è **approssimativamente normale**, con media μ e deviazione standard $\frac{\sigma}{\sqrt{n}}$, *qualunque sia la forma della distribuzione nella popolazione*

Se la popolazione ha distribuzione normale, la distribuzione campionaria della media è normale per qualsiasi n

Standardizzando la media campionaria si ottiene una variabile normale standard:

$$z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

1 Inferenza statistica

2 Stimatore

3 Distribuzioni campionarie

4 Test di ipotesi

5 Valore critico

6 Cos'è il p-value?

Obiettivi dell'inferenza statistica:

- Stima dei parametri
- **Test di ipotesi**

$\downarrow$

Procedura che si svolge per passi logici successivi:

- (Porsi una domanda di ricerca) (dotata di senso) (basata sulla letteratura)
- Formulazione ipotesi riguardanti i parametri della popolazione
- Definizione dei criteri e dei vincoli di accettazione dell'ipotesi
- Raccolta dati campionari
- Valutazione delle ipotesi formulate

Le ipotesi di ricerca sono ipotesi statistiche:

- consistono in affermazioni di tipo logico-matematico che definiscono i rapporti fra i parametri di una o più popolazioni
- il test delle ipotesi consiste in un **processo di decisione che termina nel non rifiuto delle affermazioni contenute nelle ipotesi stesse**
- Un'ipotesi statistica è un'asserzione o supposizione sulla distribuzione di una o più variabili casuali, o su uno o più parametri della stessa, e si indica con la lettera ***H***.

Esempio

Sia $X_1, X_2, \ldots, X_n$ un campione casuale estratto da una popolazione normale con media incognita. Si può formulare l'ipotesi che la media di tale popolazione sia 12. Formalmente si esprime con:

$$\mathrm{H}: \ \mu = 12$$

1 Inferenza statistica

2 Stimatore

3 Distribuzioni campionarie

4 Test di ipotesi
- Null Hypothesis Significance Testing (NHST)

5 Valore critico

6 Cos'è il p-value?

Fisher (1925)

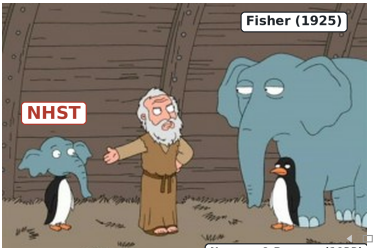
- Solo H_0, nessuna ipotesi alternativa formale
- Il p-value indica quanto i dati sono poco compatibili con H_0

Neyman e Pearson (1933)

- H_0 contro H_1
- α e β fissati prima di raccogliere i dati $\rightarrow$ decisione: si rifiuta o non si rifiuta H_0

NHST

È una *forzatura* dei due approcci: prende H_0 e il p-value da Fisher, H_1, α e β da Neyman e Pearson, e li mette insieme (anche se i due approcci hanno logiche diverse)



Ipotesi nulla e ipotesi alternativa

Le distribuzioni di probabilità a livello delle popolazioni che identificano lo schema logico del confronto sono classificate in due gruppi distinti:

- $\mathbf{H}_0$: definita come **l'ipotesi nulla**
- $\mathbf{H}_A$: definita come **l'ipotesi alternativa**

L'ipotesi alternativa viene indicata con altri simboli equivalenti come $\mathbf{H}_1$ oppure $\mathbf{K}$

Nota

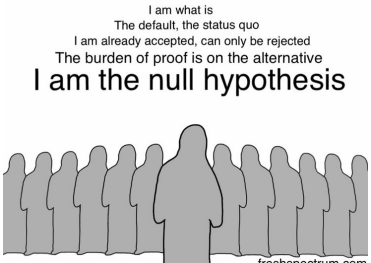
H_0 è definita come la **negazione logica** di H_A e viceversa.
Ad esempio, supponiamo che H_0 affermi che $\mu \leq \mu_0$, allora H_A indica la relazione complementare $\mu > \mu_0$.

$$\Theta_0 = (\Theta_A)^c$$

1. **Ipotesi** H_0: è l'ipotesi che costituisce l'oggetto del test; specifica i valori dei parametri della popolazione da cui si suppone provenga il campione (o i campioni) in esame. Stabilisce che i diversi valori ottenuti nel campione sono puramente **casuali**. Formalmente si esprime con:

$$H_0 : \theta = \theta_0$$

dove θ indica il parametro della popolazione e θ_0 il valore che ci si attende



2. **Ipotesi** H_1: è l'ipotesi alternativa, solitamente l'ipotesi di ricerca secondo la quale i risultati ottenuti **non sono casuali** ma sono spiegabili secondo una qualche regola o teoria. L'ipotesi alternativa può essere:

Bidirezionale

$$\theta \neq \theta_0$$

Monodirezionale

Sinistra

$$\theta < \theta_0$$

Destra

$$\theta > \theta_0$$

Esempio

Si vuole stabilire, attraverso un esperimento, se una moneta sia truccata o meno. Si indicherà con π la probabilità di ottenere testa in un lancio. Prima di eseguire l'esperimento si devono formulare le due ipotesi relativamente al parametro π:

- H_0 : $\pi = .50$ la moneta non è truccata
- H_1 : $\pi \neq .50$ la moneta è truccata

Il problema è stabilire se i risultati dell'esperimento (ad es. lanciare una moneta 30 volte) falsificano o meno l'ipotesi;

I valori empirici possono considerarsi dovuti a fluttuazioni casuali intorno al valore atteso e di conseguenza non confutare H_0?

Oppure il risultato non lo consente, le fluttuazioni non sono casuali ma sistematiche e di conseguenza H_0 è confutata?

La decisione si basa sul calcolo di un test statistico e sulla probabilità associata al valore di tale test:

Test statistico

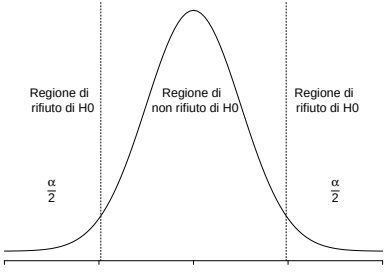
Valore di una variabile casuale che può assumere i valori di una distribuzione campionaria caratterizzata da una determinata distribuzione di probabilità

Ogni test statistico divide lo spazio campionario:

1. Regione di non rifiuto di H_0:
2. Regione di rifiuto di H_0

In base alla regione in cui andrà a cadere il valore campionario, si prenderà una decisione sull'ipotesi H_0

Le regioni di rifiuto e di non rifiuto corrispondono ad aree di probabilità sottese alla curva



Regione di non rifiuto: valori delle statistiche campionarie con probabilità maggiori di verificarsi *data* H_0 *vera*

Regione di rifiuto: valori delle statistiche campionarie con probabilità molto basse di verificarsi *data* H_0 *vera*

1 Inferenza statistica

2 Stimatore

3 Distribuzioni campionarie

4 Test di ipotesi

5 Valore critico

6 Cos'è il p-value?

Livello di significatività

α (Errore di I tipo)

Il **livello di significatività** α è la probabilità di rifiutare H_0 quando H_0 è vera. Si fissa **prima** di raccogliere i dati (valori convenzionali: $.05$, $.01$)

- α è l'area della **regione di rifiuto** sotto la distribuzione campionaria costruita assumendo vera H_0
- $1 - \alpha$ è l'area della **regione di non rifiuto**

Una volta scelto α, la regione di rifiuto è fissata e con essa il **valore critico**

È il valore che separa le due regioni

Per stabilire se il valore di un test è coerente o meno con l'ipotesi nulla è necessario verificare che il suo valore sia compreso all'interno della **regione di non rifiuto**.

Se il valore campionario cade nella **regione di rifiuto** c'è da ritenere che le osservazioni campionarie si discostino dai valori più probabili della distribuzione; in tal caso si può decidere di rifiutare H_0.

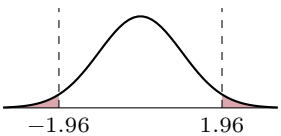
p-value

Il valore di p-value viene ricavato sulla base del valore della statistica test, del valore di α e del valore critico.

Valore critico e direzione di H_1

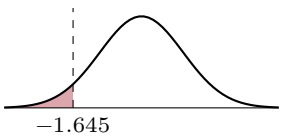
La posizione della regione di rifiuto dipende da H_1. Esempio con la normale standard e $\alpha = .05$:

Bidirezionale: $\theta \neq \theta_0$



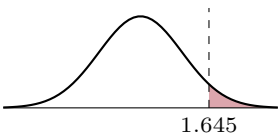
$\alpha/2 = .025$ in ciascuna coda
`qnorm(.975)` $= 1.96$

Sinistra: $\theta < \theta_0$



$\alpha = .05$ nella coda sinistra
`qnorm(.05)` $= -1.645$

Destra: $\theta > \theta_0$



$\alpha = .05$ nella coda destra
`qnorm(.95)` $= 1.645$

I valori delle statistiche campionarie che cadono nella **zona di rifiuto** non sono impossibili se H_0 è vera, ma la loro probabilità è così bassa ($\leq \alpha$) che si accetta il rischio di rifiutare H_0



Figure 1: Stai barando vero? Come è possibile che tu vinca a ogni mano?? Le probabilità sono 50-50, vuol dire che stai barando!!!!!

1 Inferenza statistica

2 Stimatore

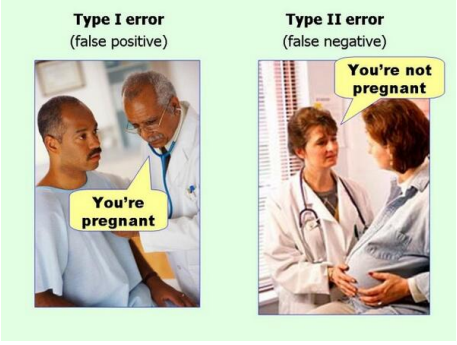
3 Distribuzioni campionarie

4 Test di ipotesi

5 Valore critico
- Errori di I e II tipo
- Regola decisionale

6 Cos'è il p-value?

decisione \ *ipotesi*	H_0 *vera*	H_0 *falsa*
si accetta H_0	corretta	errore II tipo
si rifiuta H_0	errore I tipo	corretta



Non è mai possibile sapere con certezza se è vera H_0, l'unica cosa che si può fare è **minimizzare** la probabilità di prendere una decisione sbagliata

La probabilità di non rifiutare H_0 quando è vera è $1-\alpha$ (l'area della regione di non rifiuto)

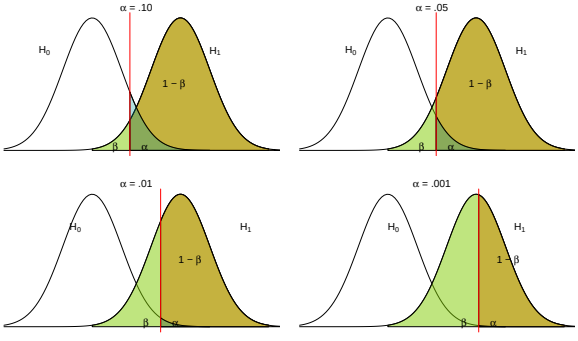
Facendo un ragionamento analogo su H_1 e definendo β la probabilità di non rifiutare H_0 quando è falsa, si ottiene $1-\beta$: la probabilità di rifiutare H_0 quando è falsa, detta **potenza** del test

		Ipotesi	
		H_0 vera	H_0 falsa
Decisione	Non si rifiuta H_0	Corretta $(1-\alpha)$	Errore di II tipo (β)
	Si rifiuta H_0	Errore di I tipo (α)	Corretta $(1-\beta)$

Quello che si controlla: α (la probabilità di commettere un errore di I tipo)

Quello che viene ignorato: β (la probabilità di commettere un errore di II tipo)

Relazione tra α e β



α	β	$1-\beta$
.10	.04	.96
.05	.09	.91
.01	.25	.75
.001	.54	.46

$\mu_0 = 0$, $\mu_1 = 3$

Bianca: sotto H_0; colorata: sotto H_1 (unilaterale destro)

Se α diminuisce, β aumenta e la potenza $1-\beta$ diminuisce

1 Inferenza statistica

2 Stimatore

3 Distribuzioni campionarie

4 Test di ipotesi

5 Valore critico
- Errori di I e II tipo
- Regola decisionale

6 Cos'è il p-value?

Valore critico e p-value

In generale, se indichiamo con ψ_c e ψ_o rispettivamente il **valore critico** e il **valore osservato** di una statistica ψ, allora sussiste il seguente rapporto relazionale tra $(p\text{-value}, \alpha)$ e (ψ_c, ψ_o):

$$p\text{-value} < \alpha \Rightarrow H_1$$
$$p\text{-value} \geq \alpha \Rightarrow \neg H_1$$

$\Leftrightarrow$

Bidir.: $|\psi_o| > |\psi_c| \Rightarrow H_1$
Destra: $\psi_o > \psi_c \Rightarrow H_1$
Sinistra: $\psi_o < \psi_c \Rightarrow H_1$

Significatività statistica

Statisticamente significativo (si rifiuta H_0): ψ_o cade nella regione di rifiuto definita da ψ_c, cioè p-value $< \alpha$
Statisticamente non significativo (non si rifiuta H_0): ψ_o cade nella regione di non rifiuto, cioè p-value $\geq \alpha$

1 Inferenza statistica

2 Stimatore

3 Distribuzioni campionarie

4 Test di ipotesi

5 Valore critico

6 Cos'è il p-value?

Il p-value indica la probabilità di osservare un valore uguale o più estremo rispetto a quello osservato, ***posto che sia vera*** H_0

Unilaterale destro:	$P(T \geq T_0 \mid H_0)$
Unilaterale sinistro:	$P(T \leq T_0 \mid H_0)$
Bidirezionale:	$P(\lvert T\rvert \geq \lvert T_0\rvert \mid H_0)$

Un esempio

Test bidirezionale, $T_0 = 2.70$, p-value $= .0073$ $(p < .01)$
Se H_0 fosse vera e si replicasse l'esperimento moltissime volte, quante volte si otterrebbe un valore della statistica uguale o più estremo di 2.70?
$P(|T| \geq 2.70 \mid H_0) = .0073$: Se fosse vera H_0, il risultato osservato sarebbe un risultato estremamente poco probabile, per cui questo risultato si osserverebbe meno dell'1% delle volte

Dettagli sul p-value

- Il p-value è la probabilità di ottenere un valore uguale o più estremo rispetto a T_0 *se* H_0 *fosse vera*. NON è la probabilità che H_0 sia vera $\rightarrow$ non può essere usato come indicatore della verità o falsità di H_0
- Il p-value è sensibile all'ampiezza campionaria: se H_0 è falsa, all'aumentare dell'ampiezza campionaria il p-value tende a diminuire e aumenta la probabilità di rigettare H_0 (anche differenze molto piccole diventano significative con campioni grandi). Se H_0 è vera, aumentare n non rende il p-value più piccolo
- Il p-value permette solo di prendere una decisione qualitativa nei termini di "Non rigetto H_0" vs. "Rigetto H_0" $\rightarrow$ **Non è una misura dell'evidenza statistica**

1 Inferenza statistica

2 Stimatore

3 Distribuzioni campionarie

4 Test di ipotesi

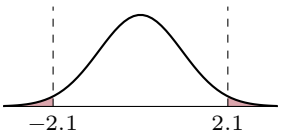
5 Valore critico

6 Cos'è il p-value?

- Calcolo del p-value

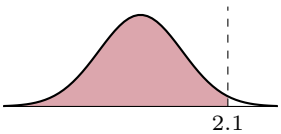
Il p-value è l'area oltre la statistica osservata, nella direzione indicata da H_1.
Esempio con $z_{oss} = 2.1$:

Bidirezionale: $\theta \neq \theta_0$



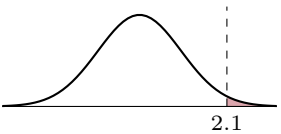
$p = 2 \cdot P(Z \geq |z_{oss}|)$
`2 * (1 - pnorm(2.1))`
$= .036$

Sinistra: $\theta < \theta_0$



$p = P(Z \leq z_{oss})$
`pnorm(2.1)` $= .982$

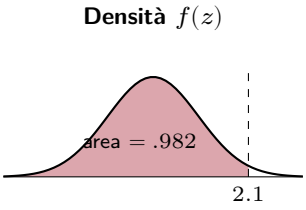
Destra: $\theta > \theta_0$

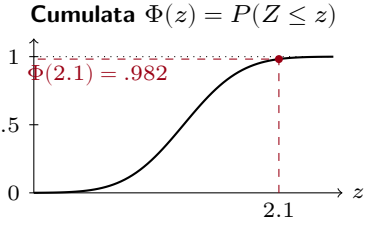


$p = P(Z \geq z_{oss})$
`1 - pnorm(2.1)` $= .018$

Stesso z_{oss}, tre p-value diversi: conta la direzione di H_1

`pnorm(q)` restituisce $P(Z \leq q)$, cioè l'area a sinistra di q sotto la densità, che corrisponde all'altezza della cumulata in q.





Da quantile a probabilità
`pnorm(2.1)` $= .982$ (coda sinistra)
`1 - pnorm(2.1)` $= .018$ (coda destra)
oppure `pnorm(2.1, lower.tail = FALSE)`

Da probabilità a quantile
`qnorm()` è l'inversa: fa il percorso al contrario
`qnorm(.982)` ≈ 2.1, `qnorm(.95)` $= 1.645$