

Modulo 5 - Prima serie

Soluzioni

Ottavia Epifania

Table of contents

Introduzione	1
Esercizi	1
es 1	1
es 2	3
es 3	3
es 4	4
es. 5	5
Esercizio 6.	6
Esercizio 7	7

Introduzione

Il presente caso studio richiede di eseguire delle procedure di analisi dei dati su un insieme di variabili associate a 70 candidati di un corso di laurea del nord-est (nota: questi dati sono già stati analizzati da un punto di vista descrittivo in un precedente Laboratorio R del Modulo 2).

Esercizi

es 1

Scaricare il file `datiTestCR2005.csv` e caricarlo in R assegnandolo alla variabile (data frame) `DATITEST`. Il file contiene un database con 70 osservazioni misurate su 7 variabili distinte:

1. `DIPAA` indica l'anno in cui lo studente ha ottenuto il suo diploma di scuola superiore;
2. `VOTO` è il voto di diploma ottenuto dallo studente (espresso in centesimi);

3. SESSO codifica il sesso dello studente (1: maschio, 2: femmina);
4. D1 punteggio complessivo ad un test per la misura del ragionamento deduttivo: gamma di valori da 0 a 17;
5. D2 punteggio complessivo ad un test per la misura del ragionamento spaziale: gamma di valori da 0 a 20;
6. D3 punteggio complessivo ad un test per la misura del pensiero creativo: gamma di valori da 0 a 4;
7. D4 punteggio complessivo ad un test per la comprensione di testi, grafici e tabelle: gamma di valori da 0 a 12.

```
dati = read.csv2("datiTestCR2005.csv")
```

```
Warning in scan(file = file, what = what, sep = sep, quote = quote, dec = dec,
: embedded nul trovati in input
```

```
head(dati)
```

	DIPAA	VOTO	SESSO	D1	D2	D3	D4
1	2005	63	2	9	17	2	11
2	1999	80	1	12	18	2	8
3	2005	64	1	11	17	2	5
4	2005	95	1	9	14	3	3
5	2005	93	2	13	18	4	12
6	2005	65	2	7	11	0	12

```
str(dati)
```

```
'data.frame': 70 obs. of 7 variables:
 $ DIPAA: int 2005 1999 2005 2005 2005 2005 2004 2004 2005 2004 ...
 $ VOTO : int 63 80 64 95 93 65 60 100 76 100 ...
 $ SESSO: int 2 1 1 1 2 2 1 2 2 2 ...
 $ D1 : int 9 12 11 9 13 7 11 10 12 14 ...
 $ D2 : int 17 18 17 14 18 11 13 15 13 17 ...
 $ D3 : int 2 2 2 3 4 0 1 2 1 3 ...
 $ D4 : int 11 8 5 3 12 12 12 9 12 8 ...
```

```
summary(dati)
```

DIPAA	VOTO	SESSO	D1
Min. :1998	Min. : 39.00	Min. :1.000	Min. : 5.00
1st Qu.:2004	1st Qu.: 68.25	1st Qu.:1.000	1st Qu.: 9.00
Median :2005	Median : 78.50	Median :2.000	Median :11.00
Mean :2004	Mean : 78.11	Mean :1.643	Mean :10.79
3rd Qu.:2005	3rd Qu.: 87.00	3rd Qu.:2.000	3rd Qu.:13.00
Max. :2005	Max. :100.00	Max. :2.000	Max. :15.00

D2	D3	D4
Min. : 7.00	Min. :0.000	Min. : 3.000
1st Qu.:13.00	1st Qu.:1.000	1st Qu.: 9.000
Median :14.00	Median :2.000	Median :10.000
Mean :14.36	Mean :2.057	Mean : 9.686
3rd Qu.:17.00	3rd Qu.:3.000	3rd Qu.:11.000
Max. :20.00	Max. :4.000	Max. :12.000

es 2

Correggere la variabile **VOTO** secondo la modalità descritta nel Laboratorio R che ha analizzato lo stesso set di dati (ovvero, i valori fuori dal range vanno sostituiti con la media di **VOTO** calcolata sui soli valori all'interno del range).

```
index = which(dati$VOTO < 60 | dati$VOTO > 100)
dati$VOTO[index] = mean(dati$VOTO[-index])
```

es 3

Visualizzare le statistiche descrittive di base per le variabili di tipo numerico. Aggiungere anche il calcolo della deviazione standard per tutte le variabili di tipo numerico

```
summary(dati[, -3])
```

DIPAA	VOTO	D1	D2
Min. :1998	Min. : 60.00	Min. : 5.00	Min. : 7.00
1st Qu.:2004	1st Qu.: 69.25	1st Qu.: 9.00	1st Qu.:13.00
Median :2005	Median : 78.84	Median :11.00	Median :14.00
Mean :2004	Mean : 78.68	Mean :10.79	Mean :14.36
3rd Qu.:2005	3rd Qu.: 87.00	3rd Qu.:13.00	3rd Qu.:17.00
Max. :2005	Max. :100.00	Max. :15.00	Max. :20.00

D3	D4
Min. :0.000	Min. : 3.000

```

1st Qu.:1.000    1st Qu.: 9.000
Median :2.000    Median :10.000
Mean   :2.057    Mean   : 9.686
3rd Qu.:3.000    3rd Qu.:11.000
Max.   :4.000    Max.   :12.000

```

```
apply(dati[, -3], 2, sd)
```

DIPAA	VOTO	D1	D2	D3	D4
1.1764599	12.0692360	2.3087286	3.1209238	0.9910573	2.1369276


es 4

Verificare se il voto medio di diploma del gruppo dei *maschi* sia significativamente differente dal voto medio di diploma del gruppo delle *femmine* (si consideri come livello di riferimento $\alpha = .05$). Quali conclusioni puoi trarre? Presentare i risultati con le opportune rappresentazioni grafiche

```

boxplot(dati$VOTO ~ dati$SESSO)
points(c(1,2), c(mean(dati$VOTO[dati$SESSO == 1]), mean(dati$VOTO[dati$SESSO == 2])),
      pch = c(16, 19), col = c("salmon", "royalblue"),
      cex = 3)

```



```
t.test(dati$VOTO[dati$SESSO ==1], dati$VOTO[dati$SESSO ==2])
```

Welch Two Sample t-test

```
data: dati$VOTO[dati$SESSO == 1] and dati$VOTO[dati$SESSO == 2]
t = -2.1451, df = 52.614, p-value = 0.03658
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -11.9628181 -0.4004669
sample estimates:
mean of x mean of y
 74.70725  80.88889
```

```
# analogo a
t.test(dati$VOTO ~ dati$SESSO)
```

Welch Two Sample t-test

```
data: dati$VOTO by dati$SESSO
t = -2.1451, df = 52.614, p-value = 0.03658
alternative hypothesis: true difference in means between group 1 and group 2 is not equal to 0
95 percent confidence interval:
 -11.9628181 -0.4004669
sample estimates:
mean in group 1 mean in group 2
 74.70725      80.88889
```

es. 5

Derivare utilizzando le funzioni di riferimento di R il valore del p-value ed il valore critico della statistica target (considerato $\alpha = .05$).

```
mytest = t.test(dati$VOTO ~ dati$SESSO) # assegna all'oggetto mytest i
# risultati

2*(1-pt(abs(mytest$statistic),mytest$parameter)) # calcolo del p-value
```

```
t
0.03658469
```

```
2*(pt(mytest$statistic,mytest$parameter))      # modo equivalente dato il segno
```

```
t  
0.03658469
```

```
      # del t osservato  
qt(0.975,mytest$parameter)    # valore critico della statistica, test a due code
```

```
[1] 2.00609
```

Esercizio 6.

Verificare se il voto medio di diploma degli studenti (indipendentemente dal genere sessuale) sia significativamente superiore a 70. Si richiede di testare l'ipotesi inferenziale utilizzando il confronto diretto tra il valore della statistica target osservata e il valore critico della statistica (assunto $\alpha = 0.05$).

```
t.test(dati$VOTO, mu=70, alternative = "greater")
```

One Sample t-test

```
data:  dati$VOTO  
t = 6.0179, df = 69, p-value = 3.794e-08  
alternative hypothesis: true mean is greater than 70  
95 percent confidence interval:  
 76.27609      Inf  
sample estimates:  
mean of x  
 78.68116
```

```
qt(0.95,69)    # calcolo del valore critico della
```

```
[1] 1.667239
```

```
      # statistica pari a 1.667239 (test ad una coda dx)  
  
# di conseguenza dato che il t osservato è maggiore del t critico  
# concludo per il rigetto dell'ipotesi nulla (ovvero, il voto medio è  
# significativamente superiore a 70)
```

Esercizio 7

Relativamente al gruppo delle *donne*, verificare la presenza di una differenza statisticamente significativa tra la variabile ND1 e la variabile ND2 (assunto $\alpha = 0.01$).


Nota: le variabili ND1 e ND2 sono le versioni normalizzate delle variabili originarie D1 e D2, mediante la seguente formula:

$$ND_i = \frac{D_i}{\max D_i}$$

dove $\max D_i$ fa riferimento al massimo valore *teorico* di D_i . Quali conclusioni puoi trarre? Presentare i risultati con le opportune rappresentazioni grafiche

```
# 17 e 20 sono i valori massimi teorici delle variabili D1 d D2
# rispettivamente
dati$ND1 = dati$D1/17
dati$ND2 = dati$D2/20

boxplot(dati$ND1[dati$SESSO==2], dati$ND2[dati$SESSO==2], names = c("ND1", "ND2"))
```



```
t.test(dati$ND1[dati$SESSO==2],
       dati$ND2[dati$SESSO==2], paired=T)
```


Paired t-test

```
data: dati$ND1[dati$SESSO == 2] and dati$ND2[dati$SESSO == 2]
t = -1.8153, df = 44, p-value = 0.07629
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 -0.104268061  0.005444532
sample estimates:
mean difference
 -0.04941176
```

###Esercizio 8.

Ripetere la stessa analisi questa volta sul gruppo dei maschi.

```
boxplot(dati$ND1[dati$SESSO==1], dati$ND2[dati$SESSO==1], names = c("ND1", "ND2"))
```



```
t.test(dati$ND1[dati$SESSO==1],
       dati$ND2[dati$SESSO==1],paired=T)
```

Paired t-test

```
data:  dati$ND1[dati$SESS0 == 1] and dati$ND2[dati$SESS0 == 1]
t = -4.0424, df = 24, p-value = 0.0004733
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 -0.21840878 -0.07076769
sample estimates:
mean difference
 -0.1445882
```