Modulo Didattico 6-A: Statistica Inferenziale – Indici di tendenza centrale

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
Univeristà di Trento
ottavia.epifania@unitn.it

A.A. 2026/2027

1 Riepilogo

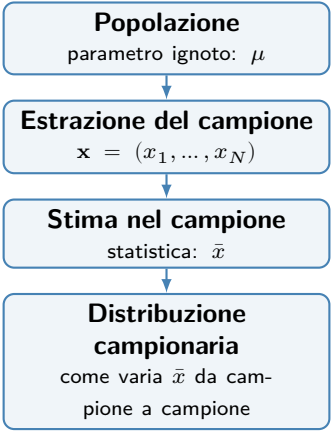
2 Un campione

3 Due campioni indipendenti

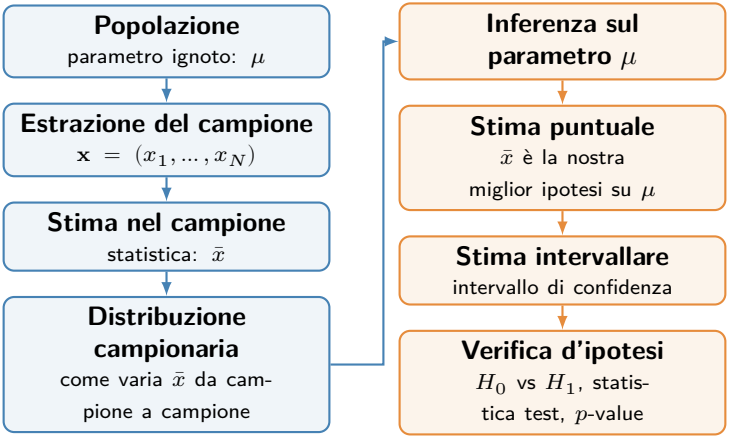
4 Due campioni appaiati

5 Intervalli di confidenza

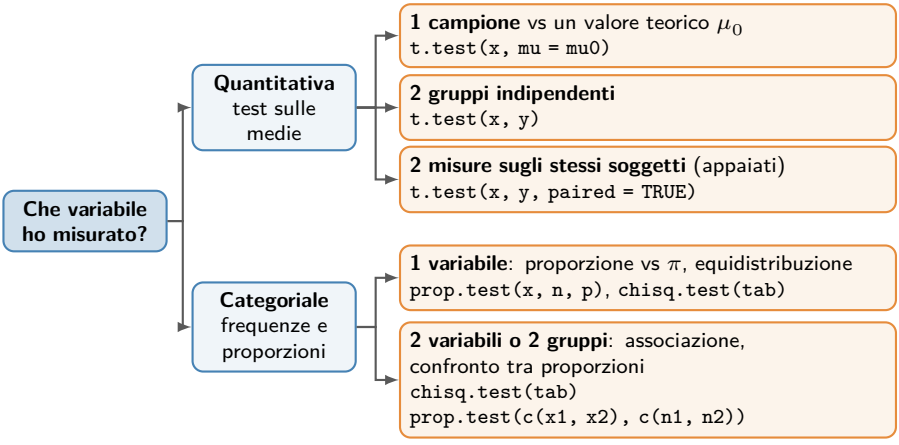
Il workflow dell'inferenza



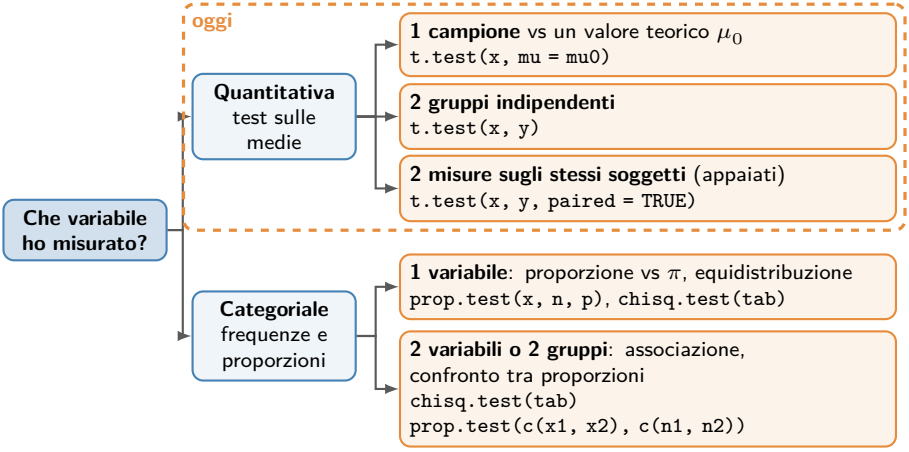
Il workflow dell'inferenza



Come scegliere il test statistico



Come scegliere il test statistico



1 Riepilogo

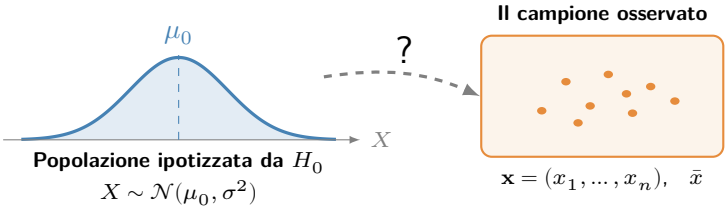
2 Un campione

3 Due campioni indipendenti

4 Due campioni appaiati

5 Intervalli di confidenza

un solo campione di N unità statistiche, con media $\bar{x}$.



La domanda del test

Il campione può provenire da una popolazione in cui $X \sim \mathcal{N}(\mu_0, \sigma^2)$?
Se $\bar{x}$ è *troppo lontana* da $\mu_0 \rightarrow$ rifiutiamo H_0.

Se conoscessimo σ: il test z

Se la deviazione standard della popolazione σ fosse **nota**:

Distribuzione Campionaria

$$\mu_{\bar{x}} = \mu, \quad \sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

Statistica test

$$z = \frac{\bar{x} - \mu_0}{\sigma_{\bar{x}}} \sim \mathcal{N}(0, 1)$$

Si confrontano i valori di test con i quantili della normale standard (ad es. ± 1.96 per $\alpha = .05$ e H_1 a due code).

Il problema

σ è un **parametro della popolazione**: non si conosce quasi mai

Non conoscendo σ della popolazione, $\sigma_{\bar{x}}$ viene stimato a partire dalla *deviazione standard campionaria*

σ noto:

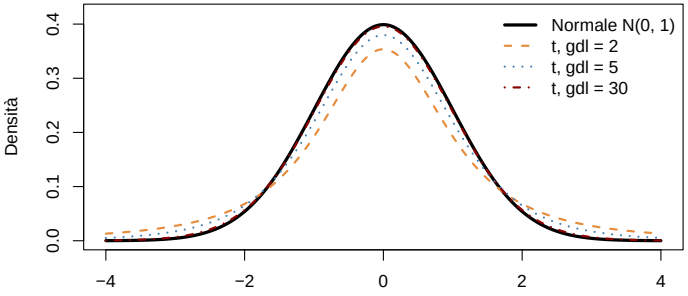
$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

σ NON noto:

$$\sigma_{\bar{x}} = \frac{\mathrm{sd}(x)}{\sqrt{n-1}}$$

$$\text{Statistica Test} = \frac{\bar{x} - \mu_0}{\sigma_{\bar{x}}}$$

La distribuzione t di Student ha **code più pesanti** della normale, e quanto più pesanti dipende dai gradi di libertà $(n-1)$.



Al crescere di n la t_{n-1} si avvicina alla $\mathcal{N}(0,1)$: con campioni grandi test t e test z danno risultati praticamente uguali.

- In R base esiste `t.test()`, ma **non** esiste una funzione per il test z: il caso in cui σ è nota non capita quasi mai con dati reali
- Quando n è grande, `t.test()` dà comunque risultati praticamente identici al test z
- Se σ fosse davvero nota, il test z si calcola a mano in due righe:

```
z = (mean(x) - mu0) / (sigma / sqrt(length(x)))
2 * (1 - pnorm(abs(z)))  # p-value a due code
```

dove `mu0` è il parametro della popolazione definito in H_0.

Scopo

permette di valutare se la media μ della popolazione di un dato campione X sia significativamente differente (risp. maggiore/minore) rispetto ad una specifica soglia teorica μ_0

Sia $\mathbf{x} = (x_1, x_2, \dots, x_n)$ un campione empirico di n osservazioni quantitative indipendenti tali che $x_i \sim \mathcal{N}(\mu, \sigma^2)$, dove μ e σ^2 sono parametri ignoti della popolazione di $\mathbf{x}$.

Inoltre sia $\mu_0 \in \mathbb{R}$ il parametro della popolazione sotto H_0

$$t = \frac{\bar{x} - \mu_0}{\sigma_{\bar{x}}}, \quad \sigma_{\bar{x}} = \mathrm{sd}(x)/\sqrt{n}$$

$\bar{x}$: Media campionaria di $\mathbf{x}$
$\mathrm{sd}(x)$: D.s. campionaria $\mathbf{x}$

Test a due code (two-sided)

$H_0 : \mu = \mu_0 \qquad H_1 : \mu \neq \mu_0$

Una coda-destra (one-sided right)

$H_0 : \mu = \mu_0 \qquad H_1 : \mu > \mu_0$

Una coda sinistra (one-sided left)

$H_0 : \mu = \mu_0 \qquad H_1 : \mu < \mu_0$

1 Riepilogo

2 Un campione
- In R
- Esempi

3 Due campioni indipendenti

4 Due campioni appaiati

5 Intervalli di confidenza

```
t.test(x, mu = 0, alternative = "two.sided")
```

Svolge il test su un campione di osservazioni x, considerando $\mu_0 = 0$ (`mu = 0`) come default e ipotesi alternativa bidirezionale (`alternative = "two.sided"`):

Definizione ipotesi in R	**Significato**
`alternative = "two.sided"`	H_1: $\mu \neq \mu_0$
`alternative = "greater"`	H_1: $\mu > \mu_0$
`alternative = "less"`	H_1: $\mu < \mu_0$

1 Riepilogo

2 Un campione
- In R
- Esempi

3 Due campioni indipendenti

4 Due campioni appaiati

5 Intervalli di confidenza

```r
set.seed(999)
x = rnorm(11, mean = 12, sd = 7.5)
mu0 = 10
t.test(x, mu = mu0, alternative = "two.sided")
```

```
    One Sample t-test

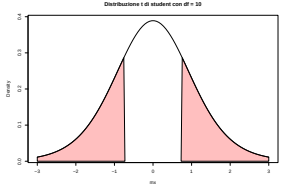
data:  x
t = -0.72806, df = 10, p-value = 0.4833
alternative hypothesis: true mean is not equal to 10
95 percent confidence interval:
  3.50030 13.29817
sample estimates:
mean of x
 8.399236
```

```
> t.test(x, mu = mu0)
One Sample t-test

data:  x
t = -0.72806, df = 10, p-value = 0.4833
alternative hypothesis: true mean is not equal to 10
95 percent confidence interval:
 3.50030 13.29817
sample estimates:
mean of x
 8.399236
```

1. Tipo di test
2. Statistica test t_0
3. Gradi di libertà: $df = n - 1$
4. p-value
5. Ipotesi alternativa H_1: bidirezionale
6. Intervallo di confidenza al 95% per μ
7. Media campionaria $\bar{x}$

$$p\text{-value} = \int_{-\infty}^{-|t_o|} f_T(t \mid \theta)\, dt + \int_{|t_o|}^{\infty} f_T(t \mid \theta)\, dt$$
$$= 2 \int_{|t_o|}^{\infty} f_T(t \mid \theta)\, dt$$



t_0: Statistica test osservata -0.7281
$f_T(t|\theta)$: Distribuzione t di Student con parametro θ (ovvero i gdl)

```
# calcolo p-value
2*(1-pt(abs(-0.72806),10))
```

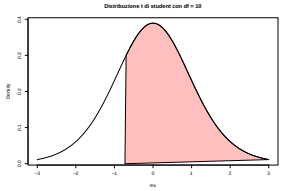
```
[1] 0.4832762
```

```
> t.test(x, mu = mu0, alternative = "greater")
One Sample t-test

data:  x
t = -0.72806, df = 10 (2), p-value = 0.7584 (3)
alternative hypothesis: true mean is greater than 10 (1)
95 percent confidence interval:
 4.414237      Inf (4)
sample estimates:
mean of x
 8.399236
```

1. H_1: $\mu > \mu_0$
2. t_0 e gradi di libertà: **identici** al test a due code
3. $p = P(T \geq t_0)$, area a destra di t_0: qui $t_0 < 0$ va nella direzione **opposta** a $H_1 \rightarrow p$ grande
4. IC **unidirezionale**: solo il limite inferiore, l'altro estremo è `Inf`

$$p\text{-value} = \int_{t_o}^{\infty} f_T(t \mid \theta)\, dt$$



t_0: Statistica test osservata -0.7281
$f_T(t|\theta)$: Distribuzione t di Student con parametro θ (ovvero i gdl)

```
# calcolo p-value
1-pt(-0.72806, 10)
```

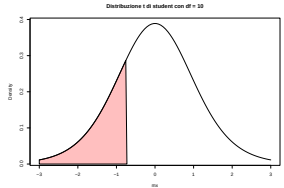
```
[1] 0.7583619
```

```
> t.test(x, mu = mu0, alternative = "less")
One Sample t-test

data:  x
t = -0.72806, df = 10, p-value = 0.2416
alternative hypothesis: true mean is less than 10
95 percent confidence interval:
 -Inf 12.38424
sample estimates:
mean of x
 8.399236
```

1. H_1: $\mu < \mu_0$
2. t_0 e gradi di libertà: **identici** al test a due code
3. $p = P(T \leq t_0)$, area a sinistra di t_0: qui $t_0 < 0$ va nella **stessa** direzione di $H_1 \rightarrow p$ dimezzato rispetto al test a due code
4. IC **unidirezionale**: solo il limite superiore, l'altro estremo è `-Inf`

$$p\text{-value} = \int_{-\infty}^{t_o} f_T(t \mid \theta)\, dt$$



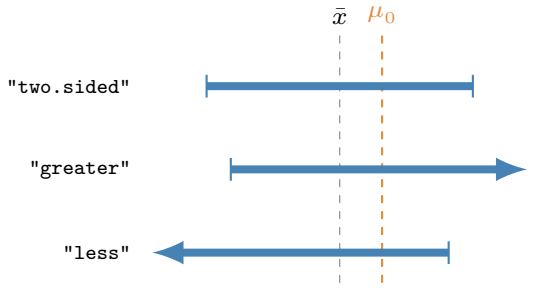
t_0: Statistica test osservata -0.7281
$f_T(t|\theta)$: Distribuzione t di Student con parametro θ (ovvero i gdl)

```
# calcolo p-value
pt(-0.72806, 10)
```

```
[1] 0.2416381
```

Perché l'IC ha un estremo infinito?

`t.test()` riporta sempre l'intervallo **coerente con** H_1: rifiutiamo H_0 ($\alpha = .05$) se e solo se μ_0 cade **fuori** dall'intervallo.



$\left[\bar{x} - t_{1-\alpha/2}\, SE;\ \bar{x} + t_{1-\alpha/2}\, SE\right]$
α divisa nelle due code

$[\bar{x} - t_{1-\alpha}\, SE;\ +\infty)$
tutta α in una coda

$(-\infty;\ \bar{x} + t_{1-\alpha}\, SE]$
tutta α in una coda

1 Riepilogo

2 Un campione

3 Due campioni indipendenti

4 Due campioni appaiati

5 Intervalli di confidenza

Scopo

Permette di valutare se la media μ_X della popolazione di un campione di dati x sia significativamente differente (risp. maggiore/minore) rispetto alla media μ_Y della popolazione di un campione di dati y.

Sia $\mathbf{x} = (x_1, x_2, \dots, x_N)$ un campione empirico di N osservazioni quantitative indipendenti tali che $x_i \sim N(\mu_X, \sigma^2)$ e sia $\mathbf{y} = (y_1, y_2, \dots, y_M)$ un campione empirico di M osservazioni quantitative indipendenti tali che $y_j \sim N(\mu_Y, \sigma^2)$, dove σ^2 è la varianza comune ad entrambe le popolazioni.

$$t = \frac{(\overline{x} - \overline{y}) - (\mu_x - \mu_y)}{s\sqrt{\frac{1}{N} + \frac{1}{M}}} \qquad s = \sqrt{\frac{(N-1)\mathrm{var}(\mathbf{x}) + (M-1)\mathrm{var}(\mathbf{y})}{N+M-2}}$$

Test a due code (two-sided)

$H_0 : \mu_X = \mu_Y \qquad H_1 : \mu_X \neq \mu_Y$
$H_0 : \mu_X - \mu_Y = 0 \qquad H_1 : \mu_X - \mu_Y \neq 0$

Una coda-destra (one-sided right)

$H_0 : \mu_X = \mu_Y \qquad H_1 : \mu_X > \mu_Y$
$H_0 : \mu_X - \mu_Y = 0 \qquad H_1 : \mu_X - \mu_Y > 0$

Una coda sinistra (one-sided left)

$H_0 : \mu_X = \mu_Y \qquad H_1 : \mu_X < \mu_Y$
$H_0 : \mu_X - \mu_Y 0 \qquad H_1 : \mu_X - \mu_Y < 0$

1 Riepilogo

2 Un campione

3 Due campioni indipendenti
- In R
- Esempi

4 Due campioni appaiati

5 Intervalli di confidenza

```
t.test(x, y, var.equal = TRUE, alternative = "two.sided")
```

Svolge il test su due campioni indipendenti di osservazioni x e y, assumendo che le varianze delle due popolazioni siano uguali (`var.equal = TRUE`), con ipotesi alternativa bidirezionale come default (`alternative = "two.sided"`):

Definizione ipotesi in R	**Significato**
`alternative = "two.sided"`	H_A: $\mu_X \neq \mu_Y$
`alternative = "greater"`	H_A: $\mu_X > \mu_Y$
`alternative = "less"`	H_A: $\mu_X < \mu_Y$

Il default di R è `var.equal = FALSE`: senza specificare `var.equal = TRUE`, R svolge il test di Welch, che non assume varianze uguali.

1 Riepilogo

2 Un campione

3 Due campioni indipendenti
- In R
- Esempi

4 Due campioni appaiati

5 Intervalli di confidenza

```
x = c(12.2, 23.2, 14, 20.3, 9.2, 3.7, 8, 16.8, 3.7, 1.9, 20.5)
y = c(8.5, 3.2, 4, 10.5, 7.7, 3.1, 2, 3.9)
t.test(x, y, var.equal = TRUE, alternative = "two.sided")
```

```
    Two Sample t-test

data:  x and y
t = 2.4064, df = 17, p-value = 0.02776
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
  0.8349434 12.7127839
sample estimates:
mean of x mean of y
 12.13636   5.36250
```

```
> t.test(x, y, var.equal = TRUE)
Two Sample t-test

data:  x and y
t = 2.4064, df = 17, p-value = 0.02776
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 0.8349434 12.7127839
sample estimates:
mean of x mean of y
 12.13636   5.36250
```

1. Tipo di test
2. Statistica test t_0
3. Gradi di libertà: $df = N + M - 2$
4. p-value
5. Ipotesi alternativa H_A: bidirezionale $(\mu_X - \mu_Y \neq 0)$
6. Intervallo di confidenza al 95% per $\mu_X - \mu_Y$
7. Medie campionarie $\bar{x}$ e $\bar{y}$

```
> t.test(x, y, var.equal = TRUE, alternative = "greater")
Two Sample t-test

data:  x and y
t = 2.4064, df = 17, p-value = 0.01388
alternative hypothesis: true difference in means is greater than 0
95 percent confidence interval:
 1.877044      Inf
sample estimates:
mean of x mean of y
 12.13636   5.36250
```

1. H_A: $\mu_X > \mu_Y$ ($\mu_X - \mu_Y > 0$)
2. t_0 e gradi di libertà: **identici** al test a due code
3. $p = P(T \geq t_0)$, area a destra di t_0: qui $\bar{x} > \bar{y}$ va nella **stessa** direzione di $H_A \to p$ dimezzato rispetto al test a due code
4. IC **unidirezionale**: solo il limite inferiore, l'altro estremo è `Inf`

var.equal = FALSE (test di Welch)

```
> t.test(x, y)
Welch Two Sample t-test

data:  x and y
t = 2.708, df = 14.144, p-value = 0.01687
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 1.413924 12.133803
sample estimates:
mean of x mean of y
 12.13636   5.36250
```

1. Test di Welch: le varianze delle due popolazioni **non** sono assunte uguali (default di R)
2. t_0 e gradi di libertà **diversi** dal test con `var.equal = TRUE`: i df sono corretti e non sono interi
3. p-value
4. Intervallo di confidenza al 95% per $\mu_X - \mu_Y$

1 Riepilogo

2 Un campione

3 Due campioni indipendenti

4 Due campioni appaiati

5 Intervalli di confidenza

Scopo

Permette di valutare se le medie μ_x e μ_y delle popolazioni di due campioni di dati appaiati (x, y) siano significativamente differenti (risp. maggiore/minore).

Sia $(\mathbf{x}, \mathbf{y}) = ((x_1, y_1), (x_2, y_2), \dots, (x_N, y_N))$ un campione bivariato di N osservazioni (x_i, y_i) indipendenti. Inoltre sia $d_i \sim N(d \mid \mu_D, \sigma^2)$ l'osservazione differenziale $d_i = x_i - y_i$ derivata da $(\mathbf{x}, \mathbf{y})$. I parametri μ_D e σ^2 sono i termini ignoti della variabile differenziale D.

$$t = \frac{\overline{d}}{\sqrt{\mathrm{var}(\mathbf{d})/N}}$$

Test a due code (two-sided)

$H_0 : \mu_D = 0 \qquad H_A : \mu_D \neq 0$

Una coda-destra (one-sided right)

$H_0 : \mu_D = 0 \qquad H_A : \mu_D > 0$

Una coda sinistra (one-sided left)

$H_0 : \mu_D = 0 \qquad H_A : \mu_D < 0$

1 Riepilogo

2 Un campione

3 Due campioni indipendenti

4 Due campioni appaiati
- In R
- Esempi

5 Intervalli di confidenza

```
t.test(x, y, paired = TRUE, alternative = "two.sided")
```

Svolge il test su due campioni appaiati di osservazioni x e y (`paired = TRUE`), cioè un test t su un campione sulle differenze $d_i = x_i - y_i$ con $\mu_0 = 0$, con ipotesi alternativa bidirezionale come default (`alternative = "two.sided"`):

Definizione ipotesi in R	**Significato**
`alternative = "two.sided"`	H_A: $\mu_D \neq 0$
`alternative = "greater"`	H_A: $\mu_D > 0$
`alternative = "less"`	H_A: $\mu_D < 0$

1 Riepilogo

2 Un campione

3 Due campioni indipendenti

4 Due campioni appaiati
- In R
- Esempi

5 Intervalli di confidenza

```r
x = c(5.2, 3.5, 3.4, 7.1, 6.2, 3.0, 1, 4)
y = c(8.5, 3.2, 4, 10.5, 7.7, 3.1, 2, 3.9)
t.test(x, y, paired = TRUE, alternative = "two.sided")
```

```
    Paired t-test

data:  x and y
t = -2.303, df = 7, p-value = 0.05475
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 -2.40676258  0.03176258
sample estimates:
mean difference
        -1.1875
```

```
> t.test(x, y, paired = TRUE)
Paired t-test

data:  x and y
t = -2.303, df = 7, p-value = 0.05475
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 -2.40676258  0.03176258
sample estimates:
mean difference
 -1.1875
```

1. Tipo di test
2. Statistica test t_0
3. Gradi di libertà: $df = N - 1$ ($N =$ numero di coppie)
4. p-value
5. Ipotesi alternativa H_A: bidirezionale ($\mu_D \neq 0$)
6. Intervallo di confidenza al 95% per μ_D
7. Media delle differenze $\bar{d}$

```
> t.test(x, y, paired = TRUE, alternative = "less")
Paired t-test

data:  x and y
t = -2.303, df = 7, p-value = 0.02737
alternative hypothesis: true mean difference is less than 0
95 percent confidence interval:
 -Inf -0.2106053
sample estimates:
mean difference
 -1.1875
```

1. H_A: $\mu_D < 0$
2. t_0 e gradi di libertà: **identici** al test a due code
3. $p = P(T \leq t_0)$, area a sinistra di t_0: qui $\bar{d} < 0$ va nella **stessa** direzione di $H_A \rightarrow p$ dimezzato rispetto al test a due code
4. IC **unidirezionale**: solo il limite superiore, l'altro estremo è `-Inf`

1 Riepilogo

2 Un campione

3 Due campioni indipendenti

4 Due campioni appaiati

5 Intervalli di confidenza

L'intervallo di confidenza viene calcolato come:

$$IC_{1-\alpha} = \hat{\theta} \pm c_{1-\alpha/2} \cdot SE(\hat{\theta})$$

- $\hat{\theta}$: stimatore generico del parametro θ, ad esempio $\bar{x}$ per μ;
- $c_{1-\alpha/2}$: valore critico della distribuzione di riferimento, ad esempio z o t;
- $SE(\hat{\theta})$: errore standard dello stimatore.