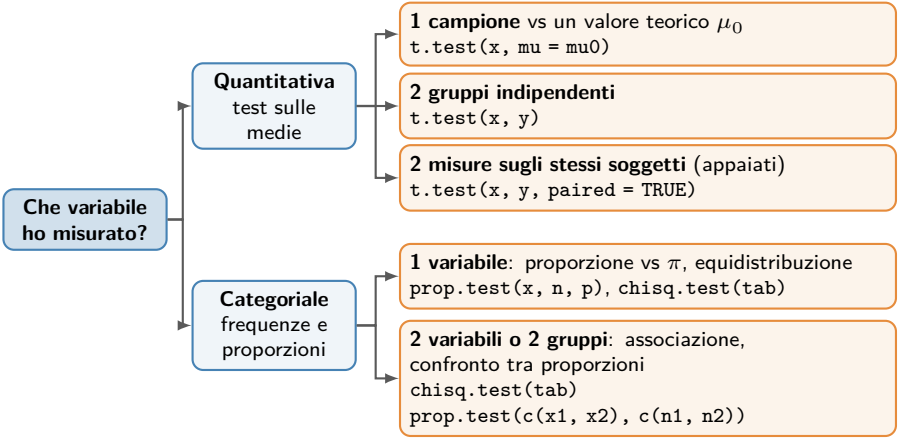
Modulo Didattico 5: Statistica inferenziale - Misure di associazione

Corso Analisi dei dati con applicazioni informatiche

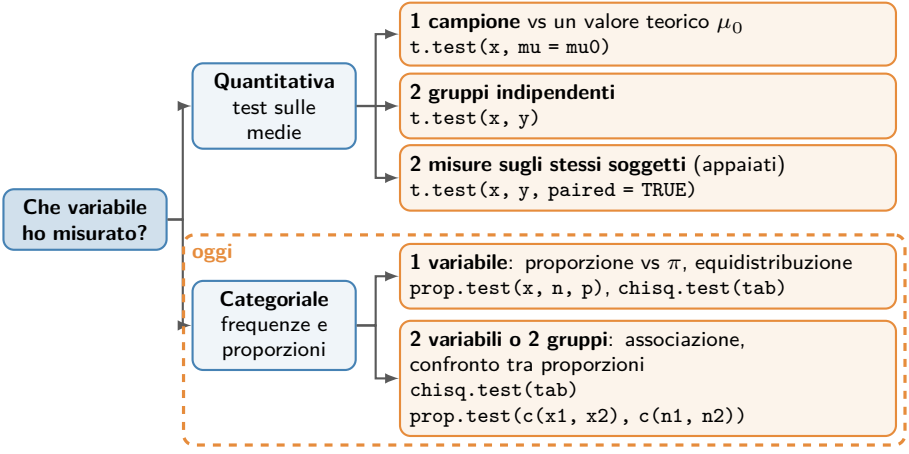
Ottavia M. Epifania
Univeristà di Trento
ottavia.epifania@unitn.it

A.A. 2026/2027

Come scegliere il test statistico



Come scegliere il test statistico



Scopo

Quantificare il grado di associazione tra due variabili nominali A con I categorie e B con J categorie

$$\chi^2 = \sum_i \sum_j \frac{(n_{ij} - n^*_{ij})^2}{n^*_{ij}}$$

$$n^*_{ij} = \frac{n_{i.} \times n_{.j}}{n} \qquad N = \sum_{i=1}^{I} \sum_{j=1}^{J} n_{ij}$$

Le ipotesi riguardano la popolazione, quindi si formulano sulle proporzioni nella popolazione:

- π_{ij}: proporzione di casi che hanno sia la categoria i di A sia la categoria j di B
- $\pi_{i.}$: proporzione di casi nella categoria i di A
- $\pi_{.j}$: proporzione di casi nella categoria j di B

Se A e B sono indipendenti, la proporzione congiunta è il prodotto delle proporzioni marginali: $\pi_{ij} = \pi_{i.}\,\pi_{.j}$

È la stessa logica delle frequenze attese calcolate sul campione:

$$\frac{n^*_{ij}}{N} = \frac{n_{i.}}{n} \times \frac{n_{.j}}{n}$$

Sistema di ipotesi

H_0: A e B sono indipendenti nella popolazione, cioè $\pi_{ij} = \pi_{i\cdot}\,\pi_{\cdot j}$ per ogni i, j
H_1: A e B sono associate nella popolazione, cioè $\pi_{ij} \neq \pi_{i\cdot}\,\pi_{\cdot j}$ per almeno una coppia i, j

Se H_0 è vera, ci aspettiamo che le frequenze osservate si discostino da quelle attese solo per effetto della variabilità campionaria. Il χ^2 misura questo scostamento: più è grande, meno i dati sono compatibili con H_0.

Simbolo R	Significato
`chisq.test(mytab)`	Calcola il test statistico del chi quadro alla tabella di frequenze chiamata `mytab`

```
mytable <- matrix(c(21,9,9,33,10,28,7,12,10),3,3)
rownames(mytable) <- c("a1","a2","a3")
colnames(mytable) <- c("b1","b2","b3")
chisq.test(mytable)
```

```
chisq.test(mytable)
```

```
    Pearson's Chi-squared test

data:  mytable
X-squared = 12.458, df = 4, p-value = 0.01425
```

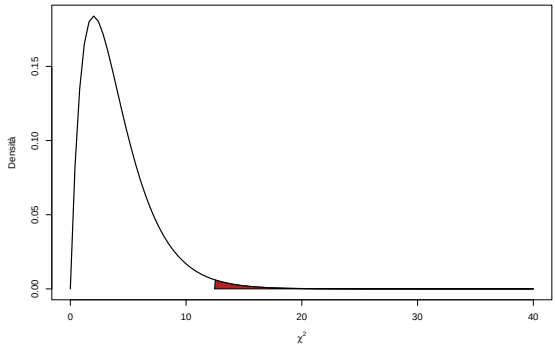
```
> chisq.test(mytable)
Pearson's Chi-squared test

data:  mytable
X-squared = 12.458, df = 4, p-value = 0.01425
```



1. Tipo di test
2. Statistica test χ_0^2
3. Gradi di libertà: $df = (I-1)(J-1)$
4. p-value: area a destra di χ_0^2

$$p\text{-value} = 1 - \int_{-\infty}^{\chi_0} f_x(x|\theta)dx$$




```
1-pchisq(12.458, 4)
```

```
[1] 0.01425141
```

Scopo

Valutare se le proporzioni nelle I categorie di una variabile categoriale A siano o meno conformi a un modello teorico (solitamente di omogeneità)

$$\chi^2 = \sum_i \frac{(n_i - n_i^*)^2}{n_i^*}$$

Frequenze attese sotto il modello teorico di omogeneità

$$n_i^* = \frac{1}{I} n$$

Frequenze osservate per le I categorie

$$n = \sum_{i=1}^{I} n_i$$

Indichiamo con π_i la proporzione di casi nella categoria i di A nella popolazione.

Sistema di ipotesi

H_0: le proporzioni nelle I categorie sono uguali nella popolazione, cioè $\pi_i = 1/I$ per ogni i
H_1: nella popolazione almeno una proporzione è diversa da $1/I$, cioè $\pi_i \neq 1/I$ per almeno un i

Se H_0 è vera, ci aspettiamo che le frequenze osservate si discostino da quelle attese solo per effetto della variabilità campionaria. Il χ^2 misura questo scostamento: più è grande, meno i dati sono compatibili con H_0.