Modulo Didattico 5: Statistica inferenziale - Altri tipi di test

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
Univeristà di Trento
ottavia.epifania@unitn.it

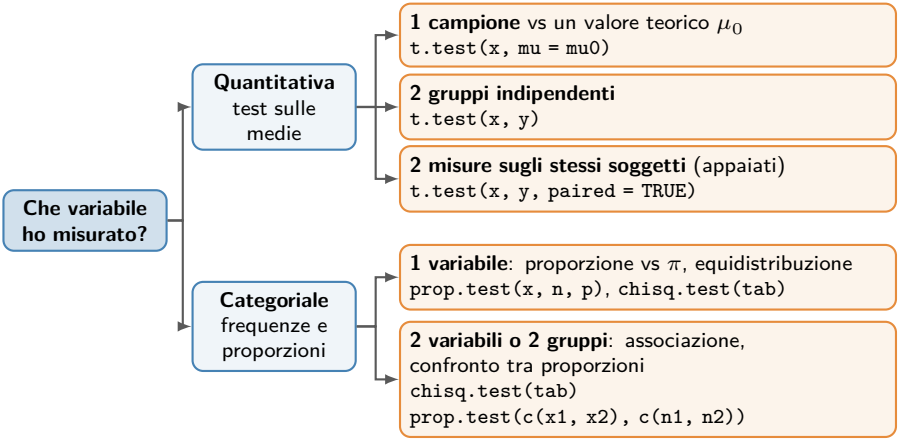
A.A. 2026/2027

1 Riepilogo

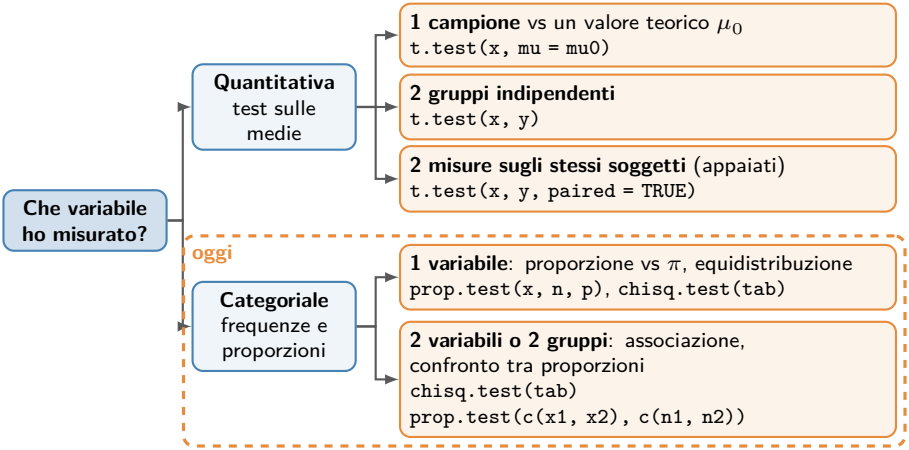
2 Test Chi-quadrato

3 Altri test per variabili categoriali

Come scegliere il test statistico



Come scegliere il test statistico



1 Riepilogo

2 Test Chi-quadrato

3 Altri test per variabili categoriali

1 Riepilogo

2 Test Chi-quadrato

- Associazione tra due variabili
- In R
- Equidistribuzione nelle categorie
- In R

3 Altri test per variabili categoriali

Scopo

Quantificare il grado di associazione tra due variabili nominali A con I categorie e B con J categorie

$$\chi^2 = \sum_i \sum_j \frac{(n_{ij} - n^*_{ij})^2}{n^*_{ij}}$$

$$n^*_{ij} = \frac{n_{i.} \times n_{.j}}{n} \qquad n = \sum_{i=1}^{I} \sum_{j=1}^{J} n_{ij}$$

Le ipotesi riguardano la popolazione, quindi si formulano sulle proporzioni nella popolazione:

- π_{ij}: proporzione di casi che hanno sia la categoria i di A sia la categoria j di B
- $\pi_{i.}$: proporzione di casi nella categoria i di A
- $\pi_{.j}$: proporzione di casi nella categoria j di B

Se A e B sono indipendenti, la proporzione congiunta è il prodotto delle proporzioni marginali: $\pi_{ij} = \pi_{i.}\,\pi_{.j}$

Sistema di ipotesi

H_0: A e B sono indipendenti nella popolazione, cioè $\pi_{ij} = \pi_{i\cdot}\,\pi_{\cdot j}$ per ogni i, j
H_1: A e B sono associate nella popolazione, cioè $\pi_{ij} \neq \pi_{i\cdot}\,\pi_{\cdot j}$ per almeno una coppia i, j

Se H_0 è vera, ci aspettiamo che le frequenze osservate si discostino da quelle attese solo per effetto della variabilità campionaria. Il χ^2 misura questo scostamento: più è grande, meno i dati sono compatibili con H_0.

1 Riepilogo

2 Test Chi-quadrato

- Associazione tra due variabili
- In R
- Equidistribuzione nelle categorie
- In R

3 Altri test per variabili categoriali

Simbolo R	Significato
`chisq.test(mytab)`	Calcola il test statistico del chi quadro alla tabella di frequenze chiamata `mytab`

```
mytable <- matrix(c(21,9,9,33,10,28,7,12,10),3,3)
rownames(mytable) <- c("a1","a2","a3")
colnames(mytable) <- c("b1","b2","b3")
chisq.test(mytable)
```

```
    Pearson's Chi-squared test

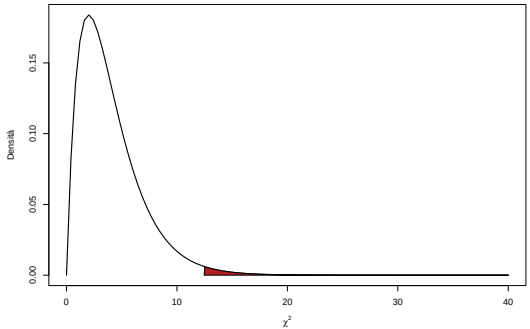
data:  mytable
X-squared = 12.458, df = 4, p-value = 0.01425
```

```
> chisq.test(mytable)
Pearson's Chi-squared test

data:  mytable
X-squared = 12.458, df = 4, p-value = 0.01425
```

1. Tipo di test
2. Statistica test χ^2_0
3. Gradi di libertà: $df = (I-1)(J-1)$
4. p-value: area a destra di χ^2_0

$$p\text{-value} = 1 - \int_{-\infty}^{\chi_0} f_x(x|\theta)dx$$




```
1-pchisq(12.458, 4)
```

1 Riepilogo

2 Test Chi-quadrato

- Associazione tra due variabili
- In R
- Equidistribuzione nelle categorie
- In R

3 Altri test per variabili categoriali

Scopo

Valutare se le proporzioni nelle I categorie di una variabile categoriale A siano o meno conformi a un modello teorico (solitamente di omogeneità)

$$\chi^2 = \sum_i \frac{(n_i - n_i^*)^2}{n_i^*}$$

Frequenze attese sotto il modello teorico di omogeneità

$$n_i^* = \frac{1}{I} n$$

Frequenze osservate per le I categorie

$$n = \sum_{i=1}^{I} n_i$$

Indichiamo con π_i la proporzione di casi nella categoria i di A nella popolazione.

Sistema di ipotesi

H_0: le proporzioni nelle I categorie sono uguali nella popolazione, cioè $\pi_i = 1/I$ per ogni i
H_1: nella popolazione almeno una proporzione è diversa da $1/I$, cioè $\pi_i \neq 1/I$ per almeno un i

Se H_0 è vera, ci aspettiamo che le frequenze osservate si discostino da quelle attese solo per effetto della variabilità campionaria. Il χ^2 misura questo scostamento: più è grande, meno i dati sono compatibili con H_0.

1 Riepilogo

2 Test Chi-quadrato

- Associazione tra due variabili
- In R
- Equidistribuzione nelle categorie
- In R

3 Altri test per variabili categoriali

Simbolo R	Significato
`chisq.test(mytab)`	Calcola il test statistico del chi quadro alla tabella di frequenze chiamata `mytab`

```
mytable <- matrix(c(22,45,18),1,3)
colnames(mytable) <- c("a1","a2","a3")
chisq.test(mytable)
```

```
    Chi-squared test for given probabilities

data:  mytable
X-squared = 14.988, df = 2, p-value = 0.0005563
```

```
> chisq.test(mytable)
Chi-squared test for given probabilities

data:  mytable
X-squared = 14.988, df = 2, p-value = 0.0005563
```

1. Tipo di test
2. Statistica test χ^2_0
3. Gradi di libertà: $df = I - 1$
4. p-value: area a destra di χ^2_0

1 Riepilogo

2 Test Chi-quadrato

3 Altri test per variabili categoriali

1 Riepilogo

2 Test Chi-quadrato

3 Altri test per variabili categoriali

- Test delle proporzioni
- Esempi: 1 Campione
- Esempi: 2 campioni

Una proporzione

Scopo

Valutare se la proporzione π di successi nella popolazione sia diversa (rispettivamente maggiore o minore) da un valore teorico π_0

Stimatore di π: x/n, proporzione di successi su n prove indipendenti. In `prop.test()`, π_0 è l'argomento `p`

Sistema di ipotesi

Due code: $H_0 : \pi = \pi_0 \qquad H_1 : \pi \neq \pi_0$
Una coda destra: $H_0 : \pi = \pi_0 \qquad H_1 : \pi > \pi_0$
Una coda sinistra: $H_0 : \pi = \pi_0 \qquad H_1 : \pi < \pi_0$

Due proporzioni

Scopo

Valutare se la proporzione di successi π_1 di una popolazione sia diversa (rispettivamente maggiore o minore) dalla proporzione di successi π_2 di un'altra popolazione

Stimatore di $\pi_1 - \pi_2$: $x_1/n_1 - x_2/n_2$, differenza tra le proporzioni di successi nei due campioni

Sistema di ipotesi

Due code: $H_0 : \pi_1 = \pi_2 \qquad H_1 : \pi_1 \neq \pi_2$
Una coda destra: $H_0 : \pi_1 = \pi_2 \qquad H_1 : \pi_1 > \pi_2$
Una coda sinistra: $H_0 : \pi_1 = \pi_2 \qquad H_1 : \pi_1 < \pi_2$

Funzione R	Significato
`prop.test(x, n, p)`	Calcola se la proporzione x/n (dove $x \leq n$) sia significativamente differente dal valore di probabilità p. Il valore x è il numero di esiti dicotomici positivi su n distinte prove ($\pi \neq \pi_0$)
`prop.test(x, n, p, alternative = "less")`	*Test inferenziale a una coda sinistra* $\pi < \pi_0$
`prop.test(x, n, p, alternative = "greater")`	*Test inferenziale a una coda destra* $\pi > \pi_0$
`prop.test(c(x1,x2), c(n1,n2))`	*Test inferenziale a due code per due proporzioni* $\pi_1 \neq \pi_2$
`prop.test(c(x1,x2), c(n1,n2), alternative = "less")`	*Test inferenziale a una coda (sinistra) per due proporzioni* $\pi_1 < \pi_2$
`prop.test(c(x1,x2), c(n1,n2), alternative = "greater")`	*Test inferenziale a una coda (destra) per due proporzioni* $\pi_1 > \pi_2$

1 Riepilogo

2 Test Chi-quadrato

3 Altri test per variabili categoriali

- Test delle proporzioni
- Esempi: 1 Campione
- Esempi: 2 campioni

Campione di bambini che supera (1) o non supera (0) un punteggio minimo alle matrici di Raven. Nella popolazione a cui appartengono, la maggioranza degli individui supera la soglia minima alle matrici di Raven?

$H_0 : \pi = .50 \qquad H_1 : \pi > .50$

```
# Test delle proporzioni
pass_scores = c(1,0,0,1,1,0,0,0,0,1,0,1,0,1,0,0) #
table(pass_scores) # Frequenze insuccessi/successi
x = sum(pass_scores) # x, numero dei successi
n = length(pass_scores) # n, numero totale di prove indipendenti
prop.test(x, n = n, p = .50, alternative = "greater") # Test
```

Esempi: 1 Campione

```
> prop.test(x, n = n, p = .50, alternative = "greater")
1-sample proportions test with continuity correction

data:  x out of n, null probability 0.5
X-squared = 0.5625, df = 1, p-value = 0.7734
alternative hypothesis: true p is greater than 0.5
95 percent confidence interval:
 0.1843081 1.0000000
sample estimates:
    p
0.375
```

1. Tipo di test
2. Statistica test χ^2_0
3. Gradi di libertà: $df = 1$
4. p-value a una coda
5. Ipotesi alternativa H_1: $\pi > \pi_0$
6. IC **unidirezionale** al 95% per π
7. Stimatore di π: proporzione campionaria x/n

1 Riepilogo

2 Test Chi-quadrato

3 Altri test per variabili categoriali

- Test delle proporzioni
- Esempi: 1 Campione
- Esempi: 2 campioni

$x_1 = 6, \quad n_1 = 16 \qquad\qquad x_2 = 21, \quad n_2 = 30$

Le proporzioni di successi nei due gruppi sono diverse?

$H_0 : \pi_1 = \pi_2 \qquad H_1 : \pi_1 \neq \pi_2$

```
x_1 = 6; n_1 = 16
x_2 = 21; n_2 = 30
prop.test(c(x_1,x_2), c(n_1, n_2),
          alternative = "two.sided")
```

```
    2-sample test for equality of proportions with continuity co

data:  c(x_1, x_2) out of c(n_1, n_2)
X-squared = 3.3045, df = 1, p-value = 0.06909
alternative hypothesis: two.sided
95 percent confidence interval:
```

```
> prop.test(c(x_1,x_2), c(n_1, n_2), alternative = "two.sided")
2-sample test for equality of proportions with continuity correction

data:  c(x_1, x_2) out of c(n_1, n_2)
X-squared = 3.3045, df = 1, p-value = 0.06909
alternative hypothesis: two.sided
95 percent confidence interval:
 -0.66129416  0.01129416
sample estimates:
prop 1 prop 2
 0.375  0.700
```

1. Tipo di test
2. Statistica test χ^2_0
3. Gradi di libertà: $df = 1$
4. p-value
5. Ipotesi alternativa H_1: $\pi_1 \neq \pi_2$
6. IC al 95% per $\pi_1 - \pi_2$
7. Proporzioni campionarie: stimatore $= x_1/n_1 - x_2/n_2$