

Modulo Didattico 6: Modelli di regressione

Corso Analisi dei dati con applicazioni informatiche

Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

A.A. 2025/2026

1 Modello di regressione lineare semplice

2 Stima dei parametri

3 Inferenza statistica sui parametri

4 I residui

Scopo

Stimare la dipendenza lineare tra una variabile indipendente (X) e una variabile dipendente (Y)

Siano $\mathbf{x} = (x_1, x_2, \dots, x_N)$ e $\mathbf{y} = (y_1, y_2, \dots, y_N)$ i due campioni empirici associati, rispettivamente, alla variabile indipendente X e alla variabile dipendente Y

$$y_i = \beta_0 + \beta x_i + \varepsilon_i \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2) \quad (i = 1, \dots, n)$$

Dove β_0 , β e ε sono, rispettivamente, l'intercetta, il coefficiente angolare e la componente d'errore del modello di regressione lineare

Sistema di ipotesi sull'intercetta

$H_0 : \beta_0 = 0$: L'intercetta interseca l'origine $(0, 0)$

$H_A^1 : \beta_0 \neq 0$: L'intercetta NON interseca l'origine $(0, 0)$

Sistema di ipotesi sul coefficiente angolare

$H_0 : \beta = 0$: Modello di indipendenza lineare

$H_A^1 : \beta \neq 0$: Modello di associazione lineare

1 Modello di regressione lineare semplice

- In R
- Esempi

2 Stima dei parametri

3 Inferenza statistica sui parametri

4 I residui

Simbolo R	Significato
<code>lm(y ~ x)</code>	Fitta un modello lineare dove si spiega la y in funzione della x
<code>summary(lm(y ~ x))</code>	Restituisce l'output inferenziale del modello lineare

1 Modello di regressione lineare semplice

- In R
- Esempi


2 Stima dei parametri

3 Inferenza statistica sui parametri

4 I residui

```
X <- c(9,8,12,9,10,14,5,4,13,7,5,3.4,15.3,6.8)
Y <- c(9,6,8,9,7,10,8,4,11,5,4,2,12.6,8.6)
LM <- lm(Y~X)
plot(X,Y, pch = 8)
abline(LM, lwd = 2, col = "darkorange")
summary(LM)
```

Esempi



summary(LM)

Call:

lm(formula = Y ~ X)

Residuals:

Min	1Q	Median	3Q	Max
-1.9579	-1.2400	-0.6551	1.2051	2.9858

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.7131	1.1316	1.514	0.155939
X	0.6602	0.1201	5.495	0.000137 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.645 on 12 degrees of freedom

Multiple R-squared: 0.7156, Adjusted R-squared: 0.6919

F-statistic: 30.19 on 1 and 12 DF, p-value: 0.0001374

```
> summary(LM)
```

```
Call:
```

```
lm(formula = Y ~ X)
```

```
Residuals:
```

Min	1Q	Median	3Q	Max
-1.9579	-1.2400	-0.6551	1.2051	2.9858

Descrittive dei residui

```
Coefficients:
```

Errore standard

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.7131	1.1316	1.514	0.155939
X	0.6602	0.1201	5.495	0.000137 ***

p-value

Stime dei parametri

t critico

```
Signif. codes:
```

```
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1.645 on 12 degrees of freedom
```

```
Multiple R-squared: 0.7156, Adjusted R-squared: 0.6919
```

```
F-statistic: 30.19 on 1 and 12 DF, p-value: 0.0001374
```

```
> summary(LM)
```

```
Call:
```

```
lm(formula = Y ~ X)
```

```
Residuals:
```

```
      Min       1Q   Median       3Q      Max
-1.9579 -1.2400 -0.6551  1.2051  2.9858
```

```
Coefficients:
```

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   1.7131     1.1316   1.514 0.155939
X              0.6602     0.1201   5.495 0.000137 ***
```

```
---
```

```
Signif. codes:
```

```
0. '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

**R quadro del
modello**

**Gradi di libertà del
modello**

```
Residual standard error: 1.645 on 12 degrees of freedom
```

```
Multiple R-squared:  0.7156,    Adjusted R-squared:  0.6919
```

```
F-statistic: 30.19 on 1 and 12 DF,  p-value: 0.0001374
```

1 Modello di regressione lineare semplice

2 Stima dei parametri

3 Inferenza statistica sui parametri

4 I residui

$$SQE = \sum_{i=1}^N (y_i - y_i^*)^2 \quad y_i^* = \beta_0 + \beta x_i$$

$$\sum_{i=1}^N (y_i - (\beta_0 + \beta x_i))^2 = \sum_{i=1}^N e_i^2 \quad e_i = y_i - y_i^*$$

Per il principio dei minimi quadrati:

$$\hat{\beta} = \frac{Cov(X, Y)}{Var(X)} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

e:

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta} \bar{X}$$

- 1 Modello di regressione lineare semplice
- 2 Stima dei parametri
- 3 Inferenza statistica sui parametri**
- 4 I residui

1 Modello di regressione lineare semplice

2 Stima dei parametri

3 Inferenza statistica sui parametri

- Step 1
- Step 2
- Step 3 & 4
- Step 5
- Intervalli di confidenza
- In R

4 I residui

Step 1

Si stima la varianza della componente di errore ε_i usando la varianza campionaria corretta per i residui e_i^2 del modello di regressione

$$\begin{aligned}\hat{\sigma}^2 &= \frac{\sum_{i=1}^n (y_i - y_i^*)^2}{n - 2} \\ &= \frac{\sum_{i=1}^n e_i^2}{n - 2} \\ &= \frac{SQE}{n - 2}\end{aligned}$$

1 Modello di regressione lineare semplice

2 Stima dei parametri

3 Inferenza statistica sui parametri

- Step 1
- Step 2
- Step 3 & 4
- Step 5
- Intervalli di confidenza
- In R

4 I residui

Step 2

Si stima la varianza del parametro dell'intercetta β_0 come

$$\hat{\sigma}_{\beta_0}^2 = \hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

Si stima la varianza del parametro del coefficiente angolare β come

$$\hat{\sigma}_{\beta}^2 = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

1 Modello di regressione lineare semplice

2 Stima dei parametri

3 Inferenza statistica sui parametri

- Step 1
- Step 2
- Step 3 & 4
- Step 5
- Intervalli di confidenza
- In R

4 I residui

Step 3 & 4

Stima della varianza del parametro dell'intercetta β_0

$$\hat{\sigma}_{\beta_0}^2 = \hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

Step 4

Le stime degli errori standard dei parametri sono:

$$\text{SE}(\hat{\beta}_0) = \sqrt{\hat{\sigma}_{\beta_0}^2}$$

$$\text{SE}(\hat{\beta}) = \sqrt{\hat{\sigma}_{\beta}^2}$$

Stima della varianza del parametro del coefficiente angolare β :

$$\hat{\sigma}_{\beta}^2 = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

1 Modello di regressione lineare semplice

2 Stima dei parametri

3 Inferenza statistica sui parametri

- Step 1
- Step 2
- Step 3 & 4
- Step 5
- Intervalli di confidenza
- In R

4 I residui

Step 5

Valore t osservato calcolato per il parametro di intercetta β_0 :

$$t_{\beta_0}^o = \frac{\hat{\beta}_0}{\widehat{SE}(\beta_0)}$$

$$H_0: \beta_0 = 0$$

Sotto le rispettive ipotesi nulle, i t osservati seguono una distribuzione f_T di Student con $\theta = n - 2$ gradi di libertà.

Gli associati p -value saranno dunque:

β_0 :

$$p\text{-value} = 2 \int_{|t_{\beta_0}^o|}^{\infty} f_T(t \mid n - 2) dt$$

Valore t osservato calcolato per il parametro di coefficiente angolare β :

$$t_{\beta}^o = \frac{\hat{\beta}}{\widehat{SE}(\beta)}$$

$$H_0: \beta = 0$$

β :

$$p\text{-value} = 2 \int_{|t_{\beta}^o|}^{\infty} f_T(t \mid n - 2) dt$$

Definizione statistica t osservato sotto ipotesi nulla H_0

$$\beta_0 = 0 \text{ e } \beta = 0$$

$$t_{\beta_0}^o = \frac{\hat{\beta}_0 - \beta_0}{\widehat{SE}(\beta_0)} = \frac{\hat{\beta}_0 - 0}{\widehat{SE}(\beta_0)} = \frac{\hat{\beta}_0}{\widehat{SE}(\beta_0)}, \quad \text{con } H_0 : \beta_0 = 0$$

$$t_{\beta}^o = \frac{\hat{\beta} - \beta}{\widehat{SE}(\beta)} = \frac{\hat{\beta} - 0}{\widehat{SE}(\beta)} = \frac{\hat{\beta}}{\widehat{SE}(\beta)}, \quad \text{con } H_0 : \beta = 0$$

Definizione statistica t osservato sotto ipotesi nulla H_0

$$\beta_0 = a \text{ e } \beta = b$$

$$t_{\beta_0}^o = \frac{\hat{\beta}_0 - \beta_0}{\widehat{SE}(\beta_0)} = \frac{\hat{\beta}_0 - a}{\widehat{SE}(\beta_0)}, \quad \text{con } H_0 : \beta_0 = a \text{ dove } a \in \mathbb{R}$$

$$t_{\beta}^o = \frac{\hat{\beta} - \beta}{\widehat{SE}(\beta)} = \frac{\hat{\beta} - b}{\widehat{SE}(\beta)}, \quad \text{con } H_0 : \beta = b \text{ dove } b \in \mathbb{R}$$

1 Modello di regressione lineare semplice

2 Stima dei parametri

3 Inferenza statistica sui parametri

- Step 1
- Step 2
- Step 3 & 4
- Step 5
- Intervalli di confidenza
- In R

4 I residui

$$\text{IC95\%}(\beta_0) = [\hat{\beta}_0 - \delta_{\beta_0}, \hat{\beta}_0 + \delta_{\beta_0}]$$

$$\text{IC95\%}(\beta) = [\hat{\beta} - \delta_{\beta}, \hat{\beta} + \delta_{\beta}]$$

dove

$$\delta_{\beta_0} = \widehat{SE}(\beta_0) \times q_T(0.975 \mid n - 2), \quad \delta_{\beta} = \widehat{SE}(\beta) \times q_T(0.975 \mid n - 2)$$

dove $q_T(0.975 \mid n - 2)$ è il quantile 0.975 della distribuzione t di Student con $n - 2$ gradi di libertà.

1 Modello di regressione lineare semplice

2 Stima dei parametri

3 Inferenza statistica sui parametri

- Step 1
- Step 2
- Step 3 & 4
- Step 5
- Intervalli di confidenza
- In R

4 I residui


In R

```
coefs = data.frame(summary(LM)$coefficients)
qt95 = qt(.975, 12)
deltaB0 = coefs$Std..Error[1]*qt95
deltaB1 = coefs$Std..Error[2]*qt95
CIB0 = c(coefs$Estimate[1]-deltaB0,
          coefs$Estimate[1]+deltaB0)
CIB1 = c(coefs$Estimate[2]-deltaB1,
          coefs$Estimate[2]+deltaB1)
CIB0
[1] -0.7524355  4.1787223
CIB1
[1] 0.3984310 0.9219969
```


- 1 Modello di regressione lineare semplice
- 2 Stima dei parametri
- 3 Inferenza statistica sui parametri
- 4 I residui**

- 1 Modello di regressione lineare semplice
- 2 Stima dei parametri
- 3 Inferenza statistica sui parametri
- 4 I residui
 - Errori distribuiti normalmente
 - Indipendenza errore-predittore

SI!




NO!



- 1 Modello di regressione lineare semplice
- 2 Stima dei parametri
- 3 Inferenza statistica sui parametri
- 4 I residui**
 - Errori distribuiti normalmente
 - Indipendenza errore-predittore

SI!



NO!

